

点燃数学之火

给初中生的数学世界漫游

目录

前言	ix
第一部分 从初中代数出发——字母、方程和函数	1
第一章 数与字母：把具体问题变成可以搬运的模型	2
1.1 一张一百元的购物清单	2
1.2 算术的办法：当“挨个试”开始失控	2
1.3 先点一次名：我们已经认识的数	3
1.4 给“不知道”起一个名字：字母与代数式	4
1.5 天平的守则：等式变形与唯一解	5
1.6 世界不总是刚刚好：不等式	6
1.7 字母的另一种工作：装下一整类数	7
1.8 换一个视角：模型是可以搬运的	8
第二章 方程与函数：从求一个答案到研究所有答案	11
2.1 出租车计价器与笼子里的鸡兔	11
2.2 猜，猜到天黑：试数法的失败	11
2.3 把问题翻译成等式	12
2.4 配方：二次方程的万能钥匙	13
2.5 从“求一个答案”到“研究所有答案”	14
2.6 图像：规则留下的轨迹	15
2.7 斜率与截距：读懂函数的性格	16
2.8 换一个视角：图像替方程说话	17
第三章 初等几何：从测量、作图到证明	21
3.1 影子里的金字塔	21
3.2 为什么可以，为什么不可以	21
3.3 从“看起来一样”到定义	22
3.4 一条定理，两种理由	24
3.5 不变量、分类讨论和圆	25
3.6 换一种眼光：三角测量与星空	27
3.7 动手做一做	27

第四章 坐标桥梁：把代数和几何接在一起	29
4.1 海战棋上的争吵	29
4.2 一个卡住人的问题	29
4.3 一条直线装下所有的数	30
4.4 给平面上的每个点发一张地址	30
4.5 距离公式：把勾股定理搬上坐标纸	31
4.6 方程是形状的身份证	33
4.7 翻译演示之一：用代数做几何题	34
4.8 翻译演示之二：用几何解代数题	35
4.9 让点动起来：参数方程	36
 第二部分 沿着两条主轴深入——多项式、变换和向量	 39
第五章 多项式：方程背后的结构	40
5.1 滑板公园的三个测量点	40
5.2 先试试直觉：两种容易掉的坑	40
5.3 把式子当建筑：多项式、次数与根	41
5.4 因式定理：根与因子的翻译机	42
5.5 韦达关系：不拆也能听见根的声音	43
5.6 图像是根的地图	44
5.7 三个点猜一条规则：插值	45
5.8 当解不够用时： i 的诞生	46
5.9 动手时间	48
 第六章 变换与对称：从图形动作走向群	 50
6.1 把正方形放回框架里	50
6.2 先猜，再错	50
6.3 把“动作”变成数学对象	51
6.4 八种，一种不多	53
6.5 对称到底有什么用	55
 第七章 向量与线性代数：二维箭头通向高维空间	 58
7.1 游戏里的一个下午	58
7.2 第一次尝试：只记数字够吗	58
7.3 发明箭头：向量的诞生	59
7.4 核心定理：每个箭头只有一种写法	60
7.5 矩阵：把变换装进格子	62
7.6 保持方向的箭头：特征向量的故事	63
7.7 换一个视角：压缩、排序与振动	64

第八章 从直线到曲面：局部近似的预告	67
8.1 一场雨中的自行车赛	67
8.2 第一次尝试：几根不够格的尺子	67
8.3 把曲线放到显微镜下	68
8.4 切线：曲线在一点处的替身	68
8.5 弯得有多厉害：曲率	70
8.6 换一个视角：球面上的“直线”	71
 第三部分 从变化走向无限——微积分与分析	 75
第九章 极限：无限接近不是含糊其辞	76
9.1 一场永远跑不完的比赛？	76
9.2 先把直觉押在桌上	76
9.3 第一次尝试：一项一项地加	77
9.4 给“无限接近”下定义	78
9.5 核心定理：无限个越来越小的数可以加出确定的和	80
9.6 换一个视角：数轴上有没有洞	81
9.7 数学实验	83
 第十章 导数：曲线在某一点的速度	 86
10.1 过山车上一个问题	86
10.2 先猜一猜：瞬时速度到底存不存在	86
10.3 第一次尝试：用很短的时间间隔	87
10.4 把同一个想法搬到曲线上：割线与切线	87
10.5 亲手算几个导数： x^2 、 x^3 和一次函数	89
10.6 为什么导数有用：局部线性近似	89
10.7 函数之间怎么求导：乘法与链式法则	90
10.8 换一个视角：误差、优化与经济学中的边际	91
10.9 再看一眼“山顶”：导数为零与极值	92
10.10 挑战：亲手算一条“会拐弯的跑道”	93
 第十一章 积分：把无数个小量加起来	 95
11.1 里程表不量速度，却会算路程	95
11.2 一个把人卡住两千年的问题	95
11.3 第一次尝试：矩形太少，误差太大	96
11.4 把“越切越细”变成一个定义	96
11.5 万能钥匙：微积分基本定理	98
11.6 切面包片：从面积到体积	99
11.7 换一个视角：密度、概率和一碗汤	100
11.8 无限相加，什么时候有有限的结果	101
11.9 动手逼近一次积分	103

第十二章 分析：把直觉变成可靠的定理	105
12.1 山路上的一道怪题	105
12.2 直觉第一次被骗	105
12.3 把“连续”说清楚	106
12.4 介值定理：不许跳，就得过	107
12.5 最高点与“脾气均匀”的函数	107
12.6 柯西序列：不知道答案，也能证明答案存在	108
12.7 幂级数：把函数拆成无限长的多项式	109
12.8 傅里叶级数：任何声音都是一堆纯音	109
12.9 复数平面与欧拉公式	111
12.10 本章的收获	112
 第四部分 从整数问题分流——数论与解析数论	 114
第十三章 初等数论：质数、同余与整数的机关	115
13.1 拆不开的班：从一次排队说起	115
13.2 第一次尝试：筛子和误会	115
13.3 发明概念：质数是整数的“原子”	116
13.4 辗转相除：一台两千岁的机器	117
13.5 奇偶、不变量与同余：换一种眼光看整数	118
13.6 质数用不完：一个两千多年前的证明	120
13.7 换一个视角：这些机关如何锁住现代世界	121
 第十四章 组合与离散结构：数数、连线和算法	 124
14.1 一场联欢会前的点票难题	124
14.2 先猜一猜，再错一次	124
14.3 数数的两条军规与两件武器	125
14.4 把每支球队画成一个点：图、树与路	127
14.5 算法：让机器按图索骥	128
14.6 离散结构、密码与数论：为什么它们分不开	129
14.7 数学实验	130
 第十五章 解析数论：用连续工具研究离散的素数	 133
15.1 一场越报越吃力的报数游戏	133
15.2 第一个猜想：按比例分钱为什么行不通	133
15.3 给素数造一台计数器	134
15.4 素数定理：稀疏中的规律	135
15.5 一台把素数“调出来”的级数机器	137
15.6 黎曼的惊天一跃：把 s 送进复数平面	137
15.7 亲手数一数：实验能做到什么，做不到什么	139

第五部分 从曲线和空间继续分流——拓扑、微分几何、概率与基础	142
第十六章 拓扑学：橡皮泥眼中什么才算同一种形状	143
16.1 一张不像地图的地图	143
16.2 七座桥，一条走不出来的路线	143
16.3 把地图揉成一团之后，剩下什么	144
16.4 破案：数一数为奇数的“路口”	145
16.5 字母的分类游戏：什么是拓扑性质	146
16.6 会数洞的数字：欧拉示性数	147
16.7 拧半圈的世界：莫比乌斯带与克莱因瓶	148
16.8 换一个视角：网络、地图和机器人	149
第十七章 微分几何：弯曲空间中的距离和方向	152
17.1 地图上那条奇怪的弯路	152
17.2 直觉失灵：摊不平的橘子皮	152
17.3 给曲面建立坐标：一本地图册就够了	153
17.4 切平面与切向量：在曲面上站稳	154
17.5 曲率：弯了多少，用什么量	154
17.6 球面三角形：内角和的反叛	155
17.7 测地线：最直的，也是最短的	156
17.8 流形：每一小块都是平面，整体可以千奇百怪	157
17.9 从局部几何到星空：一次科普性的远眺	158
第十八章 概率与统计：不确定性也能被精确研究	161
18.1 一场生日聚会上的赌局	161
18.2 直觉给出的答案错得离谱	161
18.3 给“可能性”一个数	162
18.4 已知一半信息之后	163
18.5 平均值能告诉我们什么	164
18.6 掷得足够多，混乱就变成了秩序	165
18.7 用乱撒的点子算出圆周率	166
18.8 当统计开始骗人	168
第十九章 数学与计算机：算法能走多远	170
19.1 一千万次成功之后	170
19.2 验证了这么多，为什么还不算证明？	170
19.2.1 一个骗了四十次的公式	170
19.2.2 藏在九亿后面的反例	171
19.2.3 大人物的猜想也会翻船	171
19.3 算法：一台思想上的机器	171
19.4 有些事，算法永远做不到	172

19.5 快与慢的鸿沟：计算复杂度	173
19.6 计算机反过来帮助数学	175
19.6.1 海量计算，作为证明的一部分：四色定理	175
19.6.2 机器当校对员：形式化证明	175
19.6.3 机器当望远镜：探索几何、数论与分析	175
19.7 纸上机房：动手实验	177
第二十章 数学的边界与统一地图	179
20.1 挂在校园里的一幅地图	179
20.2 无穷也分大小吗？	179
20.3 理发师与那本不能存在的目录	181
20.4 哥德尔：数学装不下全部的真	182
20.5 六个镜头：把全书装进一张地图	184
20.6 一道题，三种命运：最短路径	184
附录 A 读懂数学证明的入门语法	187
A.1 命题：可以判断真假的话	187
A.2 充分条件与必要条件：两顶不能混戴的帽子	187
A.3 量词：把“所有”和“存在”说清楚	188
A.4 反例：一个就足够	188
A.5 数学归纳法：推倒一排多米诺骨牌	188
A.6 反证法：先假设敌人是对的	188
附录 B 初等数学工具箱	190
B.1 分数与比例：整体的一部分	190
B.2 方程：把未知数当已知数来用	190
B.3 坐标：给平面上的每个点一个地址	191
B.4 三角形：平面几何的基本积木	191
B.5 指数与对数：乘法的加速器与倒车挡	192
附录 C 符号表与词汇表	193
C.1 数	193
C.2 代数	193
C.3 几何	194
C.4 分析	194
C.5 概率	195
C.6 离散数学	195
附录 D 数学实验与编程资源	197
D.1 电子表格：最被低估的数学仪器	197
D.2 GeoGebra：会动的几何	197
D.3 Python：让计算机替你数一万次	198

D.4 去哪里找这些工具	198
附录 E 分级阅读路线	200
E.1 默认路线：四级台阶	200
E.2 四条兴趣路线	200
E.3 三条阅读建议	201

前言：先别急着背公式

这是一本写给初中生的数学漫游书。它不按课本顺序检查你“应该会什么”，而是从一个个真实、好玩的疑问出发，带你看看数学家们如何提出问题、发明概念、寻找证据，并让这些想法彼此连接。

读这本书时，你可以暂时放下标准答案和公式清单——但请保留两样东西：好奇心，和追问“为什么”的习惯。书里的每一个关键结论，我们都给出直观的解释、必要的证明，或者你可以亲手复核的实验。

每章结尾的思考题分为“观察题、证明题、挑战题”三个层次，我们只给提示，不直接给答案。卡住是正常的，卡住正是数学开始的地方。

第一部分

从初中代数出发——字母、方程和函数

第一章 数与字母：把具体问题变成可以搬运的模型

1.1 一张一百元的购物清单

开学前一天，妈妈递给你一张一百元的钞票，说：“去买这学期要用的文具，笔记本六元一本，中性笔四元一支，自己搭配，最好刚好把这一百元花完。”

这听起来像一件小事，但站在文具店的货架前，你会发现它其实是个正经的问题：买几本笔记本、几支笔，才能恰好花完一百元？而且妈妈说说不定还会追加条件——“笔记本和笔都得买，不能只买一样”。

先凭直觉猜一猜。买十本笔记本是六十元，剩下四十元正好买十支笔——一个答案到手了：10 本、10 支。那还有没有别的买法？16 本笔记本是九十六元，再加一支笔，正好一百。看起来答案不止一个。于是一个更“贪心”的问题冒了出来：

到底有多少种买法？你能保证一种都不漏、一种都不重复吗？

这个问题会让人卡住。它不像“10 本加 10 支多少钱”那样一步算出结果；它要你找出所有答案，还要给出“没有遗漏”的理由。凭感觉报数是不行的——你说有 8 种，同桌说有 9 种，谁对？怎么裁判？

这就是本章的起点。我们会看到：先老老实实用算术去试，试着试着会失控；然后请出本章的主角——字母，把“每一道题”变成“一类题”；最后你会得到一个小小的模型，它不只解决这一家文具店的问题，还能原封不动地搬到出租车计费、手机套餐、调配饮料、分压岁钱等一大堆看似无关的场景里。

1.2 算术的办法：当“挨个试”开始失控

最朴素的办法谁都想得出来：挨个试。

笔记本最少 1 本、最多 16 本（17 本就超过一百元了）。对每一种本数，算出剩下的钱，再看看能不能被四整除、商是不是至少为 1。于是我们得到一张表：

笔记本 x (本)	剩下的钱 (元)	中性笔 y (支)
2	$100 - 12 = 88$	22
4	$100 - 24 = 76$	19
6	$100 - 36 = 64$	16
8	$100 - 48 = 52$	13
10	$100 - 60 = 40$	10
12	$100 - 72 = 28$	7
14	$100 - 84 = 16$	4
16	$100 - 96 = 4$	1

仔细核对之后，一共 8 种买法。注意一个细节：奇数本笔记本都不可能出现——剩下的钱会是 94、82 这样的数，它们除以 4 有余数，买不到整支的笔。我们是靠“逐个数钱”才发现这一点的。

到这里问题似乎解决了。但请看看这个办法的代价：我们做了 16 次减法、16 次除法，还要自己留意“剩下的钱必须刚好分完”。如果妈妈把预算改成一百五十元、两百元，表格就得重做一遍。如果货架上多一种商品——比如两元一张的贴纸，条件变成“三样都要买、刚好花完一百元”——那枚举就不再是一张表，而是几十行甚至上百行：买 1 张贴纸时有哪些买法、买 2 张时又有哪些买法……手工做下去，出错只是时间问题。

算术的失败不在于算错，而在于每一个新问题都要从头再来。我们算完一百元，对“一百二十元”毫无积累；数清两种文具，对三种文具毫无办法。我们需要的不是更快的试，而是一种能把“试”本身写下来的办法。


一分钟实验

拿一张纸，自己动手把上面的枚举重做一遍，但把预算改成 120 元（笔记本仍为 6 元、笔仍为 4 元，两样都至少买一件）。数一数你做了多少次除法。然后先别往下看，想一想：这些除法里有没有重复出现的“套路”？如果你必须把同样的套路写给一个不会算术的机器人看，你会怎么写？

1.3 先点一次名：我们已经认识的数

在请字母出场之前，先花一点时间和老朋友们打个招呼——因为从这一章开始，它们会常常出现在同一个式子里。

自然数 $0, 1, 2, 3, \dots$ 是数数的数。买几本笔记本、分几颗糖，都是自然数的领地。整数在自然数之外添上负数 $-1, -2, -3, \dots$ ，用来表示“反方向”的量：零下三度、欠款五元、电梯地下二层。把整数画在一条直线上，就是我们熟悉的数轴：



分数（以及小数、百分数这对“近亲”）处理的是“整体的一部分”：半块披萨是 $\frac{1}{2}$ ，六元的笔记本打七五折就是 $6 \times 0.75 = 4.5$ 元，班级里 60% 的同学参加了春游。比例则研究两个量之间的

倍数关系：地图上 1 : 10000 的比例尺说“图上 1 厘米代表实地 100 米”；把 12 块巧克力按 2 : 1 分给两人，就是把它切成 3 等份，一人拿两份、一人拿一份。

这些数各有脾气。自然数做除法会“出界”——7 除以 2 在自然数里没答案；整数做除法也一样；分数的世界宽得多，两个分数加减乘除（除数不为零）总还是分数。百分数只是分母固定为 100 的分数，七五折、八折、九五折，说的都是“按原价的百分之多少收钱”。

为什么要在这里点名？因为接下来，当我们写下一个式子时，必须先想清楚：式子里的量允许取哪些数？买文具的数目只能是自然数；温度可以是整数和分数；折扣是百分数。一个问题的“数的世界”，往往决定了它有没有解、有几个解。一百元买文具如果允许买“3.5 本笔记本”，买法立刻多得数不清——但文具店不卖半本。这一点我们很快还会用到。

1.4 给“不知道”起一个名字：字母与代数式

回到那张一百元的清单。我们枚举时的每一步其实在做同一件事：假设买了若干本笔记本，算一算，再调整。数学家们很久以前就意识到，与其每次写“假设买了某个数本”，不如干脆给这个“还不知道的数”起一个临时的名字——一个字母。

把笔记本的数量叫作 x ，中性笔的数量叫作 y 。花掉的钱就是

$$6x + 4y,$$

“刚好花完一百元”这个要求就是

$$6x + 4y = 100.$$

请停下来看一眼这行式子，因为它完成了本章第一件大事：刚才那一整张表格、那十几次除法，被压缩成了一行字。这行字里没有具体假设买几本，它同时谈论所有可能的买法。预算改成一百二十元？不用重想，只要把式子右边换成 120： $6x + 4y = 120$ 。文具店换单价？换掉 6 和 4 就行。式子的骨架纹丝不动。

像 $6x + 4y$ 这样，由数、字母和运算符号组成的式子，叫作代数式。

术语卡片：代数式

直观解释：把一道算术题里“会变的那部分”用字母代替后留下的骨架。

正式定义：用运算符号（加、减、乘、除、乘方等）把数和表示数的字母连接起来的式子。

一个例子：笔记本 6 元一本、笔 4 元一支，买 x 本、 y 支的总价是代数式 $6x + 4y$ ；令 $x = 10$ 、 $y = 10$ ，它就变回一道普通的算术题 $6 \times 10 + 4 \times 10 = 100$ 。

字母在这里扮演的第一个角色是未知数：一个具体但暂时不知道的数，我们的工作是通过条件把它“揪出来”。方程 $6x + 4y = 100$ 里， x 和 y 就是两个未知数，而“ x, y 都是正整数”这个来自文具店规矩的限制（回想上一节：数的世界很重要！）将帮我们把答案锁定在有限的几种里。

别小看“起个名字”这一步，数学家们为它摸索了上千年。早期的数学著作里没有符号，一道题要用日常语言写满一整段：“有这样一个量，取它的三倍，再加上二，所得为五十，问这个量是多少。”读的人要先做阅读理解，才能开始算。不同地区的数学家各自发明过各种缩写和记号，彼此看不懂对方的“密码”，争论哪种写法更省事的文章流传了不少。直到字母记号逐渐统一，同一道题才被压缩成 $3x + 2 = 50$ 这七个符号。符号的胜利不在于省墨水，而在于：当条件全部住

进式子里，推理就可以对式子直接进行，不再依赖脑内那本账。本章后面所有的变形、求解、推广，都是这场胜利的红利。

用字母写条件还有一个立刻可见的好处：我们能用式子直接推理，而不必每次都回到数钱。比如“奇数本笔记本不可能”这件事，用字母说就是： $6x + 4y$ 永远是偶数（ $6x$ 是偶数， $4y$ 是偶数，偶数加偶数还是偶数），而 100 也是偶数，所以方程两边在“奇偶”上没有矛盾；但 $6x$ 除以 4 的余数随 x 变化——当 x 是奇数时 $6x$ 里有 6, 18, 30 这样的“4 的倍数加 2”，配上 $4y$ 后总和除以 4 余 2，而 100 除以 4 余 0，矛盾。所以 x 必须是偶数。一句话的推理，代替了表格里八行被划掉的尝试。


1.5 天平的守则：等式变形与唯一解

写下 $6x + 4y = 100$ 只是开始，我们还要会“解”它。先把术语摆正：

定义 1.1 (方程). 含有未知数的等式叫作方程。使方程左右两边相等的未知数的值，叫作方程的解；求出解的过程叫作解方程。

解方程的全部技术，建立在一个古老而朴素的图像上：天平。

一个等式就像一架平衡的天平：左边托盘放着 $6x + 4y$ ，右边托盘放着 100，横梁水平。只要不破坏平衡，我们可以对两边做相同的操作——同时添上同样重的砝码，同时拿走，同时翻倍，同时减半。平衡始终保持。



定理 1.2 (天平原理). 如果两个式子相等，那么对它们同时加上（或减去）同一个数或式子、同时乘以同一个数、同时除以同一个非零的数，得到的两个式子仍然相等。

这条原理听起来平淡，但它是整个方程世界的宪法。比如把 $6x + 4y = 100$ 两边同时除以 2，得到更清爽的 $3x + 2y = 50$ ；再把 $2y$ 从两边“拿走”（同时减去 $2y$ ），得到 $3x = 50 - 2y$ ；两边除以 3： $x = \frac{50 - 2y}{3}$ 。每一步都只是让天平换一种姿势保持平衡，但走到最后， x 几乎被“单独请了出来”——只要定下一个 y ， x 立刻被算出来。我们的表格其实就是在 $y = 22, 19, 16, \dots$ 时反复使用这个式子。

天平原理最经典的舞台是一元一次方程——只有一个未知数、未知数只出现一次方的方程。关于它，有一个干净利落的结论：

定理 1.3 (一元一次方程的解). 设 $a \neq 0$ ， b, c 是任意已知的数。那么方程 $ax + b = c$ 恰好有一个解

$$x = \frac{c - b}{a}.$$

证明. 分两步：先找一个解，再证明没有第二个解。

第一步，用天平原理把 x 解出来。方程两边同时减去 b ，得 $ax = c - b$ ；因为 $a \neq 0$ ，两边可以同时除以 a ，得 $x = \frac{c - b}{a}$ 。把这个值代回原方程检验： $a \cdot \frac{c - b}{a} + b = (c - b) + b = c$ ，确实成立，所以它是解。

第二步，证明唯一。假设 x_1 和 x_2 都是方程的解，即 $ax_1 + b = c$ 且 $ax_2 + b = c$ 。两式相减（天平两边减同样的东西），得 $a(x_1 - x_2) = 0$ 。由于 $a \neq 0$ ，两个数相乘得零时必有一个是零，所以 $x_1 - x_2 = 0$ ，即 $x_1 = x_2$ 。所谓“两个解”其实是同一个。证毕。□

请留意证明里的小机关：除以 a 之前必须先确认 $a \neq 0$ 。“两边同时除以同一个数”这条守则有个前提——那个数不能是零。除以零没有定义，天平守则在这里有一条明确的边界。这不是吹毛求疵：当 $a = 0$ 时方程变成 $0 \cdot x + b = c$ ，若 $b = c$ 则任何 x 都满足，若 $b \neq c$ 则无解——和“恰好一个解”完全不同。定理的条件和结论一样，都是定理的一部分。

再看一个数值例子感受一下这条定理的力量。文具店挂出两种优惠：A 方案“满一百减二十五”，B 方案“全场七五折”。买多少钱的东西两种方案一样划算？设原价为 x 元（假设 $x \geq 100$ ，否则 A 不生效），A 方案实付 $x - 25$ 元，B 方案实付 $0.75x$ 元。“一样划算”就是 $x - 25 = 0.75x$ 。两边减 $0.75x$ ： $0.25x = 25$ ，再除以 0.25 ： $x = 100$ 。原价恰好一百元时两方案打平；超过一百元后 B 方案更便宜（因为 B 的折扣跟着总价涨，A 的减免却固定不变）。百分数、一次方程、天平原理，在一道生活小题里完成了一次合作。

1.6 世界不总是刚刚好：不等式

妈妈的要求如果松一点——“一百元以内随便买，但不能超支”——等式就失效了，因为实付金额 $6x + 4y$ 不再等于某个确定的数，而是要满足

$$6x + 4y \leq 100.$$

这是一个不等式。现实中的限制大多长这样：预算不超支、工期不拖延、载重不超标、考试至少及格。等式描述“刚刚好”，不等式描述“够用就行”，后者的地盘其实大得多。

不等式也能像天平一样变形，但守则多了一条警示。同时加上或减去同一个数，方向不变；同时乘以或除以一个正数，方向不变；但乘以或除以一个负数时，不等号必须掉头。

为什么？看一眼数轴就明白。 $2 < 3$ ，说的是 2 在 3 的左边。两边同乘 -1 得到 -2 和 -3 ，在数轴上它们关于 0 翻了个面： -2 跑到了 -3 的右边，所以 $-2 > -3$ 。乘以负数等于给数轴照镜子，左右当然互换。

反例警报

警报一：“不等式两边同乘一个数，不等号方向不变。”——错。乘 -1 试试：由 $5 < 7$ 若得 $-5 < -7$ 就闹笑话了，正确的是 $-5 > -7$ 。只有乘正数方向才不变，乘负数必须变号，乘零则两边都变成 0，不等式直接“死亡”。

警报二：“字母代表的就是那个未知数，解出来就没用了。”——也不对。在 $6x + 4y = 100$ 里， x, y 可以取 8 组不同的值，字母代表的是“所有候选者”；在下一节你还会看到字母代表“任意一个自然数”。把字母只理解成“藏起来的一个数”，会漏掉它大半的本领。

不等式和等式常常联手。回到三种文具的问题：笔记本 6 元、笔 4 元、贴纸 2 元，三样都买、花完一百元。设贴纸买 z 张，那么前两样要满足的正是 $6x + 4y = 100 - 2z$ ，同时 $x \geq 1, y \geq 1$ 。后两个不等式给 z 划定了活动范围： $100 - 2z$ 至少要够买一本一笔，即 $100 - 2z \geq 10$ ，解得 $z \leq 45$ ；而 $z \geq 1$ 。于是 z 只在 1 到 45 之间活动，对每个 z 解一个我们已经会解的二元问题——一个吓人的三元枚举，被不等式修剪成了有边界的、可以分批处理的任务。

1.7 字母的另一种工作：装下一整类数

到目前为止，字母都在替“某个不知道但确定的数”站岗。但字母还有第二份、也许更重要的工作：一次谈论所有的数。

看一个古老的规律。把 1 到 100 的自然数全部加起来，和是多少？硬算要算 99 次加法。传说年幼的高斯在课堂上几秒钟就给出了答案 5050——这个故事的细节可能经过美化，但其中的想法千真万确，而且用字母一句话就能说清。

定理 1.4 (连续自然数之和). 对任意正整数 n ,

$$1 + 2 + 3 + \cdots + n = \frac{n(n+1)}{2}.$$

证明. 把这个和写两遍，一遍正着写、一遍倒着写，上下对齐：

$$\begin{array}{ccccccccc} 1 & + & 2 & + & \cdots & + & (n-1) & + & n \\ n & + & (n-1) & + & \cdots & + & 2 & + & 1 \end{array}$$


每一列上下两个数之和都是 $n+1$ ：第一列 $1+n$ ，第二列 $2+(n-1)$ ，依此类推，最后一列 $n+1$ 。一共有 n 列，所以两行加起来等于 $n(n+1)$ 。而这两行是同一个和写了两遍，因此

$$2(1 + 2 + \cdots + n) = n(n+1),$$

两边同时除以 2（天平原理），即得结论。证毕。 $\square$

代入 $n = 100$ ： $\frac{100 \times 101}{2} = 5050$ ，与传说一致。但这个定理说的远不止“1 加到 100”——它说 n 是 7、1000、1000000 都对。一个字母 n 把无穷多道加法题合并成了一道题。这就是字母的第二份工作：不代表某个未知数，而代表“一整类数里的任意一个”。

这个公式还有一个几何面孔。把 $1 + 2 + \cdots + n$ 想成堆圆点：第一行 1 个、第二行 2 个……第 n 行 n 个，堆成一个三角形。取两个一模一样的“点三角形”，把其中一个倒扣过来，刚好拼成一个 n 行、 $n+1$ 列的矩形：



实心点是 $1 + 2 + 3 + 4 + 5$ ，空心点是倒扣的另一份，合起来是 5×6

证明里的“写两遍、上下配对”，在图里就是“拿两份、拼成矩形”。同一个事实，代数说一遍，图形再说一遍——这种双重陈述的习惯，会在本书后面反复出现。

术语卡片：变量、参数与常量

直观解释：一场戏里的三种角色。变量是真正在动的演员；参数是这场戏里固定、换一场才换的布景；常量是雷打不动的道具。

正式定义：在一个问题中可以取不同值的量叫变量；在同类问题中保持不变、换一类问题才改变的量叫参数；永远不变的数叫常量。

一个例子：在 $6x + 4y = 100$ 中， x, y 是变量， $6, 4, 100$ 是常量。把问题推广成 $px + qy = m$ (单价 p, q 、预算 m)， x, y 仍是变量，而 p, q, m 成了参数——换一家文具店、换一个预算，只是换一组参数，模型原封不动。

分清这三种角色，是从“做一道题”跨到“造一个模型”的关键一步。写下 $6x + 4y = 100$ ，你只解决了妈妈的这一张清单；写下 $px + qy = m$ ，你同时解决了所有单价、所有预算下的同类问题。参数越多，模型搬得越远。

1.8 换一个视角：模型是可以搬运的

现在回头看，本章其实只干了一件事：把具体问题翻译成由字母、等式和不等式组成的模型。值得强调的是，同一个模型会在完全不同的场景里反复现身——这正是代数“一本万利”的地方。

出租车计费：起步价 10 元，之后每公里 2 元。乘 x 公里 ($x \geq 3$ ，假设 3 公里内算起步价) 的车费是 $2(x - 3) + 10$ ，即 $2x + 4$ 元。手里只有 30 元，最远能坐多远？解 $2x + 4 \leq 30$ ，得 $x \leq 13$ 。手机套餐：月租 19 元含 10 GB 流量，超出部分每 GB 收 3 元，月消费上限 50 元，最多能用多少流量？设超出 x GB，则 $19 + 3x \leq 50$ ，得 $x \leq \frac{31}{3}$ ，即最多超出 10 GB。调饮料：浓缩汁与水按 1:5 调配，要配 1.2 升，浓缩汁要多少？设浓缩汁 x 升， $x + 5x = 1.2$ ， $x = 0.2$ 升。

看出共同点了吗？车费、流量、饮料，剥掉外壳之后都是“形如 $ax + b$ 的量，配上一个等式或不等式”。你在文具店里学会的那套天平守则，在出租车里、在套餐里、在厨房里照样管用——一个字都不用改。

这正是本章最想让你带走的一句话：代数不是把同一道题算得更快，而是一次解决许多相似的问题。枚举的努力随问题的规模水涨船高——预算翻倍，表格就翻倍；而模型的努力只花一次，往后的每一个新问题都变成“换一组参数、解一遍方程”的例行公事。算术回答“这一题的答案是多少”，代数回答“这一类题的答案长什么样”。从“一个”到“一类”，就是本章标题里“可以搬运”四个字的全部含义。

连接线

这种“翻译”能力是现代世界的底层技术之一。导航软件把道路网翻译成变量之间的限制，替你解一个庞大的“怎样最快到达”的问题；电商后台把库存、优惠券、满减规则翻译成成百上千个像 $6x + 4y \leq 100$ 这样的式子，自动判断每个订单能不能成交、该收多少钱；你写程序时声明的每一个“变量”，正是本章字母的电子化身。反过来，本书后面每一章都在给这个翻译器增加新语种：第 2 章加上“变化”，第 3、4 章加上“形状”，再往后还有“随机”和“无限”。

也要诚实地说出模型的边界。把行程压成 $2x + 4$ 时，我们忽略了堵车和绕路；把优惠比成 $x - 25$ 与 $0.75x$ 时，我们假设你真会把钱花到一百元以上。模型是对现实的翻译，而翻译永远有

取舍。好的模型抓住问题的主要结构、舍掉无关的细节；判断取舍是否得当，是建模者和数学家共同的功课，本书第 2 章和第 18 章还会回到这个话题。

继续攀登

继续向前的话，本章的每条线都通向一个更大的世界。要求未知数取整数的方程（如 $6x + 4y = 100$ 的“文具店版本”）叫丢番图方程，是数论的经典猎场，本书第 13 章会专门拜访；一堆不等式围出可行区域、再在其中找最优方案，是线性规划的用武之地，运筹学和经济学每天靠它调度真实的货物与资金；“两边做同样操作保持平衡”这条守则本身，在大学的抽象代数里被提炼成群与域的公理——数学家们问：还有哪些世界里也存在着自己的“天平”？关键词：丢番图方程、线性规划、公理化。

数学工具箱

本章新增的工具，请收好：

- **设字母**：给不知道的数（未知数）或一整类数（任意数）起名字，是建模的第一步。
- **代数式**：把“会变的部分”抽出来，留下可以反复使用的骨架，如 $6x + 4y$ 。
- **天平原理**：等式两边同加、同减、同乘、同除（除数非零）保持相等——解方程的全部依据。
- **不等式变形**：乘除负数要变号；等式管“刚好”，不等式管“范围”，两者常联手。
- **区分角色**：变量在动、参数随问题而换、常量不动；参数化是让模型可搬运的关键。
- **先问数的世界**：未知数允许取自自然数、整数还是任意数？这决定解有几个、甚至有没有。

思考题

观察题

1. 再看一遍一百元清单的解： $(x, y) = (2, 22), (4, 19), (6, 16), \dots$ 。每换一种买法， x 增加 2， y 减少 3。为什么恰好是“加 2 减 3”，而不是别的搭配？（提示：假设从一种买法改成另一种， $6x + 4y$ 的总额必须不变；让 x 增加某个数，算算 y 该怎么配合。）
2. 在数轴上标出满足 $6x + 4y \leq 100$ （且 $x \geq 1, y \geq 1$ ）的几组 (x, y) ——把 x 画在横的方向、 y 画在竖的方向，一个买法对应一个点。观察这些点的排列，你有什么发现？（提示：先描 $6x + 4y = 100$ 对应的点，再看看其他点落在它的哪一侧。）

证明题

1. 证明：任意两个相邻整数之和必为奇数。（提示：把较小的那个整数叫作 n ，把另一个用 n 表示出来再相加。）
2. 证明： $1 + 3 + 5 + \dots + (2n - 1) = n^2$ ，即从 1 开始的前 n 个奇数之和是一个完全平方数。（提示：模仿本章“写两遍配对”的办法；或者画点阵——每次在角上添一个“拐弯”形的点层。）

挑战题

1. 三种文具问题： $6x + 4y + 2z = 100$, x, y, z 都是正整数。设计一套不遗漏、不重复的计数流程，把买法的总数数清楚。（提示：先固定 z ，把问题化回本章已解决的二元情形；注意 $6x + 4y = 100 - 2z$ 要求右边满足什么条件才有解。）
2. 用 40 米长的围栏靠墙围一块矩形菜地（墙算作一条边，围栏只围三条边），长和宽都取整数米。怎样围面积最大？（提示：设与墙平行的边为 x 米，另两条边各为 y 米，先用围栏长度写出 x, y 的关系，再把面积单独用 x 表示出来，列表试几个值；猜猜不靠墙的版本答案会怎么变。）

通往下一章的门

挑战题的最后一问里，藏着一个本章工具回答不彻底的问题。围栏总长固定时， x 和 y 被绑在一起： x 每变一点， y 被迫跟着变，面积 S 也跟着变。我们用“列表试几个值”找到了最大的面积，但心里不踏实：整数之外呢？ x 取 13.5 米会不会更好？我们试了几个点，却声称看见了全部。

本章的办法是盯着一个一个的数；而这里的真正主角是变化本身—— S 怎样随着 x 连续地起伏。数学家们为这种问题准备了一件新武器：把关系画到坐标纸上。横的方向表示 x ，竖的方向表示 S ，每一个可能的围法变成纸上的一个点，所有点连起来，就是这条关系的“画像”。画像一出，最高点在哪里、从哪边爬上去、往哪边走下坡路，一目了然——不再需要猜测，也不再怕漏掉 13.5 这样的中间值。

这条“画像”就是函数的图像。把同一个关系从式子翻译成图形，我们会得到一整套新问题：图像为什么长成抛物线的样子？斜的陡缓说明什么？两条图像相交意味着什么？第 2 章，我们从解一个方程，走向研究所有答案排成的形状。

第二章 方程与函数：从求一个答案到研究所有答案

2.1 出租车计价器与笼子里的鸡兔

傍晚下起雨，你拦下一辆出租车。坐定之后，计价器先跳出一个数字：11。车子开动了，你盯着那个红色的小屏幕，发现它并不理睬你——直到开出一段距离，它开始每隔一会儿“咔”地跳一下，每次多加 2 元。到目的地时，屏幕停在 21 元。

司机师傅说，规矩很简单：起步价 11 元，含 3 公里；超过 3 公里以后，每公里加收 2 元。你忽然好奇：刚才这一趟到底走了多远？

这是一个小学生都能试着回答的问题。但如果我们把问题变一变：计价器显示 35 元呢？显示 100 元呢？如果出租车公司把规矩改成“起步价 13 元含 2 公里，之后每公里 3 元”呢？你会发现，每一次改变，你都得重新算一遍。有没有一种办法，能把所有这类问题一次性解决？

再看一个老问题，它在中国古代的算书里已经躺了一千多年：一个笼子里有鸡和兔，从上面数有 35 个头，从下面数有 94 条腿。问鸡和兔各有多少只？这道题没有告诉你任何“单价”或“规则”，只给了你两堆混杂的信息。先别急着往下读，凭直觉猜一猜：鸡多还是兔多？大概各有多少？

这两个问题——计价器和鸡兔——表面上一个关于钱，一个关于动物，毫无关系。但这一章结束时你会看到，它们在数学的深处是同一类问题的两种面孔，而认识这一类问题的方式，会把我们从“求出一个答案”带到一片更广阔的天地：研究所有答案的规律。

2.2 猜，猜到天黑：试数法的失败

面对鸡兔同笼，最自然的办法是猜。先猜 35 只全是鸡：腿有 $35 \times 2 = 70$ 条，比 94 少了 24 条。说明兔子不能太少。改成猜 20 只鸡、15 只兔：腿有 $20 \times 2 + 15 \times 4 = 100$ 条，又多了 6 条。再调成 23 只鸡、12 只兔：腿有 $23 \times 2 + 12 \times 4 = 94$ 条——中了！答案是 23 只鸡、12 只兔。

猜中了，值得高兴。但请诚实回想一下刚才的过程：每一次猜测，你都做了两三次乘法和一次加法，猜错了还得从头再来。如果题目改成 3500 个头、9400 条腿，你还愿意猜吗？更要命的是，猜的方法有一个根本的缺陷：它依赖运气和耐心，而不是方法。你没法向别人保证“按这个步骤来，一定能找到答案”，你只能说“多试几次，大概能蒙对”。

出租车问题也一样。你可以试：走了 5 公里，车费是 $11 + 2 \times (5 - 3) = 15$ 元，不够；走 10 公里，车费是 $11 + 2 \times (10 - 3) = 25$ 元，超了；走 8 公里， $11 + 2 \times (8 - 3) = 21$ 元，正好。三个问题猜了三次，每次都像在黑暗中摸钥匙。

第 1 章我们见过字母的威力：一个字母可以代表任何数，于是一个等式可以概括无穷多个具

体问题。这一章的第一件大事，就是把“猜”升级成“翻译”——把问题翻译成等式，然后让等式自己告诉我们答案。

2.3 把问题翻译成等式

先看出租车。我们不知道的是“走了多少公里”，于是给它一个名字： x 。注意，给未知数起名字这件事本身就是一次发明——我们把一个看不见摸不着的量，变成了一个可以在纸上推来推去的符号。

根据规矩，车费分两段：3 公里以内的 11 元是固定的，超出部分是每公里 2 元，超出的里程是 $(x - 3)$ 公里。于是“车费是 21 元”这句话翻译成数学语言就是

$$11 + 2(x - 3) = 21.$$

这样一个含有未知数的等式叫作**方程**。方程左边和右边像一架天平的两端，只要我们做的操作不改变两边的平衡——两边同时加、减同一个数，或同时乘、除以同一个非零的数——等式就依然成立。利用这条“保持平衡”的原则：

$$2(x - 3) = 10, \quad x - 3 = 5, \quad x = 8.$$

走了 8 公里。这次不是猜出来的，是推出来的。而且请注意：如果车费是 35 元，我们只需要把 21 换成 35 再走一遍同样的步骤；如果计价规则变了，我们只需要改方程里的数字。一个方程，把无穷多个“问车费”的问题压缩成了一行字。

鸡兔同笼只有一个未知数吗？其实有两个：鸡的数量和兔的数量。那就给它们各起一个名字，鸡 x 只、兔 y 只。题目给了两个条件，翻译成两个方程：

$$\begin{cases} x + y = 35, \\ 2x + 4y = 94. \end{cases}$$

两个方程捆在一起，叫作**方程组**。它的解法有一个朴素的思想：用一个方程把一个未知数“换掉”。由第一个方程得 $y = 35 - x$ ，代入第二个：

$$2x + 4(35 - x) = 94, \quad 140 - 2x = 94, \quad x = 23,$$

于是 $y = 35 - 23 = 12$ 。和刚才猜出来的答案一模一样——但这次我们确信它一定对，而且确信它是唯一的答案，因为每一步推理都是可复查的。

顺带一提，古人解这道题有一种漂亮的巧思：想象吹一声哨子，所有鸡和兔都抬起两条腿，这时地上还剩 $94 - 35 \times 2 = 24$ 条腿；鸡已经一屁股坐下了，站着的全是兔子，每只兔子还剩两条腿，所以兔子有 $24 \div 2 = 12$ 只。这个“抬腿法”聪明得让人拍案——但你注意到了吗？它和代入消元做的其实是同一件事： $2x + 4y = 94$ 减去 $x + y = 35$ 的两倍，消掉的正是“每只动物两条腿”的部分。巧思解决一道题，方程解决一类题；巧思是风景，方程是道路。数学偏爱道路，但从不拒绝风景。

上面这些方程里，未知数都只以“一次”的面目出现（没有平方、立方），所以叫一元一次方程、二元一次方程组。可是，是不是所有问题都这么客气？

再看一个问题。你家想用 20 米长的篱笆围一个矩形菜园，要求面积恰好是 24 平方米，长和宽各是多少？设长为 x 米，那么宽就是 $(10 - x)$ 米（因为长加宽等于周长的一半）。面积条件翻译成

$$x(10 - x) = 24, \quad \text{整理得} \quad x^2 - 10x + 24 = 0.$$

未知数出现了平方！天平平衡的套路在这里不够用了——你没法把 x^2 和 x 直接“合并同类项”再除过去。我们被困住了，而数学家们最喜欢的处境，恰恰就是被困住。

2.4 配方：二次方程的万能钥匙

面对 $x^2 - 10x + 24 = 0$ ，先试试老办法：因式分解。能不能找到两个数，乘积是 24、和是 10？试几组：4 和 6 正好合适！于是

$$x^2 - 10x + 24 = (x - 4)(x - 6) = 0.$$

两个数相乘等于 0，必有至少一个是 0，所以 $x = 4$ 或 $x = 6$ 。长 6 米、宽 4 米（或者反过来），面积 $6 \times 4 = 24$ ，验算通过。

但这个方法有个软肋：它靠的是“刚好能猜到”。如果方程是 $x^2 - 10x + 23 = 0$ 呢？乘积 23、和 10 的两个整数不存在。难道这方程就无解了？不一定，可能只是答案不是整数。我们需要一个不靠猜的办法。

这个办法叫**配方法**，它的核心想法来自一个你可能背过的公式： $(x + a)^2 = x^2 + 2ax + a^2$ 。倒过来读：如果看到 $x^2 + 2ax$ ，加上一个 a^2 就能把它“补成一个完全平方”。以 $x^2 - 10x + 23 = 0$ 为例：前半截 $x^2 - 10x$ 里， $2a = -10$ ，所以 $a = -5$ ，需要补的数是 25。方程两边同时加 2（也就是把 23 变成 25）：

$$x^2 - 10x + 25 = 2, \quad (x - 5)^2 = 2, \quad x - 5 = \pm\sqrt{2}.$$

所以 $x = 5 + \sqrt{2}$ 或 $x = 5 - \sqrt{2}$ ，大约是 6.41 和 3.59。答案不是整数，照样抓得住。配方法的可贵之处是：它对所有二次方程都有效，一视同仁。把这个过程对着最一般的二次方程做一遍，就得到本章的核心定理。

定理 2.1 (一元二次方程求根公式). 设 $a \neq 0$ ，方程 $ax^2 + bx + c = 0$ 在 $b^2 - 4ac \geq 0$ 时的全部实数解为

$$x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}.$$

当 $b^2 - 4ac = 0$ 时两个解重合；当 $b^2 - 4ac < 0$ 时没有实数解。

证明. 因为 $a \neq 0$ ，方程两边同除以 a ：

$$x^2 + \frac{b}{a}x + \frac{c}{a} = 0.$$

一次项系数是 $\frac{b}{a}$ ，所以配方需要加上它的平方的一半，即 $\left(\frac{b}{2a}\right)^2$ 。两边同时加这个数，并把它与 $\frac{c}{a}$ 合并：

$$x^2 + \frac{b}{a}x + \left(\frac{b}{2a}\right)^2 = \left(\frac{b}{2a}\right)^2 - \frac{c}{a} = \frac{b^2}{4a^2} - \frac{4ac}{4a^2} = \frac{b^2 - 4ac}{4a^2}.$$

左边恰好是完全平方：

$$\left(x + \frac{b}{2a}\right)^2 = \frac{b^2 - 4ac}{4a^2}.$$

一个实数的平方不可能是负数，所以右边必须非负，这正是条件 $b^2 - 4ac \geq 0$ 的来源。满足条件时两边开平方（注意开平方会得到一正一负两个可能）：

$$x + \frac{b}{2a} = \pm \frac{\sqrt{b^2 - 4ac}}{2a},$$

把 $\frac{b}{2a}$ 移到右边，通分即得结论。 □

这个公式值得被郑重对待。几百年前，数学家们为了它争吵、打赌、决斗（真的决斗过——那是关于三次方程的故事，我们第 5 章再讲），而今天它安安静静地躺在你面前的纸上。 $b^2 - 4ac$ 这个式子有个专门的名字，叫**判别式**，它像一个体检指标：看一眼它的正负，不用算解，就知道方程“有没有救”。

例 2.2. 用求根公式解 $2x^2 - 7x + 3 = 0$ 。这里 $a = 2$, $b = -7$, $c = 3$, 判别式 $= 49 - 24 = 25 > 0$, 于是

$$x = \frac{7 \pm 5}{4}, \quad x_1 = 3, \quad x_2 = \frac{1}{2}.$$

代入原方程验算： $2 \times 9 - 7 \times 3 + 3 = 0$, $2 \times \frac{1}{4} - 7 \times \frac{1}{2} + 3 = 0$ 。都成立。

2.5 从“求一个答案”到“研究所有答案”

到现在为止，我们一直在做同一件事：给定一个条件，找出满足条件的那个数（或那几个数）。这是“解方程”的视角。

可是回到出租车。车费 21 元对应 8 公里，35 元对应 15 公里……我们可以没完没了地解下去，但每解一次只得到一个点。有没有办法把“里程”和“车费”这对关系整个地端出来，让我们一次看清它的全貌？

有的。只要里程 $x \geq 3$ ，车费就是 $11 + 2(x - 3)$ ，化简一下是 $2x + 5$ 。这个式子不再是“某个答案”，而是一条**规则**：你随便报一个里程，它告诉你一个车费；报 4，得 13；报 10，得 25；报 100，得 205。规则把无穷多个输入和无穷多个输出配成了一对对，像一台永不停歇的机器。

这样的规则在数学里有一个名字——它大概是整个中学数学里最重要的名字。

术语卡片：函数

直观解释：一台输入—输出机器。你投入一个数，它吐出一个数，而且同一个输入永远吐出同一个输出。

正式定义：设有两个量 x 和 y 。如果每当 x 在某个范围内取定一个值， y 都有唯一确定的值与它对应，就说 y 是 x 的函数，记作 $y = f(x)$ 。 x 叫自变量， f 表示对应规则。

一个例子： $f(x) = 2x + 5$ 就是计价器规则（ $x \geq 3$ 时）： $f(4) = 13$, $f(10) = 25$ 。

记号 $f(x)$ 刚出现时常常让人别扭： f 和 x 是在相乘吗？不是。 $f(x)$ 读作“ f 在 x 处的值”，意思是“把 x 放进规则 f 里，出来的结果”。这个记号解决的麻烦是：以前我们只能说“那个关系”，现在我们可以给每一台机器起名字—— f 是计价器， g 可能是温度转换， h 可能是手机套餐——然后比较它们、组合它们。


一台函数机器可以有三种“证件照”：用式子写，如 $f(x) = 2x + 5$ ；用表格列，一行输入一行输出；用图像画，把每一对数描成一个点。式子最精确，表格最具体，图像最直观——三者是同一条规则的三张面孔，接下来几节我们会反复在它们之间切换。

请注意定义里“唯一确定”这四个字。一台机器如果对同一个输入有时吐 5、有时吐 7，那它不是函数，是坏机器。反过来，不同的输入吐同一个输出完全没问题——所有人把“今天星期几”这台机器输入进去，得到的都是同一个答案。

从方程到函数，是视角的一次大迁移。方程问：“哪些 x 让 $2x + 5 = 21$ 成立？”——目光钉在一个值上。函数问：“规则 $f(x) = 2x + 5$ 长什么样？它变快还是变慢？有没有最大最小？”——目光扫过所有值。前者是破案，找到那个嫌疑人；后者是研究一座城市的地图。这一章的下半部分，我们就来学会看地图。

2.6 图像：规则留下的轨迹

一台机器的输入和输出是一对数，比如 $(4, 13)$ 、 $(10, 25)$ 。一对有序的数恰好是坐标纸上的一个点。把一台函数机器产生的所有点都描在坐标纸上，就得到了它的**图像**——你可以把它想象成规则留下的轨迹，像雪地上的脚印，暴露了规则的全部行踪。




上面这张图画的是直线 $y = 0.4x + 4$ 。为什么它的轨迹恰好是一条直线？看规则本身： x 每增加 1， y 就增加 0.4； x 每增加 5， y 就增加 2。增加的步伐永远一样大——匀速变化的轨迹不会拐弯，只能是直线。所有形如 $y = kx + b$ (k, b 是固定的数， $k \neq 0$) 的函数都叫**一次函数**（或线性函数），它们的图像都是直线。

换一个规则试试： $y = x^2$ 。描几个点：

x	-3	-2	-1	0	1	2	3
y	9	4	1	0	1	4	9

注意表格里的对称： $(-2, 4)$ 和 $(2, 4)$ 一样高。把这些点连起来（为了让图能塞进书页，我们画它的缩小版 $y = \frac{1}{2}x^2 - 4$ ）：



这条曲线叫**抛物线**。它不是直线的理由从表格里就能看出： x 从 0 走到 1, y 只挪动了一点； x 从 2 走到 3, y 却蹿了一大截。变化的步伐越来越快，轨迹当然要弯。抛向空中的皮球、喷泉里射出的水柱，走的都是这条曲线——这就是为什么你总觉得抛物线眼熟。

还有一种关系值得认识：**反比例**。班级凑 300 元包车去郊游，人均车费取决于去的人数 x ： $y = \frac{300}{x}$ 。去 10 人，人均 30 元；去 30 人，人均 10 元；去 60 人，人均 5 元。人越多越便宜，但便宜的速度在放慢——从 10 人到 20 人，人均骤降 15 元；从 50 人到 60 人，只降了 1 元。它的图像是一条越来越贴近坐标轴、却永远碰不到轴的曲线（叫双曲线的一支）。路程固定时的速度与时间、矩形面积固定时的长与宽，都是反比例关系。

直线、抛物线、双曲线——三种轨迹，三种脾气。直线匀速，抛物线加速，双曲线先急后缓。你可能会问：既然规则都知道了，为什么还要画图？因为眼睛和大脑处理“形”的速度远快于处理“数”：一条曲线是升是降、是陡是缓、有没有最高点和最低点，扫一眼就明白，而这些信息埋在式子里要费一番功夫才能挖出来。图像是给规则做的一次“可视化体检”。

2.7 斜率与截距：读懂函数的性格

拿到一条直线的方程 $y = kx + b$ ，两个数字 k 和 b 各自管什么？

先看 b 。当 $x = 0$ 时 $y = b$ ，所以 b 是直线与 y 轴交点的高度，叫**截距**。在出租车例子中，截距像“起步价”——还没开始按里程计价，账单上已经有的那部分。

再看 k 。 x 每增加 1, y 就增加 k ，所以 k 衡量这条直线的**陡峭程度**，叫**斜率**。斜率为正，直线从左往右爬坡；斜率为负，直线走下坡路；斜率的绝对值越大，坡越陡。

术语卡片：斜率

直观解释：直线的“坡度”——水平方向每走 1 个单位，竖直方向上升多少。

正式定义：直线上任取两点 (x_1, y_1) 和 (x_2, y_2) ($x_1 \neq x_2$)，斜率

$$k = \frac{y_2 - y_1}{x_2 - x_1}.$$

一个例子：直线过 $(1, 4)$ 和 $(5, 12)$ ，斜率 $k = \frac{12 - 4}{5 - 1} = 2$ ，即每向右走 1，上升 2。

斜率定义的下面藏着一个重要事实：这个比值和你选哪两个点**无关**。这并不平凡——为什么换两个点算出来的坡度一样？因为一次函数的变化是匀速的： $y_2 - y_1 = kx_2 + b - (kx_1 + b) = k(x_2 - x_1)$ ，一除恰好是 k ， b 被抵消了。反过来说，如果某个函数的“斜率”随位置变化，它的图像就一定不是直线——抛物线在山脚平缓、在半山腰陡峭，正是这个原因。

斜率还有个更响亮的名字：**变化率**。里程—车费直线的斜率是 2，意思是“每公里 2 元”；时间—路程直线的斜率是速度；时间—存款直线的斜率是存钱速度。读懂斜率，就读懂了“这个世界变化得有多快”。

斜率还带着单位，这一点常被忽略却极其有用。车费对里程的斜率单位是“元每公里”，路程对时间的斜率单位是“米每秒”——单位本身就告诉你这个变化率在度量什么。负斜率同样有意义：登山时海拔对时间的斜率是正的，下山时是负的；发烧时体温的斜率为正，退烧时为负。一条直线斜率的正负，讲的就是“这个量在涨还是在跌”。

反例警报

“ y 随着 x 的增大而增大，所以 y 和 x 成正比例。”——错。反例： $y = x + 1$ 。 x 从 1 变到 2， y 从 2 变到 3，确实在增大；但 y 和 x 的比值一会儿是 2、一会儿是 1.5，并不固定， $x = 0$ 时 y 也不是 0。正比例要求图像是过原点的直线，即 $b = 0$ 。另一个相似的陷阱：“图像在上升，所以它是直线”——抛物线 $y = x^2$ 在 $x > 0$ 时也一直上升，可它分明是弯的。上升只说方向，不说形状。

反比例函数 $y = \frac{300}{x}$ 则展示了另一种性格：它没有一个统一的“斜率”，离原点近的地方陡得吓人，远处几乎平躺。变化率本身在变化——承认这一点，是人类数学史上的一次深呼吸，我们将在第 10 章正式面对它。

2.8 换一个视角：图像替方程说话

学会了看图像，我们回头看方程，眼光会完全不同。

方程 $2x + 5 = 21$ 是在问：直线 $y = 2x + 5$ 在高度 21 处的横坐标是多少？方程组

$$\begin{cases} y = 2x + 5, \\ y = -x + 23 \end{cases}$$

是在问：这两条直线在哪里相交？画出来你会发现，两条不平行的直线恰好交于一点——这正是二元一次方程组通常有唯一解的几何原因。而 $x^2 - 10x + 24 = 0$ 是在问：抛物线 $y = x^2 - 10x + 24$

在哪里贴着地面（与 x 轴相交）？判别式为正，抛物线穿过地面两次；判别式为零，它刚好碰到地面就弹起来；判别式为负，它整个悬在半空——“没有实数解”在图像上就是“根本没碰着”。

连接线

第 1 章里，字母把一个个算术题压缩成代数式；这一章，图像又把代数式翻译回“形”。方程、函数、图像是同一件东西的三种语言：方程是审问（找出特定的 x ），函数是全景（描述整个对应），图像是地图（把全景画给你看）。第 4 章我们会把这套翻译系统彻底打通，让几何图形直接变成代数方程。至于图像上的点、线、角到底凭什么可信——凭什么“看起来相交”就是真的相交——那是第 3 章要用证明来回答的问题。

这种“换语言”的本事有实实在在的力量。面对一堆数据——比如过去一年每月的电费——直接看数字很难有感觉；描成图像，趋势、异常、周期全都跳出来。天气预报的温度曲线、股票软件的起起伏伏、体测报告里的生长曲线，背后都是同一句话：规则留下轨迹，轨迹泄露规则。

反方向同样行得通：把一个几何问题翻译成方程。公园喷泉的水柱是一条抛物线，设计师想让水柱在 4 米外落回水池、最高点 2 米——这些“形状上的要求”可以变成几个方程，解出来就得到喷口的精确参数。形状提要求，方程给答案，这是工程师每天都在做的事。我们第 4 章会系统地练习这门翻译。

一分钟实验

实验一：画一条自己的抛物线。在方格纸上描出 $y = x^2$ 的 9 个点（ x 取 -4 到 4 ），用光滑的曲线连接。然后做两件事：（1）沿 y 轴对折纸张，看看两边是否重合；（2）用尺子量一量曲线在 $(1, 1)$ 附近和 $(3, 9)$ 附近的“坡度”，感受斜率随位置变化。

实验二：测一测生活的斜率。找一个有阶梯的地方，量出某一级台阶的高度和深度（比如高 15 厘米、深 28 厘米），算出坡度 $15 \div 28 \approx 0.54$ 。再找一段无障碍坡道做同样的测量，比较两者。你刚刚做的事情，和工程师设计坡道、和数学家定义斜率，是同一回事。

数学工具箱

本章你获得的新工具：

- **列方程：**给未知数起名字，把条件翻译成等式；多个未知数就列方程组，用代入消元。
- **配方法与求根公式：**对付一切一元二次方程的通用程序；判别式 $b^2 - 4ac$ 先报“有没有解”。
- **函数记号 $f(x)$ ：**把“对应规则”当作一个可以研究、可以起名字的对象。
- **图像：**描点连线，把规则变成看得见的轨迹；直线、抛物线、双曲线是三种最常见的轨迹。
- **斜率与截距：**一次函数的两个“性格参数”，分别管陡峭程度和起始位置；斜率就是变化率。

继续攀登

继续往前，这些词会在更高处等你：**增长率与导数**（第 10 章，抛物线上每一点的“瞬时斜率”怎么定义）；**函数的复合与反函数**（把两台机器串联起来，以及把一台机器倒着开）；**指数函数与对数函数**（增长速度本身在增长的关系，比如细菌和存款）；**不动点**（有没有一个输入，机器吐出的恰好是它自己）。再远一点，大学数学会把“函数”这个词推广到难以想象的范围——函数之间也可以谈“距离”，函数的全体也可以组成一个“空间”。

思考题**观察题**

1. 在同一张坐标纸上画出 $y = 2x + 5$ 和 $y = -x + 23$ ，找到交点，再解方程组。交点坐标和方程组的解有什么关系？为什么会这样？提示：交点同时躺在两条直线上，意味着它的坐标同时让两个规则成立。
2. 观察 $y = \frac{12}{x}$ 的函数值： x 从 1 变到 2 时 y 变了多少？ x 从 6 变到 7 时呢？两个区间一样长，为什么 y 的变化差这么多？提示：把具体的 y 值都算出来，比较两次“变化量”而不是“变化率”。

证明题

1. 证明：若两个正数之和固定为 10，则它们的乘积不超过 25，且只有当两数都等于 5 时取到 25。提示：设一个数为 x ，另一个为 $10 - x$ ，把乘积写成二次式并配方；也可以想想本章围菜园的例子。
2. 证明：设 $f(x) = kx + b$ 且 $k > 0$ 。若 $x_1 < x_2$ ，则 $f(x_1) < f(x_2)$ （这称为“单调递增”）。提示：计算 $f(x_2) - f(x_1)$ ，利用 $x_2 - x_1 > 0$ 和 $k > 0$ 判断符号。

挑战题

1. 设 x_1, x_2 是方程 $ax^2 + bx + c = 0$ 的两个解。不求出它们，直接证明 $x_1 + x_2 = -\frac{b}{a}$, $x_1 x_2 = \frac{c}{a}$ 。提示：把求根公式里的两个解原样相加、相乘，注意 $\sqrt{\quad}$ 会怎样消失；第 5 章会给这组关系一个专门的名字。
2. 某城市的出租车计价规则是：3 公里以内 11 元，3 到 10 公里每公里 2 元，超过 10 公里的部分每公里 3 元。写出车费 y 关于里程 x 的分段表达式并画出图像。这台“机器”是函数吗？它的图像在 $x = 3$ 和 $x = 10$ 处发生了什么？提示：检查每个输入是否只有一个输出；图像不会断，但“坡度”会突然改变——这种点以后会有专门的名字。

通往下一章的门

这一章我们养成了一个习惯：凡是关系，就画成图像；凡是方程，就看成交点。图像成了我们最信任的眼睛。

但请你仔细回想一件小事：画抛物线的时候，你描了 9 个点，然后“用光滑的曲线连接”。凭什么？你只是看着那 9 个点大致在一条弯弯的轨道上，就顺手把它们连了起来。也许曲线在两个点之间偷偷拐了个你没看见的弯？也许你画的两条直线“看起来交在 $(6, 17)$ ”，量一量却是 $(5.98, 17.03)$ ？眼睛和尺子能帮我们发现线索，却永远不能替我们做担保——这正是数学里“测量”和“证明”的分界线。

下一章，我们回到比函数更古老的数学：点、线、角、三角形和圆。我们会看到，古希腊人如何从画不出一条“完美直线”的困境出发，建立起人类历史上第一座证明的大厦；也会看到同一个结论——比如那个关于直角三角形三边的著名定理——为什么值得用十几种不同的方式各证明一遍。图像让我们看见答案，证明让我们确信答案。现在，去认识第二样东西。

第三章 初等几何：从测量、作图到证明

前两章里，我们用字母和方程把许多具体问题压缩成了可以搬运的模型。那些问题大多发生在“数量”的世界里：价格、速度、时间。这一章我们要换一个世界——形状的世界。你将看到，人类最早的几何知识来自非常实际的需要：丈量土地、建造房屋、观察星空。但这门学科最惊人的地方在于，它最终挣脱了尺子和绳子的限制，变成了一门只凭推理就能保证结论的学问。这是数学史上第一次出现“证明”，也是整本书反复回响的主题第一次登场。

3.1 影子里的金字塔

大约两千六百年前，一位旅行者来到埃及。他站在巨大的金字塔前，问了一个让当地祭司发愣的问题：这座塔有多高？

直接测量是不可能的。塔身是石头砌成的斜面，没有梯子能爬到尖顶，把绳子从塔顶垂下来也做不到——那时没有任何工具能够到一百多米高的顶点。旅行者没有爬塔，他只要了一根木杆、一段绳子和一个晴天。

他把木杆竖直插在地上，等阳光照下来。木杆在地上投下一段影子，金字塔也在沙地上投下一大片阴影。他量了三个数：木杆的高度，木杆影子的长度，以及金字塔影子的长度（从塔底边缘量到阴影的尖端，再加上塔底边长的一半，因为塔的中心才是塔顶正下方的点）。然后他用一个简单的比例算出了金字塔的高度，据说误差很小。

这位旅行者就是古希腊的泰勒斯。传说中祭司们大为惊讶，但请你先别急着佩服他。这个故事里藏着一个真正的数学问题，它是本章的起点。

3.2 为什么可以，为什么不可以

泰勒斯的做法为什么是对的？他的直觉大概是：同一时刻，太阳光以相同的角度斜射下来，所以“木杆和它的影子”组成的小三角形，与“金字塔和它的影子”组成的大三角形，是同一个形状的放大版。形状相同，对应边的比例就相同，于是

$$\frac{\text{金字塔高}}{\text{木杆高}} = \frac{\text{金字塔影长}}{\text{木杆影长}}.$$

四个量里知道三个，第四个就能算出来。比如木杆高 2 米，影长 3 米，金字塔影长（折算到塔中心）180 米，那么金字塔高就是 $2 \times 180 \div 3 = 120$ 米。

这个推理听起来很自然。但请停下来，像数学家那样多问一句：凭什么“形状相同”就能推出“对应边成比例”？这件事你量一百个三角形都会觉得对，可“量着对”和“一定对”之间隔着一条鸿沟。

先看一个容易上当的例子。画一个三角形，用量角器量它的三个内角，加起来是多少？多半不是正好 180° ，可能是 179° 或 181° 。再画一个，再量，还是差一点。你会说：这是量角器不准，理论上应该是 180° 。很好——可这个“理论上”是哪里来的？你没有量过世界上所有的三角形，连一亿个都没量过。就算量了一亿个都是 180° 附近，第一亿零一个呢？边长一光年的三角形呢？小得看不见的三角形呢？

这就是测量和证明的分工。测量非常了不起，它能帮我们发现规律、提出猜想，工程师靠它造出真的桥梁；但测量永远带着误差，而且永远只能检查有限个例子。几何里到处是“无限多个情形”的结论——“所有三角形的内角和都是 180° ”说的是每一个三角形，无论大小胖瘦。对付“所有”，尺子无能为力，只有推理能胜任。

这也解释了为什么古埃及人会测地、会建金字塔，却没有留下“定理”的概念，而古希腊人把几何变成了证明的学问。测量的知识告诉你“大概是什么”，证明的知识告诉你“为什么一定是”。本章的目标，就是带你走完从“大概”到“一定”的这条路。

3.3 从“看起来一样”到定义

要用推理代替测量，第一步是把日常语言里模糊的词汇变成精确的定义。“点”“线”“角”这些词你以为自己懂，但请试着给一个从不曾见过它们的人解释清楚，你会发现比想象中难。

古希腊人的办法有点出人意料：他们干脆承认最基本的概念无法被真正“定义”，只能被约定。点是没有大小的位置，线是没有宽度的长度，直线是可以向两端无限延伸的线。这些话不告诉你点“是什么”，而是告诉你点“遵守什么规则”。比如约定：过两个不同的点，有且只有一条直线；两点之间的所有连线中，线段最短。这些约定叫公理，它们是推理的起点，就像下棋前先要约定马走日、象走田。

有了点和线，就可以造出第一个真正的研究对象：把三条线段首尾相接、围成一个封闭图形，就得到三角形。三角形是几何世界的“原子”——任何多边形都可以切成三角形，所以弄懂三角形几乎等于弄懂了整个平面几何。

接下来是两个关键概念，它们都是把口语里的“一样”拆开的结果。

定义 3.1 (全等). 两个图形如果能够通过平移、旋转、翻折完全重合，就称它们**全等**。两个全等的三角形，对应边相等，对应角也相等。记作 $\triangle ABC \cong \triangle DEF$ 。

定义 3.2 (相似). 两个图形如果形状相同（大小可以不同），就称它们**相似**。两个三角形相似，当且仅当它们的对应角相等；此时对应边的长度成同一个比例，这个比例叫相似比。

全等是“完全重合”，相似是“同一个形状的不同缩放”。泰勒斯测金字塔，用的正是相似：木杆三角形和金字塔三角形相似，相似比就是影长之比。

术语卡片：全等

直观解释：一个模子里刻出来的，挪动、转动、翻面后还能严丝合缝地叠上。正式定义：经过平移、旋转、翻折后能完全重合的两个图形。例子：复印机印出的两份同样的三角形纸片，是全等的。

术语卡片：相似

直观解释：同一张照片的原图和放大图，形状没变，尺寸变了。正式定义：对应角都相等、对应边都成同一比例的两个图形。例子：地图上的三角形地块和真实的三角形地块是相似的，相似比就是地图比例尺。

定义解决了“什么叫一样”，但还没有解决“怎么判断一样”。把两个三角形叠在一起比较，往往做不到——金字塔你搬不动。好在数学家发现，判断两个三角形全等，不必六个量（三条边、三个角）全对，只要核对其中恰当的三个就够了：

- 三边对应相等（边边边）；
- 两边及其夹角对应相等（边角边）；
- 两角及其夹边对应相等（角边角）。


这些判定是有内容可证的，比如“边角边”的直觉是：固定两条边的长度和它们的夹角，第三条边就被唯一决定了，三角形没有变形的余地。相似也有对应的省力判定：只要两角对应相等，两个三角形就相似。因为三角形的内角和固定（这一点我们马上会证明），两角定了，第三个角也定了，形状就被锁死了。

反例警报

“两边和其中一边的对角对应相等，两个三角形就全等”——这个说法听起来和前几条判定差不多顺耳，但它是错的。固定边 AB 、边 AC 和角 B （注意角 B 不是 AB 与 AC 的夹角）时，点 C 必须在从 B 出发、与 BA 成定角的那条射线上，同时又要满足 AC 等于给定长度——也就是说，它是这条射线与“以 A 为圆心、给定长度为半径的圆弧”的交点。而圆弧可能与射线交出两个不同的点，于是得到一胖一瘦两个不同的三角形，它们满足同样的条件却不全等。这个陷阱提醒我们：判定定理里的每个字都不能随便挪动，“夹角”和“对角”一字之差，结论就塌了。顺便说，这也是“分类讨论”登场的自然场合：条件相同却可能对应两种图形，就必须分情形逐一检查。

在继续之前，我们先补上那个欠下的证明，它同时是本章第一个重要的证明技术——辅助线——的范例。

定理 3.3 (三角形内角和). 任意三角形的三个内角之和等于 180° 。



证明. 设三角形为 $\triangle ABC$ 。过顶点 A 作一条与边 BC 平行的直线 ℓ （即图中的虚线）。这条线不在原图里，是我们为了推理加进去的，所以叫辅助线。

边 AB 同时穿过两条平行线 ℓ 与 BC ，于是 ℓ 在 A 点左侧与 AB 形成的角 β 等于角 B （内错角相等）；同理， ℓ 在 A 点右侧与 AC 形成的角 γ 等于角 C 。而在点 A 处， β 、角 A 本身（图中的 α ）与 γ 恰好拼成一个平角，也就是 180° 。所以

$$\angle A + \angle B + \angle C = 180^\circ.$$

注意这个论证没有量任何一个角，它对每一个三角形都成立，无论边长多少。□

这个证明里最值得品味的动作是“作一条平行线”。图上本来没有它，是我们请来帮忙的客人。客人一到，角 B 和角 C 就被“搬”到了点 A 旁边，三个角肩并肩站成一条直线，结论自己走了出来。辅助线是几何证明里最有创造性的部分：没有固定套路，靠的是对图形的理解和一点点运气。后面你还会看到它更多的表演。

3.4 一条定理，两种理由


现在轮到本章的主角登场。直角三角形是三角形里最特别的一类：有一个角恰好是 90° 。夹直角的两条边叫直角边，直角对着的最长边叫斜边。关于它有一条也许是全世界最著名的定理。

定理 3.4 (勾股定理). 直角三角形两条直角边的平方和，等于斜边的平方。若直角边长为 a 、 b ，斜边长为 c ，则

$$a^2 + b^2 = c^2.$$

先看几个数。3、4、5： $9 + 16 = 25$ ，对。5、12、13： $25 + 144 = 169$ ，对。古埃及人拉绳子定直角时用的就是 3、4、5：把一根绳子打上等距的十二个结，围成三边为 3、4、5 段的三角形，最大的角就是直角。但同样的问题又来了：验证一万组数，不等于证明了定理。下面给出两种完全不同的证明——同一个结论，两种不同的理由。这本身就是一个重要的数学事实：定理是被结论保证的，不是被某一种证法垄断的；多一种证法，就多一种理解。

证法一：拼一拼面积。



证明. 取四个全等的直角三角形，直角边为 a 、 b ，斜边为 c 。把它们摆进一个边长为 $a+b$ 的大正方形里：每个三角形占据一个角，斜边朝内。四个斜边围出中间一个四边形。

先确认中间这块确实是正方形。它的四条边都是 c ，只需再看一个角：在大正方形底边的拼接点处，一个三角形的锐角 α 、另一个三角形的锐角 β 与中间四边形的角拼成平角 180° ，而 $\alpha + \beta = 90^\circ$

(它们是同一个直角三角形的两个锐角)，所以中间那个角是 90° 。四边相等且有一个直角的菱形是正方形，面积为 c^2 。

现在用两种方法算同一个大正方形的面积。直接算： $(a+b)^2$ 。拆开算：四个三角形加中间正方形，每个三角形面积为 $\frac{1}{2}ab$ ，所以

$$(a+b)^2 = 4 \times \frac{1}{2}ab + c^2 = 2ab + c^2.$$

把左边展开： $a^2 + 2ab + b^2 = 2ab + c^2$ ，两边同时减去 $2ab$ ，得到 $a^2 + b^2 = c^2$ 。□

这个证明的灵魂是什么？是**面积在剪开和重新拼合中不变**。图形的形状变了，面积没有变——面积是剪拼操作下的“不变量”。抓住一个在变化中保持不变的量，常常是证明的钥匙，这个思想以后会反复出现。

证法二：用相似。

证明. 设直角三角形为 $\triangle ABC$ ，直角在 C ，斜边为 AB 。从 C 向斜边 AB 作垂线，垂足为 D ——又是一条辅助线。这条垂线把原三角形劈成两个小三角形： $\triangle ACD$ 与 $\triangle CBD$ 。

比较 $\triangle ACD$ 和原来的 $\triangle ABC$ ：它们共用角 A ，又各有一个直角（角 ADC 与角 ACB ），两角对应相等，所以相似。同理 $\triangle CBD$ 也与 $\triangle ABC$ 相似。写下对应边的比例。设 $AB = c$ ， $AC = b$ ， $BC = a$ ， AD 记为 x ， BD 记为 y ，注意 $x + y = c$ 。由 $\triangle ACD \sim \triangle ABC$ （斜边对斜边，直角边 AC 对直角边 AD ）得

$$\frac{AC}{AB} = \frac{AD}{AC}, \quad \text{即 } b^2 = cx.$$

由 $\triangle CBD \sim \triangle ABC$ 同理得 $a^2 = cy$ 。两式相加：

$$a^2 + b^2 = cx + cy = c(x + y) = c^2.$$

这里我们用到了“相似三角形对应边成比例”这条基本性质；它的严格证明需要更多准备，本章先把它当作约定的工具，就像下棋时先约定规则。□

请比较两种理由的“口味”。证法一把定理讲成面积的故事： a^2 、 b^2 、 c^2 不再是抽象的平方，而是三块实实在在的、可以剪下来称重的正方形面积，勾股定理说的是“两块小正方形恰好能拼成斜边上的大正方形”。证法二把定理讲成形状的故事：直角三角形里藏着它自己的两个缩小版，自相似的结构迫使等式成立。两个证明都没有量任何长度，都对每一个直角三角形成立。

顺带一提，这个定理的证明可能有几百种：有靠梯形面积的，有靠圆的，还有纯代数配方和弦图的另一摆法（见思考题）。数学家们至今仍偶尔发表新的证明——不是因为旧证明不可靠，而是因为每种新理由都可能照亮定理的一个新侧面，并在别处派上用场。

3.5 不变量、分类讨论和圆

勾股定理的两个证明用了两件通用武器：不变量和辅助线。这一节把第三件武器也摆上桌面，然后让它们一起到圆那里去干活。

分类讨论的意思很朴素：当一个命题的条件可能对应几种不同情形时，把情形分干净，每种分别解决。前面“边边角”的反例里，一段圆弧和一条射线可能交出零个、一个或两个点，三种情形给出“不存在、唯一、两解”三种命运——不分类，就说不清。再比如判断三条线段能否围成三角形，只需用到下面这条从“两点之间线段最短”直接推来的**事实**。

推论 3.5 (三角形不等式). 三角形任意两边之和大于第三边。反过来，三条线段中若两条较短者之和大于最长者，它们就能围成一个三角形。

注意这个推论自带分类思想：不用把三对边全查一遍，只查“最短两条加起来是否超过最长那条”这一种关键情形就够了。

不变量则是反过来问：图形在动，什么东西不动？剪拼时面积不动；放大缩小时角度不动、形状不动（这正是相似的全部内容）；而圆给了我们一个更漂亮的例子。

把圆定义为“到一个定点（圆心）距离等于定长（半径 r ）的所有点”，然后看它的周长。拿绳子量几个圆：硬币、杯口、圆桌，你会发现周长除以直径总是大约 3.14。这又是测量带来的猜想。它为什么一定成立？因为任意两个圆都相似——把一个圆以任意点为中心放大，它还是一个圆。相似图形对应长度的比是固定的，于是“周长与直径之比”对所有圆都是同一个数。这个数就是 π 。它是一个无理数，小数部分永远写不完，3.14 或 3.14159 都只是近似值。古人为了逼近它想出了绝妙的办法：在圆内作内接正多边形，边数越多，多边形周长越接近圆周。用正 96 边形上下夹逼，可以把 π 夹在 3.1410 与 3.1427 之间——这是阿基米德时代的成就，也是用有限逼近无限的第一次胜利，第十一章讲极限时我们还会回到这个画面。

术语卡片：不变量

直观解释：大家都在变，它偏不变，所以它能当“标尺”和“证人”。正式定义：在某种操作或变换下保持不变的量或性质。例子：剪纸重拼时面积不变，所以可以用“两种摆法算同一面积”来证明勾股定理。

面积本身也值得一个定义。严格定义面积并不容易（第十二章的积分才会真正对付它），但在初中阶段我们可以约定：边长为 1 的正方形面积为 1，面积在剪拼下可加、不变。由此推出矩形面积是长乘宽，平行四边形面积是底乘高（剪下一个直角三角形挪到另一边就拼成矩形），三角形面积是底乘高的一半（两个全等三角形拼成平行四边形），圆面积是 πr^2 （把圆切成很多小扇形交错拼成近似的矩形，长为半周长 πr 、宽为 r ——这又是逼近思想的预演）。每一条公式背后都站着一剪一拼，而不是一次测量。

数学工具箱

本章添置的新工具：

- **公理与定义**：推理的起点不是“是什么”，而是“遵守什么规则”；先把“一样”拆成全等与相似。
- **全等、相似判定**：不必叠在一起比较，核对恰当的两三个条件即可锁定形状。
- **辅助线**：图上没有的线可以请来帮忙，平行线负责搬角，垂线负责制造直角与相似。
- **分类讨论**：条件对应多种情形时，分干净、逐个击破；边边角的陷阱就是漏分类的下场。
- **不变量**：剪拼中的面积、缩放中的角度、所有圆共享的 π ——抓住不变的量，变化就有了把柄。
- **测量与证明的分工**：测量负责发现猜想、提供例证，证明负责为“所有情形”签字画押。

3.6 换一种眼光：三角测量与星空

几何学最壮观的应用，恰恰建立在它最抽象的结论上。古希腊人想知道月亮有多远、太阳有多远，他们手里没有火箭，只有相似三角形和角度。

思路今天还在用，叫三角测量：要测一个到不了的点 C ，先在选好的两个点 A 、 B 量出基线长度 AB ，再分别量出视线 AC 、 BC 与基线的夹角。三角形 $\triangle ABC$ 被“两角夹一边”完全锁定，虽然 C 远在天边，它的形状却是确定的。画一个按比例缩小的副本，或者用相似与比例计算， AC 、 BC 就出来了。测量员测河对岸的塔、测绘队画全国地图、天文学家用地面上两个观测站对准月球，用的都是同一招。到了更晚的时代，人们还试着用地球本身当基线去量行星的距离。

注意这个应用的前提：我们相信“两角夹一边唯一决定三角形”“相似三角形对应边成比例”这些命题对地面上、月球那么大的三角形同样成立。如果这些命题只是“量过很多小三角形都对”的经验，把结论外推到天文尺度就是一场豪赌；正因为它们是定理，工程师和天文学家才敢把身家性命押上去。这就是证明的实用价值——它不是书斋里的洁癖，而是让知识可以放大到任何尺度的许可证。

连接线

回头看：第 1 章的字母和比例，在本章变成了相似比与面积公式；第 2 章的方程，让我们能从 $a^2 + b^2 = c^2$ 里解出未知边。往前看：本章始终在一个没有名字的平面上画图，点只有位置、没有“地址”。下一章我们将给每个点发一张写着两个数的身份证——坐标。到那时，直线、圆都会变成方程，几何题可以用代数算，代数式也可以画出形状。你即将看到本章的定理（尤其是勾股定理）变成坐标世界里最忙的公式：距离公式。

3.7 动手做一做

一分钟实验

实验一：绳结直角。找一根软绳，用记号笔打上 12 个等距的结。把绳子围成三边分别为 3、4、5 段间隔的三角形，拉紧，用三角板的直角去比最大的那个角。再试试 5、12、13 段（需要 30 个间隔）。想一想：你为什么相信拉紧后得到的是直角——这是测量结论还是定理结论？

实验二：剪纸证勾股。在方格纸上画一个直角边为 3 格、4 格的直角三角形，再复印三份（或照画三个全等的）。按本章证法一的摆法，把四个三角形摆进一个 7×7 的方格里，数一数中间空出的正方形占几格。 $49 - 4 \times 6 = 25$ ，正好是 5×5 。再换一组直角边（比如 2 格、5 格）重做一遍，验证中间面积是否为 $2^2 + 5^2 = 29$ 格。

实验三：逼近 π 。用圆规画一个半径 5 厘米的圆，用直尺在圆内依次作内接正六边形、正十二边形（把每条弧用中点劈开），量出多边形周长，除以直径 10 厘米，记录结果如何向 3.14 靠近。注意：无论你量得多仔细，这一步永远只是测量； π 的精确性质要靠推理。

思考题

观察题

1. 画三个形状差别很大的三角形（一个瘦高、一个扁宽、一个接近等边），量各自的三个内角并

求和，把每次的偏差记下来。偏差有正有负还是总朝一边？提示：想想量角器的最小刻度和你的读数习惯，误差从哪里来。

2. 同一根竖直旗杆，在一天的不同时刻量它的影长，算一算“杆高除以影长”是否变化。提示：什么时候这个比值相同？什么在变化、什么是不变量？

证明题

1. 弦图还有另一种摆法：把四个全等的直角三角形（直角边 a 、 b ， $a < b$ ）摆进一个边长为 c 的大正方形里，使斜边贴着大正方形的四条边，中间空出一个小正方形。提示：中间小正方形的边长是 $b - a$ ，用两种方法算大正方形面积。
2. 证明：等腰三角形的两个底角相等。提示：作顶角的平分线（或底边上的高），把三角形分成两块，用全等判定说明两块全等。

挑战题

1. 证明：圆内接三角形中，若一条边是直径，则这条边所对的角是直角。提示：连接圆心与这个角的顶点，圆被分成两个等腰三角形，给四个底角起两个名字，再用内角和。
2. 两千多年前，有人利用“夏至正午，某城太阳光直射井底（影长为零），同一时刻北方另一城的杆影偏角约为圆周的五分之一，而两城距离已知”算出了地球的周长。提示：把太阳光当作平行线，两座城和地心构成什么图形？杆影的偏角等于哪个圆心角？你需要哪些假设，其中哪一条只是近似成立？

继续攀登

本章的图景在两千多年前被系统地整理进一部叫《几何原本》的书里：从五条公理出发，推出几百条定理，这种“公理化”的写法至今仍是数学的硬通货。继续向前，你会遇到这些关键词：欧几里得第五公设（平行公理）与非欧几何——换掉它，三角形内角和就不再是 180° ；射影几何——研究透视与影子本身的学问；三角学——把相似三角形浓缩成正弦、余弦两张函数表；解析几何——下一章的起点，用方程驯服曲线；以及现代的几何证明自动化与计算机辅助证明，机器也能当几何学家。

通往下一章的门

这一章我们学会了在一张白纸上证明事情：作辅助线、找全等、用相似、抓不变量。但你可能注意到了一个隐隐的不便——纸上的点没有名字。我们说“斜边上的垂足”，说“圆心右侧三厘米处”，全靠手势和形容词。如果一个几何问题里有一百个点、二十条曲线呢？如果你想让一台没有眼睛的计算机帮你画图、验证猜想呢？它听不懂“左边那个点”，它只认数。

于是有一个朴素到近乎幼稚的问题浮上来：能不能给平面上的每一个点起一个由数字组成的名字？一旦做到，“两点之间的距离”会变成一道算术题，“直线”和“圆”会变成方程，本章所有的定理将拥有一种新的语言。下一章，我们就去建这座桥——从勾股定理出发，给平面装上坐标。

第四章 坐标桥梁：把代数和几何接在一起

前三章里，我们其实一直住在两个分开的世界里。代数的世界里住着数、字母、方程和函数，它关心的是“关系”：谁和谁相等，谁随谁变化。几何的世界里住着点、线、角、三角形和圆，它关心的是“形状”：谁和谁全等，谁比谁长，谁和谁平行。这两个世界各自都很精彩，但它们之间隔着一道河——代数式子看不出形状，几何图形没法直接计算。

这一章要造的，就是跨过这条河的桥。桥的名字叫坐标。桥造好以后你会发现：一个方程可以“变成”一条曲线，一条曲线也可以“变成”一个方程；一道几何题可以搬去代数那边算，一道代数题也可以搬来几何这边看。数学家给这套办法起了一个正式的名字：解析几何。但在记住这个名字之前，我们先从一场争吵说起。

4.1 海战棋上的争吵

有一种在方格纸上玩的游戏，常叫“海战棋”：两个人各自在自己的方格纸上画几艘“军舰”——其实就是几个连在一起的小方格，然后轮流报位置猜对方的船藏在哪里，猜中了就算“击中”。

小明和小红正在玩。小明报：“第三行第五列！”小红看了一眼自己的纸，说：“没中。”小明急了：“不可能，你的船明明就在那里！”两个人把两张纸摆到一起一对，才发现出问题出在哪：小明数行是从上往下数的，小红数行是从下往上数的；小明说的“第三行”，在小红那里其实是倒数第三行。两个人说的根本不是同一个格子，争吵当然没完没了。

这场争吵的根子，是一个比游戏大得多的问题：**怎样准确地说出“一个位置”**？生活里到处都要回答这个问题。电影院门票上印着“7 排 12 号”，你拿着它就能走到唯一的那个座位；手机地图上的外卖小哥显示成一个移动的小点，系统靠一组数字随时知道他在哪；地球仪上画着经线和纬线，北京大约在东经 116 度、北纬 40 度的交叉处。你会发现这些办法有一个共同点：都不用“在那边”“靠左边一点”这种模糊的话，而是用一组数，把位置钉死。

海战棋用的是方格，电影票用的是排和号，地球仪用的是经度和纬度——它们都是本章主角的亲戚。而我们要把事情做得更彻底：不只给方格编号，还要给平面上**每一个点**都发一张独一无二的“数字地址”。

4.2 一个卡住人的问题

先别急着发明工具，先来感受一下这个问题为什么不好办。

想象学校的操场上立着一根旗杆，你在操场上随便站了一个位置，要把这个位置准确地告诉一个看不见你的朋友。第一种说法：“我在旗杆东边。”不行，旗杆东边有一大片地方，朋友还是找不到你。第二种说法：“我在旗杆东边挺远的地方，再靠北一点。”“挺远”是多远？“一点”是多少？

这种话在生活里凑合能用，在数学里完全不合格——两个人对“挺远”的理解可以差出几十米。

那就上工具，用卷尺量。第三种说法：“我离旗杆正好 5 米。”这次够精确了，可还是不够：到旗杆距离为 5 米的点不是一个，而是整整一圈——以旗杆为圆心、5 米为半径的圆上，每个点都符合。朋友收到这个信息，面对的是无穷多个候选位置。

“那我再加一个条件：我离旗杆 5 米，离操场角落的球门 8 米。”这回好多了，两个圆一画，交点最多只有两个。但“最多两个”的意思是有时候恰好两个：你还是得补一句“我在偏北的那个交点上”，才能最终说清楚。转了一大圈，我们又回到了“偏北”这种模糊的话上。

用距离描述位置，似乎总会留下一点尾巴。数学家们想要的，是一种干净利落的约定：**每个位置对应唯一的一组数，每组数也对应唯一的位置**，谁也不多，谁也不少。这个约定不是天上掉下来的，是人们被上面这类问题卡得够久之后，才一步步发明出来的。发明的第一步，得先从一条线开始。

4.3 一条直线装下所有的数

你可能早就见过数轴，但我们重新把它发明一遍，看看它到底解决了什么麻烦。

温度计就是一根竖起来的数轴：玻璃管上刻着一个 0，往上是零上，往下是零下，每一格代表一度。电梯的按钮面板也是数轴的亲戚：地下 2 层记作 -2 ，地面上的 1 层、2 层往上排。人们从这些经验里提炼出一个办法：画一条水平的直线，在上面选定一个点叫**原点**，它代表数 0；规定向右为**正方向**；再选定一段长度作为**单位长度**，从原点向右依次标出 $1, 2, 3, \dots$ ，向左依次标出 $-1, -2, -3, \dots$ 。分数和小数也有家： $\frac{1}{2}$ 住在 0 和 1 的正中间， -1.5 住在 -1 和 -2 的正中间。

术语卡片：数轴

直观解释：一条标好刻度的直线，让每个数都有一个确定的“座位”。

正式定义：规定了原点、正方向和单位长度的直线，叫做数轴。

一个例子：数轴上表示 -2 的点在原点左边两个单位处；表示 3.5 的点在原点右边三个半单位处。

数轴最重要的地方，不是它能标出几个整数，而是它建立了一种**一一对应**：每一个实数都对应数轴上唯一的一个点，数轴上每一个点也对应唯一的一个实数。不多不少，不重不漏。从此“数”和“点”成了同一件东西的两种说法——这就是第一座小桥，虽然它只有一维。

有了数轴，一维世界里的距离问题立刻变得好算。数轴上两个点分别表示数 a 和数 b ，它们之间的距离就是 $|b - a|$ 。为什么要套一个绝对值？因为距离不问方向。从 -2 到 5 ，往右数过去是 7 个单位；从 5 到 -2 ，往左数回来还是 7 个单位。 $5 - (-2) = 7$ ， $(-2) - 5 = -7$ ，差的符号取决于你从哪头数起，但距离只有一种，所以取绝对值，把方向的信息扔掉，只留下大小。这个“坐标之差取绝对值”的小公式，待会儿会在平面里长成一个更有名的公式。

4.4 给平面上的每个点发一张地址

一维的线搞定了，二维的面呢？答案朴素得惊人：一条数轴不够，就用两条。

关于这个办法的诞生，流传着一个故事：法国数学家笛卡尔生病躺在床上，盯着天花板上一只爬来爬去的苍蝇，忽然想到——只要记下苍蝇到两面墙的距离，就能说出它在天花板上的任何

位置。这个故事多半经过后人加工，当不得信史，但它把那个关键的想法讲得很传神：**平面上的位置，用两个数就够了。**

把两条数轴垂直地放在一起，让它们的原点重合：一条横着，叫**横轴**（常叫 x 轴），向右为正；一条竖着，叫**纵轴**（常叫 y 轴），向上为正。这样得到的东西，叫做**平面直角坐标系**。现在，平面上随便点一个点 P ，从它向横轴作垂线，垂足在横轴上对应的数是 3；再向纵轴作垂线，垂足在纵轴上对应的数是 2。我们就说点 P 的**坐标**是 $(3, 2)$ ，其中 3 叫横坐标，2 叫纵坐标。反过来，随便给一对数 $(3, 2)$ ，在横轴上找到 3、竖直向上走，在纵轴上找到 2、水平横着走，两条路线交于唯一的一点。点和数对之间，又是一一对应。

术语卡片：坐标

直观解释：平面上每个点的“数字地址”，由一对按顺序排列的数组成。

正式定义：在平面直角坐标系中，点 P 向两条坐标轴作垂线，垂足对应的数 x 、 y 依次组成的有序数对 (x, y) ，叫做点 P 的坐标。

一个例子：电影票上“7 排 12 号”和“12 排 7 号”是两个不同的座位；同样，点 $(7, 12)$ 和点 $(12, 7)$ 是平面上两个不同的点——数对的顺序不能乱。

两条坐标轴把平面分成了四块，右上角那块横纵坐标都是正的，叫**第一象限**，然后逆时针依次是第二、第三、第四象限。坐标轴上的点不属于任何象限，它们是“边界”。这些名字不用死记，画两次图就熟了。

请注意我们刚才做成了一件什么事。点，是几何世界里最小的居民；有序数对，是代数世界里最普通的居民。坐标系让这两者严格地一一对应起来。这不是“举几个例子很像”，而是一种彻底的翻译机制：从这一刻起，关于点的任何陈述，原则上都能翻译成关于数的陈述，反之亦然。桥的两端已经对准了河的两岸，接下来要做的，是往桥上搬运第一批货物。

4.5 距离公式：把勾股定理搬上坐标纸

第一批要搬的货物，是几何里最常用的量：距离。

第 3 章里我们学过勾股定理：直角三角形两条直角边的平方和等于斜边的平方。那是一个纯粹的几何结论，讲的是图形。现在有了坐标，点变成了数对，我们问：已知 A 的坐标是 $(1, 2)$ ， B 的坐标是 $(4, 6)$ ， A 、 B 两点相距多远？

光盯着两个数对看，是看不出距离的。诀窍是补出一个直角三角形：过 A 画一条水平线，过 B 画一条竖直线，它们交于一点 C ，坐标是 $(4, 2)$ ——和 A 一样高，和 B 一样靠右。现在看三角形 ACB ：角 C 是直角； AC 是水平线段，长 $4 - 1 = 3$ ； BC 是竖直线段，长 $6 - 2 = 4$ 。勾股定理一用：

$$AB = \sqrt{AC^2 + BC^2} = \sqrt{3^2 + 4^2} = \sqrt{9 + 16} = \sqrt{25} = 5.$$

距离是 5。整个过程中我们只做了一件事：把坐标之差分别变成两条直角边，再请勾股定理发话。把具体的数换成字母，同样的推理对任何两个点都成立。

定理 4.1 (两点间的距离公式). 平面直角坐标系中，点 $A(x_1, y_1)$ 与点 $B(x_2, y_2)$ 之间的距离为

$$AB = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}.$$


证明. 分两种情形。

情形一： $x_1 \neq x_2$ 且 $y_1 \neq y_2$ 。取点 $C(x_2, y_1)$ ，它与 A 有相同的纵坐标，与 B 有相同的横坐标。于是线段 AC 水平，线段 BC 竖直，二者垂直，三角形 ACB 是以 C 为直角顶点的直角三角形。由数轴上的距离结论， $AC = |x_2 - x_1|$ ， $BC = |y_2 - y_1|$ 。对直角三角形 ACB 应用勾股定理：

$$AB = \sqrt{AC^2 + BC^2} = \sqrt{|x_2 - x_1|^2 + |y_2 - y_1|^2} = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2},$$

最后一步是因为任何数的平方与它的绝对值的平方相等，绝对值号可以去掉。

情形二： $x_1 = x_2$ 或 $y_1 = y_2$ 。此时 A 、 B 在同一条竖直线或水平线上，两点距离就是坐标之差的绝对值；而此时公式中有一项是 0，公式正好退化成一个结果。两种情形合并，结论成立。□



这个公式值得多看两眼。左边 AB 是几何对象——一段线段的长度；右边是代数对象——一堆坐标的四则运算和开方。一个公式，两种语言，这就是坐标桥梁通车的第一辆车。

反例警报

“ A 在 $(1, 2)$ ， B 在 $(4, 6)$ ，横向差 3，纵向差 4，所以距离是 $3 + 4 = 7$ 。”——错。 $3 + 4$ 算出来的是“先水平走、再竖直走”的折线长度，像出租车沿着方格马路绕路走的里程；而两点间的距离指直线段的长度，是斜着抄近路的那一条。勾股定理告诉我们斜边是 $\sqrt{3^2 + 4^2} = 5$ ，恰好比 7 小，这与“两点之间线段最短”完全一致。把坐标差直接相加，是把马路里程当成了直线距离。

距离公式还有一个好用的副产品。线段 AB 的中点 M 该是什么坐标？直觉是“各取一半的平均”，这个直觉是对的：

推论 4.2 (中点公式). 点 $A(x_1, y_1)$ 与点 $B(x_2, y_2)$ 连线的中点 M 的坐标为

$$M\left(\frac{x_1 + x_2}{2}, \frac{y_1 + y_2}{2}\right).$$

道理可以这样想：从 A 走到 B ，横坐标一共变化 $x_2 - x_1$ ，走到一半就是变化一半，所以中点横坐标是 $x_1 + \frac{x_2 - x_1}{2} = \frac{x_1 + x_2}{2}$ ；纵坐标同理。严格的证明可以把 M 的坐标代入距离公式，验证 $AM = MB = \frac{1}{2}AB$ 即可，留给你动手。比如 $A(1, 2)$ 、 $B(4, 6)$ 的中点是 $(\frac{5}{2}, 4)$ ，也就是 $(2.5, 4)$ ，看图上的位置，确实在线段正中间。

4.6 方程是形状的身份证

到目前为止，我们是“先有图形，后算坐标”。现在把方向调过来，问一个更好玩的问题：**给平面上所有的点立一个规矩，守规矩的点会组成什么图形？**

比如这条规矩：“到原点的距离等于 3。”凭几何直觉，你大概已经喊出答案了：一个圆！圆的定义本来就是这样。但我们假装不知道，用坐标把这件事重新走一遍。设守规矩的点坐标是 (x, y) ，它到原点 $(0, 0)$ 的距离由距离公式给出，规矩翻译成代数语言就是：

$$\sqrt{x^2 + y^2} = 3, \quad \text{两边平方得} \quad x^2 + y^2 = 9.$$


于是一个几何条件（到某点距离固定）变成了一个代数方程 $(x^2 + y^2 = 9)$ 。这个方程像一个筛子：点 $(3, 0)$ 的坐标代进去， $9 + 0 = 9$ ，成立，它在圆上；点 $(1, 2)$ 代进去， $1 + 4 = 5 \neq 9$ ，它不在圆上；点 $(\sqrt{5}, 2)$ 代进去， $5 + 4 = 9$ ，它在圆上。平面上亿万个点，每个点要么通过筛子、要么被筛掉，而通过筛子的点连起来，正好是以原点为圆心、3 为半径的圆，一个不多，一个不少。

定义 4.3 (曲线的方程与轨迹). 如果一个方程 $F(x, y) = 0$ 与一条曲线满足两方面的对应：曲线上每个点的坐标都满足方程，坐标满足方程的每个点都在曲线上，那么这个方程叫做这条曲线的方程，这条曲线叫做这个方程的图形（轨迹）。

“轨迹”这个词很形象：一个守规矩的点在平面上跑动，它跑过的痕迹就是轨迹。规矩用代数写出来是方程，痕迹用几何画出来是曲线。请看下面这张“对照表”：

代数一侧：方程	几何一侧：图形
$y = 2x - 1$	一条直线（斜率 2，过点 $(0, -1)$ ）
$x^2 + y^2 = 9$	以原点为圆心、3 为半径的圆
$y = x^2$	开口向上的抛物线，顶点在原点

直线的那一行你在第 2 章已经见过：一次函数 $y = kx + b$ 的图像是一条直线。现在你知道这件事的新说法了：二元一次方程 $y = kx + b$ 的轨迹是直线。抛物线那一行也值得亲手验证：取 $x = 0, \pm 1, \pm 2$ 算出 $y = 0, 1, 1, 4, 4$ ，在坐标纸上描出这五个点，用光滑的曲线连起来，就是那条著名的碗形曲线。



例 4.4. 判断点 $P(2, \sqrt{5})$ 是否在圆 $x^2 + y^2 = 9$ 上，并说明它在圆内还是圆外。

把坐标代入方程左边： $2^2 + (\sqrt{5})^2 = 4 + 5 = 9$ ，恰好等于右边，所以 P 在圆上。再看点 $Q(1, 1)$ ： $1^2 + 1^2 = 2 < 9$ ，它到原点的距离是 $\sqrt{2}$ ，小于半径 3，所以在圆内。一般地， $x^2 + y^2 < 9$ 的点在圆内，大于 9 的在圆外——一个等式分出曲线，两个不等式分出曲线的两侧，全是距离公式在背后工作。

一分钟实验

拿一张坐标纸（或自己画格子的白纸），标出两个点 $A(0, 0)$ 和 $B(4, 0)$ 。现在寻找“到 A 、 B 距离相等”的点：先用尺子量着找，比如 $(2, 0)$ 显然算一个； $(2, 1)$ 到两点的距离都是 $\sqrt{5}$ ，也算； $(2, 3)$ 、 $(2, -2)$ 呢？多描几个这样的点，看看它们排成了什么——一条竖直的直线，正是线段 AB 的垂直平分线。再用代数验证一遍：设 (x, y) 到 A 、 B 距离相等，则 $\sqrt{x^2 + y^2} = \sqrt{(x-4)^2 + y^2}$ ，两边平方化简， $x^2 = (x-4)^2$ ，展开得 $8x = 16$ ，即 $x = 2$ 。几何里需要作图才能找到的垂直平分线，代数里化简两行就出现了。

4.7 翻译演示之一：用代数做几何题

桥是双向的，我们先走“几何到代数”这个方向。选一道经典的几何题：

题目（三角形中位线定理）：连接三角形两边中点的线段，平行于第三边，并且长度等于第三边的一半。

第 3 章里，这类题的标准打法是作辅助线、凑全等三角形——需要一点灵感，而灵感这东西不是每次都准时到场。坐标法提供的则是另一种性格的路线：不需要灵感，只需要耐心。我们把这个定理用坐标完整证一遍。

设三角形的三个顶点为 $A(x_1, y_1)$ 、 $B(x_2, y_2)$ 、 $C(x_3, y_3)$ 。注意这里故意不用具体数字，因为定理对**所有**三角形成立，字母正好代表“任意”。

第一步，翻译已知。设 M 是 AB 的中点， N 是 AC 的中点。由中点公式：

$$M\left(\frac{x_1 + x_2}{2}, \frac{y_1 + y_2}{2}\right), \quad N\left(\frac{x_1 + x_3}{2}, \frac{y_1 + y_3}{2}\right).$$

第二步，翻译结论之“一半”。用距离公式算 MN 。横坐标之差为

$$\frac{x_1 + x_3}{2} - \frac{x_1 + x_2}{2} = \frac{x_3 - x_2}{2},$$

纵坐标之差同理为 $\frac{y_3 - y_2}{2}$ 。于是

$$MN = \sqrt{\left(\frac{x_3 - x_2}{2}\right)^2 + \left(\frac{y_3 - y_2}{2}\right)^2} = \frac{1}{2} \sqrt{(x_3 - x_2)^2 + (y_3 - y_2)^2} = \frac{1}{2} BC.$$

“长度等于第三边的一半”证完了。注意每一步都只是通分、提公因数 $\frac{1}{2}$ 、套距离公式，没有任何一步需要灵感。

第三步，翻译结论之“平行”。两条线段平行，在坐标里是什么意思？看方向：从 M 到 N ，横坐标变化 $\frac{x_3 - x_2}{2}$ ，纵坐标变化 $\frac{y_3 - y_2}{2}$ ；从 B 到 C ，横坐标变化 $x_3 - x_2$ ，纵坐标变化 $y_3 - y_2$ 。前者的每一个变化量恰好都是后者的一半——两段路“横纵步伐的比例”完全一样，所以方向相同， MN 与 BC 平行。（如果 $x_3 = x_2$ ，则两个横坐标变化都是 0，两条线段都是竖直的，依然平行。）定理证毕。

回头品味一下这种解法。几何证法像一位侦探，要灵光一闪找到那条辅助线；坐标证法像一台碾米机，把图形碾成坐标，把结论碾成等式，然后按部就班地碾下去，出口处就是证明。碾米机不浪漫，但它从不旷工。而且坐标法有一个几何法比不了的好处：**它能批量处理**。同样的套路，换成“三条中线交于一点”“对角线互相平分”等一大批定理，几乎原样照搬，全都碾得出来。这正是代数“一次解决一整类问题”的精神，借坐标桥开进了几何的地盘。

4.8 翻译演示之二：用几何解代数题

反方向的车也发一班。看一道让代数方法皱眉头的题：

题目：当 x 取什么值时，式子

$$f(x) = \sqrt{x^2 + 9} + \sqrt{(6 - x)^2 + 16}$$

取得最小值？最小值是多少？

纯代数地看，这题相当棘手：两个根号套着平方，配方配不干净，平方又越弄越复杂。初中生手里的代数工具对它基本无效。但如果你刚走完上一节，应该会冒出一个念头：这两个根号，长得太像距离公式了。

$\sqrt{x^2 + 9} = \sqrt{(x - 0)^2 + (0 - 3)^2}$ ，这是点 $(x, 0)$ 到点 $(0, 3)$ 的距离。 $\sqrt{(6 - x)^2 + 16} = \sqrt{(x - 6)^2 + (0 - (-4))^2}$ ，这是点 $(x, 0)$ 到点 $(6, -4)$ 的距离。于是整个式子在说：在 x 轴上取一点 $P(x, 0)$ ，它到 $A(0, 3)$ 和 $B(6, -4)$ 的距离之和是 $PA + PB$ 。题目变成了——

翻译后的几何题： x 轴上有一动点 P ， A 在轴上方， B 在轴下方，求 $PA + PB$ 的最小值。

这道题几何上几乎是白给的：两点之间，线段最短。 A 、 B 分居 x 轴两侧，连接 A 、 B 的线段必然穿过 x 轴，交点就是我们找的 P 。此时 $PA + PB$ 正好等于 AB ； P 挪到任何别的位置， $PA + PB$ 都是一条折线，必然更长。所以最小值就是

$$AB = \sqrt{(6 - 0)^2 + (-4 - 3)^2} = \sqrt{36 + 49} = \sqrt{85}.$$

$\sqrt{85}$ 约等于 9.22。如果想把 x 也求出来：直线 AB 从 $(0, 3)$ 走到 $(6, -4)$ ，横向每走 6 格、纵向下落 7 格，走到 x 轴上意味着纵坐标从 3 降到 0，占总下降量的 $\frac{3}{7}$ ，所以横向也走了总量的 $\frac{3}{7}$ ， $x = 6 \times \frac{3}{7} = \frac{18}{7}$ 。你可以把 $x = \frac{18}{7}$ 代回原来的式子验算，两个根号加起来正好是 $\sqrt{85}$ 。

请停下来感受一下刚才发生了什么。我们没有把那个代数式算出来——我们只是认出它的几何化身，然后引用了一条三岁小孩都能理解的原理：直线比折线短。代数里面目狰狞的最小值问题，几何里是一个一目了然的事实。这就是翻译的第二种用法：当一种语言里说不清楚时，换到另一种语言里，难题可能自己会亮出底牌。

连接线

这种“翻译”不是书斋里的游戏。导航软件每时每刻都在做本章的演示：卫星告诉它你的经纬度（坐标），它把街道变成平面上的线，把“怎么走最近”变成距离与折线的问题。电脑游戏里的角色沿着抛物线跳跃，那是程序在反复计算 $y = x^2$ 一类的方程；医生看的 CT 图像，本质是机器把人体切面上每个点的“密度数对”重建成了图形。往后看，第 2 章的函数图像是“方程变曲线”的第一次亮相，本章把它变成了系统的方法；第 7 章的向量会让“点的平移和旋转”也能代数化；而微积分里最核心的动作——研究曲线的弯曲与变化——每一步都踩在这座坐标桥上。

4.9 让点动起来：参数方程

到目前为止，方程描述的都是静态的画面：哪些点在曲线上，哪些不在。但现实世界里的点几乎都在动：秒针尖端绕着表盘转，抛出去的篮球划出弧线，游戏角色在屏幕上奔跑。怎么给“运动”本身写一个方程？

再看一眼我们的老朋友，抛物线 $y = x^2$ 。换一种眼光：把它想象成一个小球爬出来的痕迹。设小球从原点出发，向右爬的速度是每秒 1 个单位，而它的高度按规则随时间变化——用 t 表示出发后的秒数，那么

$$x = t, \quad y = t^2.$$

$t = 0$ 时小球在 $(0, 0)$ ； $t = 1$ 时在 $(1, 1)$ ； $t = 2$ 时在 $(2, 4)$ ； $t = 3$ 时在 $(3, 9)$ 。每一秒，小球都有一个确定的位置，所有位置连起来，还是那条抛物线。看出区别了吗？ $y = x^2$ 说的是“横纵坐标之间的关系”，不管点什么时候到；而 $x = t$ 、 $y = t^2$ 这一对方程说的是“每个时刻点在哪里”——它不仅画出了轨迹，还记录了行程表。这个多出来的变量 t 叫做**参数**，这样的一对方程叫做**参数方程**。

定义 4.5 (参数方程). 如果曲线上动点的坐标 (x, y) 分别表示成某个变量 t 的式子

$$x = f(t), \quad y = g(t),$$

当 t 取遍允许的值时， (x, y) 正好描出这条曲线，那么这对方程叫做曲线的参数方程， t 叫做参数。

参数常常扮演“时间”的角色，但它不是非得是时间不可，它只是一个“指挥棒”： t 变，点就走。来一个更像物理的例子。把一个小球水平抛出，忽略空气阻力，它向右匀速、向下加速（这里简化数字，不追求精确的重力数据）：

$$x = 2t, \quad y = 5 - t^2 \quad (t \geq 0).$$

$t = 0$ 时球在 $(0, 5)$ ，出手高度 5； $t = 1$ 时在 $(2, 4)$ ； $t = 2$ 时在 $(4, 1)$ ； t 再大一点， y 变负，球落地了。如果我只关心球划出的弧线形状、不关心时刻，可以把参数消掉：由第一式得 $t = \frac{x}{2}$ ，代入第二式：

$$y = 5 - \left(\frac{x}{2}\right)^2 = 5 - \frac{x^2}{4}.$$

参数不见了，剩下一条开口向下的抛物线——平抛运动的轨迹果然是抛物线，和投篮、喷泉的水柱是同一个家族。从参数方程消去 t ，就回到普通方程；反过来，同一条曲线可以有許多不同的参数方程，对应“以不同方式走这条路”： $x = t$ 、 $y = t^2$ 是匀速横移地爬抛物线， $x = t^3$ 、 $y = t^6$ 描出的是同一段弧的右半边，只是节奏不同。轨迹是舞台，参数方程是剧本——舞台只有一个，剧本可以写很多本。

为什么非要让点动起来？因为太多的问题天然带着“时间”或者“进度”：行星什么时候走到离太阳最近，炮弹落在哪里，动画里这一帧角色该画在屏幕哪个像素。静态方程回答“在哪条路上”，参数方程回答“此刻在路上的哪一点”。后者显然更接近工程师和物理学家真正想问的东西。

继续攀登

坐标桥的另一端通向一片很大的大陆，关键词包括：**解析几何**——系统研究“方程与曲线互译”的学科，笛卡尔和费马被公认为它的两位奠基人，据说两人还为此争执过优先权；**圆锥曲线**——椭圆、抛物线、双曲线为什么都叫“圆锥”曲线，它们和行星轨道有什么关系；**极坐标**——用“距离加方向”而不只“横纵”来给点编地址，雷达屏幕用的就是它；**参数方程与微积分**——知道行程表 $x = f(t)$ 、 $y = g(t)$ ，怎样求每一刻的速度。这些名词现在不懂完全没有关系，把它们当作地图上尚未解锁的区域即可。

数学工具箱

本章新增的工具，按出场顺序：

- **数轴与一一对应**：实数与数轴上的点一一对应；一维距离 $= |b - a|$ 。
- **平面直角坐标系**：平面上的点与有序数对 (x, y) 一一对应，顺序不可乱。
- **距离公式**： $AB = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$ ，本质是坐标化的勾股定理。
- **中点公式**：中点坐标是两端坐标的平均。
- **方程与轨迹互译**：点在曲线上，当且仅当它的坐标满足曲线的方程；几何条件可以筛出一个方程，一个方程可以描出一条曲线。
- **双向解题**：几何题可以设坐标“硬算”，代数题（尤其含根号的）可以翻译成距离“巧看”。
- **参数方程**：用第三个变量 t 记录动点的行程表；消去参数回到普通方程。

思考题

观察题

1. 取 $t = -2, -1, 0, 1, 2$ ，分别计算参数方程 $x = t^2$ 、 $y = 2t$ 给出的点，描在坐标纸上连成光滑曲线。它像什么形状？提示：由第二式解出 $t = \frac{y}{2}$ ，代入第一式消去 t ，看看 x 和 y 满足什么方程——它和 $y = x^2$ 是什么关系？
2. 在坐标纸上把满足 $x^2 + y^2 \leq 9$ 的点所在区域涂上阴影，再把满足 $x + y > 0$ 的区域用另一种方式标出。两块重叠的部分像什么？提示：先分别画出两条边界 $x^2 + y^2 = 9$ 和 $x + y = 0$ ，不等式对应边界的哪一侧，可以代一个试点（比如原点）来判断。

证明题

1. 用坐标证明：对角线互相平分的四边形是平行四边形。提示：把两条对角线的公共中点设在原点，两个对角顶点设为 (a, b) 与 $(-a, -b)$ ，另两个设为 (c, d) 与 $(-c, -d)$ ，再比较两组对边的“横纵步伐”。
2. 平面上两定点 $A(-1, 0)$ 、 $B(1, 0)$ ，动点 $P(x, y)$ 满足 $PA^2 + PB^2 = 10$ 。证明 P 的轨迹是一个圆，并指出圆心和半径。提示：把 PA^2 、 PB^2 用距离公式展开（注意是距离的平方，根号正好消失），合并同类项后观察。

挑战题

1. 求 $\sqrt{x^2 - 2x + 2} + \sqrt{x^2 - 8x + 20}$ 的最小值。提示：先把每个根号里配方，认出两个“距离”；这次两个定点在 x 轴的同一侧，直接连线不管用——想想照镜子：把其中一个点关于 x 轴对称过去，折线长度不变，直线就可以登场了。
2. 动点 P 沿抛物线 $y = x^2$ 移动，坐标可写为 (t, t^2) ；定点 A 为 $(2, 0)$ 。写出 PA^2 关于 t 的表达式。提示：用距离公式后不要急着开方—— PA^2 会是一个关于 t 的四次式子。它有没有最小值、在什么时候取得，靠初中配方已经看不出来了；这个“看不懂的四次式”正是下一章要对付的东西。

通往下一章的门

这座桥通车之后，最先被运过河的货物，是我们本章见过好几次的那条曲线——抛物线。

把抛物线 $y = x^2 - 3x + 2$ 画在坐标纸上，你会发现它和 x 轴碰了两次面。碰撞点的纵坐标是 0，所以横坐标必须满足 $x^2 - 3x + 2 = 0$ ——一个二次方程。这就是说，**曲线与 x 轴的交点，和方程的根，是同一件东西的两种说法**：一个在几何里用眼睛看，一个在代数里用计算求。方程 $x^2 - 3x + 2 = 0$ 有根 1 和 2，抛物线就正好在 $(1, 0)$ 和 $(2, 0)$ 两处碰到 x 轴。

于是一连串新问题顺着桥面涌了过来。把 2 次换成 3 次， $y = x^3 - x$ 这条曲线会和 x 轴碰几次？换成 4 次、5 次呢？有没有一条多项式曲线，永远不碰 x 轴——也就是说，有没有一个方程根本没有实数根？如果方程没有实数根，是“题目出错了”，还是“数的世界太小了，该扩建了”？

这些问题的共同主角，是 $x^2 - 3x + 2$ 、 $x^3 - x$ 这类由字母的幂加加减减拼起来的式子——**多项式**。它们看上去只是代数的零件，却藏着方程的根、曲线的交点、甚至新数系诞生的线索。下一站，我们就把多项式拆开，看看里面的结构。

第二部分

沿着两条主轴深入——多项式、变换和向量

第五章 多项式：方程背后的结构

5.1 滑板公园的三个测量点

城南新修的滑板公园里，有一座供滑板手腾空的抛台。设计师小周在图纸上画出了飞行轨迹：滑板手从台沿飞出，在空中划出一条弧线，再落回下坡的斜面上。这条弧线不是随手画的——它必须保证落点刚好在斜面最平缓的一段，否则轻则摔跤，重则出事故。

把场地搬进坐标系（这正是第4章学到的本领）：以起跳点为原点，水平方向为 x 轴，竖直方向为 y 轴，单位是米。小周知道，忽略空气阻力时，飞行轨迹的形状总是一条“二次曲线”，也就是可以用

$$y = ax^2 + bx + c$$

来描述的曲线，其中 a 、 b 、 c 是三个待定的数。这类式子在生活中到处都是：喷泉水柱的弧线、篮球出手的路线、吊桥主缆的形状，背后都是同一个数学家族。麻烦在于：仪器只测到了轨迹上的三个点——起跳位置 $(0, 2)$ ，空中的点 $(1, 5)$ ，以及斜面上预先设定的安全落点 $(4, 2)$ 。

于是问题变成了两个。第一：有没有一条二次曲线同时穿过这三个点？如果有，它是唯一的吗？第二：假如轨迹确定下来，滑板手在什么水平位置时高度恰好是3米？这相当于解方程 $ax^2 + bx + c = 3$ ，也就是问曲线和一条水平线在哪里相交。

先凭直觉猜一猜。你可能觉得三个条件定三个未知数，应该有解，而且多半只有一个——这个直觉是对的，但“为什么对”需要本章的工具才能讲清楚。你也可能觉得解方程 $ax^2 + bx + c = 3$ 无非是套求根公式——可如果算出来判别式是负的呢？那是“题目出错了”，还是数学在向我们暗示什么？

这一章的主线就从这两个疑问出发。我们把 $ax^2 + bx + c$ 这样的式子当作一种有内部结构的“建筑”来研究，看看它的“零件”（因式）、“地基”（根）和“层数”（次数）如何决定它的全部行为；然后回到滑板公园，回答“三个点能不能还原一条规则”；最后直面那个负的判别式——它将把我们带到一个全新的数的世界。

5.2 先试试直觉：两种容易掉的坑

面对“曲线过三个点”，最自然的做法是凑。比如猜 $y = -x^2 + 4x + 2$ ：代入 $x = 0$ 得 $y = 2$ ，对了；代入 $x = 1$ 得 $y = 5$ ，又对了；代入 $x = 4$ 得 $y = -16 + 16 + 2 = 2$ ，全对！运气不错，这回歪打正着。但如果换一组点，凑就难了——总不能每次都靠运气。我们需要一种“必能成功、且能证明唯一”的办法，本章后面会给出。

面对方程，直觉也容易踩坑。很多同学背熟了“图像与 x 轴的交点就是方程的根”，于是顺推出两个看似合理的说法：

- 曲线碰了几次 x 轴，方程就有几个根；
- 图像不碰 x 轴，方程就“没有意义”。

第一句会漏掉一种狡猾的情况：曲线只是“贴着” x 轴反弹，并没有穿过去，比如 $y = (x-1)^2$ 在 $x = 1$ 处轻轻碰一下就掉头。这时方程只有一个根，但这个根“占了两份”。第二句更危险： $x^2 + 1 = 0$ 的图像确实碰不到 x 轴，可本章结尾会看到，它不但有意义，还逼出了数学史上最重要的一次“数的扩张”。

反例警报

“二次方程要么有两个根，要么没有实根。”——错。 $x^2 - 2x + 1 = 0$ 只有一个根 $x = 1$ ，但它是“重复”的：左边就是 $(x-1)^2$ ，因子 $x-1$ 出现了两次。如果只说“一个根”，我们就丢掉了结构信息；更准确的说法是“一个二重根”。看图像时也请留心：与 x 轴相切和穿过 x 轴，是两种本质不同的相遇方式。

这两处失败告诉我们同一件事：光看“答案”不够，得拆开式子看结构。下面我们把“拆”这件事变成正式的工具。

5.3 把式子当建筑：多项式、次数与根

把 $3x^2 - 4x + 1$ 拆开看，它由若干“块”相加而成： $3x^2$ 、 $-4x$ 、 1 。每一块都是“一个数乘上 x 的若干次方”（ 1 可以看作 $1 \cdot x^0$ ）。这样的式子用起来极其顺手：能相加、能相乘，乘完还是同一类式子，像乐高积木一样怎么搭都不出界。为了反复谈论这类对象，我们给它一个名字。

定义 5.1 (多项式). 形如

$$a_n x^n + a_{n-1} x^{n-1} + \cdots + a_1 x + a_0$$

的式子叫作（关于 x 的）**多项式**，其中 $a_n, a_{n-1}, \dots, a_0$ 是确定的数，叫作**系数**， n 是非负整数。若 $a_n \neq 0$ ，则称这个多项式的**次数**为 n ， a_n 叫作**首项系数**。

术语卡片：次数

直观解释：多项式里“长得最快”的那一项的指数，决定了 x 很大时整个式子的脾气。

正式定义：系数非零的最高次项的指数。

例子： $x^3 - 7x + 6$ 的次数是 3；常数 5（即 $5x^0$ ）的次数是 0。

术语卡片：根

直观解释：让多项式“归零”的输入值；图像上就是曲线与 x 轴相遇的位置。

正式定义：若数 r 使 $f(r) = 0$ ，则称 r 是多项式 $f(x)$ 的一个根。

例子：1 和 3 都是 $x^2 - 4x + 3$ 的根，因为代入后都得到 0。

为什么要专门发明“次数”这个词？因为它像建筑物的层数：层数几乎决定了建筑的宏观特征。一次多项式的图像是直线，两端一头朝上一头朝下；二次的是抛物线；三次的像一条被扭了一下的丝带，从一端钻下去又从另一端冒出来。次数还回答了那个让古人纠结的问题——“方程最多有几个解”。

顺便说一句，多项式值得专门研究，还因为它“足够简单，又足够万能”。说它简单，是因为算它的值只需要乘法和加法，没有任何花哨操作，计算机最喜欢的正是这种式子；说它万能，是因为后面（第 11、12 章）我们会看到，连 $\sin x$ 、 e^x 这些看上去毫不相干的函数，都能用“无限长的多项式”任意逼近。弄懂多项式，等于给整个函数世界打下地基。

而“根”把代数与几何焊在一起：解方程 $f(x) = 0$ ，等价于找曲线 $y = f(x)$ 与 x 轴的交点。同一个对象，一副代数面孔，一副几何面孔，我们可以随时换着看。

再看“拆”。 $x^2 - 4x + 3$ 可以写成 $(x-1)(x-3)$ 。拆开之后，根几乎自己跳出来：乘积为零，当且仅当某个因子为零，所以根是 1 和 3。反过来，知道根是 1 和 3，也立刻能写出因子 $x-1$ 与 $x-3$ 。这种“根与因子互相翻译”的本领，值得升格为一条定理。

5.4 因式定理：根与因子的翻译机

定理 5.2 (因式定理). 设 $f(x)$ 是多项式， a 是一个数。则 a 是 $f(x)$ 的根，当且仅当 $x-a$ 是 $f(x)$ 的因式，即存在多项式 $q(x)$ 使得

$$f(x) = (x-a)q(x).$$

证明. 两个方向分别验证。

(如果 $x-a$ 是因式) 假设 $f(x) = (x-a)q(x)$ 。把 $x=a$ 代入，右边第一个括号变成 $a-a=0$ ，零乘任何数都是零，所以 $f(a)=0$ ，即 a 是根。

(如果 a 是根) 回忆小学学的带余除法：17 除以 5 商 3 余 2，即 $17 = 5 \times 3 + 2$ ，余数必须比除数小。多项式也有同样的除法：用 $f(x)$ 除以一次式 $x-a$ ，可以得到

$$f(x) = (x-a)q(x) + r,$$

其中“余数” r 的次数必须低于除式 $x-a$ 的次数 1，所以 r 只能是一个常数。现在把 $x=a$ 代入这个等式：左边是 $f(a)=0$ （因为 a 是根），右边第一项消失，剩下 r 。于是 $r=0$ ，即 $f(x) = (x-a)q(x)$ ， $x-a$ 确实是因式。□

例 5.3. 验证 $x=2$ 是 $f(x) = x^3 - 7x + 6$ 的根，并把它彻底拆开。代入： $f(2) = 8 - 14 + 6 = 0$ ，是根。于是 $x-2$ 是因式。做除法（或耐心凑一凑）可得

$$x^3 - 7x + 6 = (x-2)(x^2 + 2x - 3) = (x-2)(x-1)(x+3).$$

三个根一目了然：2、1、-3。原来“解三次方程”这件事，一旦找到一个根，就降级成了“解二次方程”。

那一步除法具体怎么做？和整数竖式几乎一模一样。用 $x^3 - 7x + 6$ 除以 $x-2$ ：先看最高次， x^3 里藏着多少个 x 倍的 $x-2$ ？商的第一项是 x^2 ，乘回去得 $x^3 - 2x^2$ ，从被除式里减掉，余下 $2x^2 - 7x + 6$ ；再看 $2x^2$ ，商的下一项是 $2x$ ，乘回去得 $2x^2 - 4x$ ，减掉后余下 $-3x + 6$ ；最后商 -3 ，乘回去得 $-3x + 6$ ，刚好减干净，余数为 0。余数为零正是“2 是根”的另一种写法。如果换一个不是根的数来除，最后总会剩下一小块——那一小块其实就是函数值，这就是继续攀登栏目里“余数定理”说的内容。

这个“降级”思想威力很大，而且可以反复使用，于是一个重要结论几乎免费到手：

推论 5.4. n 次多项式至多有 n 个不同的实数根。

证明. 每找到一个根 a , 因式定理就送我们一个一次因式 $x - a$, 多项式被拆成 $(x - a)q(x)$, 其中 $q(x)$ 的次数降为 $n - 1$ 。再找 $q(x)$ 的根, 又能拆出一个一次因式。每拆一次, 剩余部分的次数减一; 最多拆 n 次, 次数就降到 0, 剩下一个常数, 再也没有根可拆。所以不同的根最多 n 个。□

注. “至多”二字不能省。 $x^2 + 1$ 是二次的, 却一个实根都没有。次数给的是根数的上限, 不是保证。这个缺口, 本章结尾会回来补上。

5.5 韦达关系：不拆也能听见根的声音

拆因子很痛快, 但有时拆不动 (系数太丑), 有时根本不需要拆到底。有没有办法不解方程, 就知道根的一些信息?

对二次方程有, 而且异常漂亮。设 $x^2 + bx + c = 0$ 的两个根是 α 和 β (允许相同)。由因式定理,

$$x^2 + bx + c = (x - \alpha)(x - \beta).$$

把右边展开:

$$(x - \alpha)(x - \beta) = x^2 - (\alpha + \beta)x + \alpha\beta.$$

左右两边是同一个多项式, 对应项的系数必须相同, 于是我们得到:

定理 5.5 (韦达关系 (二次情形)). 若 α, β 是 $x^2 + bx + c = 0$ 的两个根, 则

$$\alpha + \beta = -b, \quad \alpha\beta = c.$$

对一般形式 $ax^2 + bx + c = 0$ ($a \neq 0$), 两边同除以 a 化为上面的情形, 可得 $\alpha + \beta = -\frac{b}{a}$, $\alpha\beta = \frac{c}{a}$ 。

例 5.6. 不解方程 $x^2 - 7x + 12 = 0$: 两根之和是 7, 两根之积是 12。哪两个数和为 7、积为 12? 3 和 4。再看 $x^2 + x + 1 = 0$: 如果它有实根, 两根之和为 -1 、积为 1。两个实数积为正, 必须同号; 和为负, 必须同为负; 可两个负数积为 1 时, 最接近的情况是 -1 与 -1 , 和为 -2 ——比要求的 -1 差了一点。这个“差一点”不是巧合, 本章结尾会见分晓。


韦达关系真正的价值在于“隔空取物”: 系数是根的**对称函数**。 $\alpha + \beta$ 与 $\alpha\beta$ 有个共同特点——交换 α 和 β , 它们的值不变。系数只能“看见”根的对称信息, 看不见的部分 (比如哪个根更大) 它就说不出来。请记住“对称”这个词, 它是通往下一章的钥匙之一。顺便一提, 这个关系以十六世纪法国数学家韦达的名字命名; 他的真正贡献不只是这两条公式, 而是开始系统地用字母代表已知数和未知数——正是这套记号, 让“研究所有方程”取代“解决一个个方程”成为可能。

三次、四次方程也有韦达关系: $x^3 + px^2 + qx + r = 0$ 的三根之和为 $-p$, 两两乘积之和为 q , 三数之积为 $-r$ 。规律来自同样的展开, 只是括号更多了。拿前面的老朋友 $x^3 - 7x + 6$ 检验一下: 它的三个根是 1、2、 -3 , 和为 0 (确实没有 x^2 项), 两两乘积之和为 $1 \times 2 + 1 \times (-3) + 2 \times (-3) = 2 - 3 - 6 = -7$ (正是 x 的系数), 积为 -6 (与常数项 6 差一个负号, 因为三次的常数项是“负的积”)。三个根的所有“对称信息”, 被三个系数完整封存。

5.6 图像是根的地图

现在把代数得到的结构翻译成几何。面对一条多项式曲线，哪些信息是“读图可得”的？这一节给出的答案可以概括成一句话：图像不是别的，正是因式分解画出来的样子。我们分三点来看。

第一，**根在哪里，曲线就在哪里接触 x 轴**，但接触的方式有讲究。 $(x-1)(x-3)$ 在 1 和 3 处干脆地穿过； $(x-1)^2$ 在 1 处只是亲昵一下就弹回。原因在于重数：因子 $x-a$ 出现奇数次时， x 越过 a 会让整个乘积变号，曲线穿轴；出现偶数次时乘积不变号，曲线触轴反弹。



上面第二幅图画的是 $y = (x+2)(x-1)^2$ ：在 -2 处穿过，在 1 处反弹——图像把因式分解的秘密公开画了出来。

第二，**次数与首项系数决定两端的去向**。当 x 的绝对值很大时，低次项全部变得微不足道，式子的行为由首项 $a_n x^n$ 一人说了算： n 为偶数时两端同向 ($a_n > 0$ 都朝上， $a_n < 0$ 都朝下)； n 为奇数时两端反向。于是一个副产品自动出现：奇数次多项式一端冲上云霄、一端扎入地底，中间必然跨过 x 轴——

推论 5.7. 奇数次多项式至少有一个实数根。

严格证明需要“连续曲线不能跳过 x 轴”这一事实（第 12 章的介值定理会把它变成铁律），但图像的直觉已经足够可信：从地底走到天空，不可能不穿过地面。

第三，**根把曲线切成若干段，每段内符号不变**。想知道 $x^3 - 7x + 6 > 0$ 的解集？拆成 $(x + 3)(x - 1)(x - 2)$ ，三个根 -3 、 1 、 2 把数轴切成四段。每段取一个测试点判断正负即可，也可以列一张符号表：每个因子在自己的根右边为正、左边为负，整行的正负由负因子个数的奇偶决定。

区间	$x + 3$	$x - 1$	$x - 2$	乘积 $f(x)$
$x < -3$	—	—	—	—
$-3 < x < 1$	+	—	—	+
$1 < x < 2$	+	+	—	—
$x > 2$	+	+	+	+

于是 $f(x) > 0$ 的解集是 $-3 < x < 1$ 或 $x > 2$ ，一行一行读表就行，不用再解任何方程。看上去麻烦的不等式，被“根地图”一次性解决。

5.7 三个点猜一条规则：插值

回到滑板公园：已知轨迹经过 $(0, 2)$ 、 $(1, 5)$ 、 $(4, 2)$ ，求这条二次曲线。前面我们靠运气猜中了 $y = -x^2 + 4x + 2$ ，现在给出必成之法，顺便把唯一性也证明了。

想法出人意料地简单：**先造“只在一点值班”的零件**。构造一个二次多项式 $\ell_1(x)$ ，要求它在 $x = 0$ 处等于 1，在 $x = 1$ 、 $x = 4$ 处等于 0。后两个条件用因式定理立刻办到： ℓ_1 必须含因子 $(x - 1)(x - 4)$ ，即 $\ell_1(x) = k(x - 1)(x - 4)$ ；再用“在 0 处等于 1”定出常数 k ：代入得 $k(0 - 1)(0 - 4) = 4k = 1$ ，所以 $k = \frac{1}{4}$ ，即

$$\ell_1(x) = \frac{1}{4}(x - 1)(x - 4).$$

同理，造出在 $x = 1$ 处值班、其余两处为 0 的零件 $\ell_2(x) = -\frac{1}{3}x(x - 4)$ （请验证： $\ell_2(1) = -\frac{1}{3} \cdot 1 \cdot (-3) = 1$ ），以及在 $x = 4$ 处值班的零件 $\ell_3(x) = \frac{1}{8}x(x - 1)$ 。

现在像调音台一样，把三个零件按目标高度混合：

$$f(x) = 2\ell_1(x) + 5\ell_2(x) + 2\ell_3(x).$$

检验： $x = 0$ 时， ℓ_2 、 ℓ_3 都为 0， $\ell_1 = 1$ ，所以 $f(0) = 2$ ；同理 $f(1) = 5$ ， $f(4) = 2$ 。展开合并， $f(x) = -x^2 + 4x + 2$ ——和猜的一样，但这次是算出来的，而且这套工序对任意三个点都有效。它有个名字：**拉格朗日插值**。

注（唯一性）. 过这三个点的二次多项式只有一个。假如 f 、 g 都满足要求，考察它们的差 $f - g$ ：它在 0、1、4 三处都为零——一个次数不超过 2 的多项式竟然有三个根，这就违背了“二次至多两个根”的推论，除非 $f - g$ 恒等于零。看，刚证的根数上界立刻派上了用场。

一般规律是： $n + 1$ 个横坐标不同的点，恰好确定一个次数不超过 n 的多项式。点给少了，答案不唯一；点给多了，未必存在一个低次多项式刚好全部穿过。

这里藏着一个值得警惕的分寸：点多了，是不是次数越高越好？恰恰相反。假如测量有误差（现实里永远有），一条“硬要穿过每一个点”的高次曲线会在点与点之间疯狂扭动，预测能力反而糟糕。工程师们通常宁愿用一条低次曲线“大致穿过”所有点——这叫拟合，和插值是亲兄弟。插值负责“刚好经过”，拟合负责“总体最像”，分清什么时候用谁，是数据时代的基本功。

连接线

插值绝不只是几何游戏。手机放大照片时，新像素的颜色是插值算出来的；动画师只画关键帧，中间帧由软件插值生成；气象站只在若干城市有观测，全国气温图靠插值补全。更妙的是纠错码：它把数据看作某个多项式的函数值来传输，哪怕途中丢掉几个点，也能用插值把整条多项式还原出来——你听音乐、扫二维码时天天在用它。

5.8 当解不够用时： i 的诞生

现在来面对本章最大的那个疙瘩： $x^2 + 1 = 0$ 。

在实数范围内它无解——任何实数的平方都不是负数。几百年前的数学家也这么认为，并把这类方程扔进“无意义”的废纸篓。真正的转折发生在十六世纪的意大利：数学家们竞赛解三次方程，发现求根公式在中途要求对负数开平方。奇怪的是，如果假装负数的平方根存在，硬着头皮按普通规则算下去，最后那些“虚”的部分竟然两两抵消，蹦出来的答案代回原方程——完全正确！

这就尴尬了：一个“不存在”的数，却在通往正确答案的路上充当了不可或缺的桥梁。拒绝它，明明存在的实根算不出来；接受它，一切顺畅。数学家们争论、怀疑了上百年——有人称这种数为“诡辩的量”，有人干脆拒绝书写它们——但计算的威力实在太诱人：凡是借道“虚数”算出的结果，最后都能用实数检验，而且次次正确。实践一再投票之后，理论终于让步。数学家们决定：把这座桥扶正，让它成为正式公民。规定一个新数 i ，满足

$$i^2 = -1.$$

i 不是实数轴上的居民——数轴上找不到它的位置。那它住在哪里？答案漂亮得让人释怀：既然实数占满了一条直线，就把 i 放到直线外面，放在平面上点 $(0, 1)$ 处。于是一般的复数 $a + bi$ 就是平面上的点 (a, b) ：实数躺在横轴上， i 站在纵轴的单位处。

术语卡片：复数

直观解释：平面上的一个点，横坐标是“实的部分”，纵坐标是“虚的部分”。


正式定义：形如 $a + bi$ 的数，其中 a, b 是实数， i 满足 $i^2 = -1$ 。

例子： $3 - 2i$ 对应点 $(3, -2)$ ；实数 5 就是 $5 + 0i$ ，纯虚数 $2i$ 就是 $0 + 2i$ 。

复数的运算规则全部来自一条原则：像普通代数一样算，遇到 i^2 就换成 -1 。加法是对应分量相加： $(1 + 2i) + (3 - i) = 4 + i$ ，在平面图上就是两个箭头首尾相接。乘法用分配律展开：

$$(1 + 2i)(3 - i) = 3 - i + 6i - 2i^2 = 3 + 5i - 2 \times (-1) = 5 + 5i.$$

每个复数 $a + bi$ 还有一位“镜像伙伴” $a - bi$ ，叫作它的**共轭**：两者相加得 $2a$ （实数），相乘得 $a^2 + b^2$ （非负实数，恰好是到原点距离的平方）。靠这对伙伴，除法也能化为乘法——分子分母同乘分母的共轭，分母立刻变成实数。



复数乘法有个几何解读：乘以 i 相当于绕原点逆时针旋转 90° 。 $1 \times i = i$ （从右方转到上方）， $i \times i = i^2 = -1$ （再转 90° 到左方）——所谓“负数的平方根”，原来就是“转半圈这个动作的平方根”，多么合理！

有了 i ， $x^2 + 1 = 0$ 有了根 $\pm i$ ； $x^2 + x + 1 = 0$ 用求根公式得到

$$x = \frac{-1 \pm \sqrt{-3}}{2} = -\frac{1}{2} \pm \frac{\sqrt{3}}{2}i.$$

还记得前面“差一点”的悬念吗？这两个复根的和不折不扣是 -1 ，积不折不扣是 1 ——韦达关系在复数世界里依然成立。更惊人的是下面这个事实：

定理 5.8 (代数基本定理). 每个 n 次 ($n \geq 1$) 复系数多项式在复数范围内至少有一个根；配合因式定理反复拆，它恰好可以拆成 n 个一次因式的乘积，也就是说，恰有 n 个根（重根按重数计数）。

这条定理的证明超出了本书的工具范围（它需要一点分析或拓扑的知识，大学的复变函数课会给出特别优雅的证法），但它的信息很清楚：**复数让“次数”和“根的个数”完美地对上了**。前面“奇数次必有实根”“二次可能没有实根”这类含糊的例外，在复数世界里全部消失—— n 次方程永远恰有 n 个解，一个不多，一个不少。一种新数的引入，换来的不是更乱，而是惊人的整齐。

回头看，数的扩张走过一条熟悉的路：丈量土地不够用，有了分数；记账表示欠债不够用，有了负数；测量对角线不够用，有了无理数；解方程不够用，有了复数。每一次“解不够”，都不是数学的失败，而是数学在敲门：门后站着一个更大的数系，以及更整齐的定理。

继续攀登

继续向前，你会遇到这些词：**余数定理**（ $f(a)$ 恰好等于 f 除以 $x - a$ 的余数）、一般的**拉格朗日插值公式**、**共轭根定理**（实系数方程的虚根总是成对出现）、复平面上的**单位根**。再远处还站着一个大问题：“为什么五次及五次以上的方程没有通用求根公式？”它的答案诞生了一门用“对称”研究方程的学问——**群论**。

5.9 动手时间

一分钟实验

实验一：根地图预测图像。不看任何计算器，仅根据 $f(x) = (x+2)(x-1)(x-3)$ 回答：(1) 曲线在哪三个位置接触 x 轴？是穿过还是反弹？(2) x 很大和很小时，两端各朝哪走？(3) 在数轴上标出 $f(x) > 0$ 和 $f(x) < 0$ 的区间。然后描点画出草图，逐条核对你的预测。

实验二：亲手做一次插值。取三个点 $(0, 1)$ 、 $(2, 3)$ 、 $(3, 1)$ ，仿照正文造出三个“值班零件” ℓ_1 、 ℓ_2 、 ℓ_3 ，按高度混合出 $f(x)$ ，展开后把三个点代回检验。再任取一个横坐标（比如 $x = 1$ ）算出函数值，描在坐标纸上，看看曲线是否真的光滑地串起了你的点。

实验三：韦达侦探。让一位同学在心里想好一个二次方程的两个整数根，只告诉你它们的和与积；你用韦达关系反推出方程，再求根验证。交换角色玩三轮，体会“系数只看得见对称信息”这句话的含义。

数学工具箱

本章新增的工具：

- **多项式、系数、次数：**把一大类式子当作统一的研究对象；
- **因式定理：**根与一次因式互相翻译，找到一个根就把方程降一次；
- **根数上界：** n 次多项式至多 n 个实根；奇数次至少有一个实根；
- **韦达关系：**系数是根的对称函数，不解方程也能听到根的消息；
- **重数与图像：**单根穿轴而过，重根触轴反弹；首项决定两端走向；
- **拉格朗日插值：** $n+1$ 个点唯一确定一条不超过 n 次的规则；
- **复数：** $i^2 = -1$ ；在复数世界里， n 次方程恰有 n 个解。

思考题

观察题

1. 观察 $y = x^2$ 、 $y = x^3$ 、 $y = x^4$ 、 $y = x^5$ 的草图。偶数次与奇数次多项式在 x 很大和很小时各有什么规律？提示：只看首项，把其他项想象成“可以忽略的小波动”。
2. 画一画 $y = (x-1)^3$ 的草图。 $x = 1$ 是三重根，曲线在那里是穿过还是反弹？提示：奇数次方会改变符号，但增长在附近被“压平”了，描 $x = 0.5$ 、 1 、 1.5 三点细看。

证明题

1. 证明：若 $x^2 + bx + c = 0$ 有两个实根，则当两根之积为正时两根同号，为负时两根异号。提示：直接用韦达关系 $\alpha\beta = c$ 。
2. 已知 $f(x)$ 是三次多项式，且 $f(1) = f(2) = f(3) = 0$ ， $f(0) = 6$ 。求 $f(4)$ 。提示：先用因式定理写出 f 的形状，只差一个待定系数。

挑战题

1. 利用 $i^2 = -1$ 计算 $(1+i)^2$ 和 $(1+i)^4$ 。提示：算完后把每个结果标在复平面上，观察每次平方时“到原点的距离”和“转角”发生了什么变化——这与“乘以 i 等于转 90° ”暗暗呼应。
2. 证明：过 $n+1$ 个横坐标不同的点，至多只有一个次数不超过 n 的多项式。提示：仿照正文中唯一性的注，考察两个候选多项式的差，数一数它有多少个根。

通往下一章的门

这一章里，“对称”这个词悄悄出现了好几次：韦达关系里， $\alpha + \beta$ 与 $\alpha\beta$ 交换两个根而不变；系数永远只能“看见”根的对称信息；而那个终极问题——为什么三次、四次方程有求根公式，五次及以上却没有——最后的答案竟然是：五次方程的根之间的“对称性”太复杂了，复杂到无法用有限次开方表达出来。

给方程的根做“对称性体检”，听上去不可思议。但“对称”本身就是可以精确定义、可以运算的数学对象：正方形有几种翻折和旋转？这些动作怎样互相复合？先翻折再旋转，和先旋转再翻折，结果一样吗？下一章，我们把“对称”从形容词变成名词，从感觉变成结构——它会一路通向现代代数学的心脏：群。

第六章 变换与对称：从图形动作走向群

6.1 把正方形放回框架里

过年的时候，很多地方还保留着剪窗花的习惯。把一张红纸对折，再对折，拿剪刀随手剪出几个缺口，展开之后，纸上会出现一幅惊人的图案：左边有的花样，右边一定有；上面有的花样，转个方向又出现一次。剪的人根本没有设计过这些重复——它们是对折这个动作“免费赠送”的。

如果你看过万花筒，感受会更直接。几片碎玻璃渣，在三面镜子围成的圆筒里，竟能映出工整得像精密仪器的图案。转动圆筒，图案千变万化，但永远保持着一种说不出的整齐。为什么偏偏是六瓣的花、十二瓣的花，而不是七瓣、十三瓣？因为镜子的夹角是固定的，碎玻璃的影像被镜子反复反射，每反射一次就多复制一份，复制的次数由夹角说了算。玻璃的碎是随机的，图案的整齐却是被镜子的角度强制出来的。

这些“整齐”背后藏着同一个数学问题，而这一章，我们要从一个更朴素的游戏开始研究它。

请准备一张正方形的硬卡片，在它的四个角上分别写上数字 1、2、3、4，正反两面都要写，并且保证从任何一面都能看清哪个角是哪个。再在桌面上画一个和卡片一样大的正方形凹槽。现在问：把卡片正好放回凹槽，一共有多少种不同的放法？

注意规则：卡片可以翻面，所以别只想到旋转。

先凭直觉猜一个数。猜 4 的人很多，因为他们只想到了旋转：转 0° 、 90° 、 180° 、 270° ，正好四种。但卡片还能翻过来，所以答案至少是 8。可事情到这里并没有完——真正有意思的问题来了：

如果我把“转 90° ”和“沿竖直中线翻折”这两个动作接连做，做出来的结果算不算一种“新的放法”？会不会存在第九种放法？再进一步：先旋转再翻折，和先翻折再旋转，是同一件事吗？

这个问题看起来小得像课间游戏，但它难倒过人。十九世纪的数学家们在研究方程时，被迫认真思考“动作接连做”这回事，最后从中提炼出一个全新的数学概念——群。这个概念后来变成了整个现代数学和现代物理的通用语言：晶体的分类、基本粒子的命名、魔方的解法，全都靠它。而这一切，确实可以从桌上这张正方形卡片开始。

6.2 先猜，再错

在发明任何术语之前，我们先看看直觉会把我们带到哪些沟里去。

第一个常见的猜测是：“旋转和翻折接连做，顺序无所谓。”毕竟加法乘法都满足交换律， $3+5=5+3$ ，凭什么动作不行？这个猜测错得很干脆。拿你的卡片试一下：让角 1 本来在凹槽的左上角。先逆时针转 90° ，角 1 跑到左下角；再沿竖直中线翻折，角 1 到了右下角。换个顺序：先沿竖直中线翻折，角 1 先到右上角；再逆时针转 90° ，角 1 落到左上角。两种顺序，角 1 落在完全不同的位置。动作的复合，顺序是要紧的。


反例警报

警报：“两个动作接连做，先做哪个都一样。”

反例就是上面的卡片实验：先转 90° 再翻折，与先翻折再转 90° ，角 1 的落点不同。这和数的乘法有本质区别——数的世界里 $3 \times 5 = 5 \times 3$ 天经地义，动作的世界里顺序一变，结果就可能天差地别。生活里你早就知道这一点：先穿鞋再穿袜子，和先穿袜子再穿鞋，绝不是同一回事。

第二个常见的猜测是：“对称轴就是横一条、竖一条，共两条。”找正方形的对称轴时，很多同学画出水平中线和竖直中线就停笔了，忘了两条对角线也能让正方形对折后严丝合缝。正方形有四条对称轴，不是两条。少算轴，就会在数“放法”时漏掉一半。

第三个猜测更隐蔽：“既然每个动作都能再做一次、再做一次，那放法应该有无穷多种。”这个猜测错在没注意到“回到原位”这件事。转四次 90° ，卡片和没转一模一样；翻两次，卡片也恢复原状。动作可以无限地做下去，但做出来的结果会不断重复。我们要数的不是“动作序列”——那确实有无穷多条——而是卡片最终的状态。把这一点想通，问题才算真正收紧了。



四条对称轴（虚线）与逆时针旋转 90° 的动作 r

三次失败给了我们三条线索：动作复合有顺序问题；翻折不止一种；“回到原位”让总数变得有限。要把这些线索织成一张网，我们需要把“动作”本身变成可以计算的数学对象。

6.3 把“动作”变成数学对象

我们平时说“把图形转一下”，说的是一个过程。数学家做的关键一步，是把这个过程看成一个规则：平面上的每一个点，都被这个规则搬到了一个新的位置。

定义 6.1 (变换). 平面的一个变换，是把平面上每个点 P 都搬到某个确定的点 P' 的规则，并且

不同的点搬到不同的点，每个点也都被某个点搬到（不丢点、不撞点）。点 P' 叫做点 P 在这个变换下的像。

这个定义解决了什么麻烦？它让我们不再需要“盯着图形看”，而可以盯着一个一个的点看。一个变换是否把正方形搬回自身，只要检查正方形的每个点（其实只要检查几个关键点）落到哪里就够了。定义里“不丢点、不撞点”两条限制不是吹毛求疵：如果允许两个点撞到同一个点上，变换就没法撤销——你分不清新来的点原先是谁；撤销不了，后面“逆变换”的故事就讲不下去了。

初中几何里见过的几类变换，都在这里集合了：

- 平移：所有点朝同一个方向移动同样的距离，比如把整张卡片向右推三厘米；
- 旋转：所有点绕某个固定点（旋转中心）转过同一个角度；
- 翻折（也叫轴对称或反射）：所有点翻到某条直线（对称轴）的另一侧，像照镜子；
- 缩放：以某点为中心，所有距离按同一个倍数放大或缩小。

前三种有一个共同点：任意两点的距离保持不变。这类变换叫全等变换（或等距变换），它们把图形变成和自己全等的图形。缩放就不一样了：距离会变，形状不变而大小变，它把图形变成相似图形。这一章的主角是前三种，但缩放在下一章会以新的面目回来。

定义 6.2 (复合). 设 a 和 b 是两个变换。先做 b 、再做 a 得到的整体效果，仍是一个变换，记作 ab ，叫做 a 与 b 的复合。

请特别记住这个约定： ab 是先做 b 、后做 a 。写成乘法的样子确实方便，但读的时候要“从右往左”读。这个约定来自函数记号——第 2 章里 $f(g(x))$ 也是先算 g 再算 f ——暂时不习惯没关系，用卡片做两次实验就记住了。

复合的好处立竿见影。比如，两次平移接连做，效果仍是一次平移：先向右推三厘米、再向上推两厘米，合起来就是沿斜方向推一段，距离和方向都能算出来。两次旋转呢？绕同一个中心转 30° 再转 45° ，等于绕这个中心转 75° ——角度直接相加。可如果两次旋转的中心不同，事情就有趣了：结果仍是一次旋转（或一次平移），但新的旋转中心藏在哪儿，得画辅助线找半天。这正是“动作接连做”值得研究的原因：每一步都简单，合起来却有惊喜。

还有一个最“懒”的变换：什么都不做，每个点原地不动。它叫恒等变换，记作 e 。别小看它，它在整个理论里的地位，相当于乘法里的 1。

定义 6.3 (对称变换). 如果一个变换把图形 F 的每个点都搬到 F 内部的点上，使整个图形变换后与原来完全重合，就称这个变换是图形 F 的一个对称变换。

注意“完全重合”四个字。把正方形转 45° 不是它的对称变换——四个角戳出去了。把正方形向右平移三厘米也不是——图形挪窝了。对称变换是一类特殊的全等变换：它不但保持距离，还保持图形这个整体。

这里有个耐人寻味的差别：正方形只有寥寥几种对称变换，而圆有无穷多种——绕圆心转任何角度，圆都和自身重合，沿任何一条直径翻折也一样。直觉上我们会说“圆比正方形更对称”，现在这句话有了精确的度量：一个图形的对称变换越多，它就越对称。正方形的“对称程度”是一个有限的清单，我们马上就能把它全部清点出来。

现在, 正方形卡片的问题有了精确的语言: 我们问的其实是“正方形有多少个对称变换”, 而“动作接连做”就是对称变换的复合。

数学工具箱

本章的新工具, 请收好:

- 变换: 把“动一下图形”翻译成“搬运每个点的规则”, 从此动作可以精确比较;
- 复合 ab : 先做 b 再做 a , 把“接连做”变成可以列式计算的对象;
- 恒等变换 e : 什么都不做, 是计数和比较的基准;
- 逆变换: 把变换的效果撤销。转 90° 的逆是转 270° , 翻折的逆是它自己;
- 对称变换: 让图形与自身重合的变换, 是我们清点“整齐程度”的清单条目。

术语卡片: 逆变换

直观解释: 动作的“撤销键”。正式定义: 若变换 a 与变换 b 满足 $ab = e$ 且 $ba = e$, 就称 b 是 a 的逆变换, 记作 a^{-1} 。例子: 逆时针转 90° 的逆变换是顺时针转 90° (也就是逆时针转 270°); 沿任何轴翻折的逆变换是这次翻折本身, 因为翻两次就回到了原样。

6.4 八种, 一种不多

回到卡片问题。我们现在可以给出完整的答案, 并且证明它。

用 r 表示绕正方形中心逆时针转 90° , 用 f 表示沿竖直中线翻折。那么 $r^2 = rr$ 是转 180° , r^3 是转 270° , 而 $r^4 = e$ 。看起来我们能造出的动作越来越多, 但下面的定理说: 全是这八个里头的。

定理 6.4 (正方形的对称变换). 正方形恰好有 8 个对称变换:

$$e, \quad r, \quad r^2, \quad r^3, \quad f, \quad rf, \quad r^2f, \quad r^3f,$$

即四个旋转 (含恒等变换) 和四个翻折。

证明. 先证明“不超过 8 个”。设 T 是正方形的任意一个对称变换。由于对称变换保持距离, 正方形的中心 (对角线交点) 是唯一到四个顶点距离都相等的点, 所以 T 必然把中心搬到中心。于是四个顶点只能被搬到四个顶点。看角 1: 它的像至多有 4 种选择。角 1 的像确定后, 看与角 1 相邻的角 2: 因为 T 保持距离, 角 2 的像必须落在“角 1 的像”的相邻顶点上, 而至多只有 2 个相邻顶点。最后, 一旦角 1 和角 2 的像都确定了, 整个正方形的位置就被唯一确定——由“边边边”全等判定, 以这两个相邻顶点为一条边的正方形只有一种摆法, 其余两个顶点无处可逃。所以 T 至多有 $4 \times 2 = 8$ 种可能。

再证明“这 8 种都能做到”。 e, r, r^2, r^3 是四个旋转, 显然都是对称变换。 f 是沿竖直中线的翻折; rf 是“先沿竖直中线翻折、再转 90° ”, 直接检查顶点落点, 它等价于沿一条对角线的翻折; 同理 r^2f, r^3f 分别等价于沿水平中线和另一条对角线的翻折。正方形恰有四条对称轴, 所以这四个翻折都是对称变换, 且与四个旋转互不相同。合起来恰好 8 个, 一种不多, 一种不少。□

推论 6.5. 正方形的每个对称变换都有逆变换，而且逆变换仍在这八个之中。

证明. 旋转 r 的逆是 r^3 ，因为 $rr^3 = r^4 = e$ ； r^2 的逆是它自己；四个翻折的逆都是它们自己，因为沿同一条轴翻两次必回原位； e 的逆是 e 。八个成员，人人有逆，且逆不出这个圈子。□

注. 证明里“由边边边全等判定，正方形只有一种摆法”这一步，其实说出一个更普遍的事实：平面上的全等变换，被它不共线的三个点的像完全决定。正方形有四个顶点，但我们只需要盯住两个相邻的——因为中心已被锁定，第三点的选择自动收紧。这就是为什么“ 4×2 ”这个小小的乘法能管得住整个图形。

这个证明的方法值得记住：要数清楚“有多少种动作”，不用把动作一个个表演出来，只需要盯着关键点的像。两个相邻顶点的去向，锁定了整个正方形。这种“用少量信息锁定整体”的想法，后面还会反复出现。

八个变换清点完了，接下来是最能体现本章精神的一步：把它们的复合关系全部算出来，列成一张表。表中第 x 行、第 y 列的格子，写的是先做 y 、再做 x 的结果 xy 。

	e	r	r^2	r^3	f	rf	r^2f	r^3f
e	e	r	r^2	r^3	f	rf	r^2f	r^3f
r	r	r^2	r^3	e	rf	r^2f	r^3f	f
r^2	r^2	r^3	e	r	r^2f	r^3f	f	rf
r^3	r^3	e	r	r^2	r^3f	f	rf	r^2f
f	f	r^3f	r^2f	rf	e	r^3	r^2	r
rf	rf	f	r^3f	r^2f	r	e	r^3	r^2
r^2f	r^2f	rf	f	r^3f	r^2	r	e	r^3
r^3f	r^3f	r^2f	rf	f	r^3	r^2	r	e

这张表值得你趴在桌上研究十分钟。先看左上角 4×4 的小方块：旋转复合旋转还是旋转，而且规律就是“角度相加、满 360° 归零”，所以它其实是加法表的翻版。再看右下角 4×4 ：翻折复合翻折，得到的却是旋转——照镜子照两次（沿不同的轴），效果等于一个旋转，而且转角恰好是两轴夹角的两倍。这一点你可以拿两面小镜子摆个角度亲自看到。

还有两个重要观察。第一，表里每个格子都还是那八个成员之一：八个动作在复合下是封闭的，任做多少步都逃不出去，所以根本不存在“第九种放法”。第二，表关于主对角线不对称：比如 r 行 f 列是 rf ，而 f 行 r 列是 r^3f 。也就是说

$$fr = r^3f \neq rf.$$

这正是第一节卡片实验的代数形式：复合不满足交换律。

一分钟实验

用实物验证表里的一格。拿你的正方形卡片，四角标好 1, 2, 3, 4。先沿竖直中线翻折（这就是 f ），再逆时针转 90° （这就是 r ），记下四个角的位置——你刚才做的是 rf 。把卡片复位，反过来做：先转 90° ，再翻折，这是 fr 。对照复合表，看看 fr 那一格里写的 r^3f 和 rf 是不是不同的角位置。再挑三格验证，直到你对这张表心服口服。

现在退后一步，看这八个动作的整体。它们满足四条性质：复合封闭（格子里没有外人）；有恒等元 e （和任何动作复合都不改变对方）；每个动作都有逆（每行每列都恰好出现一次 e ，转 90° 配转 270° ，翻折配自己）；复合满足结合律 $((ab)c = a(bc))$ ，因为两边都是“先做 c 、再做 b 、再做 a ”，括号怎么括只是说话的节奏）。

结合律值得多说一句。它听起来像废话，却是整个体系能运转的地基：正因为有它，“先做 c 、再做 b 、再做 a ”这串长动作才能不加分号、不加括号地写成 abc ，谁都不必争论先算哪一段。对比一下：减法就没有这条性质， $(8-5)-2=1$ 而 $8-(5-2)=5$ ，所以连减必须老老实实加括号。动作的复合天生自带结合律，这是我们的运气——也是“群”这套语言能如此简洁的原因之一。

满足这四条性质的系统，有一个专门的名字。

术语卡片：群

直观解释：一袋子可以互相复合、可以撤销、复合结果跑不出袋子的“动作”。正式定义：一个集合 G 配上一种运算，满足：运算封闭；有恒等元；每个元素都有逆元；运算满足结合律。这样的 $(G, \text{运算})$ 称为一个群。例子：正方形的八个对称变换配上复合，构成一个群，叫做正方形的对称群。它有 8 个元素，不满足交换律。

这就是本章标题里那个“群”。它不是天上掉下来的术语，而是被逼出来的：当我们认真追问“动作接连做”的规律时，这四条性质自己浮出了水面。数学家们后来发现，值得研究的对称系统——图形的、方程的、晶体的、粒子的——全都恰好满足这四条。于是群成了研究一切对称的统一语言。

6.5 对称到底有什么用

学会一个新概念的标志，是它能帮你做成以前做不到的事。群和对称至少在三件大事上立下过功劳。

第一件：给图案分类。剪窗花时，对折一次剪出的图案有一条对称轴；对折两次再剪，图案通常有两条对称轴，甚至更多。墙纸、地砖、布料上的图案沿着整个平面无限重复，数学家问：平面上的重复图案，按对称变换的组成来分，一共有多少种？答案令人吃惊：不多不少，恰好 17 种。也就是说，从古埃及的壁画到现代的瓷砖，人类能贴出来的所有平面重复图案，无论花纹多花哨，其对称结构必然是这 17 种之一。把问题升到三维——晶体的原子排列——答案变成 230 种，化学家至今仍用这张表来登记晶体。这些结论的证明超出了本书范围，但计数用的工具你已经见过：就是“复合封闭、有逆、有恒等”那一套。

连接线

回头看看：第 3 章讲的全等三角形，本质就是“存在一个全等变换把一个三角形搬到另一个上”；第 5 章讲多项式的韦达定理，马上要在下面重新登场，它是“方程根的对称”的化身。往前看看：第 7 章会告诉你，旋转、翻折、缩放这些变换可以写成数表（矩阵）来做计算。对称不是孤立的景点，它是连通代数、几何和物理的立交桥。

第二件：解方程。这件功劳最漂亮，也最出人意料。以二次方程 $x^2 - 5x + 6 = 0$ 为例，它的两个根是 2 和 3。现在做一个“动作”：把两个根互换位置。哪些式子在这个动作下不变？ $x_1 + x_2 = 5$

不变, $x_1x_2 = 6$ 不变——交换两个数, 和与积都不变。而 $x_1 - x_2$ 会变号。换句话说, $x_1 + x_2$ 和 x_1x_2 是“根互换”这个变换的对称式, 而韦达定理说的正是: 这些对称式可以直接从方程的系数读出来, 根本不用先求根。

把这个想法推向三次、四次方程, 数学家们发现: 方程能不能用根式解出来, 取决于它的根的“对称群”的某种内部结构。五次方程的群结构太复杂, 于是一般五次方程没有根式解——这个震撼数学界的结论, 证明里用到的核心概念, 正是我们桌上这八个动作所示范的群。当年创立这套理论的年轻数学家们, 是在和当时整个数学界的怀疑作斗争的; 他们关于“对称决定可解性”的洞见, 后来长成了代数学的主干。

第三件: 驯服魔方。一个打乱的三阶魔方, 所有可能的彩色图案共有 43,252,003,274,489,856,000 种, 大约是 4.3×10^{19} , 念出来约是“四千三百亿亿”。如果靠瞎转还原, 宇宙的年龄都不够用。但魔方的所有转法构成一个群: 每一次转动是一个变换, 转法可以复合, 可以撤销。群论的语言让玩家能说清楚“这一段操作只交换了两个棱块、其余不动”——这类只改动极少块的操作叫做交换子, 是一切魔方公式的原料。数学家还借助计算机证明: 任何打乱状态, 至多 20 步 (把转 180° 也算一步) 就能还原。这个数字不是猜的, 是靠群的结构把天文数字的局面先归并成等价类, 再逐一核验得到的。

三件事用的是同一把钥匙: 不去追踪每一个具体的对象, 而去追踪对象之间的变换; 不满足于“形状相同”, 而追问“结构相同”。

什么是“结构相同”? 看一个最小的例子。正方形的四个旋转 e, r, r^2, r^3 自己封闭, 构成一个小群。另一边, 考虑“钟面上只有 0, 1, 2, 3 四个刻度、做模 4 加法”的系统: $1+2=3, 2+3=1, 3+3=2$ 。这两个系统, 一个是几何动作, 一个是算术, 成员完全不同。但把 r 对应到 1, r^2 对应到 2, r^3 对应到 3, e 对应到 0, 你会发现两边的运算表一模一样——旋转 90° 再转 180° 等于转 270° , 正如 $1+2 \equiv 3 \pmod{4}$ 。两张表只是标签不同, 骨架全同。这时我们说: 这两个群结构相同 (术语叫“同构”)。

这一步跨出去很大。几何动作和整数加法, 看上去风马牛不相及, 却在结构的层面上是同一个东西。数学的力量正来自这种“换个标签看世界”的本领: 只要结构相同, 在一侧证明的结论, 立刻免费搬运到另一侧。比如模 4 加法里 1 重复加自己能生成所有元素, 立刻就知道旋转群里 r 重复复合也能生成全部四个旋转; 这种“一个成员生出全家”的群有个专门的名字, 叫循环群。反过来, 正方形完整的八元素群就找不到这样一个成员—— r 生不出翻折, f 翻来覆去只有它和 e 两个。结构的眼光, 让“八个动作的大家庭”和“四个旋转的小家庭”的差别一目了然。

回头看全章的旅程: 我们从“形状相同” (全等) 出发, 经过“动作相同” (对称变换), 最后抵达“结构相同” (群与同构)。抽象程度一级比一级高, 但每一级都不是为了抽象而抽象——站得越高, 一次能看清楚的东西就越多。

继续攀登

想继续往上爬的同学, 可以记住这些关键词: 群论 (研究对称结构的分支)、同构 (结构相同的精确定义)、伽罗瓦理论 (用群判定方程可否根式解)、置换群 (魔方的数学模型)、壁纸群与空间群 (17 种与 230 种的故事)、李群 (连续的对称, 物理学的语言)。这些名词今天只是路标, 但它们全都从一张正方形卡片出发。

思考题

观察题

1. 把本章的正方形换成等边三角形，数一数它有多少个对称变换，并把旋转和翻折分开数。提示：模仿定理的证明——顶点 1 的像有几种选择？相邻顶点的像还剩几种？
2. 在正方形的复合表中，找出所有满足 $x^2 = e$ 的元素，数一数有几个。提示：除了四个翻折，旋转里也藏着一个“做两次回到原位”的成员。

证明题

1. 证明：若 a 和 b 都是某个图形 F 的对称变换，则复合 ab 也是 F 的对称变换。提示：回到定义，检查“变换后图形与自身重合”这句话经过两步之后是否仍然成立。
2. 证明脱鞋脱袜定律： $(ab)^{-1} = b^{-1}a^{-1}$ 。提示：把 ab 与 $b^{-1}a^{-1}$ 复合起来，利用结合律一步步消成 e ；再想想为什么顺序要反过来——早上先穿袜子后穿鞋，晚上就得先脱鞋后脱袜。

挑战题

1. 一个魔方只靠六面的转动来玩。问：保持立方体整体重合的旋转对称变换有多少种（不许翻折）？提示：盯住一个面——它有几种去处？面定了之后，立方体还能绕哪根轴转？答案是一个让你有点小得意的两位数。
2. 设计一个只有两个元素的动作系统，使它构成群，并写出它的复合表。提示：从“翻折加恒等变换”或“奇数偶数相加”里挑一个下手，再验证四条群规则。

通往下一章的门

这一章里，我们把“转一下”“翻一下”变成了能列进表格、能计算的对象。但你可能已经隐隐不满：验证一个复合，要拿卡片摆弄；算一个旋转之后某点落到哪里，要靠画图量取。动作在我们手里还是手工活。

有没有办法让变换变成算术？比如，把平面上每个点用两个数 (x, y) 记下位置，那么“绕原点转 90° ”能不能写成一套对这两个数的固定算法——不管什么点代进去，转完的新坐标立刻算出来？“向右平移三厘米”呢？缩放两倍呢？如果能做到，那么复合变换就是两种算法的接连执行，复合表可以用算式自动生成，卡片可以彻底退休。

可以做到。为此我们需要一个新的主角：一种既有长度又有方向的量——向量，以及操纵它的数表——矩阵。下一章，二维箭头将带我们走进线性代数的世界，而本章的旋转、翻折和缩放，会在那里变成几行干净利落的数字。

第七章 向量与线性代数：二维箭头通向高维空间

前面几章里，我们学会了用字母搬运数、用方程研究关系、用坐标把代数和几何缝在一起，还看过平移、旋转、翻折这些“动作”怎样组成对称的家族。这一章我们要做一件看起来很小、实际上改变整个数学面貌的事：给平面上的每一个“移动”画一支箭头，然后问——这些箭头本身能不能像数一样相加、相乘、被研究？

答案不但能，而且一旦做到这一点，二维的游戏画面、三维的动画、几万维的网页排序、甚至琴弦的振动，全都变成了同一套语言的练习题。这套语言叫线性代数。它是现代数学里应用最广的分支之一，而它的起点，只是平面上的一支箭头。

7.1 游戏里的一个下午

想象你在玩一款俯视角的冒险游戏。你的角色站在一片草原上，屏幕上没有东西南北，只有角色自己的朝向。键盘上有两个键：一个让角色“向前跨一步”，一个让角色“向左横移一步”。

下午的任务是走到地图上的一口井。你面朝东北方向，先向前跨了 3 步，又向左横移了 2 步，发现走过头了，于是掉头向前跨了 1 步。问题来了：折腾这一通之后，你离出发点到底多远？方向朝哪？

如果只是问“你一共走了几步”，小学生都会算： $3 + 2 + 1 = 6$ 步。但你真正想问的显然不是这个——走 6 步可能绕回原地，也可能走出老远。你想问的是：从出发点到终点，那支“可以直接飞过去”的箭头长什么样？

这个游戏里的困惑每天都在真实世界重演。快递员先向东骑 3 公里，又向北骑 4 公里，他离站点多远？帆船先被风吹向东南，又被洋流推向东北，最终漂到了哪里？无人机同时收到“上升”和“前进”两个指令，它的实际航线是什么？这些问题都有一个共同结构：几次移动叠在一起，要合成一次总的移动。

先凭直觉猜一猜：向东 3 公里再向北 4 公里，离出发点多远？很多人第一反应是 7 公里。也有人隐约记得勾股定理，猜 5 公里。哪个对？更重要的是：我们能不能发明一套记法，让这一类问题永远不用重新猜？

7.2 第一次尝试：只记数字够吗

最自然的尝试是：把每次移动记成一个数——走了多远。然后把数加起来。

这个方案立刻会撞上灾难。假设快递员向东骑了 3 公里，掉头又向西骑了 3 公里。按“路程”记账，他奔波了 6 公里，汗水是真的；可按“离站多远”记账，他就在站点门口，等于哪儿也没去。两笔一模一样的“3 公里”，叠在一起的结果却是零。

反例警报

有人说：“两次移动合起来，总移动的距离就是两次距离相加。”这对吗？找一个反例：向东走 3 公里，再向西走 3 公里。 $3 + 3 = 6$ ，但人回到了原地，总位移是 0。错误出在哪？出在“距离”这个数里根本不包含方向的信息。两个方向相反的移动，在距离账本上长得一模一样，在真实世界里却互相抵消。任何试图用一个数描述移动的方案，都会在这类反例上翻车。

失败给了我们一条重要线索：移动这种东西，天生带着两样信息——走了多远，以及朝哪个方向。丢掉方向，数字再大也没法相加出正确答案。我们需要的新概念必须同时装下这两样信息。

还有一个更隐蔽的麻烦。就算我们记下“向东 3 公里”“向北 4 公里”这样的短语，叠加三次、五次之后，口头描述会变成一团乱麻：“先向东再向北再向东南再向西北……”我们需要的是有一套能算的记法——像数一样可以相加、可以乘倍、可以列式子，而不是一篇游记。

7.3 发明箭头：向量的诞生

解决方案朴素得让人意外：既然移动有方向有距离，那就干脆画一支箭头来代表它。箭头的指向就是移动的方向，箭头的长度就是移动的距离。

术语卡片：向量


直观解释：一支有方向、有长度的箭头，代表一次移动、一个力、一个速度——任何“大小加方向”的量。

正式定义：平面（或空间）中由一对（或一组）有序实数确定的对象，记作 $\vec{v} = (x, y)$ 。两个向量相等，当且仅当它们方向相同、长度相等，与画在哪里无关。

例子：从原点指向点 $(3, 4)$ 的箭头是向量 $(3, 4)$ ，它的长度是 $\sqrt{3^2 + 4^2} = 5$ 。

注意定义里那句“与画在哪里无关”。向东 3 公里这支箭，从你家门口画和从学校门口画，是同一个向量。向量只记录“怎么动”，不记录“站在哪”。这个约定初看奇怪，其实是向量好算的关键：它让我们可以把所有箭头平移到同一个起点来比较。

向量的伟大之处在于，它的加法是被几何逼出来的，而不是被规定出来的。先走 $\vec{a}$ 再走 $\vec{b}$ ，总效果是什么？把 $\vec{b}$ 的尾巴接到 $\vec{a}$ 的箭尖上，从起点画到终点的那支箭就是答案，记作 $\vec{a} + \vec{b}$ 。这就是著名的三角形法则；换一种画法，把两支箭尾巴对齐、补成一个平行四边形，对角线就是和。



用坐标来算，加法简单得不像话：对应分量分别相加。

$$(3, 1) + (1, 2.5) = (3 + 1, 1 + 2.5) = (4, 3.5).$$

几何上的“首尾相接”，代数上的“分量相加”，是同一件事的两种语言——这正是第4章那座坐标桥梁的又一次通车。

有了加法，自然有“加倍”：把一支箭拉长到原来的2倍、缩短到一半、或者翻转方向，叫作数乘，记作 $2\vec{v}$ 、 $\frac{1}{2}\vec{v}$ 、 $-\vec{v}$ 。坐标上就是把每个分量乘以同一个数： $2 \cdot (3, 4) = (6, 8)$ 。

现在回到游戏里的困惑。把“向前一步”记作向量 $\vec{f}$ ，“向左一步”记作向量 $\vec{l}$ 。你下午的全部行踪——向前3步、向左2步、掉头向前1步——就可以写成一个式子：

$$3\vec{f} + 2\vec{l} + (-1)\vec{f} = 2\vec{f} + 2\vec{l}.$$

游记压缩成了一行代数。像 $3\vec{f} + 2\vec{l}$ 这样“若干向量各自乘上倍数再相加”的东西，叫做这些向量的**线性组合**。“线性”这个词的意思是：只允许做加法和数乘这两件最朴素的事，不允许向量互相乘、平方或者更花俏的操作。别小看这个限制——只允许两件朴素操作的数学，恰好是世界上最强大的数学之一。

接下来的问题决定了整章的走向：选哪几支箭当“基本步伐”，才能让平面上所有可能的移动都写成它们的线性组合？

一支箭显然不够：只会“向前”，你永远到不了侧方的井。两支不共线的箭呢？比如 $\vec{f}$ 朝东、 $\vec{l}$ 朝北。直觉上，朝任何方向的移动都能拆成“先走多少东、再走多少北”。在平面上，两支不同方向的箭似乎就够用了；而第3支箭（比如东北方向）是多余的，因为它本身已经是前两支的线性组合。

术语卡片：基与维数

直观解释：基是一组“基本步伐”，少一个就走不全，多一个就有冗余；维数就是这组步伐的个数。

正式定义：如果一组向量线性无关（谁也不是其他成员的线性组合），并且它们的所有线性组合能铺满整个空间，就称这组向量为空间的一组基；基中向量的个数叫做空间的维数。

例子：平面上 $\vec{e}_1 = (1, 0)$ 与 $\vec{e}_2 = (0, 1)$ 是一组基，平面是二维的； $(1, 0)$ 与 $(1, 1)$ 也是一组基——基并不唯一。

“维数”这个被我们随口用了十几年的词，在这里第一次有了精确的意思：一个空间是几维的，就是问它最少需要几个独立的“基本方向”才能拼出所有的向量。直线是一维的，平面是二维的，我们生活的空间是三维的——而代数对此毫不在意， $(x_1, x_2, \dots, x_{100})$ 这样的一百个分量排成一排，照样可以加、可以数乘，照样是一个一百维空间里的向量。箭头画不出来了，但算术照常运转。这就是标题里“通向高维空间”的含义：二维的直觉，通过代数规则，原封不动地搬运到了眼睛看不见的地方。

7.4 核心定理：每个箭头只有一种写法

凭什么相信“两支不同方向的箭就能拼出平面上的一切”？凭直觉不行，我们把它变成一个定理，并且证明它。

定理 7.1 (坐标的唯一性). 设 $\vec{e}_1$ 和 $\vec{e}_2$ 是平面上两个不共线的向量。那么平面上任意一个向量 $\vec{v}$ 都可以唯一地写成

$$\vec{v} = a\vec{e}_1 + b\vec{e}_2,$$

其中 a, b 是实数。也就是说：表示一定存在，而且系数只有一组。

证明. 先证存在性。把 $\vec{e}_1$ 、 $\vec{e}_2$ 和 $\vec{v}$ 的尾巴都平移到同一点 O 。过 $\vec{v}$ 的箭尖，作一条平行于 $\vec{e}_2$ 的直线，它与 $\vec{e}_1$ 所在的直线相交于一点 P （因为 $\vec{e}_1$ 与 $\vec{e}_2$ 不共线，这两条直线不平行，必相交）。从 O 到 P 的箭头与 $\vec{e}_1$ 共线，所以它是 $\vec{e}_1$ 的某个倍数 $a\vec{e}_1$ ；从 P 到 $\vec{v}$ 箭尖的那段与 $\vec{e}_2$ 共线，是某个倍数 $b\vec{e}_2$ 。由向量加法的三角形法则， $\vec{v} = a\vec{e}_1 + b\vec{e}_2$ 。

再证唯一性。假设同一支箭有两种写法：

$$\vec{v} = a\vec{e}_1 + b\vec{e}_2 = a'\vec{e}_1 + b'\vec{e}_2.$$

两式相减得 $(a - a')\vec{e}_1 + (b - b')\vec{e}_2 = \vec{0}$ 。如果 $a - a' \neq 0$ ，就能解出

$$\vec{e}_1 = -\frac{b - b'}{a - a'}\vec{e}_2,$$

这说明 $\vec{e}_1$ 是 $\vec{e}_2$ 的倍数，即两箭共线，与假设矛盾。所以 $a = a'$ ，同理 $b = b'$ 。表示法只有一组。□


这个定理值得停下来端详一会儿。它说的是：一旦选定基，平面上每个向量就和一对有序实数 (a, b) 一一对应。向量是几何对象，坐标是代数对象，这一定理保证了翻译是完美无损的——不多也不少。我们在第 4 章天天写坐标 (x, y) ，其实一直在默认这个定理成立；现在它终于从后台走到台前，被正式证明了。

同一套“线性组合”的脑子，顺手就能解开第 2 章留下的一个几何谜团：二元一次方程组

$$\begin{cases} 2x + y = 5, \\ x - y = 1 \end{cases}$$

到底在画什么？有两种看法，都正确，都重要。

第一种看法是“一行一行看”：每个方程是一条直线，解就是两条直线的公共点。两条直线相交，恰有一个解；平行不重合，无解；重合，无穷多解。三种情况，再无其他——因为平面上两条直线的关系就只有这三种。数值验证一下：相加得 $3x = 6$ ，即 $x = 2$ ，代入得 $y = 1$ ，交点是 $(2, 1)$ 。



第二种看法是“一列一列看”，把方程组改写成

$$x \begin{pmatrix} 2 \\ 1 \end{pmatrix} + y \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} 5 \\ 1 \end{pmatrix}.$$

它问的是：用 $(2, 1)$ 和 $(1, -1)$ 这两支箭，各取多少倍，才能拼出目标箭 $(5, 1)$ ？方程组有唯一解，正因为这两支箭不共线——它们构成一组基，定理保证拼法恰有一种。无解的情况对应两支箭共线而目标箭不在这条线上：怎么拼都够不着。无穷多解对应三者都共线：拼法随便挑。

升到三维：每个三元一次方程是空间中的一个平面。三个平面可以交于一点（唯一解），交成一条线（无穷多解），或者像翻开的书页那样两两相交却没有公共点（无解）。代数里“方程组有没有解、有几个解”的问题，在几何里变成了“几个平面怎么摆放”的问题。线性代数这门学问，本质上就是把这两幅图景来回翻译的艺术。

7.5 矩阵：把变换装进格子

第 6 章我们研究过旋转、缩放、翻折这些“动作”。当时我们用几何语言描述它们：把整个平面绕原点转 90° ，把每点到原点的距离放大 2 倍。现在有了向量和坐标，可以问一个更实用的问题：能不能给每种动作配一张“说明书”，让我把任意一点的坐标代进去，就能算出它动作之后的新坐标？

先看旋转 90° （逆时针）。拿两支基箭做实验： $\vec{e}_1 = (1, 0)$ 转到了 $(0, 1)$ ， $\vec{e}_2 = (0, 1)$ 转到了 $(-1, 0)$ 。由坐标的唯一性，任意向量 $(x, y) = x\vec{e}_1 + y\vec{e}_2$ 转完就是

$$x \cdot (0, 1) + y \cdot (-1, 0) = (-y, x).$$

拿一个具体点验证： $(3, 1)$ 转完应该是 $(-1, 3)$ 。在方格纸上画一下，确实如此——箭头长度没变，方向逆时针转了一个直角。

把两个基向量的像 $(0, 1)$ 和 $(-1, 0)$ 并排写成两列，装进一个方格子：

$$A = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}.$$

这个方格子叫矩阵。约定 A 乘向量 (x, y) 的规则是“行点乘列”：

$$\begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \cdot x + (-1) \cdot y \\ 1 \cdot x + 0 \cdot y \end{pmatrix} = \begin{pmatrix} -y \\ x \end{pmatrix}.$$

格子第一行算出结果的第一个分量，第二行算出第二个分量。整张平面的旋转，就这样被压缩进了四个数字。

再看缩放。把所有点到原点的距离放大 2 倍， $\vec{e}_1$ 不动方向变长为 $(2, 0)$ ， $\vec{e}_2$ 变成 $(0, 2)$ ，矩阵是

$$\begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix},$$

它把 (x, y) 变成 $(2x, 2y)$ 。类似地，沿 x 轴的翻折是 $\begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$ ，水平方向的切变是 $\begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$ 。

为什么矩阵装得下这些变换？因为旋转、缩放、翻折、切变有一个共同的“好脾气”：它们把直线仍变成直线，把原点固定不动，并且满足

$$T(\vec{u} + \vec{v}) = T(\vec{u}) + T(\vec{v}), \quad T(c\vec{v}) = cT(\vec{v}).$$

具有这两条性质的变换叫**线性变换**。这两条的威力在于：只要知道变换把两支基箭送到哪里，任意向量 $x\vec{e}_1 + y\vec{e}_2$ 的去向就被迫确定了——它的像只能是基箭之像的同系数线性组合。所以一个线性变换的全部信息，就浓缩在两支基箭的像里，也就是矩阵的两列里。矩阵不是一堆数字的随意摆放，而是一个变换的完整档案。

两个动作连着做呢？先旋转 90° 再放大 2 倍，总效果的矩阵恰好等于两个矩阵按“行点乘列”的规则相乘。具体算一次：

$$\begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 2 \cdot 0 + 0 \cdot 1 & 2 \cdot (-1) + 0 \cdot 0 \\ 0 \cdot 0 + 2 \cdot 1 & 0 \cdot (-1) + 2 \cdot 0 \end{pmatrix} = \begin{pmatrix} 0 & -2 \\ 2 & 0 \end{pmatrix}.$$

拿点 $(3, 1)$ 验证：先转 90° 得 $(-1, 3)$ ，再放大 2 倍得 $(-2, 6)$ ；直接用乘积矩阵算， $(0 \cdot 3 + (-2) \cdot 1, 2 \cdot 3 + 0 \cdot 1) = (-2, 6)$ ，一模一样。还要注意顺序：先放大再旋转，乘积矩阵相同（这两个变换恰好可交换），但“先旋转再翻折”和“先翻折再旋转”一般不是同一个变换——矩阵乘法不总服从交换律，这正对应着“动作的先后顺序通常有讲究”，第 6 章魔方那一节早就见过这个现象。

第 6 章里“动作的复合”是几何操作，矩阵乘法是它在坐标里的影子。你游戏里的角色转身、镜头推拉、三维模型渲染到屏幕，背后都是一连串矩阵相乘——显卡芯片每秒做的事情，很大部分就是飞快地算矩阵乘法。

连接线

回头看：第 4 章的坐标是“用数描述点”，本章的矩阵是“用数表描述变换”——同一座桥梁，又拓宽了一层。第 6 章的旋转、翻折在这里变成了具体的方格子，而正方形的八种对称动作，对应八个具体的 2×2 矩阵。往前看：本章的向量与矩阵在第 8 章会变成“曲线在一点附近像什么直线”的语言；到了高中和大学，它会出现物理的力与速度、经济学的投入产出、计算机图学的每一帧画面里。线性代数是所有理工科的公共母语。

7.6 保持方向的箭头：特征向量的故事

一般的线性变换会把平面上大多数箭头拧向新的方向。旋转 90° 最极端：没有哪支箭转完还保持原方向。但有些变换藏着“忠诚的箭头”——变换之后方向不变（或恰好反向），只是长度伸缩。

看一个具体的例子：

$$M = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$

拿几支箭试一试。 $(1, 0)$ 被送到 $(2, 1)$ ，方向变了； $(0, 1)$ 被送到 $(1, 2)$ ，方向也变了。但 $(1, 1)$ 被送到

$$\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 3 \\ 3 \end{pmatrix} = 3 \begin{pmatrix} 1 \\ 1 \end{pmatrix},$$

方向纹丝不动，长度放大 3 倍！再看 $(1, -1)$ ——“西北—东南”方向的箭，这个变换对它也许温柔些。算出来：

$$\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} 1 \\ -1 \end{pmatrix},$$

方向不变，长度也恰好不变。

术语卡片：特征向量与特征值

直观解释：一个变换中“不被拧弯”的箭头，方向（或反方向）保持不变，只被拉长、缩短或不动。

正式定义：对矩阵 A ，如果非零向量 $\vec{v}$ 满足 $A\vec{v} = \lambda\vec{v}$ (λ 是某个数)，就称 $\vec{v}$ 是 A 的特征向量， λ 是对应的特征值。

例子：上面的矩阵 M 有特征向量 $(1, 1)$ （特征值 3）和 $(1, -1)$ （特征值 1）。

为什么要找这样的箭头？因为特征向量是变换的“主轴”。沿着主轴看，一个复杂的变换退化成最简单的动作：单纯的伸缩。矩阵 M 看起来把平面搅得复杂，其实它只是把“东北—西南”方向拉长 3 倍、“西北—东南”方向保持不动。看懂了这两条主轴，就看懂了整个变换。数学家们常说，理解一个线性变换的最好方式，就是找到它的全部特征向量——这相当于给变换拍了一张“骨架照片”。

7.7 换一个视角：压缩、排序与振动

线性代数听起来抽象，它却藏在你每天用的三样东西里。

图像压缩。一张 512×512 像素的灰度照片，本质上是一个 512×512 的矩阵——每个格子里填一个表示明暗的数。直接存储要记 26 万多个数。但照片不是杂乱的：天空那一片数值几乎相同，墙角的边缘只在少数方向上有剧烈变化。线性代数提供了一种叫奇异值分解的技术，能把这样的矩阵拆成几个“特征方向”的叠加，而且最重要的几个方向就承载了画面九成以上的信息。只保留前几十个方向、丢掉其余，数据量可以缩小到原来的十分之一，肉眼却几乎看不出差别。你手机里的每一张 JPEG 图片、每一集流媒体动画，背后都是这类“用少数重要方向近似整个矩阵”的思想。

网页排序。想象整个互联网是一张巨大的网：每个网页是一个点，每个链接是一支箭。搜索引擎怎么判断哪个网页重要？一个绝妙的想法是：设每个网页有一个“重要度”分数，一个网页的重要度等于所有链接到它的网页贡献的分数之和——被越多重要网页引用，就越重要。拿一个只有三个网页的玩具互联网试试：网页甲被乙、丙引用，乙被丙引用，丙被甲引用。设三者的分数为 x 、 y 、 z ，规则写成方程就是 x 来自乙和丙的贡献、 y 来自丙、 z 来自甲——三个未知数、三个方程，全体分数排成一个三维向量 $\vec{v} = (x, y, z)$ ，整个引用规则装进一个 3×3 矩阵 A ，方程恰好是 $A\vec{v} = \vec{v}$ 。

把玩具换成真实互联网，几百亿个网页就是几百亿个未知数。吓人吗？可它仍然是一个线性方程组，而且正是“求某个巨大矩阵的特征向量”的问题：分数向量满足 $A\vec{v} = \vec{v}$ ，即特征值 1 的特征向量。实际计算时并不硬解方程，而是用前面实验二里那招：从一个随便猜的分数向量出发，反复乘矩阵 A ，几百亿维的向量会迅速倒向那个最重要的特征向量，网页的名次就此排定。世界上最赚钱的算法之一，核心就是本章那句 $A\vec{v} = \lambda\vec{v}$ 。

振动。一根两端固定的吉他弦，拨一下会振动发声。弦的形状时刻在变，看似复杂，但物理学家发现：任何振动都可以分解成若干“标准振型”的叠加——最低沉的基音、高八度的泛音，等等。每个标准振型就是弦的运动方程的特征向量，对应的特征值决定它的音高。一根弦发出的丰满音色，是许多个“特征振型”同时在歌唱。建筑抗震、桥梁设计、麦克风降噪，用的都是同一

套分析：把复杂运动拆成特征方向上的简单运动。

数学工具箱

本章新增的工具：

- 向量：用一支箭头（一对坐标）同时记录方向与大小；加法按“首尾相接”，坐标上就是分量相加。
- 线性组合与基：所有向量都是基向量的线性组合，且系数唯一——坐标因此可靠。
- 维数：最少需要几个独立方向，空间就是几维；规则对一百维同样成立。
- 矩阵：线性变换的完整档案，两列就是两支基箭的像；矩阵乘法对应变换的复合。
- 方程组的几何：直线、平面的相交问题，就是“用基箭拼目标箭”的问题。
- 特征向量：变换中保持方向的箭头，揭示变换的主轴；它是压缩、排序、振动分析的共同核心。

一分钟实验

实验一：基箭拼图。在方格纸上取 $\vec{e}_1 = (2, 1)$ 、 $\vec{e}_2 = (-1, 2)$ 当基箭。目标是拼出 $\vec{v} = (1, 8)$ ：求 $a\vec{e}_1 + b\vec{e}_2 = \vec{v}$ ，即解 $2a - b = 1$ 、 $a + 2b = 8$ 。算一算，再按三角形法则在纸上画出来验证。然后换一组共线的“基箭” $(2, 1)$ 和 $(4, 2)$ ，试试还能不能拼出 $(1, 8)$ ——体会“共线就缺一个方向”。

实验二：追踪一支箭的命运。取矩阵 $M = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$ 。在纸上画出 $(1, 0)$ 、 $(1, 1)$ 、 $(1, -1)$ 、 $(2, 1)$ 四支箭，算出它们被 M 送走后的像并画出来。哪支箭方向没变？哪支被拉长得最多？把 M 连续作用三次在 $(1, 0)$ 上，观察这支箭越来越“倒向”哪个方向——这个方向就是特征值最大的特征向量的方向。这正是网页排序算法实际计算特征向量的办法：反复乘矩阵，让最重要的方向自己浮出来。

继续攀登

想继续攀登的同学可以搜索这些关键词：行列式（变换对面积的缩放倍数，也是判断基是否退化的开关）；逆矩阵（撤销一个变换的说明书）；特征值的求法（特征方程）；奇异值分解（图像压缩的真正主角）；马尔可夫链（网页排序的概率外衣）；线性空间与希尔伯特空间（把向量推广到函数，傅里叶级数的家）。竞赛里的“平面向量基本定理”和“定比分点”也都是本章故事的直系后代。

思考题

观察题

1. 在方格纸上随便画三支箭 $\vec{a}$ 、 $\vec{b}$ 、 $\vec{c}$ 。用三角形法则分别画出 $(\vec{a} + \vec{b}) + \vec{c}$ 和 $\vec{a} + (\vec{b} + \vec{c})$ 。你观察到什么？再画 $\vec{a} + \vec{b}$ 和 $\vec{b} + \vec{a}$ 呢？（提示：把每次加法都落实到“首尾相接”上，别凭感觉。）

2. 取矩阵 $\begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$ (水平切变), 算一算 x 轴上的箭头 $(1, 0)$ 和 y 轴上的箭头 $(0, 1)$ 各被送到哪里。有没有特征向量? (提示: 一支箭方向不变, 它的两个分量必须按同一个倍数缩放。)

证明题

1. 证明: 如果 $\vec{v}_1$ 和 $\vec{v}_2$ 都是矩阵 A 的属于特征值 λ 的特征向量, 那么它们的任意线性组合 $a\vec{v}_1 + b\vec{v}_2$ (只要不是零向量) 也是属于 λ 的特征向量。(提示: 从 $A\vec{v}_1 = \lambda\vec{v}_1$ 和 $A\vec{v}_2 = \lambda\vec{v}_2$ 出发, 对 $A(a\vec{v}_1 + b\vec{v}_2)$ 使用线性变换的两条好脾气。)

2. 证明: 平面绕原点逆时针旋转角度 θ 的矩阵是 $\begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}$ 。(提示: 只需要算出 $(1, 0)$ 和 $(0, 1)$ 各被转到哪里, 矩阵的两列就是它们。用单位圆上一点的坐标定义回想 $\cos$ 与 $\sin$ 的几何意义。)

挑战题

1. 三个平面在空间中“两两相交却没有公共点”, 除了正文提到的“翻开的书页”, 你还能想出别的摆法吗? 每种摆法对应方程组无解的哪种代数原因? (提示: 先让两个平面交于一条直线, 再考虑第三个平面与这条直线可能的位置关系。)

2. 设矩阵 A 反复作用在平面上: $\vec{v}_0 = (1, 0)$, $\vec{v}_{n+1} = A\vec{v}_n$ 。取 $A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$, 计算 $\vec{v}_1$ 到 $\vec{v}_4$, 观察 $\vec{v}_n$ 的方向越来越接近哪支箭、长度大约每次放大几倍。你能解释为什么“反复乘同一个矩阵”总会让箭头倒向特征值最大的特征向量吗? (提示: 把 $\vec{v}_0$ 写成两个特征向量的线性组合, 看看每一项被乘了多少次 3、多少次 1。)

通往下一章的门

这一章我们活在一个笔直的世界里: 向量是直箭, 矩阵把直线送到直线, 方程组的解是直线与平面的交点。线性代数之所以强大, 恰恰因为直线是最容易完全理解的几何对象。

可世界并不总是直的。过山车轨道在弯, 咖啡杯的水面在弯, 地球表面本身就是弯的。一根弯曲的轨道, 还有“方向”可言吗? 一支箭头能贴在球面上吗? 弯得最厉害的地方, 能不能用一个数来衡量?

数学家们想出的对策出奇地符合本章精神: 弯的东西虽然整体复杂, 但放得足够大、看得足够局部, 每一小段都近似是直的——弯道上每一点附近, 都附着一条最接近它的直线; 曲面上每一点附近, 都贴着一个最贴合它的平面。而直线和平面, 正是我们这一章已经完全驯服的对象。下一章, 我们就从“曲线在很小范围内为什么像直线”这个问题出发, 把线性的世界铺到弯曲的世界去。

第八章 从直线到曲面：局部近似的预告

8.1 一场雨中的自行车赛

环青海湖自行车赛进行到下坡路段，天上下起了小雨。电视镜头从直升机上俯拍：盘山公路像一条灰色的丝带，在绿山坡上绕出一个又一个弯。解说员反复念叨一句话：“前面这个弯很急，车手一定要提前减速。”

镜头里，车手们的表现确实不一样。经过一些弯道时，他们几乎不用捏刹车，身体轻轻一斜就过去了；经过另一些弯道时，他们早早把速度降下来，车身倾斜得很厉害，轮胎在湿漉漉的路面上划出一道弧线。显然，“急”和“缓”是有客观差别的，不只是解说员的修辞。

现在请你当一回赛事工程师。组委会给你一张赛道的平面图——就是地图上那种弯弯曲曲的线，没有等高线，没有比例尺之外的任何信息。他们要你回答两个听起来很简单的问题：

第一个问题：图上这些弯，哪个最急？你能给“弯得有多厉害”配一把尺子吗？

第二个问题：为什么这张地图放大很多倍之后，再弯的路，每一小段看起来都几乎是直的？

先别往下看，凭直觉猜一猜。对于第一个问题，大多数人会说“转弯转得快就是急”——这话没错，但它把问题换了个说法而已：什么叫“转得快”？用什么单位？对于第二个问题，很多人会愣一下：这好像是天经地义的，可一旦追问“为什么”，就发现它并不像看起来那么理所当然。这两个问题，正是本章的起点。

8.2 第一次尝试：几根不够格的尺子

要量“弯”，最朴素的想法是借用直线。曲线我们不熟悉，直线我们太熟悉了，那就看看这条弯道“离直线有多远”。

第一根尺子：连接弯道起点和终点，量这条线段的长度。弯道越急，两端点应该被“甩”得越近，线段越短，对吗？不对。找一条长长的、平缓的大弧线，再找一个短短、突然掉头的小急弯，你完全可以让它们的端点距离一模一样。端点距离反映的是“你取的这段有多长”，而不是“这段弯得有多急”。

第二根尺子：还是连接起点和终点，这次量曲线离这条弦最远有多远，也就是所谓的“弓高”。弓越高越弯？还是不行。同一个弯，你取一大段来看，弓可以很高；只取中间一小段，弓又矮下去。尺子随着你取的区间忽大忽小，这样的量法没有资格叫“程度”——程度应该是弯道自己的性质，不该由旁观者随便改变。

两次失败透露了一个重要线索：“弯曲”必须是一个在一点附近说了算的性质。你不能站在远处、圈一大段来评判一个弯急不急；你必须凑近了看，在任意小的一段上，它的弯曲程度都应该有确定的答案。数学家把这种“在一点附近”的视角叫做局部视角。这一章的核心思想只有一句话：

弯曲的东西，在局部是直的；而研究弯曲的办法，就是先研究它在局部像什么样的直线、又怎样一点一点偏离这条直线。

可是“凑近了看”到底是什么意思？凑多近才算近？我们需要一个更清楚的图景。

8.3 把曲线放到显微镜下

先看一个你早就知道、却未必细想过的例子：地球是圆的，可你脚下的操场看起来是平的。这不是因为操场特殊，而是因为你太小、地球太大。我们来算一笔账。假设你沿一个半径为 R 的圆周走，每走一段弧长 s ，你的前进方向改变的角（用弧度制）是 s/R 。地球半径约 6 400 000 米，你沿地面走 1 米，方向只改变

$$\frac{1}{6\,400\,000} \text{ 弧度} \approx 0.000\,008\,9^\circ.$$

这个角度小到任何量角器都量不出来，于是你的全部生活经验都在告诉你：地面是平的。古人认为大地是平的，不是因为他们笨，而是因为“局部像平面”这件事实在太逼真了。反过来，当人们终于掌握了足够精确的测量手段——比较两地正午影子的长度、观察远航船只先消失船身再消失桅杆——大地的弯曲才从“局部的假象”里浮现出来。局部的平直与整体的弯曲并不矛盾，它们是同一件事物在不同尺度上的两副面孔。

把同一个想法倒过来用：取一条弯弯曲曲的曲线，盯住它的一小段，放大；再放大；再放大。只要这条曲线足够“顺”——不折断、不起尖角——你会发现，放大到足够程度之后，它看起来就是一条直线。圆如此，抛物线如此，盘山公路的地图也如此。这不是巧合，而是“光滑”二字的含义：光滑曲线在显微镜下是直的。

反例警报

“任何曲线，只要放得足够大，看起来都像直线。”这句话是错的。请画一个字母 V，也就是函数 $y = |x|$ 的图像，盯住它的尖角放大。放大一倍、十倍、一百倍——尖角还是那个尖角，张开的度数一丝一毫都没有变。放大改变的是尺寸，不是角度。所以“局部像直线”是光滑曲线才有的特权；有尖角、有断裂的曲线不享受这个待遇。数学家把“局部像直线”这条性质起了一个正式的名字，叫“可微”，它将是第三部的角色之一。现在你只要记住：本章谈的都是没有尖角的光滑曲线。

一分钟实验

不用任何仪器，你就能亲眼看到“放大变直”。在纸上随手画一条弯弯曲曲的线，用铅笔在其中一段上涂一个指甲盖大小的记号。把纸拿到复印机上，以记号为中心放大复印一次；把复印件再放大复印一次。两三次之后，记号附近的那段线在复印件上几乎就是一条直线段。如果家里有放大镜，直接用它看曲线上的一小段，效果也一样。然后换一张画着字母 V 的纸重复这个过程，对比尖角处的表现——反例就在你手里。


8.4 切线：曲线在一点处的替身

既然光滑曲线的一小段像直线，下一个动作顺理成章：把这条直线找出来，让它当曲线在这一点附近的“替身”。直线我们太熟悉了——一个方向、一个斜率，一个数就能说完。如果弯曲的

问题能翻译成直线的问题，难度立刻降一个档次。

可是，“最贴切的那条直线”是哪一条？这里有一个陷阱。你可能会说：切线嘛，就是只碰曲线一个点的直线。这个印象来自圆，但它搬到一般曲线身上立刻出问题。抛物线 $y = x^2$ 的顶点处，竖直的那条直线也只碰抛物线一个点，可它显然不是我们想要的“替身”——它跟抛物线的走势完全对不上。反过来，一条在局部最贴切的直线，放远了看完全可能再碰到曲线别的地方。“只碰一个点”是圆的切线的性质，不是切线的定义。

正确的想法来自上一节的失败与这一节的放大：盯住曲线上一点 P ，在旁边再取一点 Q ，连成一条直线 PQ 。这样的直线叫**割线**，它切进曲线，告诉我们从 P 到 Q 这段时间里曲线的“平均走向”。现在让 Q 沿着曲线慢慢滑向 P ：割线随之转动，转过的角度越来越小，位置越来越稳定，最后稳定下来的那个位置，就是曲线在 P 点的**切线**。



定义 8.1 (切线的直观定义). 设 P 是光滑曲线上一点。在曲线上取另一点 Q ，当 Q 沿曲线无限接近 P 时，割线 PQ 趋向的那条确定直线，称为曲线在 P 点的切线。

注意这个定义里藏着一个狡猾的东西： Q 永远不能真的等于 P ——两点才能定一条直线， Q 一旦撞上 P ，割线就不存在了。切线是由一个“永远走不到头的过程”决定的。现在我们先接受这个过程；它引起的麻烦，以及数学家怎样把它驯服成严格的“极限”，是下一章的故事。

术语卡片：切线

直观解释：曲线在一点处的“最佳直线替身”，显微镜下曲线呈现的样子。正式定义：割线 PQ 在 Q 趋向 P 时的极限位置。一个例子：圆上任意一点的切线，垂直于该点处的半径。

最后一个例子值得细看，因为它能检验新想法和老知识对不对得上。初等几何告诉我们：圆的切线垂直于半径。用割线逼近的眼光能重新看出这件事吗？能。设圆心为 O ，在圆上取点 P ，再取两个关于直线 OP 对称的点 Q 和 Q' 。由对称性，弦 QQ' 垂直于 OP 。现在让 Q 和 Q' 同时沿圆周滑向 P ：每一步它们仍然对称，割线仍然垂直于 OP ；于是极限位置——切线——也垂直于 OP 。新方法没有推翻老结论，而是把老结论变成了新图景里的一个特例。一个数学想法靠不靠谱，这是重要的试金石。

切线这把“替身”有什么用？用处大了。车轮沿弯道滚动时，如果突然打滑，车会沿切线方向飞出去——链球运动员松手后，链球正是沿切线飞出的；砂轮磨刀具时溅出的火花，也是沿切线射出的。曲线在每个瞬间的“意图”，都写在它的切线上。

8.5 弯得有多厉害：曲率

有了切线，“方向”这个词就精确了：曲线在一点的方向，就是切线的方向。现在可以正式打造量“弯”的尺子。

想象你是一只沿曲线爬行的蚂蚁，身上装着指南针，随时记录自己前进方向的角度。走同样长的一段路：在平缓的地方，指南针几乎不动；在急弯处，指南针呼呼地转。于是弯曲的程度可以定义为：单位弧长上，前进方向改变了多少。

定义 8.2 (曲率的初步定义). 光滑曲线上一点处的曲率，是切线方向角沿弧长的变化率：在这一点附近，每走过一单位弧长，切线方向角改变的弧度数。曲率越大，弯得越急。

这个定义有点抽象，好在有一类曲线可以把它算到底——圆。

定理 8.3 (圆的曲率). 半径为 R 的圆，其曲率处处相同，等于 $\frac{1}{R}$ 。

证明. 在圆周上取一点，设从它出发沿圆周走过弧长 s ，到达另一点。这段弧对应的圆心角记为 θ (用弧度制)。由弧长公式，


$$s = R\theta.$$

再看方向改变了多少。半径始终垂直于切线；半径从起点转到终点，转过了圆心角 θ ，而“垂直”这个关系在转动中保持不变，所以切线方向也恰好转过 θ 。于是方向改变量与弧长之比为

$$\frac{\theta}{s} = \frac{\theta}{R\theta} = \frac{1}{R}.$$

这个比值里不含有起点的任何信息，所以它在圆周上处处相同。这就是我们要证的。□

例 8.4. 一个半径 10 米的环形路口，沿它每走 1 米，方向改变 $\frac{1}{10}$ 弧度，约 5.7° ；一个半径 2 米的急弯，每走 1 米方向要改变 $\frac{1}{2}$ 弧度，约 28.6° 。后者曲率是前者的五倍——弯越急，半径越小，曲率越大。直觉和公式对上了。



注. 直线不转弯，方向角永远不变，曲率是 0。按公式 $\frac{1}{R}$ 理解，直线相当于“半径无穷大的圆”。这不是文字游戏，而是一个有用的视角：直线是弯曲程度为零的曲线，就像 0 是“没有”的数一样自然。

术语卡片：曲率

直观解释：弯得有多厉害——每走一单位路程，方向转过多少。正式定义：切线方向角沿弧长的变化率；圆的曲率等于半径的倒数。一个例子：半径 4 厘米的圆，曲率是每厘米 $\frac{1}{4}$ 弧度。

曲率不是书房里的摆设，工程师天天在和它打交道。铁路由直道接入弯道时，绝不能让曲率从 0 突然跳成 $\frac{1}{R}$ ——列车会被这记“急刹车式的转向”狠狠甩一下。聪明的做法是在直道和圆弯之间夹一段过渡，让曲率从零开始连续地、缓缓地升到 $\frac{1}{R}$ ，乘客几乎感觉不到。高速公路的匝道、过山车的轨道、过山车回环入口处越来越紧的弧线，背后都是同一条设计原则：让“弯得有多厉害”这个量平滑地变化。你看，一个“单位弧长上方向改变多少”的抽象定义，最后落进了每个人的安全带里。

一般的曲线在不同地方曲率不同：盘山公路的直段曲率是 0，缓弯处小，急弯处大。数学家的处理办法漂亮而自然：在曲线上每一点，找一个与该点贴合得最好的圆——既不偏松也不偏紧——叫做这一点的**密切圆**，规定这点的曲率就是密切圆半径的倒数。直线处，密切圆半径无穷大；急弯处，密切圆又小又紧。这句话我们只当作直观的描述，它的严格定义需要导数，要等下一部才能补齐。但请注意我们做的事：用直线逼近曲线，再用圆逼近曲线“偏离直线的程度”——一步一步，把弯曲翻译成越来越精细的局部近似。这条“局部近似”的路，会一直通到微分几何的深处。

8.6 换一个视角：球面上的“直线”

到目前为止，我们都在平面上打转。现在换一个舞台，看看这些想法能走多远。

打开航班追踪软件，看一趟从北京飞往纽约的飞机。在常见的平面地图上，它的航迹不是一条直线，而是一条向北鼓起的大弧线，擦着北极圈过去。飞机为什么要绕远？答案是：它没有绕远。地图是把球面硬压平得到的，压平的过程扭曲了形状；在真实的球面上，这条“弯”的航线恰恰是几乎最直的路线。

平面上，“直”和“最短”是同一件事的两面：线段是两点间最短的连接。把这个品格搬到球面上，就能找到球面世界里的“直线”：球面上两点间最短的路线。它们是什么？是用过球心的平面切出来的圆——**大圆**。赤道是大圆，所有经线圈是大圆；而赤道以外的纬线圈不是大圆，它们的平面不过球心，所以沿纬线飞并不划算。


术语卡片：大圆

直观解释：球面上的“直线”，球面上最直也最短的路线。正式定义：球面与过球心的平面相截得到的圆，也称测地线。一个例子：赤道和每一条经线圈都是大圆；北京到纽约的短航线沿着大圆走。

大圆登场之后，一件惊人的事发生了。在球面上，用大圆弧当“边”，可以围成三角形，叫做球面三角形。请看一个具体的：从北极点出发，沿一条经线向南走到赤道，再沿赤道向东走四分之一赤道周长，再沿另一条经线向北回到北极。三条边都是大圆弧，是一个标准的球面三角形。算算它的内角和。

定理 8.5 (有三个直角的三角形). 上述球面三角形的三个内角都是 90° ，内角和为 270° 。

证明. 分两步。第一步, 看赤道上的两个角。在交点处, 赤道的方向是正东, 经线的方向是正北——东西方向与南北方向互相垂直, 所以经线与赤道的夹角是 90° , 两个底角都是直角。第二步, 看北极处的顶角。两条经线在北极的夹角等于它们的经度差; 我们沿赤道走了四分之一个周长, 对应的经度差恰好是 $360^\circ \div 4 = 90^\circ$ 。三个角都是 90° , 加起来 270° 。□



270° ! 平面几何里, 三角形内角和永远是 180° , 这是我们学过的最铁的定律之一。可在球面上, 它失效了——不是差一点半, 而是整整多出 90° 。多出来的这部分叫**角盈**。先看看这个三角形到底有多大: 两条经线把球面从北极到南极切成四瓣, 赤道再把每瓣切成南北两半, 我们的三角形正好占其中一块, 也就是整个球面的八分之一。而且三角形越大, 角盈越大: 上面这个占了球面八分之一的大家伙角盈是 90° ; 如果你沿赤道只走八分之一周长就回家, 三角形变小, 顶角变成 45° , 内角和变成 225° , 角盈也随之减半。十九世纪初, 数学家把这份观察凝成了一条精确的定理: 球面三角形的角盈与它的面积成正比 (在半径为 R 的球面上, 角盈换算成弧度后恰好等于面积除以 R^2)。我们不给完整证明, 但直观是清楚的: 三角形越大, 它“裹住”的弯曲越多; 足够小的三角形几乎躺在平面上, 内角和也就几乎回到 180° 。

请你停下来体会最后这句话的分量。一只生活在球面上的蚂蚁, 不需要飞到太空去“看”地球是弯的——它只要在地面画一个三角形、量一量内角和, 就能发现自己世界的弯曲。弯曲不只是一种“从外面看到的形状”, 它写进了曲面内部的几何定律里, 用尺子、量角器和光就够探测。数学家把这叫做弯曲的**内蕴**性质。我们脚下的大地、我们头顶的星空, 都可以这样从内部探测。

连接线

本章的概念在书里书外都有远亲。向前看: “割线趋向切线”里的极限过程, 是第 9 章的主角; “切线的斜率”正是第 10 章导数的几何面孔; “曲率”和“球面上的几何”将在第 17 章长成微分几何。向外看: 全球卫星定位系统计算两点距离时用的是大圆而不是地图直线; 爱因斯坦的广义相对论更进一步, 认为引力不是力, 而是时空本身的弯曲——行星绕太阳运行, 走的正是弯曲时空里的“直线”。甚至连本章的蚂蚁都是真实的: 测绘工作者正是靠在地面上测量三角形的内角和, 来检验地球表面的形状。

一分钟实验

找一个橙子（或苹果、网球）、一支记号笔和一把软尺。在橙子中部画一个圆圈当“赤道”，再画两条经过“两极”的经线，让它们在极点处的夹角大约是直角——三条线围出一个球面三角形。把一小片纸撕成楔形当角度样板，或者直接用量角器贴着表面估一估三个角：你会发现每个角都接近 90° ，内角和明显大于 180° 。最后做一件更有破坏性的事：把橙子皮剥下来，试着把一块皮在平桌上摊平。你会发现它要么翘起来，要么裂开缝——球面无法既不拉伸又不撕裂地摊成平面。这正是所有世界地图都必须变形的原因，也是“弯曲”最实在的证据。

数学工具箱

本章往你的背包里放了五件新工具。

- **局部近似（放大法）**：研究弯曲，先盯住一小段放大；光滑曲线在局部像直线，光滑曲面在局部像平面。
- **割线到切线**：用平均走向逼近瞬时走向，切线是割线的极限位置，是曲线在一点处的直线替身。
- **曲率**：单位弧长上方向角的改变量，量“弯得有多厉害”；圆的曲率 $= 1/R$ ，直线曲率为 0。
- **大圆（测地线）**：曲面上“最直”的路线，由“最短”来定义，球面上就是过球心平面截出的圆。
- **角盈**：球面三角形内角和超过 180° 的部分，与面积成正比；它让弯曲成为可以从曲面内部测量的性质。

继续攀登

想继续往上爬的同学，可以记下这些关键词，日后在高中、大学或竞赛读物里与它们重逢：极限与导数（“无限接近”的严格化）；密切圆与曲率半径（曲线的二阶局部近似）；高斯曲率与高斯的“绝妙定理”——曲面的弯曲完全由曲面内部的测量决定；测地线与黎曼几何；以及广义相对论中“弯曲时空”的科普读物。每一个词背后，都站着本章已经见过的直观图景。

思考题**观察题**

1. 找一段你熟悉的弯路（上学的路线、操场的弯道、游乐场的过山车图），标出你认为曲率最大和最小的地方。提示：想象自己开车经过，方向盘在哪里打得最急？哪里几乎不用动？
2. 在地球仪上观察：赤道、经线圈、北纬 60° 纬线圈，哪些是大圆？沿北纬 60° 线从北京“正东”飞到同纬度的欧洲城市，是最短路线吗？提示：想象用一个平面去切地球，切面要经过球心；再看看这条纬线所在的平面经过球心吗？

证明题

1. 不用弧长公式 $s = R\theta$ ，改用“半圆”整体验证圆的曲率：沿半个圆走一圈，切线方向总共改变了多少？走过的路程是多少？两者相除，是否仍得 $\frac{1}{R}$ ？提示：半圆两端的切线方向恰好相反，圆弧长度是 πR 。
2. 证明本章那个“三个直角的球面三角形”的面积恰好是球面的八分之一，并验证：它的角盈（换算成弧度）等于面积除以 R^2 。提示：整个球面的面积是 $4\pi R^2$ ；八分之一球面由四个这样的三角形拼成还是八个？角盈是 $270^\circ - 180^\circ$ ，注意把角度换成弧度。

挑战题

1. 把一张长方形的纸卷成圆筒（不拉伸、不撕破）。纸上原来的一条直线段，卷起来后变成了什么？圆筒面上的“三角形内角和”大于 180° 吗？提示：纸既没拉伸也没撕裂，说明纸面上的所有长度、角度都没有改变——一只生活在纸面上的蚂蚁，能用本章的内角和方法区分“平面”和“圆筒面”吗？这件事和球面的情况有什么本质不同？
2. 一只蚂蚁带着一支小箭沿球面三角形的边爬行，每走一条边都让箭头尽量“指向前方、不打转”，转弯处随三角形的角改变方向。爬完一圈回到起点时，箭头的方向和出发时一样吗？差多少？提示：先在平面上试（答案应当是一样），再在球面直角三角形上试，把每次转弯的角度加起来，和角盈比一比。

通往下一章的门

回头清点一下，本章我们其实只做了一件事：把“无限小”请进了数学。光滑曲线放大到无穷倍像直线；切线是割线在 Q 无限接近 P 时的归宿；曲率是“无限小一段”上方向的改变率；球面上足够小的三角形，内角和无限接近 180° 。每一个关键概念，都站在一个“无限接近却永不到达”的过程上。

可是这个过程，我们今天全是靠直觉接住的。“ Q 滑向 P ”——滑到多近才算数？“无限接近”和“到达”到底差在哪？如果一套理论的地基建在这么模糊的动词上，我们凭什么相信它推出的结论？

两百多年前，数学家们就被同样的问题拷问着，并且吵了一个多世纪才给出答案。那个答案叫做**极限**——它能把“无限接近”翻译成不含糊的、可以检验的不等式语言。它是整个第三部的地基，也是导数、积分和一切“变化之学”的起点。下一章，我们就去直面这个躲在所有光滑与弯曲背后的幽灵：无限小，究竟是不是一个合法的数学对象？

第三部分

从变化走向无限——微积分与分析

第九章 极限：无限接近不是含糊其辞

这一章要对付的，是数学里最会“耍赖”的一个词：无限。你早就见过它了——循环小数 $0.333\dots$ 后面的省略号是无限，平行线“永不相交”是无限，连 $\sqrt{2}$ 的小数部分都拖着一条无限长的尾巴。可奇怪的是，初中数学一直在躲着它：老师会说“这个过程一直继续下去”，却很少说“继续下去到底得到了什么”。这一章我们不再躲。我们要看一看，两千多年前一个把人绕晕的悖论，是怎样逼着数学家发明出“极限”这个概念的；又是怎样把“无限接近”这句听起来模模糊糊的话，变成一条可以严格检查的规则。学完之后你会发现：无限并不神秘，神秘的只是没说清楚的无限。

9.1 一场永远跑不完的比赛？

想象一场特殊的赛跑。选手阿基里斯是传说中的飞毛腿，速度是每秒 10 米；他的对手是一只乌龟，速度只有每秒 1 米。为了公平起见（其实是故意找茬），乌龟先跑 100 米，阿基里斯才从起点出发。

请问：阿基里斯能追上乌龟吗？

你的直觉一定会喊：当然能！他快十倍呢，追上不过是几秒钟的事。可两千多年前，哲学家芝诺却讲了一个让人心里发毛的推理。他说：好，我们一步一步来看。

第一步，阿基里斯先跑到乌龟出发时的位置，也就是跑完 100 米。这需要 10 秒。可就在这 10 秒里，乌龟也没闲着，它往前爬了 10 米，到达了 110 米处。

第二步，阿基里斯再跑 10 米，到达 110 米处。这又花了 1 秒。而乌龟又趁机爬了 1 米，到了 111 米处。

第三步，阿基里斯跑 1 米，花 0.1 秒，乌龟又爬了 0.1 米……

发现规律了吗？每当阿基里斯到达乌龟“刚才所在的位置”，乌龟都已经又往前挪了一小段。这个过程可以一步接一步地说下去，第四步、第五步、第一万步，永远没有说完的时候。芝诺得意地宣布：既然追上的过程包含无限多个步骤，而每个步骤都要花一点时间，那么阿基里斯永远追不上乌龟。

这就是著名的芝诺悖论。说它“悖论”，不是因为它结论对，而是因为它看起来每一步都讲得通，结论却荒唐得离谱——谁都知道跑得快的人能追上爬得慢的乌龟。中国古代也有类似的说法，《庄子》里写着“一尺之棰，日取其半，万世不竭”：一根一尺长的木棒，每天取走它的一半，取一万年也取不完。东西方的古人不约而同地盯上了同一个怪物：无限分割。

9.2 先把直觉押在桌上

在学任何工具之前，先凭直觉猜一猜。下面三个说法，你觉得哪些对、哪些错？

第一，芝诺说的那无限多个时间段——10 秒、1 秒、0.1 秒、0.01 秒……加起来等于无穷大，所以追上要花无限长的时间。

第二， $0.999\cdots$ （9 无限循环）是一个比 1 小一点点的数，它永远接近 1，但不等于 1。

第三，一根木棒每天取走一半，取无限多天之后，木棒会剩下“无穷小的一点点”，而不是正好取完。

先别急着翻页，把你的猜测记下来。这一章结束时，你要回来给它们改卷。

这三个问题其实问的是同一件事：无限多个“越来越小的量”堆在一起，结果到底是什么？是有限的，还是无限的？是“差一点点”，还是“正好相等”？靠拍脑袋解决不了，因为直觉在这里出了名的不可靠。我们需要一套能把“无限接近”说清楚的语言。

9.3 第一次尝试：一项一项地加

最朴素的办法是：别管“无限”，我们就老实实在地加。芝诺那堆时间段是

$$10 + 1 + 0.1 + 0.01 + 0.001 + \cdots$$

我们把省略号砍掉，只加前面几项，看看会得到什么：

$$10 = 10,$$

$$10 + 1 = 11,$$

$$10 + 1 + 0.1 = 11.1,$$

$$10 + 1 + 0.1 + 0.01 = 11.11,$$

$$10 + 1 + 0.1 + 0.01 + 0.001 = 11.111.$$

有意思。每多加一项，结果就多在末尾添一个 1，一路朝着 $11.111\cdots$ 这个方向爬过去。把这张“爬坡记录”整理成表格，趋势就更清楚了：

加的项数 n	部分和 S_n	与 $\frac{100}{9}$ 的差距
1	10	$1.111\cdots$
2	11	$0.111\cdots$
4	11.11	$0.00111\cdots$
8	11.111111	约 1.1×10^{-7}

每多加两项，差距的小数点后就多出一个 0。而且 $11.111\cdots$ 这个无限循环小数，恰好等于分数 $\frac{100}{9}$ ，约等于 11.11 秒。这不正是“追上所需的时间”该有的答案吗？用路程除以相对速度也能验证：阿基里斯每秒比乌龟多跑 9 米，要追回 100 米的差距，需要 $\frac{100}{9}$ 秒。两条路指向同一个数，这让人松了一口气。

但先别庆祝，这个办法有两个大窟窿。

第一个窟窿：我们永远加不完。“只加前几项”得到的 11.11、11.111，每一个都只是近似值。凭什么说无限多项加起来的結果，就正好等于 $\frac{100}{9}$ ，而不是比它大一点点或小一点点？我们刚才实际上是“猜”出了答案，然后用另一种方法（相对速度）验证它猜得对。可如果换一道题，没有别的办法可以验证呢？猜，终究不是数学。

第二个窟窿更隐蔽：我们偷偷用了一个没证明的信念——“结果一路朝着 $\frac{100}{9}$ 爬，最后就到 $\frac{100}{9}$ ”。“一路朝着”和“最终到达”之间，隔着整整一个无限。直觉觉得这条缝可以跳过去，但数学要求我们把桥架起来。

反例警报

警惕这样一种说法：“反正加到后面每一项都小得可以忽略，所以总和就是前面那些项的值，后面不算也罢。”这在小数计算里或许够用，但它恰恰把真正的问题藏起来了。“小得可以忽略”到底是多小？是对谁来说可以忽略？如果你只关心秒的精度，0.001 秒可以忽略；如果你在调度一枚火箭，0.001 秒可能意味着几十米的偏差。“忽略”是一个工程决定，不是一个数学结论。数学要回答的是：把无限多项一项不丢地全算进去，结果到底存不存在，等于多少。

9.4 给“无限接近”下定义

要架桥，先要有桥墩。第一个桥墩是把“一串无穷无尽、但有先后顺序的数”当作一个整体来研究。

定义 9.1 (数列). 按照某种规律排成一队、可以一直写下去的数，叫做一个**数列**。排在第 n 个位置的数叫做数列的第 n 项，记作 a_n 。整个数列可以写成

$$a_1, a_2, a_3, \dots, a_n, \dots$$

比如我们刚才加出来的那些“部分和”，就是一个数列：

$$10, 11, 11.1, 11.11, 11.111, \dots$$

它的第 n 项是“前 n 个时间段之和”。注意数列和集合不一样：数列里的数有先后，可以重复出现，而且永远有“下一项”。研究无限过程的办法，就是把过程切成一站一站的，把每一站的结果排成数列，然后问：这个数列的“终点”是什么？

可是“终点”这个词本身就需要澄清。数列没有最后一项，哪来的终点？我们需要换一种问法，这就是极限思想的关键一跃：**不问数列“最后到达哪里”，而问数列“无限接近哪个数”**。那什么叫“无限接近”？“接近”是距离小，“无限接近”难道是“距离无限小”？“无限小”又是什么？我们刚说过，不能再用模糊的词去定义模糊的词。

数学家想出的办法非常聪明，他们把“无限接近”换成了一句可以逐字检查的话。先给你一个日常版本：

你想要多近，我就能让你看到多近——而且从那一步往后，永远保持那么近。

把它写成数学语言，就是数列极限的定义。

定义 9.2 (数列的极限，直观版本). 设有一个数列 $a_1, a_2, a_3, \dots$ 和一个数 L 。如果无论你指定一个多么小的正数 d ，我都能找出数列中的某一个位置 N ，使得从第 N 项往后的**所有项**，与 L 的距离都小于 d ，也就是

$$|a_n - L| < d \quad (n > N),$$

那么就说这个数列**收敛**到 L , L 叫做这个数列的**极限**, 记作

$$\lim_{n \rightarrow \infty} a_n = L.$$

这个定义值得逐句拆开看, 因为它是全书的重点之一。

首先, 它是一场你出题、我答题的游戏。你负责挑一个“接近标准” d ——可以是 0.1, 可以是 0.0001, 可以是亿分之一, 随便你挑多小。我负责证明: 数列从某一项开始, 所有项都落在以 L 为中心、宽度为 $2d$ 的“走廊” $(L-d, L+d)$ 里, 而且再也不跑出去。如果你挑一个更小的 d , 我可能要把位置 N 往后挪——比如从第 10 项挪到第 10000 项——但只要你肯出题, 我就总能答出来。只要这场游戏我永远赢, 极限就是 L 。

其次, 注意定义里没有一个字提到“无限小”, 也没有提到“无限接近”。它只用到了普通的不等式 $|a_n - L| < d$, 而 d 是一个普普通通的、大于零的数。妙处全在“无论多么小”这五个字里: 它用一个一个有限的、可以检查的挑战, 代替了对“无限”的直接谈论。这就是把含糊的“无限接近”说清楚的办法——不是给你一个神秘的无穷小量, 而是给你一个永不失败的应答程序。

这套语言来得并不容易。微积分刚诞生的时候, 数学家们直接使用“无穷小量”进行计算, 得出的结果往往正确, 却没人说得清无穷小到底是什么。批评者讥讽它是“消失了的量的鬼魂”: 一个量一会儿不是零 (否则不能当除数), 一会儿又是零 (否则舍不掉), 自相矛盾。争论持续了上百年, 直到十九世纪, 数学家们才下定决心把“无穷小”这个说不清的角色请出舞台, 换上刚才那种用不等式说话的走廊游戏。从那以后, “无限接近”不再是一种感觉, 而是一条可以逐字检查的规则。你在这一章见到的定义, 正是那场漫长争论的终点。


术语卡片: 极限

直观解释: 数列的极限就是它“想去的那个地方”。不需要真的到达, 但从某一站开始, 它会一直待在那个地方的任意小的附近。

正式定义: 对任意正数 d , 都存在位置 N , 使得 $n > N$ 时 $|a_n - L| < d$ 。

一个例子: 数列 $1, \frac{1}{2}, \frac{1}{3}, \frac{1}{4}, \dots$ 收敛到 0。你出 $d = 0.01$, 我答 $N = 100$, 因为从第 101 项起每一项都小于 0.01; 你出更小的 d , 我取一个比 $\frac{1}{d}$ 大的 N 就行。

用数轴画出来更清楚。下面这条数轴上, 黑点依次是数列 $\frac{1}{2}, \frac{3}{4}, \frac{7}{8}, \frac{15}{16}, \dots$ 的前几项。它们挤向 1, 而以 1 为中心的走廊 (虚线之间) 越来越窄, 但只要走廊还有宽度, 就总有某一项之后全体“入住”。



还要注意一个容易误会的地方: 收敛不等于到达。数列 $\frac{1}{n}$ 的每一项都大于 0, 没有任何一项等于 0, 但它的极限就是 0。极限描述的是趋势和归宿, 不要求“撞线”。反过来, 有些数列压根没有归宿: $1, -1, 1, -1, \dots$ 在两个值之间反复横跳, 你随便画一条宽度小于 2 的走廊, 无论套在 1 上还是套在 -1 上, 数列都会不断跑出走廊。这样的数列叫做**发散**, 它没有极限。

反例警报

再拆一个更精致的骗局。有人说：“数列 a_n 离 L 的距离一项比一项小，所以 L 就是它的极限。”对吗？看反例：数列 $\frac{1}{n}$ （也就是 $1, \frac{1}{2}, \frac{1}{3}, \dots$ ）到 -1 的距离是 $1 + \frac{1}{n}$ ，确实一项比一项小！按那个说法， -1 应该是它的极限。可它的极限明明是 0 。错在哪？错在“距离越来越小”太弱了—— $1 + \frac{1}{n}$ 虽然一直在缩小，却始终大于 1 ，根本缩不到“任意小”。极限定义里“无论 d 多小都能做到”这一关，它过不去。这个反例说明：**单调地靠近一个目标，和任意地接近一个目标，是两回事。**定义里每一个字都不是摆设。

9.5 核心定理：无限个越来越小的数可以加出确定的和

有了极限的语言，我们终于可以正面回答芝诺的问题了。先提出一个准确的命题。

定理 9.3 (无穷等比数列的和). 设首项为 a 、公比为 r 的等比数列 $a, ar, ar^2, ar^3, \dots$ ，其中 $|r| < 1$ 。把前 n 项加起来得到部分和

$$S_n = a + ar + ar^2 + \dots + ar^{n-1}.$$

那么当 n 无限增大时， S_n 收敛，且

$$\lim_{n \rightarrow \infty} S_n = \frac{a}{1-r}.$$

这个极限就叫做这个无穷等比数列各项的和，记作

$$a + ar + ar^2 + \dots = \frac{a}{1-r}.$$

注意这个定理的措辞：它没有说“把无限多项加起来”——那种操作我们根本不会做。它说的是：有限项的和 S_n 组成一个数列，这个数列收敛，我们把它的极限定义为无穷和。无限求和不是我们真的会做的加法，而是极限的别名。这个区别正是解开芝诺悖论的钥匙。

证明. 证明分两步。第一步，求出 S_n 的紧凑表达式，这是初中代数里的老技巧“错位相减”。由

$$S_n = a + ar + ar^2 + \dots + ar^{n-1},$$

两边同乘 r ，得

$$rS_n = ar + ar^2 + \dots + ar^{n-1} + ar^n.$$

两式相减，中间所有项全部抵消，只剩首尾：

$$S_n - rS_n = a - ar^n, \quad \text{即} \quad S_n = \frac{a(1-r^n)}{1-r}.$$

第二步，用极限的定义看 n 增大时会发生什么。把上式改写成

$$S_n = \frac{a}{1-r} - \frac{a}{1-r} r^n.$$

因为 $|r| < 1$ ， r^n 的绝对值随着 n 增大而不断缩小：比如 $r = 0.1$ 时， r^n 依次是 $0.1, 0.01, 0.001, \dots$ 。任给一个正数 d ，只要 n 足够大， $|r^n|$ 就能小到让 $\left| \frac{a}{1-r} \right| \cdot |r^n|$ 小于 d 。也就是说 S_n 与 $\frac{a}{1-r}$ 的距离可以任意小，按定义

$$\lim_{n \rightarrow \infty} S_n = \frac{a}{1-r}.$$

两步都是普通的代数与不等式推理，合在一起却跨越了无限。□

公式里的条件 $|r| < 1$ 不是摆设。如果 $r = 2$ ，数列的和是 $1 + 2 + 4 + 8 + \cdots$ ，越加越大，部分和一路奔向无穷，根本不收敛；如果 $r = -1$ ，和式变成 $1 - 1 + 1 - 1 + \cdots$ ，部分和在 1 和 0 之间来回跳，同样没有极限。这两种情况都发散， $\frac{a}{1-r}$ 这个公式一概不能套用。数学定理的条件就像电器的额定电压：插错了，再漂亮的公式也会烧掉。


这个证明里有一个值得停顿的地方：第二步为什么可信？因为它每一步都可以拿出来检查。你不信 r^n 能任意小？取 $r = \frac{1}{2}$ ，你出 $d = 10^{-9}$ ，我只要取 $n = 31$ ，就有 $2^{-31} < 10^{-9}$ 。你出更苛刻的 d ，我给出更大的 n 。没有玄学，只有应答。

推论 9.4 (芝诺悖论的解决). 阿基里斯追上乌龟所需的时间，是各阶段时间之和的极限：

$$10 + 1 + 0.1 + 0.01 + \cdots = \frac{10}{1-0.1} = \frac{100}{9} \text{ 秒}.$$

无限多个阶段不意味着无限长时间。芝诺推理的真正错误在于他默认了“无限多个正数相加必得无穷大”，而刚才的定理给出了反例。

还有一个更漂亮的看法：不套公式，直接看图。把一个面积为 1 的正方形，先取走一半，再把剩下部分取走一半，再取一半……每次取走的面积依次是 $\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{16}, \cdots$ 。从图里你能直接“看见”这些块正好拼满整个正方形：



图直观地说： $\frac{1}{2} + \frac{1}{4} + \frac{1}{8} + \cdots = 1$ ，和公式 $\frac{a}{1-r}$ 取 $a = \frac{1}{2}$ 、 $r = \frac{1}{2}$ 的结果完全一致。这也顺手回答了开头的第三个问题：“日取其半”的木棒，每天取下的长度加起来恰好等于 1 尺——无限天之后取走的总量正好是一整根，没有“剩下一点点”这回事。至于“每天取走一半，永远还有一半剩着”，那是过程永远不完结的意思；而“总量恰好是 1”说的是极限。两句话不矛盾，因为它们谈论的是不同的对象：一个是过程，一个是极限。把这两个对象混为一谈，正是芝诺悖论的病灶。

9.6 换一个视角：数轴上有没有洞

到目前为止我们一直在问“极限是多少”。现在换一个角度，问一个更深的问题：极限一定存在吗？它落在哪种数里？

看一个例子。数列

$$1, 1.4, 1.41, 1.414, 1.4142, \cdots$$

每一项都是有限小数，也就是有理数。它们越挤越拢：从某一项起，任意两项之间的距离可以任意小（因为它们的小数位相同的部分越来越长）。按直觉，它们应该挤向数轴上的某个点。可是我

们都知道，这个点对应的长度——边长为 1 的正方形的对角线——是 $\sqrt{2}$ ，而 $\sqrt{2}$ 不是有理数。如果我们只允许有理数存在，那么这个数列拼命地想收敛，却找不到归宿：它的极限“不在城里”。

这就像一部电梯匀速上升，却一直到达不了任何楼层——问题不在电梯，在大楼少盖了一层。有理数这根数轴上布满了这样的“洞”：随使用圆规在数轴上截一段对角线，落点就掉进一个洞里。

术语卡片：实数的完备性

直观解释：实数轴上没有洞。任何一个“越挤越拢”的数列（后文叫它柯西数列），都能找到一个实数作为它的极限。

正式定义：实数系满足完备性公理——每个柯西数列都收敛到某个实数；等价地，每个有上界的实数集合都有最小上界。

一个例子： $\sqrt{2}$ 就是数列 $1, 1.4, 1.41, \dots$ 的极限；不是先知道 $\sqrt{2}$ 再找数列，而是可以反过来，用这样的数列把 $\sqrt{2}$ “定义”出来。

完备性是一条公理——不是我们证明出来的，而是我们要求实数满足的性质。你可以把它理解成盖楼时的承诺：只要数列“应该”有极限，我们就保证数轴上有这个点，绝不缺货。正是在这个承诺之上，极限理论才站得稳，微积分的大厦才盖得起来。

完备性还有一个更朴素的化身，值得单独看一眼。想象一个贴着天花板不断吹大的气球：它每一步都在变大，却永远越不过天花板。直觉告诉我们，它只能越来越紧地贴向某个确定的高度。换成数列的语言就是：一个**每一项都不小于前一项、又全体不超过某个固定数的数列，必定收敛**。这叫做单调有界收敛原理，它和上面的柯西准则一样，都是“数轴没有洞”的不同说法。后文实验三里那个 $\left(1 + \frac{1}{n}\right)^n$ ，正是靠这条原理安身立命的：可以证明它单调递增，并且永远小于 3，所以它的极限必然存在——数学家是先证明了极限存在，才给这个极限起名叫 e 的。先有存在性，后有名字，这个顺序值得记住。

现在回头处理开头第二个问题： $0.999\dots$ 到底等不等于 1？先用定理 9.3 算一算。 $0.999\dots$ 的意思是无穷和

$$\frac{9}{10} + \frac{9}{100} + \frac{9}{1000} + \dots,$$

首项 $a = \frac{9}{10}$ ，公比 $r = \frac{1}{10}$ ，所以

$$0.999\dots = \frac{\frac{9}{10}}{1 - \frac{1}{10}} = \frac{\frac{9}{10}}{\frac{9}{10}} = 1.$$

没有“差一点点”，就是 1。觉得别扭吗？别扭的根源在于把 $0.999\dots$ 想成“一个正在往 1 爬、永远爬不到的数”。但它不是过程，它是那个无穷和的极限值，而极限值就是 1。换句话说：1 和 $0.999\dots$ 是同一个实数的两种写法，就像 $\frac{1}{2}$ 和 $\frac{2}{4}$ 是同一个分数的两种写法一样。事实上每一个有限小数都有这样一对“双胞胎写法”，比如 $0.5 = 0.4999\dots$ 。

连接线

极限的想法并不只属于纯数学。你在科学课上学过的“理想气体”“光滑斜面”“瞬时速度”，全是极限的产物：真实气体分子有大小，理想气体是把分子大小趋向 0 的极限；真实斜面有摩擦，光滑斜面是摩擦趋向 0 的极限。工程师在计算机里模拟天气、设计芯片，也靠极限的反面操作——把连续变化切成有限多步来算，步数越多越接近真相。你手机里的每一场天气预报，都是“有限步逼近无限”的产物。这一章学的极限，正是下一章导数的地基：导数就是“平均变化率当时间间隔趋向 0 时的极限”。

数学工具箱

本章新添的工具：

- **数列**：把无限过程切成一站一站，研究这个“站队”而不是空想无限本身。
- **极限的定义（走廊游戏）**：对任意正数 d ，存在位置 N ， $n > N$ 时 $|a_n - L| < d$ 。用它可以把“无限接近”翻译成可检查的不等式。
- **无穷等比数列求和**： $|r| < 1$ 时 $a + ar + ar^2 + \cdots = \frac{a}{1-r}$ 。无穷和是部分和的极限，不是“真的加无限多次”。
- **完备性的观念**：实数轴没有洞，该收敛的数列都有归宿。

9.7 数学实验

一分钟实验

实验一：亲手“加”出一个无穷和。找一张计算器，依次计算

$$\frac{1}{2}, \quad \frac{1}{2} + \frac{1}{4}, \quad \frac{1}{2} + \frac{1}{4} + \frac{1}{8}, \quad \cdots$$

每加一项记录一次结果，至少加到 $\frac{1}{2^{10}} = \frac{1}{1024}$ 。你会得到 0.5, 0.75, 0.875, 0.9375, ...。观察：每加一项，结果与 1 的距离缩小为原来的一半。再算一算，加到第几项时结果与 1 的距离小于 0.001？对照走廊游戏，你出的 $d = 0.001$ 对应的 N 是多少？

实验二：给 $\sqrt{2}$ 修一条“逼近公路”。不用开方键，只用四则运算。从区间 $[1, 2]$ 开始，计算中点 1.5，因为 $1.5^2 = 2.25 > 2$ ，所以 $\sqrt{2}$ 在 $[1, 1.5]$ 里；再取中点 1.25，平方后与 2 比较，决定取左半还是右半……每做一次，区间长度减半。做 8 次，记下每次的区间端点，你会得到 $\sqrt{2} \approx 1.414$ 。想想：这个“区间套”过程和 $\sqrt{2}$ 的小数展开 1, 1.4, 1.41, ... 有什么共同点？如果数轴上有洞，这个实验还能保证夹出一个数吗？

实验三（选做）：一个会变魔术的数。计算 $\left(1 + \frac{1}{n}\right)^n$ ： $n = 1$ 时是 2， $n = 10$ 时约 2.594， $n = 100$ 时约 2.705， $n = 1000$ 时约 2.717。它似乎在收敛，而且收敛到一个以 2.718 开头的神秘数。先记下这个观察，本章末尾的思考题会再回到它。

思考题

观察题

1. 观察数列 $\frac{1}{2}, \frac{2}{3}, \frac{3}{4}, \frac{4}{5}, \dots$ (第 n 项是 $\frac{n}{n+1}$)。先算前几项猜出它的极限，再算一算第 n 项与这个极限的距离是多少。**提示：**把 $\frac{n}{n+1}$ 改写成 $1 - \frac{1}{n+1}$ ，距离就一目了然了。
2. 用本章定理把 $0.333\dots$ 和 $0.121212\dots$ 分别写成分数。观察第二个数：它的“公比”是多少？**提示：** $0.121212\dots$ 每两位循环一次，可以看成首项 $\frac{12}{100}$ 、公比 $\frac{1}{100}$ 的无穷等比数列。

证明题

1. 用走廊游戏严格证明：数列 $\frac{1}{n}$ 收敛到 0。也就是对任意正数 d ，明确写出你要取的 N （可以依赖于 d ），并说明为什么 $n > N$ 时 $\left| \frac{1}{n} - 0 \right| < d$ 。**提示：**你需要的只是 $\frac{1}{n} < d$ ，两边取倒数看看 n 该多大。
2. 证明一个数列不可能同时收敛到两个不同的数 L 和 M 。**提示：**设 L 和 M 之间的距离为 $h > 0$ 。取走廊宽度 $d = \frac{h}{2}$ ，分别以 L 、 M 为中心画走廊——这两条走廊互不重叠。如果数列最终同时待在两条走廊里，会发生什么矛盾？

挑战题

1. 实验三里那个数列 $\left(1 + \frac{1}{n}\right)^n$ 看起来在收敛。查一查或者想一想：它的极限叫做自然常数 e ，约等于 2.71828。有趣的是，这个数列每一项都是有理数，极限 e 却是无理数。结合本章关于完备性的讨论，说说这件事为什么一点也不奇怪。**提示：**回忆 $\sqrt{2}$ 的例子——“每一项是哪种数”和“极限是哪种数”是两个独立的问题。
2. 芝诺还有第二个悖论“飞矢不动”：飞行的箭在每一瞬间都占据一个确定的位置，所以它在每一瞬间都是静止的，因此箭从未运动。用本章的语言指出这个推理的漏洞。**提示：**想想“位置在每一瞬间确定”和“没有运动”之间的跳跃，是不是又把“过程”和“极限”搞混了？“某一瞬间的速度”到底该如何定义？这正是下一章要解决的问题。

继续攀登

继续往上爬，你会遇到这些风景：把本章的 d 换成希腊字母 ε 、把 N 的选取写成严格证明，就是大学数学分析里的“ ε - N 语言”；“越挤越拢的数列必有极限”的严格表述叫柯西收敛准则，它和“单调有界数列必收敛”等价，都是实数完备性的化身；无穷等比数列推广成一般的无穷级数，判别它们收敛还是发散是级数理论的开端；而 $\left(1 + \frac{1}{n}\right)^n$ 的极限 e 会在对数、复利和微分方程里反复登场。竞赛中常见的“放缩法”求极限、以及“夹逼定理”（两边都挤向 L ，中间无处可逃），本质上都是走廊游戏的变体。

通往下一章的门

这一章我们驯服了“无限多个量的累加”。但芝诺的飞矢还悬在半空，留下一个更刁钻的问题：什么叫“某一瞬间”的速度？

汽车仪表盘显示时速 60 公里，这个数是哪儿来的？速度是路程除以时间——可“一瞬间”的时间里，汽车走的路程是 0，时间也是 0， $\frac{0}{0}$ 是什么？都不是。直觉又失灵了。

出路你已经见过雏形了：别问“那一瞬间”，改问“从那时起的一小段时间”。算一算 1 秒内的平均速度、0.1 秒内的、0.01 秒内的……如果这些平均速度排成的数列收敛，它的极限就有资格被称作“瞬时速度”。同样地，曲线上某一点的切线斜率，是割线斜率当两点靠拢时的极限。

平均变化率的极限，就是导数。下一章，我们把走廊游戏搬进函数的世界，去看看“变化”本身如何被精确地度量。

第十章 导数：曲线在某一点的速度

10.1 过山车上一个问题

游乐场里最刺激的设施是过山车。车爬上一个又高又缓的坡，突然俯冲下去，再被甩上一个几乎竖直的环。坐在车里的人有一种特别清楚的感受：有些地方“平”，有些地方“陡”，有些地方正在“拐弯”，而速度好像每一瞬间都不一样。

现在我们把过山车的轨道画在坐标纸上，让它成为一条曲线 $y = f(x)$ ：横坐标 x 是水平距离，纵坐标 y 是离地高度。过山车手描述体验时说的是“这里最陡”“这里开始下坡”“这里几乎是平的”。这些话在数学上能精确表达吗？

再看一个更朴素的场景。一辆车沿公路行驶，里程表告诉你：上午 10 点，已经开了 120 千米；上午 11 点，开了 180 千米。于是你说：“这一小时的平均速度是 60 千米每小时。”这谁都同意。但交警拿出的测速照片显示：10 点 23 分 15 秒，这辆车正以 92 千米每小时的速度通过一个限速 80 的路段。请注意这个区别：交警说的不是“某段时间的平均速度”，而是“那一瞬的速度”。一瞬间时间间隔是零，路程增量也是零，速度难道不是 $\frac{0}{0}$ 吗？

这两个场景——轨道在某点的陡峭程度，汽车在某瞬的速度——其实是同一个数学问题。这个问题困扰了数学家很多年，而解决它的工具，就是本章的主角：导数。

10.2 先猜一猜：瞬时速度到底存不存在

在继续之前，你可以先凭直觉回答几个问题：

- 我们说“某一时刻的速度是 92 千米每小时”，这句话真的有含义吗，还是只是口头方便？
- 一条弯弯曲曲的线，在它的某一个“点”上，谈“陡峭程度”合理吗？陡峭难道不是一整段路的事？
- 如果瞬时速度存在，为什么 $\frac{0}{0}$ 没有把它毁掉？

很多人凭直觉会说：“某一瞬间当然有一个确定的速度，我骑车的时候能感觉到。”另一些人会警觉起来：“速度的定义是路程除以时间，时间间隔为零，这个除法就没意义了。”两边都对：直觉对了一半，警觉也对了一半。数学家干的事，就是把两边的直觉都翻译成一个不矛盾的精确定义。上一章讲的极限，正是为这个翻译准备的工具。

这场翻译在十七世纪真的发生过，而且是两次。牛顿在研究行星为什么那样运行时，需要处理“每一瞬间的速度”，他管变化率叫“流数”；莱布尼茨则从几何问题出发，研究曲线的切线，发明了沿用至今的 $\frac{dy}{dx}$ 记号。两人各自独立地抓住了同一个思想，后来却为“谁先发明”争了很多

年，甚至惊动了欧洲各国学会站队。这场争论在今天看来有些可惜：两人问的问题看似不同——一个来自运动，一个来自切线——答案却是同一个概念。这恰好说明这个概念有多自然：只要认真追问“变化”本身，谁都会走到它面前。

10.3 第一次尝试：用很短的时间间隔

我们先试着解决汽车的问题。设汽车行驶的路程随时间变化的规律是 $s(t) = t^2$ （单位是千米和小时，数字当然不真实，但道理一样）。问题是： $t = 2$ 这一时刻，瞬时速度是多少？

第一种尝试：取一个很小的间隔，比如 $\Delta t = 0.1$ 小时，算平均速度

$$\frac{s(2.1) - s(2)}{0.1} = \frac{4.41 - 4}{0.1} = 4.1 \text{ 千米每小时.}$$

再取 $\Delta t = 0.01$ ：

$$\frac{s(2.01) - s(2)}{0.01} = \frac{4.0401 - 4}{0.01} = 4.01 \text{ 千米每小时.}$$

$\Delta t = 0.001$ 时答案是 4.001； $\Delta t = 0.0001$ 时答案是 4.0001。你看，间隔越短，答案越逼近 4。于是我们猜： $t = 2$ 时的瞬时速度是 4 千米每小时。

把这张“逼近过程”列成表格，会更清楚。我们还可以从左侧逼近——取 $t = 2$ 之前的一小段，看看两边是不是奔向同一个数：

Δt	1	0.1	0.01	0.001
从右侧： $\frac{s(2+\Delta t)-s(2)}{\Delta t}$	5	4.1	4.01	4.001
从左侧： $\frac{s(2)-s(2-\Delta t)}{\Delta t}$	3	3.9	3.99	3.999

右列数字从上方逼近 4，左列数字从下方逼近 4，两边在同一个地方会师。这个“两边会师”很关键：如果只从一侧逼近，另一侧却奔向别的数，那就说明这一瞬的速度并不存在——本章后面思考题里的 $y = |x|$ 在原点处正是这种情况。

但请注意，我们始终不敢把 Δt 真正取成 0，因为那样分子分母都是 0。我们真正用到的想法是： Δt 可以任意小，而平均速度可以任意接近 4——这正是上一章“极限”的语言。瞬时速度不是某个很短的间隔算出来的平均速度，而是间隔趋于零时平均速度的极限。

用符号写出来：当 Δt 趋于 0 时， $\frac{s(t+\Delta t)-s(t)}{\Delta t}$ 的极限，就是时刻 t 的瞬时速度。

反例警报

有个流传很广的“证明”是错的：既然瞬时速度是时间间隔为零时的速度，那就把 $\Delta t = 0$ 代进去，得到 $\frac{0}{0}$ ，所以瞬时速度不存在。

错在哪里？极限不是“代入”。 Δt 趋于 0 指的是它可以任意小，但始终不是 0。像 $\frac{s(t+\Delta t)-s(t)}{\Delta t}$ 这样的表达式，在 $\Delta t \neq 0$ 时常常可以先化简：例如 $\frac{(2+\Delta t)^2-4}{\Delta t} = \frac{4\Delta t+(\Delta t)^2}{\Delta t} = 4 + \Delta t$ ，化简之后再让 Δt 趋于 0，就得到干干净净的 4。整个过程中我们一次也没有真正除以零。


10.4 把同一个想法搬到曲线上：割线与切线

现在我们转到几何。看抛物线 $y = x^2$ ，想在点 $(1, 1)$ 处描述它的“陡峭程度”。一条直线的陡峭程度用斜率刻画，可这是一条弯的线，哪来的斜率？

模仿汽车问题的做法：不取一个点，取两个点。在曲线上另取一点 $(1+h, (1+h)^2)$ ，连接这两点的直线叫做割线，它的斜率是

$$\frac{(1+h)^2 - 1}{h} = \frac{2h + h^2}{h} = 2 + h.$$

取 $h = 1$ ，割线斜率是 3； $h = 0.1$ ，是 2.1； $h = 0.01$ ，是 2.01。让 h 趋于 0，割线的斜率趋于 2。在几何上这意味着：当第二个点沿着曲线滑向 $(1, 1)$ 时，割线不断转动，最后“卡”在一条确定的直线上——这条直线就是曲线在该点的切线，它的斜率就是 2。



现在两件事合一了：路程函数的瞬时速度，等于路程图像上切线的斜率。这个合一值得停一秒——代数里的“速度”和几何里的“斜率”，本来是两个世界的东西，在这里成了同一个数。这个数叫导数。

术语卡片：切线

直观解释：在切点附近与曲线“贴合得最好”的那条直线——它不是“只碰一个点”的线（抛物线的对称轴也只碰顶点一个点，却不是切线），而是曲线在该点前进方向的化身。正式定义：过曲线上定点与邻近点的割线，在邻近点趋于定点时的极限位置。一个例子： $y = x^2$ 在 $(1, 1)$ 处的切线是 $y = 2x - 1$ ，它从曲线下方整个托住抛物线。

定义 10.1 (导数). 设函数 f 在点 x 附近有定义。如果极限

$$f'(x) = \lim_{\Delta x \rightarrow 0} \frac{f(x + \Delta x) - f(x)}{\Delta x}$$

存在，就称 f 在 x 处可导，这个极限叫做 f 在 x 处的导数，记作 $f'(x)$ （物理学家也常写 $\frac{dy}{dx}$ ）。

术语卡片：导数

直观解释：函数在某一点“每走一小步横坐标，纵坐标大约变化多少”，也就是曲线在该点切线的斜率。正式定义：平均变化率在区间长度趋于零时的极限。一个例子： $f(x) = x^2$ 在 $x = 1$ 处导数为 2，意味着在 $(1, 1)$ 附近，横坐标每增加一点点，纵坐标大约增加它的两倍那么多。

10.5 亲手算几个导数： x^2 、 x^3 和一次函数

定义好不好用，算了才知道。我们用定义把三个函数的导数从头发明一遍。

先看 $f(x) = x^2$ 。对任意的 x ：

$$\frac{f(x+h) - f(x)}{h} = \frac{(x+h)^2 - x^2}{h} = \frac{2xh + h^2}{h} = 2x + h.$$

让 h 趋于 0，得到 $f'(x) = 2x$ 。这一个公式就把整条抛物线上每一点的切线斜率都装进去了： $x = 1$ 处斜率 2（正是刚才割线实验的结果）； $x = 0$ 处斜率 0，说明抛物线在最底部是水平的； $x = -3$ 处斜率 -6 ，负数表示曲线正在下降。

再看 $f(x) = x^3$ 。这里要用一个中学代数恒等式：

$$(x+h)^3 = x^3 + 3x^2h + 3xh^2 + h^3.$$

于是

$$\frac{(x+h)^3 - x^3}{h} = \frac{3x^2h + 3xh^2 + h^3}{h} = 3x^2 + 3xh + h^2.$$

h 趋于 0 时，后两项消失，得到 $f'(x) = 3x^2$ 。注意一个有趣的事： $3x^2$ 永远非负，这说明 x^3 这条曲线处处都在“往上走或走平”，最平缓的地方是原点，那里斜率为 0——但注意，它不是山峰也不是谷底，只是一个“歇脚处”。你还可以比较两条曲线“变陡”的节奏： x^2 的斜率 $2x$ 随 x 均匀增长， x^3 的斜率 $3x^2$ 却越涨越快。到 $x = 10$ 时，抛物线的切线斜率是 20，而三次曲线已经达到 300。导数不只告诉你某一点有多陡，还告诉你“陡峭本身”如何变化——这个思想在后面会自己长成一个新的研究对象。

最后看一次函数 $f(x) = kx + b$ ：

$$\frac{k(x+h) + b - (kx + b)}{h} = \frac{kh}{h} = k,$$

导数就是 k 本身。这当然应该如此：直线处处一样陡，它的“切线”就是它自己。

例 10.2. 火箭点火后离地高度 $h(t) = 5t^2$ 米，求 $t = 10$ 秒时的瞬时速度。

因为 $h(t) = 5t^2$ ，套用 x^2 的求导结果（常数倍数会原样跟着走，理由下面讲）， $h'(t) = 10t$ 。所以 $t = 10$ 秒时瞬时速度是 100 米每秒。注意我们一步平均速度都没算，但给出的答案比任何一段平均速度都精确——它说的就是“第 10 秒那一瞬”。

10.6 为什么导数有用：局部线性近似

导数最深刻的含义，不是“一个斜率”，而是“一条曲线在一个点附近的最好直线替身”。

回到 $f(x) = x^2$ 在 $x = 1$ 处。切线方程是 $y = 2x - 1$ 。我们比较一下曲线和切线在 $x = 1.02$ 处的值：曲线给出 $1.02^2 = 1.0404$ ，切线给出 $2 \times 1.02 - 1 = 1.04$ 。两者相差只有 0.0004！也就是说，在 $x = 1$ 附近，如果你懒得算平方，直接用切线 $2x - 1$ 去近似 x^2 ，误差小到可以忽略。把镜头怼得足够近，任何光滑曲线都“变成”了直线——第 8 章预告过的“局部像直线”，现在有了精确的度量：那条直线就是切线，它的斜率就是导数。

这件事有一个直接的应用：估算。比如估算 $\sqrt{4.1}$ 。函数 $g(x) = \sqrt{x}$ 的导数可以算是 $\frac{1}{2\sqrt{x}}$ （极限定义配合分子有理化可得），在 $x = 4$ 处导数是 $\frac{1}{4}$ 。用切线近似：

$$\sqrt{4.1} \approx \sqrt{4} + \frac{1}{4} \times 0.1 = 2 + 0.025 = 2.025.$$

真值约是 2.02485，误差不到 0.0002。没有计算器也能得到三位有效数字——导数替我们干的。

值得把这个近似公式单独端详一遍：

$$f(x_0 + \Delta x) \approx f(x_0) + f'(x_0) \Delta x.$$

左边是曲线上真实的点，右边是切线上的点。整件事的结构是：“现在的值”加上“变化率乘以步长”。变化率越大，同样一小步造成的变化就越大——这正和我们日常的直觉吻合：陡坡上的每一步都更费力。但要记住这个近似的边界：它只在 Δx 很小时可靠，而且曲线越“弯”（二阶导数越大），近似失效得越快。近似不是糊弄，而是标明了误差的权衡取舍。

数学工具箱

本章新工具：

- **导数**：平均变化率的极限，几何上是切线斜率，物理上是瞬时速度。
- **幂函数求导**： $(x^n)' = nx^{n-1}$ （本章算了 $n = 2, 3$ 两种）。
- **局部线性近似**： $f(x_0 + \Delta x) \approx f(x_0) + f'(x_0) \Delta x$ ，离 x_0 越近越准。
- **导数符号的解读**： $f' > 0$ 表示函数上升， $f' < 0$ 表示下降， $f' = 0$ 是可能的“山头、谷底或歇脚处”。

10.7 函数之间怎么求导：乘法与链式法则

会算 x^2 和 x^3 还不够，现实中的函数常常是“组装”出来的：两个函数相乘、一个函数套着另一个函数。导数能不能也“组装”？

两个函数相加最简单： $(f + g)' = f' + g'$ ，因为和的增量就是增量的和，用定义一推就有。常数倍也一样： $(cf)' = cf'$ 。

但乘法麻烦得多。很多人第一反应是“乘积的导数等于导数的乘积”。错。立刻拿具体例子戳穿： $x^3 = x \cdot x^2$ ，两边我们都认识。 x^3 的导数是 $3x^2$ ；而 x 的导数是 1， x^2 的导数是 $2x$ ，乘起来只有 $2x$ ，差得远。正确的规则要复杂一点。

定理 10.3 (乘积法则). 若 f 与 g 都在 x 处可导，则

$$(fg)'(x) = f'(x)g(x) + f(x)g'(x).$$

证明. 考察乘积的差商, 并在分子上“借一项、还一项”:

$$\frac{f(x+h)g(x+h) - f(x)g(x)}{h} = \frac{f(x+h)g(x+h) - f(x)g(x+h)}{h} + \frac{f(x)g(x+h) - f(x)g(x)}{h}.$$

第一项提出 $g(x+h)$, 剩 $\frac{f(x+h)-f(x)}{h} g(x+h)$; 第二项提出 $f(x)$, 剩 $f(x) \frac{g(x+h)-g(x)}{h}$. 令 h 趋于 0: 两个差商分别趋于 $f'(x)$ 和 $g'(x)$, 而 $g(x+h)$ 趋于 $g(x)$ (可导的函数必定连续, 这一点可用定义直接验证). 于是极限是 $f'(x)g(x) + f(x)g'(x)$. $\square$

几何上这个公式很形象: 把 f 和 g 想象成一个矩形的两条边长, 面积就是 fg . 两条边都变长一点, 面积的变化由两块组成——“长边增长”贡献一块, 由现在的宽乘以长的变化率; “宽边增长”贡献一块, 由现在的长乘以宽的变化率。(严格说还有一个小角, 是两块小增量的乘积, 在极限里可以忽略.)

验证一下刚才的反例: $x^3 = x \cdot x^2$, 按乘积法则, 导数是 $1 \cdot x^2 + x \cdot 2x = x^2 + 2x^2 = 3x^2$. 完全对上了。

再说函数套函数, 比如 $y = (x^2 + 1)^3$. 这里面有个“内层” $u = x^2 + 1$, 一个“外层” u^3 . 直觉是: x 动一点, u 跟着动, u 一动, y 再动. 变化率应该连乘。

定理 10.4 (链式法则). 若 $u = g(x)$ 在 x 处可导, $y = f(u)$ 在对应的 u 处可导, 则复合函数 $y = f(g(x))$ 在 x 处可导, 且

$$\frac{dy}{dx} = \frac{dy}{du} \cdot \frac{du}{dx}.$$

我们不证完整版 (需要一点关于“两个极限过程交换”的技术细节), 但说明它为什么合理: 当 Δx 很小时, $\Delta u \approx g'(x)\Delta x$, $\Delta y \approx f'(u)\Delta u$, 代进去就是 $\Delta y \approx f'(u)g'(x)\Delta x$. 两个近似的误差在取极限后消失。

算一下例子: $y = (x^2 + 1)^3$. 外层 u^3 的导数是 $3u^2$, 内层 $x^2 + 1$ 的导数是 $2x$, 链式法则给出

$$y' = 3(x^2 + 1)^2 \cdot 2x = 6x(x^2 + 1)^2.$$

要知道这有多省事, 可以试试把 $(x^2 + 1)^3$ 展开成 $x^6 + 3x^4 + 3x^2 + 1$ 再逐项求导, 结果当然是 $6x^5 + 12x^3 + 6x$, 因式分解后一模一样——但链式法则一行就写完了, 而且还告诉你变化是“哪一环贡献的”。

10.8 换一个视角：误差、优化与经济学中的边际

导数一旦普及, 许多原本“试着来”的问题就有了系统解法。这里看四个视角。

误差估计。你量一个正方形的边长, 量出 10 厘米, 但尺子有误差, 真实边长可能是 10 ± 0.05 厘米。面积的误差有多大? 面积 $S = x^2$, 导数 $S' = 2x$, 在 $x = 10$ 处是 20。用局部线性近似: 边长差 0.05, 面积约差 $20 \times 0.05 = 1$ 平方厘米。导数告诉你“测量误差会被放大多少倍”——这个倍数就是导数本身。这也是工程师检验一个设计“稳不稳”的第一件事: 如果某个量的导数很大, 微小的制造误差就会被放大成严重后果。

优化。用 40 米围栏靠墙围一个矩形菜园 (墙占一条长边), 怎样围面积最大? 设宽为 x 米, 长就是 $40 - 2x$ 米, 面积

$$S(x) = x(40 - 2x) = 40x - 2x^2.$$

以前这类题靠配方或画图猜，现在有导数： $S'(x) = 40 - 4x$ 。导数为正，面积随 x 增加而增加；导数为负，面积开始减少；所以从增到减的转折点一定在导数为零处： $40 - 4x = 0$, $x = 10$ 。此时长为 20 米，最大面积 200 平方米。山顶和谷底共同特征是“切线水平”，即导数为零——这是找极值的第一张地图（当然还要检查是不是边界或歇脚处，见下面的反例警报）。

边际。经济学家问的不是“一共生产了多少”，而是“再多生产一件，成本增加多少”。成本函数 $C(x)$ 在产量 x 处的导数叫边际成本。一个工厂总成本 $C(x) = 1000 + 20x + 0.01x^2$ 元，产量 100 件时的边际成本是 $C'(100) = 20 + 0.02 \times 100 = 22$ 元。这意味着第 101 件产品大约增加 22 元成本——注意是“大约”，因为导数是连续的局部近似，而产品是一件一件离散的。明确适用边界，这是用数学建模的好习惯。

运动。回到本章开头的汽车。路程的导数是速度，那速度的导数是什么？是速度变化的快慢——加速度。电梯启动的一瞬间你感到轻微下坠，转弯时身体被甩向一侧，你感受到的都不是速度本身，而是加速度。设自由落体的下落距离是 $s(t) = 4.9t^2$ 米，那么速度是 $v(t) = s'(t) = 9.8t$ 米每秒；速度再求一次导数， $v'(t) = 9.8$ ，是一个常数——这正是伽利略在斜面实验里发现的事实：无论多重、无论下落了多久，物体下落的加速度几乎不变。导数连求两次，就把伽利略成箱的实验数据压缩成了一行公式。物理学家把“导数的导数”叫二阶导数，它描述了曲线“弯得有多快”，在第 8 章预告过的曲率概念里还会再见面。

连接线

导数把本书前几章串了起来：第 2 章的斜率是常数函数的特例；第 8 章“曲线局部像直线”的承诺，在本章变成了切线与导数；第 9 章的极限，是导数定义的骨架。往后看，第 12 章会证明“导数为零的点是极值候选点”的严格版本，第 17 章会把“切线”升级成曲面的“切平面”。而在物理、经济、生物里，凡是有“变化率”的地方——人口增长、放射性衰变、传染病扩散——导数都是第一语言。

一分钟实验

实验一：望远镜里的切线。在方格纸上画出 $y = x^2$ （取 x 从 -3 到 3 ，每个整点描点连线）。用直尺在 $(2, 4)$ 处沿曲线方向轻轻画出一条“只碰不跨”的直线，量它的斜率（数格子算“升多少除以走多少”）。再算一算：理论上应该是 $2x = 4$ 。你的手画结果离 4 有多远？

实验二：切线估算。不许用计算器，利用 $f(x) = x^2$ 在 $x = 5$ 处的切线估算 5.1^2 。切线是 $y = 10x - 25$ ，代入 $x = 5.1$ 得 26。真实值 26.01，你的估算差了 0.01。再用同样方法估 5.5^2 ，看看误差变成多少，体会“离切点越远，近似越差”。

实验三：斜率的符号侦探。随手画一条光滑曲线（比如先上升、再下降、再上升的波浪线），不计算，只在图上的几个点标注该处导数是正、是负还是零。然后同桌交换检查。这个游戏练的是“看见导数”的眼睛。

10.9 再看一眼“山顶”：导数为零与极值

刚才围栏问题里我们用了“极大值处导数为零”。把它写成一条正式的定理。

定理 10.5 (极值的必要条件). 设 f 在某个区间内部的可导点 x_0 处取得最大值或最小值，则 $f'(x_0) = 0$ 。

证明. 以最大值为例. 既然 $f(x_0)$ 是最大, 那么对任何非零的 h (只要 $x_0 + h$ 还在区间里) 都有 $f(x_0 + h) \leq f(x_0)$. 当 $h > 0$ 时, 差商 $\frac{f(x_0+h)-f(x_0)}{h} \leq 0$, 取极限得 $f'(x_0) \leq 0$; 当 $h < 0$ 时, 分母变负, 不等式翻转, 差商 ≥ 0 , 取极限得 $f'(x_0) \geq 0$. 一个数既不大于 0 又不小于 0, 只能是 0. $\square$

注意这条定理的语言很克制: 它只说“在山顶, 切线一定水平”, 从不说“切线水平的地方一定是山顶”. 这个区别至关重要.

反例警报

有人说: “ $f'(x_0) = 0$, 所以 x_0 处是极大值或极小值.” 举 $f(x) = x^3$ 就戳穿了: $f'(x) = 3x^2$, 在原点处导数为 0, 可原点左边函数值为负、右边为正, 曲线一路单调上升, 原点既不是山顶也不是谷底——它只是我们前面说的“歇脚处”(数学上叫驻点或拐点情形).

还有第二个坑: 定理要求“区间内部”. $f(x) = x$ 在 $[0, 1]$ 上的最大值在 $x = 1$ 处取得, 但那里导数是 1, 不是 0. 闭区间上的最值还可能藏在端点. 所以找最值的完整流程是: 算出所有导数为零的点、导数不存在的点, 再加上端点, 逐个比较函数值——一张候选名单, 一个都不能漏.

推论 10.6. 若可导函数 f 在区间上处处满足 $f'(x) = 0$, 则 f 是常数函数.

这条推论听起来平凡, 却是微积分里最有用的“侦探工具”之一: 想知道两个函数是不是只差一个常数, 只要算它们的差的导数是不是恒为零. 它的严格证明需要第 12 章的中值定理, 我们这里先记下它作为悬念.

10.10 挑战：亲手算一条“会拐弯的跑道”

综合本章工具, 解一个完整问题. 游乐园设计一条滑道, 高度(米)随水平距离 x (米)变化: $y = x^3 - 6x^2 + 9x + 1$ ($0 \leq x \leq 4$). 问: (1) 滑道在哪里最陡地下降? (2) 滑道的最高点和最低点在哪里?

先求导. 逐项来: $(x^3)' = 3x^2$, $(-6x^2)' = -12x$ (常数倍法则), $(9x)' = 9$, 常数项导数为 0. 所以

$$y' = 3x^2 - 12x + 9 = 3(x^2 - 4x + 3) = 3(x-1)(x-3).$$

导数为零的点: $x = 1$ 和 $x = 3$. 看符号: $x < 1$ 时两个因子同号(都负), 导数为正, 滑道上升; $1 < x < 3$ 时导数为负, 下降; $x > 3$ 时又为正, 上升. 所以 $x = 1$ 是山顶, $y(1) = 1 - 6 + 9 + 1 = 5$ 米; $x = 3$ 是谷底, $y(3) = 27 - 54 + 27 + 1 = 1$ 米.

但题目问的是闭区间 $[0, 4]$ 上的最高最低点, 端点也要查: $y(0) = 1$, $y(4) = 64 - 96 + 36 + 1 = 5$. 比较四个值 $\{5, 1, 1, 5\}$: 最高 5 米 (在 $x = 1$ 和 $x = 4$), 最低 1 米 (在 $x = 0$ 和 $x = 3$). 如果只盯着导数为零的点, 就会漏掉端点的答案——这正是上面反例警报的用武之地.

至于“最陡地下降”, 那是导数最负的位置. $y' = 3(x-1)(x-3) = 3(x-2)^2 - 3$, 这是关于 $x = 2$ 的开口向上的抛物线, 最小值在 $x = 2$ 处取得, $y'(2) = -3$. 所以滑道在 $x = 2$ 米处下坡最猛, 斜率 -3 ——恰好是山顶与谷底连线的中点, 这个巧合在 x^3 类曲线里普遍成立, 原因藏在“导数的导数”里, 那是继续攀登的方向.

继续攀登

本章只是微积分的第一级台阶。继续往上的关键词：**二阶导数**（导数的变化率，描述凹凸与加速度）、**中值定理**（连接函数值与导数的桥梁，是“导数为零推出常数”的严格靠山）、**洛必达法则**（用导数算 $\frac{0}{0}$ 型极限）、**泰勒展开**（把局部线性近似升级成二次、三次乃至无穷多项的逼近）、**多元函数与梯度**（曲面上每个点有一整个方向的“斜率集合”）。竞赛里常见的“构造函数求导证不等式”，本质也是本章工具。

思考题**观察题**

1. 画一条你自己编的曲线，找出三个导数为零的点。它们都是极大或极小吗？提示：参考 x^3 在原点附近的樣子。
2. 函数 $f(x) = |x|$ 在 $x = 0$ 处的图像有一个尖角。分别用 $h > 0$ 和 $h < 0$ 计算差商的极限，你得到什么？提示：左右两个极限不相等意味着什么？

证明题

1. 用导数定义证明 $(x^4)' = 4x^3$ 。提示：先展开 $(x+h)^4$ ，含 h^2 及以上的项在取极限后全部消失；可以猜想并验证一般规律 $(x^n)' = nx^{n-1}$ 。
2. 用乘积法则证明：常数倍法则 $(cf)' = cf'$ 是乘积法则的特例。提示：常数函数的导数是多少？

挑战题

1. 某工厂生产 x 件产品的利润（元）为 $L(x) = -2x^2 + 80x - 300$ 。求利润最大的产量，并说明为什么“再多生产反而亏钱”。提示：先求 $L'(x) = 0$ 的点，再解释导数符号在该点两侧的变化。
2. 证明：在可导的前提下，偶函数（满足 $f(-x) = f(x)$ ）的导数是奇函数。提示：对 $f(-x) = f(x)$ 两边用链式法则求导，或回到差商定义分别比较 $f'(-a)$ 与 $f'(a)$ 。

通往下一章的门

这一章我们学会了“从累积量看变化率”：知道路程函数，就能求出每一瞬的速度；知道成本函数，就能求出边际成本。整个过程是一个极限、一个除法。

但把问题反过来问，就没有除法可用了：如果我只知道汽车每一时刻的速度表读数，能不能算出它一共开了多远？或者换一个几何版本：知道曲线 $y = x^2$ ，能不能算出它和 x 轴之间围成的面积？直边图形的面积我们会算，可这里的边界是弯的。

直觉暗示：把整段路切成无数极短的小段，每段近似匀速，路程就近似是“速度乘时间”，再把无数小段加起来。段切得越细，近似越准——这又是一个极限，但方向相反：本章是“差商的极限”，下一章是“和的极限”。更令人吃惊的是，这两个方向竟然互为逆运算，像乘法和除法一样互相解开：对累积量求导得到变化率，对变化率“求和”还原出累积量。这个深刻的对偶，就是微积分基本定理，也是下一章的故事。

第十一章 积分：把无数个小量加起来

11.1 里程表不量速度，却会算路程

坐进一辆汽车，仪表盘上有两块表：一块是速度表，指针告诉你此刻开得多快；另一块是里程表，数字告诉你一共开了多远。上一章我们关心的是反方向的问题：知道里程表随时间的变化，怎样算出每一时刻的速度？答案是求导数——用很短一段时间里里程的增加量除以这段时间，再把时间段缩到无穷小。

现在把问题反过来。假设里程表坏了，只有速度表是好的，而且它每隔一秒就把当前速度记录下来。你能不能只用这些速度记录，算出这趟车一共跑了多远？

直觉上会这样做：第一秒里车速大约是每秒 20 米，这一秒大约跑了 20 米；第二秒车速大约是每秒 22 米，这一秒大约跑了 22 米……把每一秒跑的距离加起来，就是总路程的近似值。如果记录更勤快，每十分之一秒记一次，每段里的速度变化更小，加出来的结果就应该更准。

其实生活里到处都是这样一对一对的表：水龙头开多大是“率”，水表走了多少字是“量”；电器功率多大是“率”，电表走了多少度是“量”；网速多快是“率”，手机流量统计是“量”。每一块“总量表”都在默默做同一件事：把每时每刻的“率”连续不断地累加起来。本章就是要搞清楚，这种累加到底是什么运算。

这个朴素得不能再朴素的想法——把整个过程切成许多小段，在每小段里近似当成均匀的，再把所有小段的贡献加起来——就是积分的全部起点。我们会看到，同一个想法能算出曲线围成的面积、球和圆锥的体积、变力做的功、随机事件的概率，还能回答一个更惊人的问题：无限多个数加起来，什么时候会得到一个有限的答案？

11.2 一个把人卡住两千年的问题

先从一个看起来更“几何”的问题开始。抛物线 $y = 1 - x^2$ 和 x 轴围成一个像小山包一样的图形， x 从 -1 到 1 。它的面积是多少？

三角形面积你会算，矩形面积你会算，圆的面积你背过公式。可是这个“山包”的边是弯的，既不是多边形也不是圆。凭直觉猜一猜：它外接的矩形宽 2、高 1，面积是 2；它肚子里能塞下的最大三角形底为 2、高为 1，面积是 1。所以答案在 1 和 2 之间。再猜得细一点？有人说 1.5，有人说接近 1.3，光靠直觉已经说不清了。

对付弯边图形，古人早有过辉煌的成功。圆的面积就是一个例子：魏晋时期的刘徽用“割圆术”算它——在圆内作内接正六边形，再作正十二边形、正二十四边形……边数每翻一倍，多边形就更贴近圆一圈。他的原话是：“割之弥细，所失弥少，割之又割，以至于不可割，则与圆周合体而无所失矣。”割得越细，差得越少，割到极限就和圆分毫不差。这已经是非常成熟的极限思想，

比欧洲同类想法早了一千多年。

古希腊的阿基米德则认真对待了抛物线山包。他的办法是把山包切成一层又一层越来越小的三角形：第一层一个大三角形，第二层两个小三角形，第三层四个更小的三角形……他证明了每一层三角形的总面积恰好是上一层的四分之一，于是总面积是一个无限相加的和：

$$S = 1 + \frac{1}{4} + \frac{1}{16} + \frac{1}{64} + \cdots$$

他又证明这个无限和等于 $\frac{4}{3}$ 。也就是说，抛物线山包的面积恰好是内接大三角形的 $\frac{4}{3}$ 倍。在没有代数符号、没有坐标的年代，这几乎是徒手攀岩式的成就。

但阿基米德的方法有一个让人不安的地方：每换一条曲线，就得重新发明一套切割技巧，像每把锁都要单独打一把钥匙。圆的面积有一套办法，抛物线有一套办法，螺线又是一套办法，每一套都依赖只有天才才看得到的巧妙构图。有没有一把万能钥匙，对任何曲线都用同一个套路？这个问题卡了数学家将近两千年。

11.3 第一次尝试：矩形太少，误差太大

最自然的尝试是用矩形。把区间 $[-1, 1]$ 切成几段，在每一段上立一个矩形，矩形的高取这一段上曲线的高度，把所有矩形面积加起来，当作山包面积的近似。

先切两段试试：左半段上曲线高度在 0 到 1 之间波动，右半段也一样。如果每段都用最高点的高度 1，两个矩形面积都是 $1 \times 1 = 1$ ，总面积 2——这就是外接矩形，明显偏大，两个角上多算了一大块。如果每段都用最低点的高度，左段最低点是端点处的 0，右段也是 0，总面积是 0——又小得离谱。一个在 2，一个在 0，真正的面积藏在中间，可这两个估计之间的差距太大，等于什么都没说。

切成四段会好一些，十段更好，一百段更好。而且这里有一个让人安心的规律：用每段最高点算出的“上和”永远不小于真实面积，用每段最低点算出的“下和”永远不大于真实面积，段数加倍时，上和往下缩、下和往上涨，两者的差距越挤越小。真实面积就像被两堵墙夹在中间的囚犯，墙越砌越近。可只要矩形是有限个，每个矩形的顶边是平的，而曲线的顶是弯的，两堵墙之间就始终留着一条缝。你不能说“取 100 个矩形就是答案”，只能说“取 100 个矩形离答案不远”。那答案本身是什么？难道我们永远只能逼近，永远不能到达？

反例警报

“矩形越多越准，所以取一百万个矩形，结果就是精确值了。”这个说法看似合理，其实偷换了概念。一百万个矩形仍然是有限个，顶边仍然是平的，得到的仍然是一个近似值，只不过误差很小而已。“近似得非常好”和“精确相等”是两回事。积分思想的关键一步，恰恰是不满足于任何有限的细分，而是让段数趋向无穷，取这些近似值的极限——回想第 9 章，极限才是那个“真正到达”的数。

11.4 把“越切越细”变成一个定义

走出困境的办法，是承认我们需要的不是一个更大的有限数，而是一个极限过程。把区间 $[a, b]$ 切成 n 小段，每段宽 $\Delta x = \frac{b-a}{n}$ ，在第 i 段里随便取一点，记下曲线在那里的高度 $f(x_i)$ ，这一

段贡献的矩形面积约是 $f(x_i) \Delta x$ 。全部加起来：

$$S_n = f(x_1) \Delta x + f(x_2) \Delta x + \cdots + f(x_n) \Delta x.$$

这个和叫作黎曼和。当 n 越来越大, Δx 越来越小, 如果 S_n 趋向一个确定的数 S , 而且这个数不依赖于你在每段里取哪一点, 我们就说函数 f 在 $[a, b]$ 上可积, S 就是它的定积分。


定义 11.1 (定积分). 设函数 f 在区间 $[a, b]$ 上有定义。把 $[a, b]$ 等分成 n 段, 记 $\Delta x = \frac{b-a}{n}$, 在每段中任取一点 x_i 。若当 $n \rightarrow \infty$ 时, 黎曼和

$$S_n = \sum_{i=1}^n f(x_i) \Delta x$$

的极限存在且与取点方式无关, 则称这个极限为 f 在 $[a, b]$ 上的定积分, 记作

$$\int_a^b f(x) dx = \lim_{n \rightarrow \infty} \sum_{i=1}^n f(x_i) \Delta x.$$

注. 并不是随手写一个函数都可积。好在本书遇到的函数——连续函数, 以及只有少数几个跳跃点的函数——都是可积的。真正把“哪些函数可积”问到底, 是大学实变函数课的故事。“与取点方式无关”这个要求也不是摆设: 如果换一套取点方式极限就变了, 那说明函数太“野”, 面积根本没有确定值。



新符号 $\int$ 解决了什么麻烦? 它把“切成无穷多份、每份无穷小、再加起来”这一整套极限过程压缩成一个记号。这个拉长的字母 S (sum, 求和) 提醒我们: 积分骨子里就是加法, 只不过是加到了极限。 $f(x) dx$ 则像一个“无穷小矩形”的面积: 高是 $f(x)$, 宽是 dx 。

术语卡片: 定积分

直观解释: 曲边图形面积的精确值, 由越来越细的矩形面积之和逼近而成。

正式定义: 黎曼和在分割无限加细时的极限, 记作 $\int_a^b f(x) dx$ 。

一个例子: $\int_0^2 x dx = 2$, 恰好是底为 2、高为 2 的三角形面积。

回到里程表的问题。把旅程切成 n 个很短的时间段, 第 i 段里的速度近似为 $v(t_i)$, 路程约是 $v(t_i) \Delta t$, 总路程约是黎曼和。令 $n \rightarrow \infty$, 就得到

$$\text{总路程} = \int_a^b v(t) dt.$$

在速度—时间图像上, $v(t_i) \Delta t$ 是一个细矩形的面积, 所以路程就是速度曲线下方的面积。速度和路程, 一个是“率”, 一个是“量”, 积分把它们连了起来。如果车是匀速的, 速度曲线是水平线, 曲线下方面积是矩形——这就是小学里“路程等于速度乘时间”; 积分做的事情, 是把这句小学口诀推广到速度任意变化的情形。

11.5 万能钥匙：微积分基本定理

定义有了, 可如果每算一个积分都要真的去求黎曼和的极限, 那跟阿基米德每次单独打钥匙也强不了多少。幸运的是, 微积分送给我们一份厚礼: 计算定积分根本不用求极限, 只要找到一个“导数等于 f ”的函数就够了。

定理 11.2 (微积分基本定理). 设 f 是 $[a, b]$ 上连续的函数, F 是 f 的一个原函数, 即 $F'(x) = f(x)$ 。那么

$$\int_a^b f(x) dx = F(b) - F(a).$$

这个定理为什么是对的? 用路程和速度的语言最清楚。设 $s(t)$ 是里程表读数, 那么速度 $v(t) = s'(t)$ ——这是导数的定义。另一方面, 从时刻 a 到时刻 b , 里程表增加的总路程就是 $s(b) - s(a)$ 。而我们刚刚用积分算过, 总路程等于 $\int_a^b v(t) dt$ 。两个算法算的是同一段路程, 所以

$$\int_a^b v(t) dt = s(b) - s(a).$$

把 v 换成 f 、把 s 换成 F , 这就是定理本身。下面把这个直觉写得更像证明一点。

证明. 把 $[a, b]$ 等分成 n 段, 分点为 $a = t_0 < t_1 < \cdots < t_n = b$, 每段长 Δt 。总增量可以拆成一串小增量之和:

$$F(b) - F(a) = [F(t_1) - F(t_0)] + [F(t_2) - F(t_1)] + \cdots + [F(t_n) - F(t_{n-1})],$$

右边中间项两两抵消, 只剩首尾。每一小段上, 由导数的意义, 当 Δt 很小时

$$F(t_i) - F(t_{i-1}) \approx F'(t_{i-1}) \Delta t = f(t_{i-1}) \Delta t,$$

所以 $F(b) - F(a)$ 约等于黎曼和 $\sum f(t_{i-1}) \Delta t$ 。令 $n \rightarrow \infty$, 近似变成精确的极限: 左边 $F(b) - F(a)$ 不随分割改变, 右边趋向 $\int_a^b f(t) dt$, 于是二者相等。□

注意证明里最关键的一步: 一长串括号中间全部抵消, 只剩下 $F(b) - F(a)$ 。积分的“总和”性质和导数的“局部变化率”性质, 通过这串抵消严丝合缝地扣在一起。这就是为什么说微分和积分互为逆运算。

注. 原函数并不唯一: x^2 的导数是 $2x$, $x^2 + 7$ 的导数也是 $2x$, 常数项求导就消失了。但这不影响定理——两个原函数只差一个常数, 做减法 $F(b) - F(a)$ 时常数自己消掉。所以算定积分时, 随便挑一个最顺手原函数就行。

配上数值例子尝尝味道。要算抛物线山包的面积 $\int_{-1}^1 (1 - x^2) dx$, 先找原函数: 哪个函数的导数是 $1 - x^2$? 试试 $F(x) = x - \frac{x^3}{3}$, 求导验证: $F'(x) = 1 - x^2$, 对了。于是

$$\int_{-1}^1 (1 - x^2) dx = F(1) - F(-1) = \left(1 - \frac{1}{3}\right) - \left(-1 + \frac{1}{3}\right) = \frac{4}{3}.$$

$\frac{4}{3}!$ 正是阿基米德用无限三角形拼出来的那个数。两千年后，万能钥匙和老锁匠的答案对上了——这是数学里最让人安心的时刻之一。

数学工具箱

本章新增的工具：

- **黎曼和**：把区间切细，用矩形面积之和逼近曲边面积；
- **定积分** $\int_a^b f(x) dx$ ：黎曼和的极限，几何上是曲线下方的面积；
- **微积分基本定理**：找到原函数 F ，积分等于 $F(b) - F(a)$ ，导数和积分互为逆运算；
- **切片思想**：立体的体积是截面积函数的积分，截面积处处相等的立体体积相等；
- **级数判别的直觉**：项趋于 0 只是必要条件，不是充分条件；等比级数在公比绝对值小于 1 时收敛。

连接线

这条定理把本书的三章缝在了一起：第 9 章的极限给出了积分定义的骨架，第 10 章的导数提供了计算积分的钥匙，本章的积分则把“变化率”还原成“总量”。到第 12 章你会看到，正是对这条定理中“连续”“极限存在”等条件的反复推敲，催生了一整套严格的分析学。

11.6 切面包片：从面积到体积

面积不是积分唯一的用武之地。一只圆锥、一个球，体积怎么算？初中课本给过公式：圆锥体积是同底等高圆柱的三分之一，球体积是 $\frac{4}{3}\pi r^3$ 。当时只能背下来，现在可以问一句为什么。

办法还是老一套：切。把球想象成一条面包，垂直于一条水平轴切成薄片。在距球心 x 处下刀（球心记为 0，两端是 $-r$ 和 r ），截面是一个圆。由勾股定理，这个圆的半径平方是 $r^2 - x^2$ ，面积是 $\pi(r^2 - x^2)$ 。每片厚度 Δx ，体积约是 $\pi(r^2 - x^2)\Delta x$ 。全部加起来、取极限：

$$V = \int_{-r}^r \pi(r^2 - x^2) dx.$$

被积函数只是个二次多项式，找原函数轻而易举： $F(x) = \pi\left(r^2x - \frac{x^3}{3}\right)$ 。由微积分基本定理，

$$V = F(r) - F(-r) = \pi\left(r^3 - \frac{r^3}{3}\right) - \pi\left(-r^3 + \frac{r^3}{3}\right) = \frac{4}{3}\pi r^3.$$

课本里那句“背下来就行”，原来是一行积分的结果。

传说阿基米德最得意的发现正是球与圆柱的关系：球的体积恰好是外接圆柱（底半径 r 、高 $2r$ ）的三分之二，他要求把这个图形刻在墓碑上。他没有积分符号，却用了“切片比较”的思想——在同样的高度上，球的截面加上圆锥的截面，面积恒等于圆柱的截面——先一步算出了这个比例。无独有偶，中国古代的祖暅（祖冲之之子）把同一思想总结成一句话：“幂势既同，则积不容异。”意思是：两个立体如果在每个等高处的截面积都相等，体积就必然相等。这一原理后来在欧

洲以卡瓦列里的名字流传，比祖暅晚了一千多年。切片思想在两个文明里各自生长，说明它确实是逼近体积的“自然规律”。

圆锥体积的“三分之一”也可以这样看：高 h 、底半径 r 的圆锥，尖朝上放置，在距顶点 x 处的截面半径由相似三角形给出，是 $\frac{rx}{h}$ ，截面面积是 $\pi \frac{r^2 x^2}{h^2}$ 。于是

$$V = \int_0^h \pi \frac{r^2 x^2}{h^2} dx = \frac{\pi r^2}{h^2} \cdot \frac{h^3}{3} = \frac{1}{3} \pi r^2 h.$$

常数 $\frac{\pi r^2}{h^2}$ 提到积分号外面，剩下的 $\int_0^h x^2 dx = \frac{h^3}{3}$ 正是我们熟悉的那个积分。体积公式不再是记忆负担，而是“体积等于截面面积函数的积分”这一句话的推论。

11.7 换一个视角：密度、概率和一碗汤

积分从来不只是“算面积”“算体积”的工具。凡是“一个率累积成一个量”的地方，都有它的影子。看三个例子。

质量与密度。一根不均匀的金属棒，左端稀、右端密，位置 x 处的线密度是 $\rho(x)$ （单位长度的质量）。把棒切成 n 小段，第 i 段近似均匀，质量约 $\rho(x_i) \Delta x$ ，加起来取极限：

$$\text{总质量} = \int_a^b \rho(x) dx.$$

一锅汤里盐的浓度不均匀，整锅汤的含盐量也是浓度对体积的积分——只不过那是三维的积分，大学里会学到。

电与功。电流是电量的变化率，所以一段时间内流过的总电量是电流对时间的积分。举个例子：若电流随时间增大， $I(t) = 2t$ 安培，那么前三秒流过的电量是

$$\int_0^3 2t dt = 3^2 - 0^2 = 9 \text{ 库仑}.$$

同样，力在一段距离上做的功，等于力对位移的积分。弹簧拉得越长越费劲，力随伸长量变化，用积分才能算清总共做了多少功。

概率与密度。你在车站等车，车在一个小时内的任意时刻到达的可能性相同。车到时刻落在 10 点到 10 点 15 分之间的概率是多少？直觉会答 $\frac{1}{4}$ ：时间段占整个小时的四分之一。但如果车的到达时间在傍晚更密集呢？这时“可能性”在不同时刻不一样大，需要一条密度曲线 $p(x)$ 来描述：时刻 x 附近单位时间里的“概率浓度”。那么

$$P(\text{车在 } c \text{ 到 } d \text{ 之间到达}) = \int_c^d p(x) dx,$$

概率是密度曲线下方的面积，而且全部概率加起来是 1：密度曲线在整个范围上的积分等于 1。等车这个例子里密度是常数 $\frac{1}{60}$ （按分钟计），密度曲线是一条水平线，概率就是矩形面积——又回到最朴素的图形。身高、测量误差这类随机量的密度曲线则是中间高、两边低的“钟形”，第 18 章会专门研究它。

术语卡片：概率密度

直观解释：一条曲线，它下方某区间上的面积表示随机量落在这个区间里的概率。

正式定义：非负函数 $p(x)$ ，满足整个范围上的积分等于 1； $P(c \leq X \leq d) = \int_c^d p(x) dx$ 。

一个例子： $p(x) = \frac{1}{60}$ ($0 \leq x \leq 60$ 分钟) 表示一小时内均匀到达，落在一刻钟内的概率是 $\frac{15}{60} = \frac{1}{4}$ 。

注意概率密度有一个反直觉之处：密度曲线在某一点的高度不是概率。车恰好在 10 点 30 分 00 秒到达的概率是 0——一个点的“区间宽度”为零，面积为零。概率只属于区间，密度只是“浓度的快慢”。这和“某时刻的速度不是路程”是完全相同的道理：率是率，量是量，积分才把率攒成量。


11.8 无限相加，什么时候有有限的结果

阿基米德的面积计算里藏着另一个宝藏： $1 + \frac{1}{4} + \frac{1}{16} + \cdots = \frac{4}{3}$ 。无限多个正数相加，结果居然是有限的。这和直觉打架——“无限多个东西加起来不应该无限大吗？”

不一定。第 9 章的芝诺悖论早就埋伏了答案：要跑完 1 公里，先跑 $\frac{1}{2}$ 公里，再跑剩下的 $\frac{1}{4}$ ，再跑 $\frac{1}{8}$ ……虽然要经历无限多个阶段，总路程却是有限的：

$$\frac{1}{2} + \frac{1}{4} + \frac{1}{8} + \cdots = 1.$$

几何上看得更清楚：把一个单位正方形先涂一半，再涂剩下的一半，再涂剩下的一半……每涂一次都更靠近涂满，却永远留一点没涂。涂的总面积趋向 1，不会超过。



一半又一半：总面积趋向 1

这类每次乘同一个比的和叫等比级数。只要公比 q 满足 $|q| < 1$ ，它就有有限的和：

$$a + aq + aq^2 + \cdots = \frac{a}{1 - q}.$$

验证一下芝诺的例子： $a = \frac{1}{2}$ ， $q = \frac{1}{2}$ ，和为 $\frac{1/2}{1 - 1/2} = 1$ ，分毫不差。这个公式不难证：设 $S = a + aq + \cdots + aq^n$ ，两边乘 q 得 $qS = aq + \cdots + aq^{n+1}$ ，两式相减，中间项全部抵消，

$(1-q)S = a - aq^{n+1}$ 。当 $|q| < 1$ 且 $n \rightarrow \infty$ 时 $q^{n+1} \rightarrow 0$ ，于是 $S \rightarrow \frac{a}{1-q}$ 。又一次，抵消是主角——和微积分基本定理证明里那串抵消遥相呼应。

循环小数里也藏着等比级数。0.999... 到底等不等于 1？把它拆开看：

$$0.999\dots = 0.9 + 0.09 + 0.009 + \dots = \frac{0.9}{1-0.1} = 1.$$

它不是“无限接近 1”，而是就是 1，只是换了一件无限长的外衣。极限不是一个永远走不到终点的过程——极限本身就是终点。

有的级数收敛得飞快。最著名的例子藏在自然对数的底 e 里：

$$e = 1 + 1 + \frac{1}{2} + \frac{1}{6} + \frac{1}{24} + \frac{1}{120} + \dots$$

分母是连乘积： $2 = 1 \times 2$ ， $6 = 1 \times 2 \times 3$ ， $24 = 1 \times 2 \times 3 \times 4 \dots$ 每一项都把自己的分母再乘一个大数，所以项缩小的速度比任何等比级数都猛。只加前七项，就能得到 $e \approx 2.718$ ，精确到小数点后两位。银行复利、人口增长、放射性衰变背后都是这个数，而它的庐山真面目，竟是一个收敛极快的无限和。下一章讲函数的幂级数展开时，我们还会回到这个式子。

但是，千万别以为“只要每一项越来越小，总和就有限”。最著名的反例是调和级数：

$$1 + \frac{1}{2} + \frac{1}{3} + \frac{1}{4} + \frac{1}{5} + \dots$$

每一项都趋向 0，可它的和却是无穷大。

定理 11.3 (调和级数发散). 调和级数 $1 + \frac{1}{2} + \frac{1}{3} + \frac{1}{4} + \dots$ 的和超过任何给定的数。

证明. 把项分组：第一项 1；第二组 $\frac{1}{2}$ ；第三组 $\frac{1}{3} + \frac{1}{4}$ ，两项都不小于 $\frac{1}{4}$ ，所以这一组大于 $\frac{1}{4} + \frac{1}{4} = \frac{1}{2}$ ；第四组 $\frac{1}{5} + \frac{1}{6} + \frac{1}{7} + \frac{1}{8}$ ，四项都不小于 $\frac{1}{8}$ ，所以这一组大于 $4 \times \frac{1}{8} = \frac{1}{2}$ ；依此类推，接下来 8 项都不小于 $\frac{1}{16}$ ，合起来又大于 $\frac{1}{2}$ 。每往后翻一倍个数，就能再凑出至少 $\frac{1}{2}$ 。 $\frac{1}{2}$ 加了无限多次，总和当然超过任何界限。□

这个证明最早由中世纪的学者给出，简单得让人意外，结论却深刻：项趋于 0 只是收敛的必要条件，远不是充分条件。级数收不收敛，取决于项变小得“够不够快”——所有 $\frac{1}{n^2}$ 加起来收敛，而且它等于 $\frac{\pi^2}{6}$ ：圆周率竟然从一堆平方数里冒了出来，这个结果是欧拉年轻时算出的，震惊了当时的数学界；而所有 $\frac{1}{n}$ 加起来发散。那么 $\frac{1}{n^{1.5}}$ 呢？ $\frac{1}{n^{1.001}}$ 呢？快与慢之间那条分界线究竟画在哪里，正是分析学最细腻的问题之一。

反例警报

“每一项都趋于 0，所以总和有限。”调和级数当面反驳了这句话。反过来也要小心：总和有限确实能推出项趋于 0，但项趋于 0 推不出总和有限。必要条件和充分条件，一字之差，谬以千里。

11.9 动手逼近一次积分

一分钟实验

拿一张方格纸，亲手验证微积分基本定理。

1. 画出 $y = x^2$ 在 $0 \leq x \leq 2$ 的图像（取几个点描出来即可），把 $[0, 2]$ 切成 4 段，每段宽 0.5，用每段右端点的高度立矩形，算面积之和：

$$0.5 \times (0.5^2 + 1^2 + 1.5^2 + 2^2) = 0.5 \times 7.5 = 3.75.$$

再用左端点的高度算一次： $0.5 \times (0 + 0.25 + 1 + 2.25) = 1.75$ 。真正的面积被夹在这两个数之间。

2. 用微积分基本定理算精确值： x^2 的原函数是 $\frac{x^3}{3}$ ，所以

$$\int_0^2 x^2 dx = \frac{2^3}{3} - 0 = \frac{8}{3} \approx 2.67.$$

确实落在 1.75 和 3.75 之间。

3. 把段数加到 8 段（每段 0.25），重算左右两个矩形和，把结果填进表里，观察它们怎样从两边挤向 $\frac{8}{3}$ ：

段数 n	左端点和	右端点和	精确值 $\frac{8}{3}$
4	1.75	3.75	2.666...
8	2.19	3.19	2.666...

有余力的话用计算器算 $n = 16$ ，看看两个近似值各前进了多少，猜测误差大约按什么速度缩小。

继续攀登

想继续往前走的读者，可以留意这些关键词：换元积分法与分部积分法（计算积分的两把扳手）；反常积分（区间无限长或被积函数爆炸时怎么办，例如 $\int_1^\infty \frac{1}{x^2} dx = 1$ ）；数值积分（计算机如何用梯形法、抛物线法高效逼近积分）；黎曼 ζ 函数（级数 $\sum \frac{1}{n^s}$ 收敛与发散的分界线通向第 15 章的素数故事）；以及大学里更一般的勒贝格积分——它把“竖着切条”改成“横着切层”，能处理更怪的函数。

思考题

观察题

1. 一辆车的速度表读数始终是正的，但司机先向前开、又倒车回到起点。速度曲线下的“面积”和“总路程”还是一回事吗？提示：倒车时速度该记成正还是负？积分值和里程表实际磨损的路各对应什么？

2. 观察水表、电表、手机流量统计：它们各自是“率”还是“量”？和它们对应的另一个量是什么？提示：每一对“率与量”之间都藏着一个积分和一个导数。

证明题

1. 不查公式，证明 $\frac{1}{3} + \frac{1}{9} + \frac{1}{27} + \cdots = \frac{1}{2}$ 。提示：模仿正文中等比级数的“乘 q 再相减”的办法，或者画一个正方形反复取三分之一。
2. 用微积分基本定理解释：为什么 $\int_a^b x dx = \frac{b^2 - a^2}{2}$ 恰好等于一个梯形的面积？提示： $y = x$ 的图像在 $[a, b]$ 上围出的是什么图形？梯形的两条底边各是多长？

挑战题

1. 调和级数发散，但把其中所有分母含数字 9 的项（如 $\frac{1}{9}$ 、 $\frac{1}{19}$ 、 $\frac{1}{92}$ ）统统删掉后，剩下的和竟然收敛。你能估计它为什么收敛吗？提示：一位数、两位数、三位数……各有多少个不含 9 的数？它们各自的倒数和大约被什么控制住？把各段的界加成等比级数试试。
2. 正文证明了 $\int_a^b f(x) dx = F(b) - F(a)$ 依赖“ F 的导数是 f ”。如果只知道 f 连续，能不能造出一个原函数？提示：考虑函数 $F(x) = \int_a^x f(t) dt$ ，估计 $\frac{F(x+h) - F(x)}{h}$ 在 h 很小时是多少——这正是下一章要严格化的思想。

通往下一章的门

这一章我们走得很快，快到鞋底有点打滑。黎曼和的极限“存在”是什么意思？凭什么说上和与下和两堵墙越砌越近，最后就一定严丝合缝地挤出一个数，而不是永远留着一条缝？微积分基本定理要求 f “连续”，可什么叫连续——“笔不离纸”的画法能当成定义吗？调和级数发散、 $\sum \frac{1}{n^2}$ 收敛，分界线背后有没有一把统一的尺子？

这些问题都不难懂，却难得漂亮。为了回答它们，十九世纪的数学家们把“无限接近”“连续”“收敛”这些日常词汇逐一锻造成了精确的定义，建起了一门叫分析的学问。下一章我们就走进这座锻造车间，看看直觉是怎样被炼成定理的——并且在那里重逢一个老朋友：用无穷多个简单的波，拼出任何复杂的声音。

第十二章 分析：把直觉变成可靠的定理

12.1 山路上的一道怪题

暑假里，你和家人去爬山。山脚的海拔是 100 米，山顶的海拔是 1500 米。你们早上八点出发，走走停停，中午十二点半到达山顶。途中你们休息过，折返过一段路去找掉在地上的帽子，速度时快时慢，总之走得毫无规律。

回家后，有人问你一个奇怪的问题：“在爬山过程中，你们一定有一个瞬间，海拔恰好是 618 米。你敢保证吗？”

你凭直觉会说：“当然！从 100 米到 1500 米，一路上海拔是连续变化的，总不能从 617 米‘跳’到 619 米吧？”

这个直觉听起来天衣无缝。但请先别急着点头，再听两个问题：

- 登山记录显示，早上九点你的海拔是 500 米，上午十一点是 800 米。那么是否一定存在某个时刻，海拔恰好是 600.001 米？
- 一支温度计从清晨到正午，温度从 10°C 升到 25°C 。是否一定有某个时刻，温度恰好等于 $\sqrt{500}$ 摄氏度？注意， $\sqrt{500}$ 是一个无限不循环小数，任何温度计的刻度都读不出它。

第一个问题你可能仍然答“是”，但底气已经开始动摇：海拔真的可以无限精确地谈吗？第二个问题更麻烦——一个在任何温度计上都显示不出来的数，凭什么说它“被恰好经过”过？

这一章的任务，就是把“连续变化不会跳过任何中间值”这句模糊的感觉，锻造成一条可以严格证明、可以放心使用的定理。这门手艺叫**分析**：它的目标不是算得更快，而是把直觉变成可靠的定理。数学家们为此折腾了整整两百年——他们的直觉被骗过不止一次，骗局还非常精彩。

12.2 直觉第一次被骗

先给“连续”一个最朴素的理解：函数的图像是一条“不抬笔就能画完”的曲线。这个理解有用，但它靠不住。历史上它至少在三件事上栽过跟头。

第一件事：你以为“不跳过中间值”是显然的，那请看这个函数：

$$f(x) = \begin{cases} 1, & x \geq 0, \\ -1, & x < 0. \end{cases}$$

它在 $x = -1$ 处取值 -1 ，在 $x = 1$ 处取值 1 ，中间值 0 却永远取不到——图像在 $x = 0$ 处“跳了台阶”。所以“不跳过中间值”这件事，真的和“不抬笔”有关，不是白送的。

第二件事更隐蔽。我们知道 $1^2 = 1 < 2$, $2^2 = 4 > 2$, 所以 $x^2 = 2$ 的解 $\sqrt{2}$ 应该“夹在 1 和 2 之间被经过”。可是请你回忆前面的章节： $\sqrt{2}$ 不是有理数。假如世界上只有有理数，函数 $f(x) = x^2 - 2$ 在 $x = 1$ 处为负、在 $x = 2$ 处为正，但它在有理数范围内永远不等于零——“被经过的那个中间值”根本不存在！直觉在这里失灵，不是函数的问题，而是数的世界本身有窟窿。有理数像一件满是针眼的衬衫，看着完整，凑近了全是洞。

反例警报

警报一：函数 $f(x) = x^2 - 2$ 在有理数范围内“从负变正却不经过零”。所以介值定理的秘密一半在函数身上，另一半在实数身上——实数没有窟窿，这叫“完备性”。

警报二：“连续函数的图像一定光滑”也是错的。数学家魏尔斯特拉斯构造过一个函数，处处连续、处处没有切线——一条永远“毛茸茸”、任何一点都放大不出直线的曲线。它处处不抬笔，却处处扎手。可见“连续”比“光滑”弱得多，也微妙得多。

第三件事：就算函数不跳跃、数的世界也没有窟窿，直觉还可能败在“无穷”手里。函数 $g(x) = 1/x$ 在区间 $(0, 1]$ 上每一点都很乖，可是当 x 靠近 0 时， $g(x)$ 冲向无穷大，谁也拦不住。这条曲线在有限的范围里“装着”无限的高度。直觉说“一段有限长的曲线上总有个最高点”，在这里又错了。

三次被骗，教训是同一个：分析里的每一句话，都必须经得起最刁钻的抬杠。下面我们来一一修补。

12.3 把“连续”说清楚

先修第一个窟窿。到底什么叫连续？我们要的是这样一句话：**输入变化很小，输出变化就很小**。再准确一点：

定义 12.1 (连续 (直观版))。函数 f 在点 a 处**连续**，是指：当 x 无限接近 a 时， $f(x)$ 无限接近 $f(a)$ 。也就是说，你随便指定一个误差要求，比如“输出偏差不得超过 0.001”，我总能找到 a 附近的一小段输入范围，保证这段范围内所有 x 的输出都满足你的要求。函数在一个区间上连续，是指它在区间的每一点都连续。

注意这个定义的“抬杠结构”：误差要求是**你**提的，可以多苛刻都行；而我**必须**给出应对方案。这就把“感觉上差不多”变成了可以逐条检验的协议。跳跃函数 $f(x)$ 在 $x = 0$ 处过不了这一关：你要求“输出偏差小于 $1/2$ ”，可无论我把 0 附近的输入圈缩得多小，圈里总有正数和负数，输出一会儿是 1 一会儿是 -1 ，相差 2，永远超标。

术语卡片：连续函数

直观解释：图像不抬笔就能画完；输入的小抖动只引起输出的小抖动。

正式说法： x 趋向 a 时， $f(x)$ 趋向 $f(a)$ ，即“极限值正好等于函数值”。

一个例子： $f(x) = x^2$ 处处连续，因为 x 靠近 a 时 x^2 靠近 a^2 ；而跳跃函数在 $x = 0$ 处不连续。

第二个窟窿靠实数来补。实数系有一条宝贵性质：**任何“无限逼近某个位置”的过程，都能在实数里找到那个位置**。这叫做**完备性**。有理数不具备它——列有理数 1, 1.4, 1.41, 1.414, ...

无限逼近 $\sqrt{2}$ ，可 $\sqrt{2}$ 不在有理数里。实数则没有这种漏洞。承认这一点之后，直觉的核心内容就可以被证明了。

12.4 介值定理：不许跳，就得过

定理 12.2 (介值定理). 设 f 在闭区间 $[a, b]$ 上连续, $f(a) < 0$ 而 $f(b) > 0$ (或反过来)。那么区间里至少存在一点 c , 使 $f(c) = 0$ 。


更一般地, f 会取到 $f(a)$ 与 $f(b)$ 之间的每一个值——海拔从 100 米连续变到 1500 米, 必然恰好经过 618 米, 甚至恰好经过 $\sqrt{500}$ 米对应的高度。

证明的思路就是计算机里的“二分查找”：不断把嫌疑区间砍成两半，零点无处可逃。

证明. 设 $f(a) < 0 < f(b)$ 。第一步：看中点 $m_1 = (a + b)/2$ 。若 $f(m_1) = 0$ ，已经找到；若 $f(m_1) > 0$ ，零点只能在左半边 $[a, m_1]$ 里；若 $f(m_1) < 0$ ，零点只能在右半边 $[m_1, b]$ 里。无论哪种情况，我们都得到一个长度减半的新区间，它左端函数值为负、右端为正。

把这个操作重复下去：第 n 步后，嫌疑区间的长度是 $(b - a)/2^n$ ，左端 a_n 处 $f(a_n) \leq 0$ ，右端 b_n 处 $f(b_n) \geq 0$ 。左端点列 $a_1, a_2, a_3, \dots$ 单调不减、又被 b 压着，右端点列单调不增、又被 a 托着，两列点之间的距离趋向 0。由实数的完备性，两列点无限逼近同一个位置 c 。

最后一步用连续性： x 趋向 c 时函数值趋向 $f(c)$ 。左端点列的所有函数值都不超过 0，所以它们的“逼近目标” $f(c)$ 不能超过 0；右端点列的所有函数值都不小于 0，所以 $f(c)$ 不能小于 0。两头的夹逼给出 $f(c) = 0$ 。□



这个证明值得多看一眼：它不仅证明零点存在，还真的算出了零点——每切一刀，误差减半，二十刀就把误差压到原来的百万分之一。用二分法求 $\sqrt{2}$ ： $1^2 < 2 < 2^2$ ，中点 1.5 的平方是 $2.25 > 2$ ，往左切；中点 1.25 的平方是 $1.5625 < 2$ ，往右切……十步之后你就有 1.414，和手算开方的结果吻合。分析的第一条定理，立刻变成了一台计算器。

12.5 最高点与“脾气均匀”的函数

介值定理管“中间值”，下面这条定理管“最值”，它们是一对兄弟。

定理 12.3 (最大值定理). 闭区间 $[a, b]$ 上的连续函数，一定能取到最大值和最小值。也就是说，存在区间里的点 p 和 q ，使 $f(p)$ 不小于一切函数值， $f(q)$ 不大于一切函数值。

它的两个条件——“闭区间”和“连续”——一个都不能少。 $g(x) = 1/x$ 在 $(0, 1]$ 上连续但区间不闭，它没有最大值；跳跃函数在闭区间上不连续，也可以把最高点“跳丢”。这条定理是所有“最优问题”的地基：你之所以敢问“怎样用料最省”“怎样利润最大”，是因为合理的函数在合理的范围里确实有答案，剩下的只是怎么找——那是第 10 章导数的活儿。

还有一个更精细的概念，考试不常考，却是分析的命脉：**一致连续**。普通连续是“每个点各自有一份应对方案”，点不同，方案可以不同；一致连续则要求**全区间共用一份方案**：你给定误差要求后，我能拿出一把统一长度的“尺子”，无论把它放在区间哪里，尺子两端之内的输入，输出偏差都达标。

为什么有的函数做不到？看 $g(x) = 1/x$ 在 $(0, 1]$ 上：越靠近 0，曲线越陡，同样的输入间隔 0.001，在 $x = 1$ 附近输出只差大约 0.001，在 $x = 0.001$ 附近输出能差上千。一把固定长度的尺子，越往左越不够用，永远找不到全区间通用的方案。而 $f(x) = x^2$ 在任何**闭**区间 $[a, b]$ 上都很老实：它的“坡度”有上限（不超过 2 倍区间端点中较大的那个的绝对值），统一方案随手可得。可以证明：闭区间上的连续函数一定一致连续。直觉说“有限的舞台上演不出无限的脾气”，这次直觉赢了——但赢要靠证明，不靠感觉。

12.6 柯西序列：不知道答案，也能证明答案存在

介值定理的证明里藏着一个更深的问题。二分法造出了一列数 $a_1, a_2, \dots$ ，我们断言它“无限逼近某个位置 c ”。可如果 c 就是我们要找的东西，在找到它之前，凭什么知道它存在？难道不会逼近一个“空位置”吗，就像有理数逼近 $\sqrt{2}$ 那样？

十九世纪的数学家柯西给出了绝妙的回答：判断一列数“会收敛”，**不需要提前知道它收敛到谁**，只需要看这列数内部够不够团结。

定义 12.4 (柯西序列 (直观版)). 一列数 $a_1, a_2, a_3, \dots$ 称为**柯西序列**，是指：你随便指定一个误差要求，这列数从某一项开始，**任意两项**之间的距离都不超过它。

收敛的数列一定是柯西序列：大家都往同一个目标挤，彼此自然越靠越近。深刻的反问题是：柯西序列一定有目标吗？在有理数世界里不一定—— $\sqrt{2}$ 的逼近列就是反例；在实数世界里，答案是一定有。这条“柯西序列必收敛”的性质，就是实数完备性的标准表述，也是整个分析大厦的地基石。

术语卡片：柯西序列

直观解释：一列数“越到后来越抱团”，队尾的成员彼此挤得要多近有多近。

正式说法：任意给定误差 $\varepsilon > 0$ ，存在一项，使得它后面的任意两项之差都小于 ε 。

一个例子：1, 1.4, 1.41, 1.414, ... ($\sqrt{2}$ 的逐位小数) 是柯西序列：从第 n 位小数之后，任意两项之差不超过 10^{-n} 。它收敛的目标是 $\sqrt{2}$ ——这件事在实数里成立，在有理数里不成立。

从此，“这个方程有解吗”有了新的答法：构造一列越来越团结的近似解，由完备性保证真正的解存在，再用连续性确认它真的满足方程。数学家用这套“先逼供、后定罪”的流程，证明了大量方程有解，哪怕解永远写不出精确表达式。

12.7 幂级数：把函数拆成无限长的多项式

如果说前面三节是“防守”——修补直觉的漏洞，那接下来的三节是“进攻”——用无穷过程造出惊人的新东西。第一件武器你已经见过雏形：无限小数。 $\pi = 3.14159\dots$ 其实是把 π 拆成“3 加上 0.1 加上 0.04 加上……”，每一位都是一个更小的修正项。幂级数干的是同一件事，只不过被拆的不是数，而是**函数**。

最基础的例子是等比数列求和。你知道 $1 + x + x^2 + \dots + x^n = \frac{1 - x^{n+1}}{1 - x}$ 。当 $|x| < 1$ 时， x^{n+1} 趋向 0，于是

$$\frac{1}{1-x} = 1 + x + x^2 + x^3 + \dots \quad (|x| < 1).$$

取 $x = 1/2$ 验证：右边是 $1 + 1/2 + 1/4 + \dots = 2$ ，左边是 $1/(1 - 1/2) = 2$ 。吻合。

这个公式的读法是颠覆性的：函数 $\frac{1}{1-x}$ 居然等于一条“无限长的多项式”。为什么要这么拆？因为多项式是最好算的函数——只会乘法和加法。把一个“难算”的函数拆成无穷多个幂次的叠加，我们就有了它的“配方表”，想算多精确就取多少项。

最著名的配方是指数函数的：

$$e^x = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \frac{x^4}{4!} + \dots$$

它对**所有** x 都成立（这和 $\frac{1}{1-x}$ 只在 $|x| < 1$ 成立不同——每个配方表有自己的“适用半径”，称为收敛半径）。取 $x = 1$ ，前六项给出

$$1 + 1 + \frac{1}{2} + \frac{1}{6} + \frac{1}{24} + \frac{1}{120} \approx 2.7167,$$

而 $e \approx 2.71828$ ，五项就逼近了前三位小数。你计算器里那个 e 的按键，内部多半就是这类级数在干活。

为什么适用半径有的大的有的小？看 $\frac{1}{1-x}$ 就明白了：它在 $x = 1$ 处“爆炸”（分母为零），所以它的配方表最远只能延伸到离爆炸点距离为 1 的范围，再远就救不回来了。而 e^x 在整个数轴上都风平浪静，配方表自然畅通无阻。粗略地说：**幂级数的适用范围，延伸到函数最近的“坏点”为止**。这条直觉在复数平面上会被证明得清清楚楚——“坏点”有时还藏在实轴看不见的地方，这也是数学家后来非研究复变函数不可的原因之一。

幂级数还有一个和导数有关的美妙性质： e^x 的配方里，每一项求导后正好是前一项—— $\frac{x^3}{3!}$ 求导得 $\frac{x^2}{2!}$ ， $\frac{x^2}{2!}$ 求导得 x ，常数项 1 求导得 0。整条级数求导后**原封不动还是自己**！这正是第 10 章说的“ e^x 的导数是它自己”在配方表上的倒影。

12.8 傅里叶级数：任何声音都是一堆纯音

第二件武器更浪漫。幂级数用“幂次” $1, x, x^2, \dots$ 做积木，法国数学家傅里叶提出了另一套积木：**正弦波**。他声称：几乎任何周期函数，都能用一串不同频率的正弦波叠加出来。这个主张当年被许多大数学家反对——用光滑的波浪拼出有棱角的图形，听起来像骗局。


请看这个著名的配方，一个方波（在 0 和 2π 之间，函数值在 1 与 -1 之间来回跳的矩形波）：

$$\text{方波}(x) = \frac{4}{\pi} \left(\sin x + \frac{\sin 3x}{3} + \frac{\sin 5x}{5} + \frac{\sin 7x}{7} + \dots \right).$$

只取第一项，是一条起伏平缓的正弦曲线，和方波相去甚远；加上第二项，波峰开始变平；加到第五项，矩形的样子已经很了，只剩边缘的细微波纹。取的项越多，波纹越小，棱角越锋利。

这个配方里藏着一条朴素的规律：每个正弦波的频率是前一个的“下一个奇数倍”，而振幅按频率的倒数衰减——三倍频率配三分之一高度，五倍频率配五分之一高度。为什么高频的成分越来越少？因为方波的大部分“体形”是平缓的，只有棱角的细节才需要高频波来雕刻；细节总是比主体少。这条规律在所有傅里叶分解里都成立：**低频决定轮廓，高频决定细节**。记住这句话，待会儿的实验和后面的连接线里都要用到。

傅里叶当年把这套想法写成论文提交给巴黎的科学院，评审的数学家们（包括以严格著称的拉格朗日）拒绝签字：他们要求先回答“这串无穷叠加到底收不收敛、收敛到什么”，而这正是本章前半部分的柯西序列和完备性要回答的问题。历史在这里绕了一个圈：为了审判傅里叶的级数，数学家们被迫把“连续”“收敛”这些词说得更清楚——分析的严格化，有一半是被这些波浪逼出来的。



代一个具体的数进去，你会得到一个百年不衰的惊喜。取 $x = \pi/2$ ：方波在这一点取值 1；而 $\sin(\pi/2) = 1$, $\sin(3\pi/2) = -1$, $\sin(5\pi/2) = 1$ ，交替正负。于是

$$1 = \frac{4}{\pi} \left(1 - \frac{1}{3} + \frac{1}{5} - \frac{1}{7} + \cdots \right), \quad \text{即} \quad \frac{\pi}{4} = 1 - \frac{1}{3} + \frac{1}{5} - \frac{1}{7} + \cdots$$

圆的周长里藏着的 π ，竟然能用全体奇数的倒数交错相加算出来。算到第 100 项，你大约能得到 π 的两位小数——收敛虽慢，但谁能否认这个等式的漂亮？

一分钟实验

亲手拼一个方波。在方格纸上，先画 $y = \sin x$ (x 从 0 到 2π ，取 $x = 0, 0.5, 1, \dots$ 用计算器算值描点)。再画 $\frac{1}{3} \sin 3x$ ——频率是三倍、高度是三分之一。把两条曲线在相同 x 处的高度相加，描出新曲线。你会看到波峰被压平、波谷被抬起，矩形的雏形出现了。有余力再加 $\frac{1}{5} \sin 5x$ 。三种颜色叠在一张图上，就是傅里叶两百年前看到的景象。

另一个实验：对手机上的频谱软件（或音乐软件的“均衡器”界面）哼一个长音。屏幕上会亮起几根柱子：最低最亮的是基音，上面是泛音。你的嗓音和钢琴弹同一个音，听起来完全不同，差别就在泛音柱子的相对高度上——声音里的“音色”，就是傅里叶系数。

连接线

傅里叶级数就在你口袋里。音乐文件（如 MP3）的压缩原理，是把声音切成小段，每段分解成不同频率正弦波的叠加，再把人耳听不见的高频分量删掉——数据量大减，听感几乎不变。图片压缩（JPEG）用的是同一家族的“余弦变换”：一张照片中平缓变化的区域，低频系数就能描述，细节才需要高频。电话降噪、地震波分析、医学成像，全是傅里叶思想的子孙。一个当年被嘲笑“不可能”的主张，如今每天处理着全人类的图片和声音。

12.9 复数平面与欧拉公式

第三件武器，来自前面章节认识的老朋友：虚数单位 i ，满足 $i^2 = -1$ 。当时你可能觉得它是个工具人——为了让所有二次方程有解而请来的临时工。这一节你会看到， i 一旦和分析联手，会产生数学里公认最美的一个公式。

先把复数摆在平面上： $a + bi$ 对应横坐标 a 、纵坐标 b 的点。加法就是向量的平移，这很自然。妙的是乘法：乘以 i ，相当于把向量逆时针旋转九十度。因为 1 乘 i 得 i ——点 $(1, 0)$ 转到了 $(0, 1)$ ；再乘 i 得 -1 ——又转九十度。转两次共一百八十度，正是“乘以 -1 ”。所谓 $i^2 = -1$ ，用几何语言说就是“两个九十度等于一百八十度”。复数乘法原来是旋转加伸缩。

现在请幂级数登场。数学家欧拉做了一件看似疯狂的事：把纯虚数 $i\theta$ 代入 e^x 的配方表，看会发生什么。利用 $i^2 = -1$ 、 $i^3 = -i$ 、 $i^4 = 1$ 的循环，奇数项和偶数项自动分成两队：

$$e^{i\theta} = \left(1 - \frac{\theta^2}{2!} + \frac{\theta^4}{4!} - \cdots\right) + i\left(\theta - \frac{\theta^3}{3!} + \frac{\theta^5}{5!} - \cdots\right).$$

两个括号里的级数，恰好就是 $\cos \theta$ 和 $\sin \theta$ 的配方表（可以用第 10 章的导数知识验证：它们的各阶导数在 0 点的值完全吻合）。于是：


定理 12.5 (欧拉公式). 对任意实数 θ ,

$$e^{i\theta} = \cos \theta + i \sin \theta.$$

它的几何意义令人屏息：右边是单位圆上角度为 θ 的点，左边是“ e 的纯虚数次幂”。也就是说， $e^{i\theta}$ 随着 θ 增大，在单位圆上匀速转圈。代入 $\theta = \pi$ ： $\cos \pi = -1$ ， $\sin \pi = 0$ ，于是

$$e^{i\pi} + 1 = 0.$$

一个公式里站着五个最重要的常数：0、1、 π 、 e 、 i ，被加、乘、乘方三种运算缝在一起。数学家们投票选“最美公式”时，它几乎从不落选。



欧拉公式还是傅里叶级数的“官方语言”。用 $\cos \theta = \frac{e^{i\theta} + e^{-i\theta}}{2}$ 和 $\sin \theta = \frac{e^{i\theta} - e^{-i\theta}}{2i}$ ，所有正弦余弦的叠加都可以改写成 $e^{ik\theta}$ 的叠加，三角恒等式变成了简单的指数运算。现代工程师做傅里叶分析时，笔下几乎没有 $\sin$ 和 $\cos$ ，全是旋转的小箭头 $e^{i\theta}$ 。

再往前一步，就是复分析：把 x 换成复数 z ，研究复变函数 $f(z)$ 。这里发生了数学中少见的奇迹：在复平面上，“可导”这个条件变得极其强大——一个函数只要在某个区域里处处有导数，它

就自动光滑、自动能展开成幂级数，函数值还被边界上的取值完全锁死。复变函数像一块烧红的铁板，动一处而全身知。这种刚性让复分析既优雅又有力，也让它长出了数学里最深的问题之一。

12.10 本章的收获

数学工具箱

本章新增的工具：

- **连续（直观版）**：你提误差要求，我给应对方案——输入足够接近，输出就足够接近。
- **实数完备性**：柯西序列（越来越抱团的数列）在实数里必有极限。有理数没有这条性质，这是两套数的根本差别。
- **介值定理**：连续函数取遍两端之间的一切值；证明方法是二分法，顺便还能算零点的近似值。
- **最大值定理**：闭区间上的连续函数必有最大值和最小值；条件“闭区间”“连续”缺一不可。
- **一致连续**：全区间共用一份应对方案；闭区间上的连续函数一定一致连续。
- **幂级数**：把函数拆成无限长的多项式，如 $e^x = \sum x^n/n!$ ；每个配方有适用半径。
- **傅里叶级数**：把周期函数拆成正弦波的叠加；方波的展开顺带算出 $\pi/4 = 1 - 1/3 + 1/5 - \dots$ 。
- **欧拉公式**： $e^{i\theta} = \cos \theta + i \sin \theta$ ，复数乘法是旋转加伸缩，特例 $e^{i\pi} + 1 = 0$ 。

继续攀登

继续攀登的路标：

- **ε - δ 语言**：本章“你提要求、我给方案”的协议，在大学里会写成精确的符号形式，这是数学分析的第一课。
- **魏尔斯特拉斯函数**：处处连续、处处不可导的“毛刺曲线”，它的严格构造用到了一致收敛的函数项级数。
- **泰勒级数**：幂级数配方的一般理论——函数的各阶导数决定它的全部系数。
- **快速傅里叶变换（FFT）**：把傅里叶分解的计算量降到不可思议程度的算法，被称为二十世纪最重要的算法之一。
- **黎曼 ζ 函数与黎曼猜想**：复分析皇冠上的明珠，它把本章的级数和下一章的质数缝在一起——悬赏一百万美元的未解之谜。

思考题

观察题

1. 某天中午 12 点你从山脚出发上山, 下午 4 点到顶; 第二天中午 12 点你从山顶沿同一条路下山, 下午 4 点到山脚。证明 (用介值定理): 两天中必有同一时刻, 你处在同一海拔。提示: 把两天的“海拔关于时刻”的函数画在同一坐标系里, 考虑它们的差。
2. 方程 $x^3 + x - 1 = 0$ 在 0 与 1 之间有解吗? 能否用二分法手算三步, 把解的位置缩小到长度 $1/8$ 的区间里? 提示: 算 $x = 0, \frac{1}{2}, 1$ 处的函数值, 再切。

证明题

3. 证明: 连续函数 f 若满足 $f(a) \cdot f(b) < 0$, 则它在 (a, b) 内必有零点——这正是介值定理。请把正文二分法证明中的“左端点列单调不减且有上界, 故逼近某点 c ”这一步, 用自己的话补全理由。提示: 一列数越排越靠右、却永远越不过一堵墙, 它会怎么样?
4. 设数列 $a_n = \frac{n}{n+1}$ (即 $\frac{1}{2}, \frac{2}{3}, \frac{3}{4}, \dots$)。验证它是柯西序列: 当 m, n 都大于某个 N 时, $|a_m - a_n|$ 能有多小? 提示: $|a_m - a_n| = \left| \frac{1}{n+1} - \frac{1}{m+1} \right|$, 分别给两个分数找上界。

挑战题

5. 用 $e^{i\theta} = \cos \theta + i \sin \theta$ 计算 $e^{i\alpha} \cdot e^{i\beta}$, 两边分别用指数律和复数乘法展开, 比较实部与虚部, 你能“免费”推出哪两个三角恒等式? 提示: $(\cos \alpha + i \sin \alpha)(\cos \beta + i \sin \beta)$ 展开后, 实部是什么?
6. 级数 $1 - \frac{1}{3} + \frac{1}{5} - \frac{1}{7} + \dots$ 收敛到 $\pi/4$, 但它收敛得慢: 前 100 项的误差大约有多大? 观察相邻两项的包夹关系来估计。提示: 交错级数的部分和在目标值两侧来回跳, 误差不超过被丢掉的头一项。

通往下一章的门

这一章的结尾, 留给级数一个意味深长的镜头。考虑调和级数

$$1 + \frac{1}{2} + \frac{1}{3} + \frac{1}{4} + \frac{1}{5} + \dots$$

它的每一项都趋向 0, 可它的和却**趋向无穷大**——把项分组: $\frac{1}{3} + \frac{1}{4} > \frac{1}{2}$, $\frac{1}{5} + \frac{1}{6} + \frac{1}{7} + \frac{1}{8} > \frac{1}{2}$, $\frac{1}{9}$ 到 $\frac{1}{16}$ 的八项之和又大于 $\frac{1}{2}$ ……你能凑出无穷多个“半个”, 和当然拦不住。

欧拉盯上了这件小事, 并追问了一个改变数学史的问题: 调和级数的发散, 和**质数**有什么关系? 他发现了一个惊人的恒等式: 全体正整数的倒数之和, 竟然等于只由质数造出来的一个无穷乘积。如果质数只有有限个, 这个乘积就是个有限的数, 可调和级数明明是发散的——矛盾! 于是“质数有无穷多个”这件两千年前欧几里得就证明过的事, 被欧拉用分析的语言又证明了一遍, 而且锋利得多。

这扇门的背后是一个新世界: 整数的乘除机关里, 藏着级数、函数甚至复平面的影子。而想读懂这一切, 你得先回到最朴素的问题——质数到底是什么? 它们按什么规律排列? 为什么 $7 \times 11 \times 13 = 1001$ 这样的分解是唯一的? 下一章, 我们放下连续与无限, 走进整数的世界: 质数、同余, 和它们守护的现代密码。

第四部分

从整数问题分流——数论与解析数论

第十三章 初等数论：质数、同余与整数的机关

13.1 拆不开的班：从一次排队说起

学校开运动会，体育老师要把初二年级的同学排成若干行，要求每行人数一样多，不许有落单的。六年级三个班各报了自己的人数：甲班 48 人，乙班 45 人，丙班 47 人。

甲班很快搞定了：48 人可以排成 6 行 8 列，也可以排成 4 行 12 列，花样多得很。乙班也不愁：45 人可以排成 5 行 9 列。轮到丙班，大家试了半天：每行 2 人？剩一个。每行 3 人？剩一个。每行 4 人、5 人、6 人……全都剩一个。47 这个数像一块摔不碎的石头，怎么都拆不成两个比它小的整数相乘。

先凭直觉猜一猜：这样的“石头数”是很少见的怪胎，还是其实满地都是？它们有没有一个尽头——比如说，比某个数更大的整数全都能被拆开？这个问题听起来像小孩子数数时随口一问，却难住过历史上最聪明的头脑。这一章我们就从这块“石头”出发，看看整数内部藏着哪些机关。

13.2 第一次尝试：筛子和误会

遇到 47 拆不开，最朴素的办法是把可能的因数挨个试一遍。2 不行（47 是奇数），3 不行（ $4 + 7 = 11$ 不是 3 的倍数），5 不行（末位不是 0 或 5），7 呢？ $7 \times 6 = 42$ ， $7 \times 7 = 49$ ，也不行。试到这里其实可以停了——为什么？因为 $7 \times 7 = 49$ 已经超过 47 了。如果 47 能写成两个都大于 1 的整数相乘，其中至少有一个不超过它的平方根 $\sqrt{47} \approx 6.9$ 。试到 6 就够了，不必试到 46。这是本章第一个“机关”：检验一个数能不能拆开，只需要检查到它的平方根。

顺着这个思路，有人提出一个大胆的猜想：“拆不开的数就是奇数。”听起来有道理，偶数不都能拆出 2 吗？但立刻有人反驳：9 是奇数，却等于 3×3 ；15、21、25 也都拆得开。反过来，2 是偶数，却拆不开。看来“奇偶”和“能不能拆开”是两回事。

反例警报

“奇数都是拆不开的数”——错误。 $9 = 3 \times 3$ 、 $15 = 3 \times 5$ 、 $21 = 3 \times 7$ 都是奇数，却都能拆成更小的整数相乘。判断一个数能否拆开，唯一可靠的办法是检查到平方根为止的所有可能因数，而不是看它的末位或奇偶。

两千多年前，古希腊的数学家想出了一个系统性的办法，后人称之为“筛法”：把 2 到 100 的数全写出来，圈起 2，划掉所有 2 的倍数；找到下一个没被划掉的数 3，圈起来，划掉所有 3 的倍数；再找到 5、7……凡是被划掉的，都是能被更小的数整除的“合成品”；最后剩下的，就是那些摔不碎的石头。这个方法笨，但诚实——它保证一个不漏。

这里还有一个容易错过的省力之处：划到 7 的倍数时就可以收工了。因为按平方根界限，100

以内的任何合数必有一个不超过 $\sqrt{100} = 10$ 的质因数，也就是说它早就在划 2, 3, 5, 7 的倍数时被干掉了。四轮之后幸存下来的，一定全是拆不开的数。筛完 100 以内的数，剩下的是这张清单：

2	3	5	7	11
13	17	19	23	29
31	37	41	43	47
53	59	61	67	71
73	79	83	89	97

数一数，共 25 个。盯着这张表看一会儿，你会生出许多问题：为什么除了 2 全是奇数？为什么越往后间隔好像越大？为什么有的紧紧挨着（41 和 43），有的却隔得很远？这些问题我们很快就会一一捡起来——其中有的已经有答案，有的至今没有。

13.3 发明概念：质数是整数的“原子”

被筛子剩下的数值得一个正式的名字。

定义 13.1 (质数与合数). 大于 1 的整数，如果除了 1 和它本身之外没有别的正因数，就称为质数（也叫素数）；否则称为合数。数 1 既不是质数也不是合数。

这里最容易被问倒的是：“凭什么把 1 开除出质数队伍？1 不也只能被 1 和自己整除吗？”这是一个真正的好问题，答案不在定义本身，而在后面要讲的一个定理：数学家希望“每个整数的拆法唯一”，如果让 1 混进质数里，6 就能写成 2×3 、 $1 \times 2 \times 3$ 、 $1 \times 1 \times 2 \times 3$ ……拆法就不唯一了。把 1 请出去，是为了让整数的乘法世界有一条干净的基本定律。定义不是天经地义的，而是为了让定理说得漂亮而精心设计的。

术语卡片：质数

直观解释：整数世界里摔不碎的“原子”，只能由 1 和它自己搭出来，拆不成更小的整数乘积。


正式定义：大于 1 且正因数只有 1 与自身的整数。

一个例子：47 是质数，因为 2, 3, 5 都整除不了它，而 $7 > \sqrt{47}$ ，检验可以到此为止。

化学家发现世间万物由一百多种原子构成，数论学家则发现：每个大于 1 的整数都由质数“搭”出来。 $48 = 2 \times 2 \times 2 \times 2 \times 3$ ， $45 = 3 \times 3 \times 5$ ，而 47 本身就是一块原子。更惊人的是，搭法只有一种。

定理 13.2 (算术基本定理). 每个大于 1 的整数都可以唯一地分解为质数的乘积，若不计较这些质数的书写顺序，分解方式是唯一的。

先看分解的“存在性”，它几乎是一棵树的自然生长：任取一个合数，把它拆成两个更小的数；拆出来的数如果还是合数，就继续拆。每拆一次，数都严格变小，而整数不会无穷变小下去，所以这个过程必然停在某处——停下来的那些数拆不动了，正是质数。图里画出了 360 的一棵分解树。



把所有“树叶”乘起来： $360 = 2^3 \times 3^2 \times 5$ 。换一条路拆（比如先拆成 12×30 ），叶子还是同一批质数，只是碰见的顺序不同。

“唯一性”则要费一点脑筋。凭什么不能存在两套完全不同的质数，乘出来恰好是同一个数？关键在于下面这个引理：

推论 13.3 (质数整除引理). 若质数 p 整除乘积 ab ，则 p 整除 a 或整除 b 。

这个引理对合数是假的（6 整除 $3 \times 4 = 12$ ，但 6 既不整除 3 也不整除 4），它的证明要用到下一节的最大公因数，我们先把证明思路存在那里。有了引理，唯一性就好办了：假如某个数有两套质数分解，把两套写法都列出来，左边第一个质数整除右边的乘积，由引理它必然整除右边某一个质数——而质数只能被自己和 1 整除，所以它们其实是同一个质数。两边同时约掉它，对剩下的部分重复同样的话，最后两边的质数必然一模一样。直觉上“拆法只有一种”是对的，而且是被严格证明了的。

13.4 辗转相除：一台两千岁的机器

现在来补那个引理欠下的工具。给定两个整数，比如 252 和 105，它们公共的因数里最大的是谁？这个数叫最大公因数。笨办法是把两个数各自的所有因数列出来再找交集，但有个快得惊人的老办法，写在两千多年前的古希腊数学书里，今天还在你手机的芯片里跑着。

定义 13.4 (最大公因数). 整数 a 、 b （不全为 0）的公共因数中最大的一个，记作 $\gcd(a, b)$ 。若 $\gcd(a, b) = 1$ ，称 a 与 b 互质。

一分钟实验

拿一张纸算 $\gcd(252, 105)$ 。第一步：252 除以 105，商 2 余 42，写下 $252 = 2 \times 105 + 42$ 。第二步：拿刚才的除数 105 除以刚才的余数 42， $105 = 2 \times 42 + 21$ 。第三步：42 除以 21， $42 = 2 \times 21 + 0$ ，余数为 0，停。最后那个不为零的余数 21 就是答案： $\gcd(252, 105) = 21$ 。全程三次除法，不需要知道 252 或 105 的任何因数。

这个办法叫欧几里得算法（辗转相除法）。它为什么对？核心是一句话：若 $a = bq + r$ ，那么 a 和 b 的公共因数，与 b 和 r 的公共因数，是完全相同的一批数。道理在于：凡是 b 和 r 的公因数，必然整除 $bq + r = a$ ；反过来，凡是 a 和 b 的公因数，必然整除 $a - bq = r$ 。公因数队伍原班不动，最大者当然也相同，于是

$$\gcd(a, b) = \gcd(b, r).$$

而右边的数越来越小，余数一路减小又不可能小于 0，若干步后必然余 0，此时较小的那个数就是答案。它不依赖质因数分解——这恰恰是它强大的原因，因为分解大整数恰恰是很难的（这一点后面还会救密码学一命）。

这个算法有一个几何版本，美得像一幅画：给一个 252×105 的长方形，用最大的正方形去铺它。先铺下两个 105×105 的正方形，剩下 42×105 的长条；再用 42×42 的正方形铺这个长条，铺两个剩 42×21 ；最后用 21×21 正好铺满。最后那种正方形恰好铺满不剩边角，它的边长就是最大公因数。铺不下去的余量越来越小，正如余数越来越小。

还有一个副产品：把辗转相除的算式倒着读回去，能把最大公因数写成原来两数的“整系数组合”。在上面的例子里：

$$21 = 105 - 2 \times 42 = 105 - 2 \times (252 - 2 \times 105) = 5 \times 105 - 2 \times 252.$$

一般结论是：总存在整数 x, y 使 $\gcd(a, b) = ax + by$ 。别小看这一行式子，上一节的“质数整除引理”就靠它：设质数 p 整除 ab 却不整除 a ，那么 $\gcd(p, a) = 1$ (p 的正因数只有 1 和 p)，于是有整数 x, y 使 $px + ay = 1$ 。两边乘 b 得 $pbx + aby = b$ 。左边第一项显然被 p 整除，第二项里的 ab 按假设也被 p 整除，所以 b 被 p 整除。引理得证，算术基本定理的最后一颗螺丝拧紧了。

最大公因数还有一个日常用途：约分。分数 $\frac{252}{105}$ 要约到最简，只需分子分母同除以 $\gcd(252, 105) = 21$ ，一步得到 $\frac{12}{5}$ ，不必试探性地反复约。与它搭档的是最小公倍数：两个整数的最小公倍数乘以最大公因数，恰好等于两数之积，即 $\text{lcm}(a, b) \cdot \gcd(a, b) = ab$ 。所以 252 与 105 的最小公倍数是 $252 \times 105 \div 21 = 1260$ 。一个例子让你看到它在哪出现：两盏霓虹灯分别每 252 秒和每 105 秒闪一次，从同闪到下一次同闪，间隔正是 1260 秒——所有“重逢”问题（齿轮重新对齐、行星再次连珠、公交两车同时到站）背后都是这一个数。

13.5 奇偶、不变量与同余：换一种眼光看整数

分解关心的是乘法结构。现在换一个角度：不关心一个数“是谁”，只关心它“属于哪一类”。最简单的分类是奇与偶——被 2 除余 1 还是余 0。可别嫌它简单，它是一件威力巨大的武器，学名叫不变量。

经典的一幕：一个 8×8 的棋盘，挖掉对角上的两个格子，能用 31 张 1×2 的多米诺骨牌正好铺满吗？你可以试一个下午，每次都差一点点。数学家不试，他只看颜色：每张骨牌无论横放竖放，必然盖住一黑一白两个格子，所以铺得满的图形黑白格子必须一样多。而被挖掉的两个对角格子是同色的，剩下的棋盘上黑格比白格多两个（或少两个）。31 张骨牌盖 31 黑 31 白，永远对不上 30 与 32。一次尝试都不用，答案就是“不可能”。奇偶性在铺砖过程中保持不变——正是这个“不变”宣判了死刑。

奇偶是“除以 2 的余数”。把这个想法推广到除以任何数，就得到数论里最好用的工具之一。

定义 13.5 (同余). 设 m 是正整数。若整数 a 与 b 被 m 除所得的余数相同（等价地， m 整除 $a - b$ ），就说 a 与 b 模 m 同余，记作

$$a \equiv b \pmod{m}.$$

术语卡片：同余

直观解释：钟面上的算术。现在下午 3 点，过 14 小时是几点？ $3 + 14 = 17$ ， $17 \equiv 5 \pmod{12}$ ，即凌晨 5 点。钟面上 17 和 5 是同一个位置。

正式定义： $a \equiv b \pmod{m}$ 当且仅当 m 整除 $a - b$ 。

一个例子： $100 \equiv 2 \pmod{7}$ ，所以从今天起过 100 天，星期几只取决于 2——往后数两天即可。

同余的妙处在于它像等号一样好用：同余式两边可以同时加、减、乘同一个整数。于是处理巨大的数时，可以随时把它换成模 m 意义下的小替身。想算 7^{100} 的个位数？个位数就是模 10 的余数。 $7^2 = 49 \equiv 9 \pmod{10}$ ， $7^4 \equiv 9^2 = 81 \equiv 1 \pmod{10}$ ，于是

$$7^{100} = (7^4)^{25} \equiv 1^{25} = 1 \pmod{10}.$$

个位数是 1。我们从没算出 7^{100} 这个有八十多位的庞然大物，却知道了它的末位——这就是“只看类别”的力量。

同余还能解释一些你早就背过、却未必想过为什么的口诀。比如：“一个数能被 3 整除，当且仅当它的各位数字之和能被 3 整除。”为什么数字会这么听话？秘密在于 $10 \equiv 1 \pmod{3}$ （同样 $10 \equiv 1 \pmod{9}$ ）。于是 10 的任何次幂模 3 都是 1，一个四位数展开后：

$$\overline{abcd} = 1000a + 100b + 10c + d \equiv a + b + c + d \pmod{3}.$$

换句话说，十进制写法本身就把一个数和它的数字和绑在了同一“类”里。拿 123 456 试试：数字和为 $1+2+3+4+5+6=21$ ，是 3 的倍数但不是 9 的倍数，所以 123 456 能被 3 整除而不能被 9 整除——不必真的做除法。老式会计还有一个叫“弃九法”的验算招术：检查乘法 $47 \times 62 = 2914$ 是否可信，就把 47、62、2914 各自的数字和反复加到一个数字为止（ $47 \rightarrow 11 \rightarrow 2$ ， $62 \rightarrow 8$ ， $2914 \rightarrow 16 \rightarrow 7$ ），看 $2 \times 8 = 16 \rightarrow 7$ 是否与积的数字根吻合。吻合不一定对，不吻合一定错——这是一种古老的“纠错码”，原理正是模 9 同余。

把同余推到精致处，会碰到一颗小宝石，由十七世纪的法国数学家费马发现（他常以在书页空白处写下惊人断言而闻名）：

定理 13.6 (费马小定理). 设 p 是质数，整数 a 不是 p 的倍数，则

$$a^{p-1} \equiv 1 \pmod{p}.$$

证明. 考察 $p-1$ 个数 $a, 2a, 3a, \dots, (p-1)a$ 被 p 除的余数。先说它们两两不同余：若 $ia \equiv ja \pmod{p}$ （不妨 $i > j$ ），则 p 整除 $(i-j)a$ ；由质数整除引理， p 整除 $i-j$ 或整除 a ，但 a 不是 p 的倍数，且 $0 < i-j < p$ ，都不可能。所以这 $p-1$ 个余数互不相同，又都不为 0（否则 p 整除某个 ia ，同样矛盾），恰好是 $1, 2, \dots, p-1$ 的一个重排。把这 $p-1$ 个数全部乘起来，一方面

$$a \cdot 2a \cdots (p-1)a = a^{p-1} \cdot (p-1)!,$$

另一方面，模 p 意义下这批余数乘起来就是 $1 \cdot 2 \cdots (p-1) = (p-1)!$ 。两边同余：

$$a^{p-1} \cdot (p-1)! \equiv (p-1)! \pmod{p}.$$

$(p-1)!$ 与 p 互质，可以约去，即得 $a^{p-1} \equiv 1 \pmod{p}$ 。□

配一个数值例子：取 $p = 11, a = 2$ 。 $2^5 = 32 \equiv -1 \pmod{11}$ ，所以 $2^{10} \equiv (-1)^2 = 1 \pmod{11}$ 。定理预言的事分毫不差。这个定理看上去像纯游戏，三百年后却成了银行系统的基石——谜底在下一节揭晓。

注. 定理反过来却不成立：存在合数 n ，也能让某些 a 满足 $a^{n-1} \equiv 1 \pmod{n}$ ，例如 $341 = 11 \times 31$ 就能“骗过”以 2 为底的检验。这类数叫伪质数。所以费马小定理可以铁口直断“不是质数”（同余不成立时），却只能在概率意义上说“像是质数”——现代计算机检验大质数，正是从这条缝里发展出的一整套技术。

13.6 质数用不完：一个两千多年前的证明

回到开头的疑问：丙班那种“石头数”，会不会到某个地方就没有了？会不会分解超大整数时，最终只遇到质数库里有限的存货？古希腊人给出了回答，而且这个回答被公认为数学史上最漂亮的证明之一。

定理 13.7 (质数有无穷多个). 不存在“最大的质数”：任给一个质数，总能找到比它更大的质数。

证明. 用反证法。假设质数只有有限多个，把它们全部列出来： $p_1, p_2, \dots, p_n$ 。构造一个新整数

$$N = p_1 p_2 \cdots p_n + 1,$$

即“所有质数乘起来再加 1”。 N 大于 1，由算术基本定理， N 必能被某个质数整除。这个质数是谁？不可能是 p_1 ： N 除以 p_1 余 1。也不可能是 $p_2, p_3, \dots, p_n$ 中的任何一个—— N 除以它们每一个都余 1。所以存在一个不在清单上的质数整除 N ，与“清单已穷尽所有质数”矛盾。假设错误，质数不可能只有有限个。□

请留意这个证明的结构：它没有告诉你下一个质数在哪，只是证明了“清单永远列不完”。这种“假设反面成立，推出自相矛盾”的反证法，是数学家工具箱里最锋利的工具之一。另外注意一个细节： N 本身不一定是质数。比如 $2 \times 3 \times 5 \times 7 \times 11 \times 13 + 1 = 30031$ ，它等于 59×509 ，是合数——但它确实被清单之外的新质数 59 和 509 整除，证明的关键只在这里，不在 N 是否本身是质数。

顺便一提，质数虽无穷，分布却越来越稀疏，而且极不规律。在 1 到 100 之间，质数有 25 个，占了四分之一；到 1000 附近，每十个数里大约只剩一个半质数；数越大，质数越罕见——这符合直觉，数越大，能成为它因数的“候选”越多，想保持拆不开就越难。数学家甚至证明了：想找出连着一千个整数的“质数沙漠”也可以，因为 $1001! + 2, 1001! + 3, \dots, 1001! + 1001$ 分别被 $2, 3, \dots, 1001$ 整除，整整一千个连续的合数。

可另一方面，质数又拒绝彻底疏远。像 3 与 5、17 与 19、101 与 103 这样只差 2 的“孪生质数”，目前已知的最大一对有几十万位。它们是否也有无穷多对？这就是著名的孪生质数猜想——至今既没被证明也没被推翻，人类只证明了“相差不超过某个固定上限的质数对有无穷多”这样的近似版本。越稀、越乱，却似乎永不彻底孤单：质数的分布是数学中最大的悬案之一，我们把它放进“继续攀登”里。

13.7 换一个视角：这些机关如何锁住现代世界

数论曾被称为“数学的皇后”，以纯粹、无用而自豪。二十世纪下半叶，情况戏剧性地反转：今天每次网购、每条加密消息、每张刷过的公交卡，都在调用这一章的机关。

第一道机关：纠错码。每本书封底的国际标准书号 (ISBN) 由一串数字组成，最后一位是“校验位”，由前面的数字按模运算算出。一种经典方案是：前九位 $a_1, a_2, \dots, a_9$ 分别乘以权重 $10, 9, \dots, 2$ 后求和，再选校验位 x 使总和被 11 整除：

$$10a_1 + 9a_2 + \dots + 2a_9 + x \equiv 0 \pmod{11}.$$

假设前九位是 9, 7, 8, 7, 0, 4, 0, 0, 3，加权和为

$$90 + 63 + 64 + 49 + 0 + 20 + 0 + 0 + 6 = 292,$$

而 $292 = 11 \times 26 + 6$ ，所以取 $x \equiv -6 \equiv 5 \pmod{11}$ ，校验位是 5。它的用处在于：如果录入时某一位抄错了，加权和就不再被 11 整除，系统立刻报警；甚至两位数字对调也能被发现。为什么模 11 而不是模 10？诀窍正在于 11 是质数：相邻两位对调时，加权和的改变量是权重之差乘以数字之差，即 $\pm(a_i - a_{i+1})$ ；只要两位数字不同，这个改变量就含一个介于 ± 1 与 ± 9 之间的因子，而质数 11 不可能整除这样的小整数，于是错误必然暴露。若模 10，数字差为 5 的对调就会被漏检。同样的心思藏在银行卡号、快递单号和二维码里：故意多存一点“按规则可预测”的信息，让错误无处藏身。二维码走得更远，它存的不只一位校验，而是成块的冗余信息，所以图案被污渍盖住一角、甚至被印上一个商标，手机照样读得出来——那是更强壮的纠错码，背后仍是同一套模运算的算术。

第二道机关：公开密钥密码。传统密码像一把挂锁，锁和开用同一把钥匙，传递钥匙本身就成了破绽。二十世纪七十年代，数学家们提出一个看似异想天开的方案：把锁公开送人，钥匙自己留着——任何人都能锁上盒子寄给你，但只有你能开。实现它的正是质数、同余和费马小定理。一个简化模型如下（真实系统用的是几百位的大数，原理相同）：

1. 你秘密选两个质数 $p = 3$ 、 $q = 11$ ，公开它们的乘积 $N = 33$ ，但 p 、 q 本身保密。
2. 由费马小定理的思想可以推知，取适当的“公开指数” $e = 3$ 和“秘密指数” $d = 7$ （它们满足 $ed \equiv 1 \pmod{(p-1)(q-1)}$ ，即 $21 \equiv 1 \pmod{20}$ ），则对任何信息 m 都有 $(m^e)^d \equiv m \pmod{N}$ 。
3. 朋友要寄给你数字 $m = 4$ ，用公开的 (N, e) 加密： $4^3 = 64 \equiv 31 \pmod{33}$ ，把 31 寄出。
4. 你收到 31，用秘密的 d 解密： $31^7 \pmod{33}$ 。手算验证： $31 \equiv -2 \pmod{33}$ ， $(-2)^7 = -128$ ，而 $-128 \equiv 4 \pmod{33}$ 。信息 4 原样归来。

窃听者看到的是 $N = 33$ 、 $e = 3$ 和密文 31。要推回 d ，本质上需要知道 $(p-1)(q-1)$ ，也就是需要把 N 分解回 3×11 。33 当然谁都会分，但把 N 换成两个三百位质数的乘积，人类现有最快的计算机算上宇宙年龄也分解不完。加密容易、分解难——安全的根基不是算法保密，而是分解大整数这件事本身的艰难。当年“最无用”的费马小定理，如今每天保护着天文数字的资金流动。

连接线

这一章串起了一条出人意料的因果链：欧几里得两千多年前的辗转相除，支撑了算术基本定理的唯一性；费马十七世纪的一则小定理，配上“分解大整数很难”这个至今无人攻破的经验事实，变成了现代互联网的安全锁。数学里“没用”和“有用”之间的距离，有时需要几百年才能走完——这也是判断一个理论价值时该有的耐心。

数学工具箱

本章新增的数论工具：

- **平方根界限**：检验 n 是否为质数，只需试除到 $\sqrt{n}$ 。
- **质因数分解**：每个整数唯一地写成质数幂的乘积（算术基本定理）。
- **辗转相除**： $\gcd(a, b) = \gcd(b, r)$ ，其中 $a = bq + r$ ；倒推还能写出 $\gcd(a, b) = ax + by$ 。
- **不变量**：找一个在过程中保持不变的量（如奇偶性、黑白格数之差），用它判定“不可能”。
- **同余**： $a \equiv b \pmod{m}$ ，大数随时换成小替身，加减乘保持同余。
- **反证法**：假设结论不成立，推出矛盾（质数无穷多的证明是范本）。

继续攀登

想继续往上爬，可以查这些关键词：**素数定理**（不超过 x 的质数约有 $x/\ln x$ 个，质数虽无穷却越来越稀）；**哥德巴赫猜想**（每个大于 2 的偶数都是两个质数之和，至今未证）；**黎曼猜想**（质数分布的终极密码，悬赏百万美元）；**二次剩余与互反律**；**中国剩余定理**（“韩信点兵”问题的完整理论）；**椭圆曲线密码**（RSA 之后的新一代公钥体系）。

思考题

观察题

1. 写出 2 到 50 之间所有的孪生质数对（相差为 2 的质数对）。数一数有几对。提示：先用筛法列出 50 以内的全部质数，再找相邻差为 2 的对子；注意 (3, 5)、(5, 7)、(11, 13) 这样的形状。
2. 观察 $n^2 + n + 41$ 在 $n = 0, 1, 2, 3, 4$ 时的值，它们似乎都是质数。提示：别急着下结论，继续代几个更大的 n 试试，特别留意某个“显然特殊”的取值。

证明题

1. 证明：除 2, 3 之外，每个质数都具有 $6k + 1$ 或 $6k + 5$ 的形状（ k 为整数）。提示：任何整数被 6 除的余数只有六种，逐个检查 $6k$ 、 $6k + 2$ 、 $6k + 3$ 、 $6k + 4$ 为什么是合数。
2. 证明：若 $a \equiv b \pmod{m}$ 且 $c \equiv d \pmod{m}$ ，则 $ac \equiv bd \pmod{m}$ 。提示：从定义出发，把 $a = b + sm$ 、 $c = d + tm$ 代入乘积展开，看哪些项含因数 m 。

挑战题

1. 求 2^{2025} 被 7 除的余数。提示：先算 $2^1, 2^2, 2^3, \dots$ 模 7 的余数，观察循环规律（或者用费马小定理，7 是质数）。
2. 在公开密钥的例子中，我们用了 $p = 3, q = 11, e = 3, d = 7$ 。请你用 $p = 5, q = 7$ 自己搭建一套：算出 N 和 $(p-1)(q-1)$ ，选一个与 $(p-1)(q-1)$ 互质的 e ，再找出满足 $ed \equiv 1 \pmod{(p-1)(q-1)}$ 的 d （倒用辗转相除），最后加密并解密一个你自己选的信息，验证能还原。提示： e 可以取 5；找 d 就是解同余方程 $5d \equiv 1 \pmod{24}$ 。

通往下一章的门

这一章里，我们反复在做同一件朴素的事：数。筛法是在数质数，棋盘问题是在数黑白格，费马小定理的证明是把 $p-1$ 个数“数了两遍”——先按原样乘，再按余数重排乘，两种数法给出同一个结果，定理就从等号里掉了出来。最后这个手法尤其值得回味：换一种方式清点同一批对象，竟能推出根本不显然的结论。

可一旦认真去“数”，问题立刻变多：质数定理说质数大约有 $x/\ln x$ 个，“大约”到底怎么数出来的？一副扑克牌有多少种洗牌结果？ 8×8 棋盘上放 8 个互不攻击的皇后，有几种放法？摩尔斯电码里，由五个点划组成的不同信号有多少种？这些问题里，对象不再是孤零零的整数，而是成堆的排列、选取、摆放方式——它们是离散的、一个一个的。怎样系统地清点它们而不重复、不遗漏？这正是下一章的主角：组合与离散结构。我们会看到，“数清楚”本身是一门有定理、有技巧、有陷阱的学问，而本章的整数机关——奇偶、同余、互质——会在那里反复登场。

第十四章 组合与离散结构：数数、连线和算法

14.1 一场联欢会前的点票难题

初二(3)班要办联欢会，班长小林负责两件事。第一件：全班 25 名同学排一列队伍上台合影，班主任想知道“一共有多少种不同的排法”，好决定要不要在方案里写上“随机排队”。第二件：联欢会结尾有个传统节目，每位同学都要和其他每位同学握一次手，不能重复。主持人要控制时间，得先知道一共要握多少次手。

小林觉得第一件事不难：25 个人排队，大概是“几十种”“几百种”吧？第二件事他也想估算：每个人握 24 次手，25 个人就是 $25 \times 24 = 600$ 次？

这两个问题看起来微不足道，却藏着本章的全部入口。第一个问题的答案会让你吓了一跳：它不是几十种，也不是几百种，而是一个 26 位数。第二个问题的直觉算法 25×24 犯了一个隐蔽的错误——把每一次握手数了两遍。你会发现，“数数”这件我们从幼儿园就开始做的事，一旦规模稍大、结构稍复杂，就会变成一个需要方法和定理的数学分支。这个分支叫组合数学，它和它的近亲图论、算法一起，构成所谓“离散数学”——研究一个一个、分得清清楚楚的对象的数学。

为什么单独给“离散”立一个分支？这本书前面大部分的舞台是连续的：实数轴上的点、光滑的曲线、连续变化的速度。可生活里有太多东西不是连续的：同学是一个一个的，握手是一次一次的，道路网是一个路口接一个路口的，密码是一位一位的，计算机里的数据更是一条一条的 0 和 1。对付这些“数得清个数”的对象，需要另一套工具。本章的任务就是把这套工具交到读者手里：怎样不漏不重地数数，怎样把关系画成点和线，以及怎样让一台只会按步骤办事的机器替我们高效地走完这些点和线。

14.2 先猜一猜，再错一次

先回到握手问题。小林的算法是：每人握 24 次，25 人共 $25 \times 24 = 600$ 次。请读者先凭直觉判断：这个数偏大还是偏小？

再用一个更小的班级检验。假设全班只有 3 个人：甲、乙、丙。按小林的算法，握手次数是 $3 \times 2 = 6$ 次。可实际数一数：甲乙、甲丙、乙丙，只有 3 次。6 恰好是 3 的两倍。再看 4 个人的班级：甲乙、甲丙、甲丁、乙丙、乙丁、丙丁，共 6 次，而小林的算法给出 $4 \times 3 = 12$ ，又是两倍。

问题出在哪？“甲和乙握手”与“乙和甲握手”是同一件事，但在“每人握 24 次”的算法里，这件事在甲的账上记了一次，又在乙的账上记了一次。每一次握手都有两只手，于是总账翻了一倍。把 600 除以 2，得到 300，这才是正确答案。

反例警报

看似合理的说法： n 个人两两握手，每人握 $n-1$ 次，所以总次数是 $n(n-1)$ 。

错在哪里：每一次握手属于两个人，“逐人统计再相加”必然把每次握手数两遍。凡是“数一件事有多少种”的问题，先要问：我数出来的每一件，会不会其实是同一件被重复登记了？辨别“有序”与“无序”、分辨“重复计数”，是组合计数里最常见的翻车现场。同样的错误还有：20 支球队单循环比赛（每两队踢一场），场次不是 $20 \times 19 = 380$ ，而是 $380 \div 2 = 190$ 。

再看排队问题。25 人排成一列，有多少种排法？如果读者猜“几百种”，那就掉进另一个陷阱：低估了乘法的力量。我们一步步看。第一个位置有 25 种选择；选好之后，第二个位置剩 24 种选择；接着 23 种、22 种……直到最后一个位置只剩 1 种。每个位置的选择互不干扰地串联起来，总数是

$$25 \times 24 \times 23 \times \cdots \times 2 \times 1.$$

这个连乘积大到需要专门造一个记号：记作 $25!$ ，读作“25 的阶乘”。它的值是 15511210043330985984000000，一个 26 位数。如果每秒钟试一种排法，试完所有排法需要的时间，比宇宙的年龄还要长几千亿倍。阶乘的增长速度，是本章后面讨论“算法到底跑不跑得动”的关键角色。

14.3 数数的两条军规与两件武器

上面的两次失败提示我们：数数不能靠蛮力列清单，要靠结构。组合数学的军规只有两条。

加法原理：做一件事有若干类互不相交的办法，第一类有 a 种，第二类有 b 种，那么总共有 $a+b$ 种。**乘法原理：**做一件事要分几步完成，第一步有 a 种做法，第二步有 b 种做法，那么总共有 $a \times b$ 种。排队用乘法，因为 25 个位置是“串联”的；而“从家到学校可以坐 3 路公交中的一路，或者骑 2 条路线中的一条”用加法，因为公交和骑车是“并联”的类别。

军规之下，最常用的两件武器是排列和组合。

从 n 个人里挑出 k 个人排成一列（挑出来还要分先后次序），排法数记作

$$A_n^k = n(n-1)(n-2)\cdots(n-k+1) = \frac{n!}{(n-k)!}.$$

例如从 8 名同学里选出场次表的冠、亚、季军，有 $A_8^3 = 8 \times 7 \times 6 = 336$ 种结果。如果不要名次，只要“挑出 3 个人组成组委会”，那么每 3 个人的小组会在排列里被重复计算 $3! = 6$ 次（3 个人内部有 6 种排队方式），所以要除以 6。这样得到的数记作

$$\binom{n}{k} = \frac{n!}{k!(n-k)!},$$

读作“ n 选 k ”，也叫组合数或二项式系数。从 8 人里选 3 人组委会，有 $\binom{8}{3} = 56$ 种。握手问题用它一句话解决：25 人两两握手，次数就是 $\binom{25}{2} = \frac{25 \times 24}{2} = 300$ 。

术语卡片：组合数

直观解释：从 n 个东西里不管顺序地抓出 k 个，有多少种抓法。

正式定义： $\binom{n}{k} = \frac{n!}{k!(n-k)!}$ ，其中 $0 \leq k \leq n$ ，约定 $0! = 1$ 。

一个例子： $\binom{5}{2} = \frac{5 \times 4}{2} = 10$ ，即 5 个篮球队两两比赛共 10 场。

组合数有一张著名的“地图”。把它们按行排开，每一行两端的数都是 1，中间的每个数等于它肩上两个数之和：

$$\begin{array}{ccccccc}
 & & & & 1 & & \\
 & & & 1 & & 1 & \\
 & & 1 & & 2 & & 1 \\
 & 1 & & 3 & & 3 & & 1 \\
 1 & & 4 & & 6 & & \cdots
 \end{array}$$

第 4 行（从第 0 行数起）是 1, 4, 6, 4, 1，正好是 $\binom{4}{0}, \binom{4}{1}, \binom{4}{2}, \binom{4}{3}, \binom{4}{4}$ 。这张表在中国叫杨辉三角，在西方叫帕斯卡三角，数学家们各自独立地反复发现过它。它的构造规则本身就是一个计数论证：从 n 个东西里选 k 个，要么选中了某个特定的东西（剩下 $k-1$ 个从 $n-1$ 个里选），要么没选中（ k 个全从 $n-1$ 个里选），所以

$$\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}.$$

这个等式有一个值得注意的味道：它用一个更小规模的同类型问题来回答当前问题。这种“自己调用自己的缩小版”的想法叫递推，是本章的第三件武器。

递推最经典的例子是爬楼梯：一段楼梯有 n 级，每步可以跨 1 级或 2 级，有多少种走法？设走法数为 f_n 。最后一步只有两种可能：从第 $n-1$ 级跨 1 级上来，或者从第 $n-2$ 级跨 2 级上来，所以

$$f_n = f_{n-1} + f_{n-2}, \quad f_1 = 1, f_2 = 2.$$

于是 $f_3 = 3, f_4 = 5, f_5 = 8, f_6 = 13 \cdots$ 这就是著名的斐波那契数列。注意它和杨辉三角的相似之处：一个看似要“枚举所有走法”的吓人问题，被一句“最后一步从哪里来”拆成了两个更小的问题。这种拆法后面会在“递归算法”一节里再次登场。

为什么组合数又叫“二项式系数”？把 $(a+b)^n$ 展开试试。 $(a+b)^2 = a^2 + 2ab + b^2$ ，系数是 1, 2, 1； $(a+b)^3 = a^3 + 3a^2b + 3ab^2 + b^3$ ，系数是 1, 3, 3, 1——正是杨辉三角的行。这不是巧合：展开 $(a+b)^n$ 时， $a^k b^{n-k}$ 这一项，相当于在 n 个因子中挑出 k 个贡献 a 、其余贡献 b ，挑法恰好是 $\binom{n}{k}$ 种。于是我们得到一个核心结论。

定理 14.1 (二项式定理). 对任意数 a, b 和非负整数 n ，有

$$(a+b)^n = \binom{n}{0}a^n + \binom{n}{1}a^{n-1}b + \binom{n}{2}a^{n-2}b^2 + \cdots + \binom{n}{n}b^n.$$

证明. 把 $(a+b)^n$ 写成 n 个因子 $(a+b)$ 的连乘。展开时，每个因子要么贡献一个 a ，要么贡献一个 b 。要得到 $a^k b^{n-k}$ ，必须在 n 个因子中恰好选出 k 个来贡献 a ，这样的选法有 $\binom{n}{k}$ 种，所以该项的系数是 $\binom{n}{k}$ 。把 $k = 0, 1, \dots, n$ 的所有项加起来，就得到公式。□

令 $a = b = 1$ ，立刻得到一个数值例子： $\binom{4}{0} + \binom{4}{1} + \binom{4}{2} + \binom{4}{3} + \binom{4}{4} = 2^4 = 16$ 。也就是说，一个 4 人小组的所有可能的“子集代表团”（从 0 人代表团到 4 人全去）一共 16 种。读者可以直接验证： $\binom{4}{0} = 1, \binom{4}{1} = 4, \binom{4}{2} = 6, \binom{4}{3} = 4, \binom{4}{4} = 1$ ，加起来确实是 16。

最后一件数数武器简单得不像定理，却威力惊人。

定理 14.2 (鸽巢原理). 把 $n+1$ 只鸽子放进 n 个鸽巢，至少有一个巢里有两只或更多鸽子。

证明. 反设每个巢里至多一只鸽子, 那么 n 个巢至多装 n 只, 与共有 $n+1$ 只矛盾。□


一句话的定理, 能解决看上去完全无从下手的问题。例如: 全校 400 名学生中, 必有两人同一天生日——因为生日最多 366 种, 学生比“巢”多。再如: 任意 6 个人中, 必有 3 人互相认识, 或者 3 人互不认识。这个结论可以用鸽巢原理证: 任取一人甲, 甲与其余 5 人的关系只有“认识、不认识”两种, 5 只鸽子进 2 个巢, 必有一种关系至少涉及 3 人, 再继续讨论这 3 人之间的关系即可 (细节留给思考题)。鸽巢原理的深层含义是: 当对象的个数超过分类的格数时, 碰撞不可避免。这个朴素思想是现代密码学中“哈希碰撞”研究和计算机科学中“抽屉论证”的原型。

14.4 把每支球队画成一个点：图、树与路

现在换一个角度看单循环赛。20 支球队两两比赛, 我们关心的其实不是“谁赢谁输”, 而是“谁和谁有关系”。把每支球队画成一个点, 每场比赛在两点间连一条线, 整个赛程就变成一张“点线图”。生活中的同类结构到处都是: 城市和航线、人和好友关系、网页和超链接、路口和街道、芯片上的元件和导线。数学家把这类结构抽象成一个概念。

定义 14.3 (图). 一个图由一组顶点和一组边组成, 每条边连接两个顶点。如果边有方向 (比如单行道), 称为有向图; 如果边上标有数字 (比如路程、费用), 称为加权图。与某个顶点相连的边的条数, 叫作该顶点的度数。

注意这个定义故意扔掉了所有几何信息: 图里的“点”没有位置, “线”没有长短和曲直, 唯一的信息是谁和谁连着。这是一种故意的遗忘——忘掉不重要的, 才能看清结构本身。



上面这张小图里, 顶点甲的度数是 3 (连着乙、丙、戊), 顶点戊的度数是 2。有一个所有图都遵守的定律。

定理 14.4 (握手引理). 在任何图中, 所有顶点的度数之和等于边数的两倍。

证明. 逐条边去数。每条边有两个端点, 每数一条边, 就给它的两个端点的度数各贡献 1。所以度数总和恰好是边数的 2 倍。□

这个定理有一个立刻可用的推论: 任何图中, 度数为奇数的顶点必有偶数个。因为度数总和是偶数, 奇数加奇数才可能是偶数, 奇度顶点必须成对出现。翻译回联欢会: 任何一场聚会中, “握手次数为奇数”的人数一定是偶数。读者下次参加聚会可以默默验证——这不是巧合, 是定理。

图论里最干净的一类图是树: 连通 (任意两点之间都有路可走) 且没有圈的图。树像真实的大树一样, 从任何一个点出发都不会绕回原地。一个基本事实是: n 个顶点的树恰好有 $n-1$ 条边——每条边都“必不可少”, 删去任何一条, 图就断成两截。家族谱系图、电脑里的文件夹目录、

淘汰赛的晋级图，都是树。树的一个重要用途是“用尽量少的边把大家连通”：要在 6 个村庄之间修路，让所有村庄互通，最少修 5 条；如果想让总造价最低，就要在一堆候选边里挑出一棵“最便宜的树”，这就是最小生成树问题，它有简单高效的贪心算法。

更有现实气息的问题是最短路。给一张加权图（顶点是路口，边是街道，数字是长度），从家到学校走哪条路总长度最小？读者可能想说“枚举所有路线取最短”，但路口一多，路线条数会像阶乘一样爆炸。1950 年代，计算机科学家戴克斯特拉（Dijkstra）给出了一个贪心算法：从起点出发，始终优先处理“当前已知最近”的那个顶点，用它去刷新邻居们的距离记录，像水波一样一圈圈向外扩散，直到抵达终点。这个算法的每一步只做局部比较，却保证找到全局最短路——前提是所有边的长度非负。今天导航软件里的路径规划，核心仍然是这个思想的加强版。

把“长度”换成“容量”，就进入另一个世界：网络流。把图想象成水管网，每条边有最大流量（口径），问：从水厂到你家，单位时间最多能送多少水？直观上，答案受“瓶颈”限制：如果在地图上画一条线把水厂和你家分开，所有跨过这条线的水管的总容量，就是这条线能“放行”的上限。所有这样的分割线中，最紧的那条决定了真实上限。这就是著名的最大流最小割定理：网络中的最大流量，等于最小割（容量最小的分割线）的容量。我们不证明它，但请读者品味它的形式：一个“最大化”问题的答案，恰好等于另一个“最小化”问题的答案。这种“最大等于最小”的对偶现象，在整个数学里反复出现，每出现一次都意味着找到了结构深处的对称。快递分拣、电网调度、甚至给球队安排赛程，背后都有网络流的影子。

14.5 算法：让机器按图索骥

到目前为止，问题都是我们用手和脑解决的。可现实里的图有上百万个顶点——全国的路网、整个互联网的链接结构。这时候需要把解题方法写成算法：一份严格、机械、任何人（或任何机器）照着做都能得到答案的步骤清单。算法是离散数学与计算机科学的接头处。

设计算法有两种基本姿势，本章前面已经偷偷见过。第一种是递归：把问题拆成同类型的更小问题，直到小到直接有答案。爬楼梯走法 $f_n = f_{n-1} + f_{n-2}$ 就是递归；电脑里“遍历文件夹”也是递归——“列出这个文件夹的内容”就是“对每个子文件夹再执行列出”。第二种是搜索：把所有可能性组织成一棵“决策树”，然后系统地走这棵树。走迷宫就是搜索：每个岔路口是一个顶点，每条走廊是一条边，“找到出口”就是在这张图上找一条路。

搜索又分两种性格。深度优先像一根筋的探险者：沿一条路走到底，撞墙再回头；广度优先像一圈圈扩散的水波：先检查所有一步可达的位置，再检查两步可达的，最短路问题里它保证先找到的出口一定是最近的。戴克斯特拉算法本质上就是广度优先在加权图上的升级版。

但是，“能算出答案”和“算得起答案”是两回事。这就需要本章最后一件武器：算法复杂度的直观说法。

术语卡片：大 O 记号

直观解释：只关心当问题规模 n 变大时，算法的工作量大约按什么方式增长，忽略常数倍和细枝末节。

正式说法：若工作量不超过 n 的某个固定倍数，记作 $O(n)$ ；不超过 n^2 的固定倍数，记作 $O(n^2)$ ；依此类推。

一个例子：在 n 个数里找最大值的算法是 $O(n)$ ——每个数看一眼就够；枚举 n 个人的所有排队方案是 $O(n!)$ ——根本跑不完。

用大 O 的眼光重看本章：在 n 个顶点的图上跑戴克斯特拉算法，工作量大约是 $O(n^2)$ ，路口数扩大 10 倍，时间大约扩大 100 倍——可以接受。检查“ n 个人两两关系”的问题是 $O(n^2)$ ——也可以接受。但如果一个算法的复杂度是 $O(2^n)$ 或 $O(n!)$ ，故事就完全不同了： 2^{40} 已经超过一万亿， $25!$ 更是天文数字。规模只增长到几十，机器就要跑到天荒地老。这类问题里有不少著名难题，比如“旅行商问题”：给若干城市，找一条走遍所有城市再回到起点的最短回路。至今没有人知道有没有本质上比“近乎枚举”快得多的通用算法——这是计算机科学最大的未解之谜之一（通常写作“P 与 NP 问题”），数学家们悬赏百万美元等待答案。

于是离散数学给我们上的最后一课是双面的：一方面，图、递推和贪心让我们能把看似不可能的大问题压进可计算的范围；另一方面，复杂度理论冷酷地标出了边界——有些问题不是“暂时算不动”，而可能是“本质上就算不动”。知道哪边是哪边，本身就是深刻的数学知识。

14.6 离散结构、密码与数论：为什么它们分不开

本章的主题看似是“数数和连线”，但它和第 13 章的数论、和你手机里的密码，是同一条战壕里的战友。理由有三层。

第一层，计算机本身就是离散机器。它存的是 0 和 1 的串，走的是一步一条指令，天然生活在离散世界里。连续的量（比如圆的面积）进了计算机也要被切碎成有限位小数。所以研究离散结构的数学——组合、图、逻辑、递推——就是计算机科学的“母语教材”。

第二层，密码的安全性来自离散难题。第 13 章讲过，把两个大质数相乘很容易，把乘积拆回两个质数极难——这是 RSA 密码的地基。请注意这个不对称正是“复杂度”问题：正向是 $O(\text{多项式})$ 的乘法，逆向目前只知道接近枚举的慢算法。离散对数、格上的最短向量等离散结构难题，也都站在现代密码的底层。本章的鸽巢原理则在另一头守护密码学：哈希函数把任意长的消息压成固定长度的“指纹”，消息无穷而指纹有限，鸽巢原理保证碰撞必然存在——密码学家要做的，是找到碰撞这件事在计算上不可行。

第三层，数论本身也是离散数学。整数是一个一个的，质数是一颗一颗散落在数轴上的点。组合工具一直在为数论服务：二项式系数里藏着质数的行踪（比如当 p 是质数时， $\binom{p}{1}, \binom{p}{2}, \dots, \binom{p}{p-1}$ 全都被 p 整除，读者可以用 $p = 5$ 亲手验证）；递推数列的整除性质是竞赛和研究的常客；图论甚至被用来研究质数之间的“距离”。

连接线

向前看：本章的乘法原理和阶乘，会在第 18 章的概率里再次登场——“等可能的样本空间”其实就是一次组合计数；图的连通性和“圈”的概念，会在第 16 章拓扑学里被推广成“欧拉示性数”；算法与不可计算的边界，会在第 19 章继续深挖。

向后看：第 7 章的矩阵可以记录一张图的连接关系（邻接矩阵），矩阵乘法一次，数出的就是“两步可达”的路径条数——线性代数和图论在这里握手。第 13 章的同余和质数，是本章组合数整除性质和密码应用的共同地基。

14.7 数学实验

一分钟实验

实验一：数树。在纸上画 4 个顶点，试着画出所有“不同构”（连法本质上不一样）的树，数一数有几种；再画 5 个顶点数一数。（4 个顶点有 2 种，5 个顶点有 3 种。）体会一下：这个数列增长得很快，到 10 个顶点时已有 106 种。

实验二：手算最短路。画一张 5 个路口的小图：家、学校、公园、书店、车站，随意连七八条边并标上长度。用戴克斯特拉的思想，从“家”开始，把每个路口旁标注“目前已知的最近距离”，每处理一个路口就刷新它的邻居。算完和自己凭眼睛猜的路线比一比。

实验三：二项式系数与质数。算出 $\binom{5}{1}, \binom{5}{2}, \binom{5}{3}, \binom{5}{4}$ ，检查是否都被 5 整除；再对 $n = 6$ 做同样的事，看看结论还在不在。想一想差别在哪。

数学工具箱

本章收入工具箱的新工具：

- **加法原理与乘法原理：**分类用加，分步用乘；先问“我数重了吗”。
- **排列与组合：**有序用 $A_n^k = \frac{n!}{(n-k)!}$ ，无序用 $\binom{n}{k} = \frac{n!}{k!(n-k)!}$ 。
- **递推：**用更小规模的同类问题定义当前问题，如 $f_n = f_{n-1} + f_{n-2}$ 。
- **二项式定理：** $(a+b)^n$ 的展开系数就是组合数；令 $a=b=1$ 得子集总数 2^n 。
- **鸽巢原理：**鸽子比巢多，必有碰撞——碰撞不可避免性论证的原型。
- **图的语言：**顶点、边、度数；握手引理 $\sum \text{度数} = 2 \times \text{边数}$ 。
- **树、最短路、网络流：**连通且省边的骨架、贪心扩散、最大流等于最小割。
- **大 O 记号：**用增长方式 ($O(n)$ 、 $O(n^2)$ 、 $O(2^n)$ 、 $O(n!)$) 判断算法跑不跑得动。

继续攀登

继续向前可以攀登的方向：

- **生成函数**：把数列 $a_0, a_1, a_2, \dots$ 压缩成一个函数，用代数方法解递推——斐波那契数列的通项公式就是这样求出来的。
- **拉姆齐理论**：“6 人中必有 3 人互识或互不认识”只是开端；一般地，足够大的结构里必然出现足够整齐的子结构，这是“完全的无序不可能”的数学。
- **P 与 NP**：可验证与可求解之间的鸿沟，克雷数学研究所的七大千禧年难题之一。
- **谱图论**：用矩阵的特征值研究图的连通性，支撑了搜索引擎的网页排序。
- **极值图论**：在“不能有三角形”之类的禁令下，一张图最多能有多少条边。

思考题

观察题

1. 计算 $\binom{10}{2}$ 和 $\binom{10}{8}$ ，你会发现它们相等。用“选 2 个人去开会”和“选 8 个人留下”的关系解释为什么 $\binom{n}{k} = \binom{n}{n-k}$ 永远成立。提示：每一次“选出 k 个”都同时“留下 $n-k$ 个”。
2. 数一数你所在小组（或家里）每个人认识组内其他人的数目，把度数加起来，看看是不是偶数，并用握手引理解释。提示：把“认识关系”画成图。

证明题

1. 证明： n 个顶点的树恰好有 $n-1$ 条边。提示：对顶点数用归纳法；一棵树总能找到一片“叶子”（度数为 1 的顶点），摘掉它和连着的边，剩下的仍是一棵更小的树。
2. 证明：任意 6 个人中，必有 3 人两两互相认识，或 3 人两两互不认识。提示：正文已经走了一半——固定一人，用鸽巢原理找出与他关系相同的 3 人；再分“这 3 人中有两人关系也如此”和“没有”两种情况。

挑战题

1. 在一条直线上等距取 n 个点，把每对点连一条线段。所有线段的中点中，至少有多少个互不相同的点？提示：先对 $n=3, 4, 5$ 画图数一数；把点放在坐标 $1, 2, \dots, n$ 上，中点坐标是 $\frac{i+j}{2}$ ，考察它能取哪些值。
2. 8 枚外观相同的金币中有 1 枚较轻的假币，用一架没有砝码的天平，至少称几次能保证找出假币？如果改成“不知道假币偏轻还是偏重”，12 枚金币又需要几次？提示：每称一次有三种结果（左沉、右沉、平衡）， k 次称量最多区分 3^k 种情形——把每一次称量看作决策树上的一个分叉。

通往下一章的门

这一章我们学会了数离散的物件：排队的人、握手的次数、图里的边。我们一再看到同一个现象：离散对象的局部规律（比如 $\binom{p}{k}$ 被质数 p 整除）往往由质数在幕后操纵。可是，如果我们把镜头拉远，问一个宏观问题——质数这些“离散的点”，在整条数轴上到底铺得多密？

具体地说：不超过 100 的质数有 25 个，不超过 1000 的有 168 个，不超过一百万的有 78498 个。这串数字有没有公式？越往后质数越稀疏，但稀疏的速度是匀速的吗？有趣的是，回答这个纯离散的问题，最强有力的工具竟然来自最连续的世界——微积分、无穷级数，甚至复数平面上的函数。数学家们发现，质数的分布仿佛被一条“连续的影子”精确牵引着，而这条影子的秘密，浓缩在一个叫黎曼 ζ 函数的对象身上。它身上还挂着数学界最著名的未解之谜。

离散与连续，这两条看起来背道而驰的河流，将在下一章交汇。

第十五章 解析数论：用连续工具研究离散的素数

15.1 一场越报越吃力的报数游戏

课间，四个同学玩一个报数游戏：第一个人说“2”，后面的人依次报出下一个素数——3、5、7、11、13……开头大家抢着答，报到五十附近开始要掰手指，报到一百附近就有人掏出草稿纸试除了。游戏有个奇怪的手感：起步时素数密密麻麻，几乎每隔一两个数就撞上一个；越往后，素数之间的“空地”越宽，等待的时间越长。

另一个场景发生在你看不见的地方。你每次用手机支付，浏览器和银行服务器之间都要交换密钥，而最流行的公开密钥方案之一，第一步就是“找两个几百位长的大素数”。计算机怎么找？它不是背一张素数表——几百位的素数全列出来，全宇宙的原子都不够用。它的办法笨得可爱：随机取一个大数，测试它是不是素数，不是就换一个，直到撞上一个为止。这个办法能行，全靠一个背景事实：即使到了几百位那么高的地方，素数虽然稀，却没有稀到绝迹，平均每试几百次总能中一次。

于是两个问题浮上来。第一个问题我们其实已经解决过：素数会不会用完？不会，欧几里得两千多年前就证明了素数有无穷多个。但第二个问题要刁钻得多，也正是这场报数游戏“越报越吃力”的原因：

素数越到后面越稀。可是——稀到什么程度？稀得有没有规律？能不能写出一个公式，大致告诉我们：在数字 x 附近，素数出现的“密度”是多少？

这个问题听起来像统计，像物理，不太像我们习惯的“整数问题”。整数是一个一个蹦的，是离散的；而“密度”“规律”“公式”这些词，属于连续变化的世界。本章要讲的解析数论，干的正是这件看起来不讲道理的事：用连续的数学工具——对数、积分、无穷级数，甚至复数——去研究最离散的素数。令人吃惊的是，这条路不但走得通，还引出了数学中最著名的未解之谜。

15.2 第一个猜想：按比例分钱为什么行不通

先凭直觉猜。一百以内有 25 个素数，占四分之一。于是最自然的猜想是：素数大约占整数的四分之一，往后也大致如此，只是慢慢再少一点。换句话说，素数的密度近似一个固定比例。

这个猜想只要多算一段就破产了。如果你耐心地把素数表数下去（或者查一张现成的表），会发现：100 以内有 25 个素数，密度是 25%；1000 以内有 168 个，密度降到 16.8%；10000 以内有 1229 个，密度只剩 12.3%。密度不是在一个固定值附近波动，而是持续、稳定地往下掉。任何“固定比例”的猜法都会被这张表否决。

第二个直觉是：密度会不会像 $\frac{1}{x}$ 那样下降？也就是到 x 附近时，大约每 x 个数里才有 1 个素数？这也错得太快——按这个说法，1000 附近每 1000 个数才有 1 个素数，可实际上 1000 以内

有 168 个素数，平均不到 6 个数就有 1 个。真实的下降速度比 $\frac{1}{x}$ 慢得多，又比“固定比例”快得多。它卡在中间，不上不下。

反例警报

“素数越来越稀，所以到了足够大的地方，就会有一段很长很长的区域一个素数都没有，长得超过任何指定的长度——这说明素数‘实际上是有限的’。”

前半句是对的（我们很快会证明：任意长的纯合数段确实存在），后半句是错的。稀，不等于消失。欧几里得的证明保证：无论你走多远，前面永远还有素数。直觉上“稀到看不见”和逻辑上“没有了”是两回事，这正是本章要反复小心的地方。

固定比例失败， $\frac{1}{x}$ 也失败。我们需要一个会“缓慢衰减”的新函数来当密度的候选人。这个函数其实你在第三部已经见过——对数。


15.3 给素数造一台计数器

要谈“密度”，先要有一把尺子。我们发明的第一个新工具是一个计数函数：

定义 15.1 (素数计数函数). 对任意正实数 x ，用 $\pi(x)$ 表示不超过 x 的素数个数。例如 $\pi(10) = 4$ (素数是 2, 3, 5, 7)， $\pi(100) = 25$ 。

这里的 π 不是圆周率，只是借用了希腊字母“p”——英语里素数是 prime。这个符号解决的麻烦是：以前我们只能说“素数好像越来越少”，现在我们可以说“ $\pi(100) = 25$ ， $\pi(1000) = 168$ ”，把模糊的感觉变成可以比较、可以作图的数。

$\pi(x)$ 的图像是什么样子？它是一个一个台阶： x 走过合数时它原地不动，每踩到一个素数就往上跳一格。它永远向右走，永远只上不下，而且（因为素数无穷多）台阶会一直延伸下去，永不到顶。



这台“计数器”是纯离散的：台阶高矮错落，看不出光滑的规律。真正神奇的事情是——如果站远一点看，这条坑坑洼洼的楼梯，竟然贴着一光滑的曲线走。为了说清楚这条曲线，我们需要第二位主角：自然对数 $\ln x$ 。

回忆一下对数的出身。指数函数 $10^2 = 100$ 、 $10^3 = 1000$ 告诉我们： $\lg 100 = 2$ 、 $\lg 1000 = 3$ 。对数做的是“把乘法翻译成加法”的买卖，它增长得极慢： x 翻十倍， $\lg x$ 只加一。数学家更偏爱以 $e \approx 2.718$ 为底的自然对数 $\ln x$ ，因为它在微积分里最顺手：曲线 $y = \frac{1}{t}$ 从 1 到 x 下方的面积，恰好就是 $\ln x$ 。这个“面积”身份，待会儿要派大用场。

第三个要请出场的工具，是一条名声很大的级数：

$$1 + \frac{1}{2} + \frac{1}{3} + \frac{1}{4} + \frac{1}{5} + \cdots$$

它叫调和级数。每一项都在变小，趋向于零，可它加起来的总和却是无穷大！看出这一点的办法很巧：把项分组—— $\frac{1}{2}$ 单独一组； $\frac{1}{3} + \frac{1}{4}$ 一组，两项都不小于 $\frac{1}{4}$ ，和至少是 $\frac{1}{2}$ ；接下来的 $\frac{1}{5}$ 到 $\frac{1}{8}$ 共四项，每项不小于 $\frac{1}{8}$ ，和又至少是 $\frac{1}{2}$ ；再往后八项、十六项……每一组的和都至少 $\frac{1}{2}$ 。无穷多个 $\frac{1}{2}$ 加起来，当然发散到无穷大。调和级数给我们的教训是：趋向于零，不等于加起来有限。

调和级数还有一个关键的量化事实：前 n 项的和，大约等于 $\ln n$ 。这不奇怪——上面说过， $\ln n$ 就是曲线 $y = \frac{1}{t}$ 下方的面积，而 $1 + \frac{1}{2} + \cdots + \frac{1}{n}$ 不过是把这块面积切成宽度为 1、高度为 $\frac{1}{k}$ 的小矩形之和，矩形和面积本来就差不了多少。粗略地说：

$$1 + \frac{1}{2} + \frac{1}{3} + \cdots + \frac{1}{n} \approx \ln n.$$

现在，三件工具都摆上桌了：台阶状的计数器 $\pi(x)$ 、慢吞吞的对数 $\ln x$ 、以及对数与“倒数之和”之间的面积桥梁。是时候说出本章的中心故事了。

15.4 素数定理：稀疏中的规律

十八世纪末，少年高斯得到一个好玩的机会：有人送他一本对数表，书的附录里印着一张素数表。据说他翻来覆去地比对这两张表，注意到了一件怪事——素数出现的“疏密节奏”，和对数增长的节奏，竟然合拍。他猜：在 x 附近，每 $\ln x$ 个连续整数里，大约有 1 个素数。换句话说， x 附近的素数密度大约是 $\frac{1}{\ln x}$ 。

密度是 $\frac{1}{\ln x}$ ，那么不超过 x 的素数总数，就该是把这个密度从 2 一路累加到 x ——用积分的语言写，这条光滑曲线就是 $\int_2^x \frac{dt}{\ln t}$ 。一个更粗糙但更好算的近似是 $\frac{x}{\ln x}$ 。高斯的猜测后来被证明是对的，这就是素数定理：

定理 15.2 (素数定理). 当 x 越来越大时，

$$\pi(x) \approx \frac{x}{\ln x},$$

精确的意思是：比值 $\pi(x)/\frac{x}{\ln x}$ 随着 x 无限增大而趋向于 1。

注. 高斯在十八世纪末猜出这条规律，但证明等了一百年。直到 1896 年，数学家阿达马和德拉瓦莱普桑才各自独立地证明了它，而他们用的武器不是整数技巧，恰恰是复数平面上的函数理论——也就是本章后半部分的主角。素数定理的证明超出了本书范围，但它的内容我们可以用表格亲手检验。

动手验一验。 $\ln 100 \approx 4.6$, $\ln 1000 \approx 6.9$, $\ln 10^6 \approx 13.8$, $\ln 10^9 \approx 20.7$ 。填进 $\frac{x}{\ln x}$ ，和真实的 $\pi(x)$ 对照：

x	$\pi(x)$	$x/\ln x$ (取整)	比值 $\pi(x)/(x/\ln x)$
10^2	25	22	1.15
10^3	168	145	1.16
10^4	1229	1086	1.13
10^5	9592	8686	1.10
10^6	78498	72382	1.08
10^9	50847534	48254942	1.05

看最右一列：1.15, 1.16, 1.13, 1.10, 1.08, 1.05，慢吞吞地、一点一点地朝 1 蹭过去。这就是“比值趋向于 1”在现实中的样子——不急，但从不停下，也从不回头。一张表当然不构成证明（这一点我们后面还要强调），但它让“素数的稀疏有精确规律”从一句口号变成看得见的数。

把素数定理翻译回报数游戏：在 x 附近，素数的平均间隔大约是 $\ln x$ 。100 附近平均每隔约 4.6 个数有一个素数； 10^6 附近平均每隔约 13.8 个数才有一个；到几百位的天文数字那里，平均每隔几百个数有一个——这正好解释了为什么电脑“随机试几百次就能撞上一个大素数”。密码学家不是运气好，是素数定理在背后托底。

术语卡片：素数定理

直观解释：素数越来越稀，但稀疏的节奏被 $\ln x$ 精确控制； x 附近的素数密度约为 $1/\ln x$ 。

正式表述： $\pi(x)/(x/\ln x) \rightarrow 1$ （当 x 无限增大）。

一个例子： $x = 10^6$ 时， $x/\ln x \approx 72382$ ，真实的 $\pi(x) = 78498$ ，两者只差约 8%，而且 x 越大这个百分比越小。

不过要小心：“平均间隔约 $\ln x$ ”说的是平均，不是每一段都如此。素数的真实间隔忽大忽小：有时两个素数只差 2，比如 29 和 31、41 和 43，这叫孪生素数；有时又一连成百上千个合数。事实上，我们能证明“空地”可以任意长：

定理 15.3 (素数间隔可以任意大). 对任意正整数 n ，都存在连续 n 个正整数，其中没有一个是素数。

证明. 取一个足够大的数 $N = (n+1)!$ ，即 $1 \times 2 \times 3 \times \cdots \times (n+1)$ 的乘积。考察紧跟在 N 后面的 n 个数：

$$N+2, N+3, N+4, \dots, N+(n+1).$$

第一个数 $N+2$ ： N 本身含有因子 2（阶乘把 2 乘进去了），所以 $N+2$ 能被 2 整除，是合数。第二个数 $N+3$ ： N 含有因子 3，所以 $N+3$ 能被 3 整除，也是合数。一般地，对 2 到 $n+1$ 之间的每个 k ， N 都含有因子 k ，于是 $N+k$ 能被 k 整除，而且 $N+k$ 显然大于 k ，所以它是合数。这样， $N+2$ 到 $N+(n+1)$ 这 n 个连续整数全是合数。□

这个证明用的是纯构造：想要多长的空地，就把阶乘造多大。比如想要连续 1000 个合数，取 $1001!$ 加 2 到 $1001!$ 加 1001 即可——一个天文数字长度的“素数沙漠”。可是另一头，孪生素数似乎又永远成双成对地冒出来：3 和 5、11 和 13、...、101 和 103、...。数学家猜孪生素数有无穷多对——这是著名的孪生素数猜想，至今没人能证明，也没人能推翻。2013 年，张益唐证明了存

在无穷多对间隔不超过七千万的素数，随后全世界的合作把这个上界一路压缩到 246。从 246 到 2，看似一步之遥，至今无人跨过。

于是素数间隔的图景是：平均而言越来越宽（受 $\ln x$ 控制），个别地方却任意宽，而相隔 2 的“双胞胎”又似乎永不消失——平均的规律性，和个体的任性，同时成立。要搞清楚“素数究竟有多规律”，光有 $\pi(x) \approx x/\ln x$ 还不够，我们还得问：误差有多大？ $\pi(x)$ 和 $\frac{x}{\ln x}$ 之间的差，是乱蹦的，还是被什么更深的东西管着？这个问题，把我们带到了数学最神秘的大门口。

15.5 一台把素数“调出来”的级数机器

让我们把镜头从表格转向一台“机器”。十八世纪，欧拉研究下面这个无穷级数：

$$\zeta(s) = 1 + \frac{1}{2^s} + \frac{1}{3^s} + \frac{1}{4^s} + \cdots$$

这里的 s 先当作大于 1 的实数。 $s = 1$ 时它就是刚才的调和级数，发散； $s = 2$ 时它收敛到 $\frac{\pi^2}{6}$ （这个结果本身就是一段传奇，圆周率竟然从整数的平方倒数里冒出来）。欧拉注意到的关键事实是：这台看似与素数无关的级数机器，骨子里完全由素数决定。原因是算术基本定理——每个整数都唯一地分解成素数的乘积。把级数里每一项的分母做素数分解、重新归拢，利用等比数列求和，就能把加法改写成乘法：

$$1 + \frac{1}{2^s} + \frac{1}{3^s} + \frac{1}{4^s} + \cdots = \frac{1}{1-2^{-s}} \times \frac{1}{1-3^{-s}} \times \frac{1}{1-5^{-s}} \times \frac{1}{1-7^{-s}} \times \cdots$$

右边是一个跑遍所有素数的无穷乘积。这个等式叫欧拉乘积公式，它是本章最深的一句诗：左边是所有整数的合唱，右边是每个素数各管一件乐器。整数的加法世界和素数的乘法世界，在这台机器里是同一件东西的两种写法。

立刻有一个推论。让 s 趋向于 1，左边的级数发散到无穷大；如果素数只有有限个，右边只是有限个分数相乘，必定是有限的，矛盾。所以素数必须无穷多——欧拉乘积给了“素数无穷”一个全新风格的证明。更精细地算下去，还能得到：所有素数的倒数之和

$$\frac{1}{2} + \frac{1}{3} + \frac{1}{5} + \frac{1}{7} + \frac{1}{11} + \cdots$$

也是发散的，而且它发散的速度大约像 $\ln(\ln x)$ 那样慢。这个数字值得咂摸：素数在全体整数中的“分量”，重到倒数和都收不住——比起平方数（ $\sum \frac{1}{n^2}$ 收敛），素数要“稠密”得多。素数无穷，不是勉强无穷，而是理直气壮地无穷。

15.6 黎曼的惊天一跃：把 s 送进复数平面

欧拉的机器要求 $s > 1$ ，否则级数收不住。1859 年，黎曼只发表了一篇八页的短文，却做了一件改变数学史的事：他问，能不能把 $\zeta(s)$ 的定义域扩展到整个复数平面？

术语卡片：黎曼 ζ 函数

直观解释：一台以复数为输入的机器， $s > 1$ 时由级数 $1 + 2^{-s} + 3^{-s} + \dots$ 驱动；通过“解析延拓”的技术，它几乎可以延伸到整个复数平面。


正式定义（的部分）： $\zeta(s) = \sum_{n=1}^{\infty} n^{-s}$ （当 s 的实部大于 1），再唯一地延拓到其余地方，仅在 $s = 1$ 处“爆炸”。

一个例子： $\zeta(2) = \frac{\pi^2}{6}$ ；而在延拓意义下 $\zeta(-1)$ 被赋予值 $-\frac{1}{12}$ ——注意这不是说 $1 + 2 + 3 + \dots$ 真的等于 $-\frac{1}{12}$ ，而是延拓后的函数在那里的取值，两者不能混为一谈。

“延拓”这一步的难处在于：级数本身只在实部大于 1 的区域收敛，出了这个圈子， $1 + 2^{-s} + 3^{-s} + \dots$ 根本不听话。数学家用了一套精巧的办法（大意是先绕个弯把级数改写成收敛的样子，再证明这样得到的函数是唯一合理的延伸），让 ζ 在除 $s = 1$ 以外的整个复数平面上都有确定的意义。这套技术叫解析延拓，属于复分析，细节超出本书——但请记住它的一个宝贵性质：延拓是唯一的，就像把一段圆弧顺着自己的弯曲方式继续画下去，只有唯一一种自然的画法。

函数有了，黎曼接着问：这台机器在哪些输入下输出为零？也就是 $\zeta(s) = 0$ 的解在哪里？零点是函数的“基因”——就像多项式由它的根决定一样，一个解析函数在很大程度上由它的零点决定。计算表明，负偶数 $-2, -4, -6, \dots$ 都是零点，这些被称为平凡零点，没什么好惊讶的。真正的秘密藏在实部介于 0 和 1 之间的一条竖直“临界带”里：那里还有无穷多个非平凡零点，而且黎曼算出，最前面几个的实部恰好都是 $\frac{1}{2}$ ：

$$\frac{1}{2} + 14.13i, \quad \frac{1}{2} + 21.02i, \quad \frac{1}{2} + 25.01i, \quad \dots$$



为什么零点与素数有关？因为 ζ 函数通过欧拉乘积“装着”全部素数的信息，而零点就是提取这些信息的旋钮。黎曼在那篇八页论文里给出了一个惊人的公式（证明后来被补全）： $\pi(x)$ 可以写成一项光滑的主项，加上每个非平凡零点贡献的一项“修正波”。零点的实部越大，它贡献的波浪起伏越厉害， $\pi(x)$ 偏离光滑曲线的误差就越难控制。于是“素数有多规律”这个问题，被精确地翻译成了“零点躺在哪里”这个几何问题。

黎曼把他算到的现象写成了一个猜想：

黎曼猜想（1859 年，至今未证明）： ζ 函数的所有非平凡零点，实部都等于 $\frac{1}{2}$ ——它们整整齐齐地躺在同一条竖直直线上。

请注意措辞：这是**猜想**，不是定理。一百六十多年里，计算机验证了超过十万亿个非平凡零点，无一例外全在这条线上；无数数学家尝试证明它，相关的等价命题和推论堆成了山，但证明

至今没有出现。它是克雷数学研究所悬赏一百万美元的七个“千禧年难题”之一。

黎曼猜想为什么重要？因为它管着素数定理的误差。数学家已经证明： $\pi(x)$ 与光滑曲线之间的偏差大小，完全由非平凡零点的实部控制。如果黎曼猜想成立，这个偏差就被压到最小，大致不超过 $\sqrt{x} \ln x$ 的量级——相对于 x 本身，这就像测量地球到月球的距离时误差不到一公里。反过来，只要有一个零点偏离临界线，素数分布就会出现比预期大得多的“异常起伏”。所以黎曼猜想的通俗版本就是一句话：**素数虽然顽皮，但顽皮得有底线；它们的随机性被一条直线死死框住。**

反例警报

“计算机已经验证了十万亿个零点都在临界线上，所以黎曼猜想基本算是成立了，只差走个形式。”

这是把实验当成证明的典型错误。非平凡零点有无穷多个，验证再多也只是无穷海洋里的一瓢水。数学史上有过残酷的教训：有的命题对极大极大的数都成立，却在更远的、人力无法企及的地方出现第一个反例（素数分布的研究里就真实发生过“巨大才反转”的现象）。实验的价值在于启发猜想、积累信心、寻找反例；而“对所有情形成立”的保证，只能来自证明。这正是本章标题里“解析”二字的分量：它要求的是论证，不是统计。

连接线

回头看，本章把前面好几章的线拧成了一股绳：第 9 章的极限（比值趋向于 1）、第 11 章的级数与积分（调和级数、 $\ln x$ 的面积身份）、第 12 章的复数（ ζ 函数的延拓）、第 13 章的算术基本定理（欧拉乘积的基石）和第 14 章的计算实验（素数表与筛法）。向前看，黎曼猜想里“所有零点躺在一条直线上”这种关于“形状与位置”的表述，已经在向第 16 章的拓扑学招手。而密码学里的公开密钥方案，则是素数分布在现实世界最硬的落地：它一边依赖“找素数容易”（素数定理保证密度），一边依赖“分解大数困难”（至今没有快速算法）。

15.7 亲手数一数：实验能做到什么，做不到什么

一分钟实验

准备一张 1 到 100 的方格表，亲手做一遍埃拉托色尼筛法：圈出 2，划掉它的倍数；圈出一个幸存的 3，划掉它的倍数；再对 5、7 各做一遍（100 以内只需筛到 $\sqrt{100} = 10$ 即可停手，想一想为什么）。最后幸存的数就是 100 以内的全部素数，数一数，是不是 25 个？

接着记录每相邻两个素数的间隔： $3 - 2 = 1$ ， $5 - 3 = 2$ ， $7 - 5 = 2$ ， $11 - 7 = 4$ ，……把间隔列成一行，回答三个问题：

1. 最大的间隔是几？出现在哪里？
2. 间隔为 2 的孪生素数有几对？
3. 平均间隔大约是多少？和 $\ln 100 \approx 4.6$ 比一比，接近吗？

如果你有计算器或电脑，可以再把实验做到 1000，观察“平均间隔”如何向 $\ln 1000 \approx 6.9$ 移动。有条件的同学还可以把这段过程写成十几行的短程序：用两重循环模仿上面的“圈与划”，让计算机替你数到十万。

做完实验，请停下来想一想：你手里的表格和程序，到底证明了什么？它告诉你“100 以内素数的平均间隔约为 4.3，与 $\ln 100$ 同量级”——这是一次观察，是素数定理在 $x = 100$ 处的一次抽样。它没有、也不可能证明比值趋向于 1 的极限事实。同样的逻辑链条也适用于黎曼猜想：十亿次验证依然是实验。数学里有三层台阶，本章恰好各占了一级：**实验**（筛法、数表、零点计算）负责提供线索，**猜想**（孪生素数、黎曼猜想）负责指出方向，**证明**（欧几里得、阶乘构造、素数定理）负责给出保证。混淆这三层，是数论里最容易掉进去的坑，也是最有资格被记住的教训。

数学工具箱

本章新添的工具：

- **计数函数** $\pi(x)$ ：把“素数越来越稀”的感觉变成可作图、可比较的函数。
- **自然对数** $\ln x$ ：增长最慢的基本函数之一，恰好是素数密度的“刻度尺”；它同时是 $y = \frac{1}{t}$ 下方的面积。
- **调和级数与它的发散**：趋向于零不等于收敛；前 n 项和约为 $\ln n$ 。
- **欧拉乘积**： $\sum n^{-s} = \prod_p (1 - p^{-s})^{-1}$ ，整数加法世界与素数乘法世界的翻译器。
- **ζ 函数与解析延拓**：把级数机器延伸到复数平面，零点的位置控制素数分布的误差。
- **实验—猜想—证明的分层意识**：表格启发猜想，猜想指引证明，只有证明给出保证。

继续攀登

想继续往前走的同学，可以记住这些路标：**切比雪夫函数**与素数定理的初等证明（1949 年塞尔伯格与埃尔德什各自给出，不依赖复分析）；**对数积分** $\text{Li}(x)$ ，它比 $x/\ln x$ 更贴近 $\pi(x)$ ；**解析延拓**与复分析，黎曼论文的真正语言；**筛法**的现代版本，它们支撑着张益唐之后的素数间隔研究；**零点计算**，人们如何用高速计算机把十亿个零点挨个钉在临界线上。这些关键词中的任何一个，都够你在图书馆或网络上泡一个暑假。

思考题

观察题

1. 重做 100 以内素数的间隔记录，找出所有“间隔突然变大”的位置（即比它前面所有间隔都大的那些）。观察这些位置上的素数，猜一猜：下一个纪录间隔大概会出现在什么样的地方？提示：纪录间隔出现时，意味着一段较长的合数沙漠；想想阶乘构造给你的感觉——沙漠更可能出现在数的“结构特殊”处，还是随便哪里？
2. 用正文的表格观察“比值”一列：从 10^2 到 10^9 ，比值每下降一点， x 要扩大多少倍？由此感受“趋向于 1”到底有多慢。提示：注意 x 每乘以 10，比值只挪动零点几个百分点；这不是它不努力，而是 $\ln x$ 增长得太矜持。

证明题

1. 证明：存在连续 1000 个正整数，其中没有一个素数。并说明你构造出的那段合数大约有多“高”。提示：把正文里的 $N = (n+1)!$ 换成合适的阶乘；检查每个 $N+k$ 为什么一定是合数。
2. 不用查表，证明调和级数中任意取出充分靠后的连续若干项，它们的和可以超过 10。提示：回忆正文的分组办法——每一组的和至少是 $\frac{1}{2}$ ；要让总和超过 10，大约需要多少个这样的组？

挑战题

1. 正文用欧拉乘积说明了“若素数只有有限个，则 $s \rightarrow 1$ 时两边矛盾”。顺着这个思路再进一步：试说明为什么“素数倒数和发散”这件事，从乘积公式的角度看几乎是必然的。提示：对乘积公式两边取对数，把乘积变成求和；当 $s \rightarrow 1$ 时左边爆炸，右边那些 $\ln(1 - p^{-s})$ 展开后领头的项正是 $\frac{1}{p}$ 。这一步需要你对“取对数把乘法变加法”足够熟练，卡住是正常的。

通往下一章的门

这一章我们干了一件“跨界”的事：用连续的、光滑的分析工具，去审问离散的、一粒一粒的素数。回头看那幅零点的示意图，有一个细节值得再盯一眼——黎曼猜想说的是：无穷多个神秘的点，全部躺在**同一条直线**上。

“躺在一条线上”“围成一个圈”“中间有一个洞”——这类话我们已经随口用了好几次。可是，什么叫一条线？什么叫一个洞？如果把整个复数平面换成一块橡皮膜，允许拉伸、弯折、扭转，只要不撕破、不粘断，那条临界线还是“一条线”吗？咖啡杯和甜甜圈，在只许揉不许撕的规则下，凭什么算是同一种东西，又凭什么和球不是同一种东西？

数论靠计数和证明前进，而回答上面这些问题，需要一门专门研究“揉不坏的性质”的学问。它不关心长度和角度，只关心连不连、通不通、有几个洞。这就是下一章——拓扑学——要带你进入的世界。

第五部分

从曲线和空间继续分流——拓扑、微分几何、概率 与基础

第十六章 拓扑学：橡皮泥眼中什么才算同一种形状

16.1 一张不像地图的地图

你大概坐过地铁，也一定见过站台里那张花花绿绿的线路图：横平竖直的线条，均匀排布的圆点，整整齐齐的转角。但如果你把这张图和真实的城市地图叠在一起，会发现它们根本对不上——图纸上相距两厘米的两站，实际上可能隔了五公里；图纸上一条笔直的线路，实际上在地底下绕了好几个弯。这张地图在长度、角度、面积上全都撒了谎。

可奇怪的是，没有一个乘客因此迷路。一九三三年，绘图员哈利·贝克为伦敦地铁画出第一版这样的线路图时，地铁公司一开始还犹豫：把地图画得这么“不真实”，乘客能接受吗？结果事实证明，这张图好用到全世界所有地铁系统都照抄了它。为什么？因为坐地铁的人只关心三件事：我现在在哪一站，要去哪一站，中间在哪里换乘。至于地下隧道究竟拐了几度的弯、两站之间到底是八百米还是一千二百米，统统无所谓。贝克看透了这一点：他扔掉了一切会干扰视线的真实细节，只保留了**谁和谁相连**这一种信息。

这就引出了一个深刻的问题：一张地图可以扭曲得面目全非，却仍然“正确地”回答了某些问题。那么，一个图形身上到底有哪些性质，是随便怎么拉伸、弯曲、压缩都不会改变的？又有哪些性质，轻轻一捏就没了？数学家把研究前一类性质的学问叫作**拓扑学**。它有一个著名的绰号：橡皮泥几何学。在拓扑学家眼里，图形是用永远拉不断的橡皮泥做的——你可以随意揉捏它，只是不许撕开，也不许把两处粘在一起。被这样揉来揉去之后还纹丝不动的那些性质，就是拓扑学要研究的“真正的形状”。

本章我们就来当一回揉橡皮泥的人。我们会看到：一个三百年前的散步问题怎样催生了这门学科；咖啡杯和甜甜圈为什么在拓扑学家眼里是同一个东西；一张纸条拧半圈之后为什么会失去“正反面”；以及这些听起来像游戏的想法，怎样用在网络、地图和机器人身上。

16.2 七座桥，一条走不出来的路线

故事要从一座真实存在过的城市讲起。十八世纪的哥尼斯堡（今天俄罗斯的加里宁格勒）有一条河穿城而过，河中有两座岛，河两岸与两座岛之间一共架着七座桥。市民们茶余饭后有一个消遣问题，据说在酒馆里争论了很多年：

能不能从家里出发散步，把七座桥每座都恰好走一遍，最后回到家里？


先别往下看，自己凭直觉猜一猜：能，还是不能？很多人第一反应是“能，多试几次总能找到路线”。也有人猜“不能”，但说不出理由。这正是这个问题迷人的地方：它听起来像一道脑筋

急转弯，实际上谁也给不出让人信服的答案。城里的聪明人拿着地图一遍遍试，画出一条又一条路线，总是在最后一两座桥那里卡住——要么某座桥被迫走了两遍，要么走到一座岛上发现没有新桥可走了。

这种“试到猴年马月”的办法有一个致命的缺陷：就算你再试一万次都失败，也不能证明第一万零一次不会成功。要证明“办不到”，需要的不是更多的尝试，而是一种全新的眼光。一七三六年，当时住在圣彼得堡的数学家欧拉听说了这个问题。他先做了一件在当时看来很不“数学”的事：把地图扔掉了。

16.3 把地图揉成一团之后，剩下什么

欧拉的思路是：河岸有多大、岛是什么形状、桥有多长、路怎么拐——这些统统不重要。散步者真正经历的，只是“在某块陆地上”以及“从这块陆地经过某座桥到了另一块陆地”。于是他把四块陆地（河的南北两岸加两座岛）各自缩成一个点，把七座桥各自缩成连接两个点的一条线。得到的图丑极了，就四个点七条线，小学生三秒钟就能画完：



原来的问题在这张丑图上变成了：能不能从某个点出发，** 每条线恰好描一遍 **，最后回到出发点？这不就是我们小时候玩的“一笔画”吗！

请注意这一步的惊人之处。欧拉没有去解原来的问题，而是先证明了：原来的问题和这个一笔画问题是 ** 同一个问题 **。他把大地图揉成了一团小毛线，几何信息（长度、面积、形状）全都扔掉了，可问题所需要的全部信息居然一点没少。这种“只留下连接关系”的压缩手法，就是拓扑学的基本功。扔掉的东西越多，剩下的结构越显眼。

在继续之前，我们需要给这堆“点和线”起几个正式的名字，否则后面的话说不清楚。

定义 16.1 (图、顶点、边、度). 由若干个点（叫作**顶点**）和连接它们的若干条线（叫作**边**）组成的整体叫作一个**图**。一个顶点上连着几条边，这个数叫作该顶点的**度**。度为奇数的顶点叫**奇点**，度为偶数的叫**偶点**。如果从一个顶点出发沿着边能走到任何一个别的顶点，就称这个图是**连通的**。

数数看，上面七桥图的四个顶点各是几度：A 连着 5 条边，B 连着 3 条边，C 连着 3 条边，D 连着 3 条边。四个顶点全是奇点。请记住这个事实，它马上就是破案的关键。

术语卡片：拓扑等价（同胚）

直观解释：两个图形由橡皮泥做成，不用撕开、不用粘合，只靠连续地拉伸、弯曲、压缩就能从一个变成另一个，那么它们就是“同一种形状”。

正式定义：两个图形之间存在一个连续的一一对应，而且反过来的对应也连续，就称它们**同胚**。

例子：圆和正方形同胚（把圆周像皮筋一样撑成方框即可）；但圆和数字“8”不同胚——“8”中间那个交叉点拆不开。

16.4 破案：数一数为奇数的“路口”

现在来解决一笔画问题。想象你拿着笔在某张图上走，经过某个顶点时，你必然是“从一条边进来，再从另一条边出去”——一进一出，成对消耗这个顶点的边。所以一个中途经过（既非起点也非终点）的顶点，它身上的边必须能配成一对一对的“进出口”，也就是说，它的度必须是偶数。

那么起点和终点呢？如果散步要回到出发点，起点被“出去一次、最后回来一次”，中间每经过一次也是一进一出，所以它的度同样是偶数。于是整个图里一个奇点都不许有。如果不要求回到出发点，那么起点“净出去一次”、终点“净进来一次”，允许它们是奇点——但也只允许这两个。这就是欧拉地发现：

定理 16.2 (欧拉一笔画定理, 1736). 一个连通的图：

1. 存在一条经过每条边恰好一次并回到起点的路线，当且仅当图中**没有奇点**；
2. 存在一条经过每条边恰好一次（不必回到起点）的路线，当且仅当图中**恰好有两个奇点**（此时它们必须充当起点和终点）。

证明. 先证“必须有这些条件”。沿任何一条这样的路线走，每当中途经过一个顶点，都要消耗两条边（进一条、出一条），所以非起点终点的顶点必为偶点。若路线回到起点，起点消耗的两条边也成对，故起点也是偶点，图中没有奇点；若路线不回到起点，起点和终点各多出一条不配对用的边，它们恰是仅有的两个奇点。

再证“这些条件够用”。以没有奇点的情形为例。从任一顶点出发，沿着没走过的边随便走。由于每个顶点的边都成对，你走进任何一个顶点时，只要不是回到起点，就一定还有没走过的边可以出去——所以你唯一可能被“堵死”的地方就是起点。走到堵住为止，你必然回到了起点，得到一条回路。如果此时还有没走过的边，由于图是连通的，这条回路上一定有某个顶点连着没走过的边；从这个顶点出发再“随便走”一圈，同理又会回到它自己，把这新的一圈插进原来的回路里，得到一条更长的回路。如此反复，直到边被用完，就得到了所求的路线。恰好有两个奇点的情形类似：从一个奇点出发，最终必被堵在另一个奇点处，再用同样的方法插入剩余的回路即可。□

现在回头看七桥问题：四个顶点全是奇点，奇点个数是 4，既不是 0 也不是 2。所以散步路线** 不存在 **——不是“暂时没找到”，而是“永远找不到”。欧拉没有多走一步路，只是数了数每个路口有几条桥，就宣判了全城人多年争论的死刑。据说哥尼斯堡后来建了第八座桥，奇点变成

了两个，散步者终于可以走完所有桥（只是回不了家）。数学先预测了可能性，工程随后跟上，这是个颇有讽刺意味的后续。

数学工具箱

本章到目前为止添置的新工具：

- **压缩法**：把地图揉成“点加线”，只保留连接关系；
- **图**（顶点、边、度）和**连通性**：描述“谁和谁连着”的最小语言；
- **奇偶配对**：一进一出必成对，奇偶性是推理的发动机；
- **同胚**：判断“橡皮泥意义下同一种形状”的标准。

16.5 字母的分类游戏：什么是拓扑性质

有了“同胚”这把尺子，我们可以玩一个分类游戏。把印刷体大写字母想象成橡皮泥做的细线：A、B、C、D、E……哪些是“同一种形状”？

C、I、J、L、M、N、S、U、V、W、Z 是一类：它们都是“一条线”，可以拉直成一根线段。A、D、O、P、Q、R 是一类：它们身上都有 ** 一个洞 **（A 的三角形孔、O 的圆孔，在橡皮泥眼里没区别）。B 独占一类：它有 ** 两个洞 **。E、F、T、Y 是一类：没有洞，但有 ** 一个三叉路口 **。K 和 X 是带四叉路口的一类。H 比较特殊，有两个三叉路口。

这个游戏告诉我们，拓扑学关心的是哪些性质呢？数一数上面的分类依据，无非就是这么几样：

- **连通性**：图形是一整块，还是分成了好几块？（字母 i 上面的点算不算连着它的身子，就是个连通性问题。）
- **洞的数量**：有几个独立的“圈”绕不过去？
- **交叉与端点**：线在哪里分叉、在哪里终止？
- **边界**：图形有没有“边缘”，边缘有几条？

而长度、角度、面积、曲直，统统不在此列。拓扑学家有一句著名的自嘲：拓扑学家是分不清咖啡杯和甜甜圈的人。为什么？想象一个橡皮泥做的咖啡杯，杯身上有个把手。你把杯身凹陷进去、捏圆，只留下那个把手变成圆环——它就成了一个甜甜圈。全程没有撕开、没有粘合，杯子的洞（把手的孔）就是甜甜圈的洞，一个不多一个不少。反过来，甜甜圈永远变不成一个 ** 没有洞的球 **：球上的任何橡皮圈都能收缩成一点，而套在甜甜圈环上的圈怎么缩都会卡在环上。洞的数量，是把图形分成不同“物种”的第一道关卡。

反例警报

“两个图形看起来差得很远，所以它们拓扑上不同”——错。圆和正方形看起来差远了，但它们同胚；反过来，“两个图形都有同样的面积，所以拓扑上相同”也错：一个圆盘和一个挖了孔的圆环面积可以一样，但前者没洞、后者有一个洞，橡皮泥捏不出那个孔。判断同胚靠的是能否连续变形，不是看长相，也不是量大小。

16.6 会数洞的数字：欧拉示性数

洞是个好东西，但“数洞”有时说不清：一个打了三个孔的奶酪块，到底算几个洞？数学家需要一个更机械、更不会吵架的办法来记录图形“绕来绕去”的程度。办法出乎意料地朴素：把图形切碎成小块，数三种零件的个数，做一道加减法。

拿凸多面体开刀。一个立方体有 8 个顶点、12 条棱、6 个面，算一算：

$$V - E + F = 8 - 12 + 6 = 2.$$

换一个，正四面体： $V = 4$ 、 $E = 6$ 、 $F = 4$ ，算出来 $4 - 6 + 4 = 2$ 。再换一个，正十二面体： $V = 20$ 、 $E = 30$ 、 $F = 12$ ，还是 $20 - 30 + 12 = 2$ 。有没有觉得不对劲？零件个数天差地别，加减完居然都是 2。欧拉（对，又是他，这个人几乎出现在数学的每一个角落）证明了这不是巧合：

定理 16.3 (多面体的欧拉公式). 任何可以连续变形为球面的多面体（或画在球面上的连通图），都满足

$$V - E + F = 2,$$

其中 V 、 E 、 F 分别是顶点数、棱数、面数。

证明大意. 把多面体想象成空心的橡皮气球，剪掉一个面，把剩下的部分摊平在桌面上，得到一个由顶点和边构成的连通图，它把平面分成若干区域，区域数比原来的面数少 1（被剪掉的那个面变成了图形外面的“无限区域”）。我们只要证摊平后的图满足 $V - E + F_{\text{区域}} = 1$ 。现在做两种“拆除手术”：若图中有一个圈，删掉圈上的一条边， E 少 1，圈两侧的两个区域合并， $F_{\text{区域}}$ 也少 1， $V - E + F_{\text{区域}}$ 不变；若没有圈了，图是一棵没有回路的“树”，此时删掉一个末端顶点连同连着它的那条边， V 少 1、 E 少 1， $V - E + F_{\text{区域}}$ 还是不变。反复拆除，最后只剩一个孤零零的顶点： $V = 1$ 、 $E = 0$ 、 $F_{\text{区域}} = 0$ ，数值为 1。既然手术从不改变这个数值，原来的图也一定等于 1，还原回多面体就是 2。□

这个数 $V - E + F$ 叫作**欧拉示性数**，通常记作希腊字母 χ 。它的神奇之处在于：你随便怎么切分这个曲面——切大块切小块、用直边用弯边——算出来的 χ 都一样。它是曲面的“指纹”。

而指纹能识别物种。把同样的游戏搬到甜甜圈（圆环面）上：在环面上画一个连通的图，把环面划分成若干块区域，你会算出 $V - E + F = 0$ 。打两个洞的“双环面”（想象两节连在一起的游泳圈）算出来是 -2 。规律是：每多一个洞， χ 就减 2。如果用 g 表示洞的数量（数学里叫作**亏格**），那么

$$\chi = 2 - 2g.$$

球面 $g = 0$, $\chi = 2$; 甜甜圈 $g = 1$, $\chi = 0$; 双环面 $g = 2$, $\chi = -2$ 。于是“数洞”这个说不清的任务，变成了一道谁算都一样的算术题：把曲面切成网格，数一数，减一减，就知道它有几个洞。咖啡杯能变成甜甜圈，正是因为它们的 χ 都是 0；它们都变不成球，因为 $\chi = 0$ 永远不等于 $\chi = 2$ 。

术语卡片：欧拉示性数

直观解释：给曲面做一次“人口普查”，顶点数减边数加面数，是曲面在连续变形下不改写的身份证号。

正式定义：把曲面划分成 V 个顶点、 E 条边、 F 个面， $\chi = V - E + F$ ；它与划分方式无关。

例子：立方体 $8 - 12 + 6 = 2$ ，所以立方体和球面同类；环面上的网格算出 0，比球面少 2，正好对应多出来的一个洞。

16.7 拧半圈的世界：莫比乌斯带与克莱因瓶

到目前为止，我们的橡皮泥游戏还保留着一条没说出口的规矩：曲面有里外两面。气球有内壁和外壁，纸片有正面和反面。可一八五八年，数学家莫比乌斯发现了一种只有 ** 一面 ** 的曲面，制作方法简单到荒谬：取一张长纸条，把一端旋转半圈，再和另一端粘起来。

做一条试试（本章后面的实验环节会带你做）。在纸带上用彩笔沿着中线画线，笔尖不离开纸面，画着画着你会发现：笔回到了出发点，而你已经把“两面”全涂满了——这条纸带根本没有“另一面”！沿中线剪开，它不像直觉预期的那样分成两个环，而是变成一个拧了一整圈的、更长的大环。一只在莫比乌斯带上爬行的蚂蚁，可以不翻越任何边缘就爬遍整条带子。

一分钟实验

找一张废纸，裁下一条约 3 厘米宽、25 厘米长的纸条。

1. 先把两端直接粘起来，得到一个普通的圆环。用彩笔沿环的中线画一圈，笔只涂到了“一面”。沿中线剪开，圆环分成两个环。
2. 重新做一条，这次粘之前把一端拧半圈。沿中线画线——这次笔迹“神奇地”布满了整条带子。沿中线剪开，数一数得到的环拧了几圈。
3. 再拧一整圈（ 360° ）粘起来，重复画线和剪开，结果和前两次各有什么不同？
4. 记录：拧 0 圈、半圈、一圈、一圈半时，剪开后分别得到几个环、各拧了几圈。你能猜出规律吗？

莫比乌斯带还有一条 ** 边界 **（就是你没剪之前那条长长的纸边，整条带子的边缘居然是连通的一条线）。数学家接着问：能不能造出一种只有一面、而且连边界都没有的封闭曲面？可以，这就是**克莱因瓶**。想象把一个瓶子的瓶底打个洞，把瓶颈拉长、弯过来、穿过瓶壁，和瓶底的洞粘在一起。做成之后，瓶子的“里面”和“外面”是同一片曲面——沿着瓶壁走，你可以从外壁不知不觉走到内壁，无须穿过任何边缘。一只蚂蚁能爬遍整个克莱因瓶。

但这里有个不得不坦白的事实：克莱因瓶在我们生活的三维空间里 ** 造不出来 **。刚才的描述里有一句“穿过瓶壁”——在三维世界中，瓶颈想接到瓶底，就必须穿透瓶身，这就违反了橡皮泥“不许穿孔”的家规。只有在四维空间里，瓶颈可以从“第四个方向”绕过去，不必碰瓶壁。

你在工艺品店里买到的“克莱因瓶”玻璃摆件，全都有一处自交，那是对这个四维居民的三维投影，就像甜甜圈的影子落在墙上可能自带交叉一样。莫比乌斯带告诉我们“面数”不是天经地义的，克莱因瓶则告诉我们：有些形状大到我们的世界装不下，却照样可以被数学精确地描述。

连接线

还记得本书前面把正方形、旋转和翻折编成“对称的运算表”吗？那里我们把“看起来一样”升级成了“结构一样”。本章做的是同一种升级，只是换了尺子：第6章问“做什么动作后图形不变”，本章问“怎么揉捏后性质不变”。而本章的“图”与第14章的图论是同一套语言——七桥问题正是图论和拓扑学共同的出生证明。下一章你将看到，当橡皮泥换回直尺和量角器，故事又会怎样翻出新的一页。

16.8 换一个视角：网络、地图和机器人

拓扑学听起来像在玩橡皮泥和剪纸，但它的“保留连接、扔掉细节”的哲学，恰恰是现代世界运转的底层逻辑。

网络。互联网有几亿台设备，城市交通网有成千上万个路口，电网有数不清的节点。工程师关心的第一件事往往不是“这根电缆多长”，而是拓扑问题：这个网络连通吗？断掉某个节点，网络会不会裂成两半？裂成两半时各有多大？这与本章开头判断“图形是几整块”是同一种思考。社交网络的“六度分隔”现象——任意两个人之间平均只隔着大约六层朋友关系——说的正是巨大网络在连接关系上出人意料地“紧”。

地图。给世界地图上色，要求相邻国家颜色不同，最少要几种颜色？注意这个问题只跟“谁和谁接壤”有关，跟国家的面积、形状、海岸线弯曲程度毫无关系——这是纯拓扑问题。人们猜了上百年“四种颜色足够”，这就是著名的四色猜想。一九七六年，数学家把它化归为一千多种基本图形的逐一检查，借助计算机完成了证明，成为第一个“计算机参与证明”的大定理，至今仍有数学家争论：一个人无法亲手核验的证明，算不算证明？

机器人。一个机械臂有几个关节，每个关节可以转动一个角度。机械臂的每一个姿势，都对应着由这些角度组成的一个“形状空间”里的一个点；规划机械臂的运动，就是在这个空间里找一条不撞墙连续路径。奇妙的是，这个空间的拓扑形状本身就有讲究：一个能整圈旋转的关节贡献一个“圆圈”，两个独立旋转的关节贡献一个“环面”——正是本章那只甜甜圈！机器人工程师规划路径时，实际上是在甜甜圈、球面或更怪的曲面上走路。路径规划里的很多困难，比如“怎么转都绕不过去的障碍”，本质上就是空间里的“洞”在作怪。

注. 以上应用里，拓扑负责回答“能不能”：能不能连通、能不能绕过、能不能四色。至于“多快、多长、多省钱”，那要把长度和角度请回来，交给别的数学分支。分清一个问题属于“能还是否”还是“好还是坏”，是解题的第一步。

继续攀登

想继续往前走，可以记住这几个关键词：**基本群**（把曲面上“缩不回去的圈”编成一种可以运算的代数结构，洞的数量由此变成严格的定理）；**同调论**（欧拉示性数的远房亲戚，能数出任意维度的“洞”）；**纽结理论**（研究三维空间里的绳结何时能解开，你的鞋带和 DNA 都在里面）；**庞加莱猜想**（三维世界版的“没有洞的封闭形状必是球面”，直到二〇〇三年才被证明，是七大千禧年难题中第一个被攻克的）。

思考题**观察题**

1. 把阿拉伯数字 0 到 9 看作橡皮泥细线（手写体，不带交叉），按拓扑形状分类。哪几个数字属于同一类？**提示**：先数每个数字有几个洞、几个端点。
2. 一件长袖衬衫（没有系扣子）平铺后，按拓扑形状算，它和一个打了几个洞的圆盘同类？**提示**：数一数身体伸进去之后，一共有几个“出口”，想想每个出口对应几个洞。

证明题

1. 证明：任何一个图里，奇点的个数一定是偶数。**提示**：把所有顶点的度加起来，每一条边被数了几次？这个总和是奇数还是偶数？
2. 用 $V - E + F$ 检验：在一个球面上画一个“经纬网”——比如 4 条经线、2 条纬线（赤道和一条），南北极点也算顶点。数一数顶点、边、区域，验证欧拉公式。**提示**：先想清楚两条经线在极点相交算不算顶点，每条纬线被经线切成几段。

挑战题

1. 甜甜圈上最多能画几个两两都直接相邻的区域（每两个区域之间都有一条公共边界）？平面上的答案至多是 4（这正是四色定理里“四”的来源之一），甜甜圈上的答案比它大。**提示**：答案是 7。先试着画 5 个两两相邻的区域，再利用“环可以绕过去”多塞两个。
2. 把两张莫比乌斯带沿各自的边界粘起来，会得到本章介绍过的哪种曲面？**提示**：先在脑子里把一张莫比乌斯带“展开”成一个圆环带子；想想克莱因瓶能不能沿着某条线剪成两半。

通往下一章的门

这一章我们过得相当潇洒：长度可以扔，角度可以扔，面积可以扔，只要连接关系和洞的数量还在，图形就算“没变”。橡皮泥的世界里，球面和土豆是同一种东西，茶杯和甜甜圈不分彼此。

可是地球人不会同意“地球和土豆一样”——导航软件要算距离，飞行员要知道从北京飞纽约为什么先往北飞，而不是沿纬线直着往东。这些问题一上来就要动用本章扔掉的东西：长度、角度、弯曲程度。球面上的三角形内角和居然大于 180° ，而甜甜圈上的直线会自己缠上自己——这些现象拓扑学一律看不见，因为橡皮泥一捏就全没了。

如果我们把橡皮泥换回一块硬一点的、有弧度的曲面，不许拉伸但允许在上面滑行，那么“最直的路”“最短的距离”“弯得有多厉害”这些词，就需要一套全新的语言来定义。曲面在每个点附近怎样近似成一张平面？一只蒙着眼睛的蚂蚁，能不能只凭脚下的感觉判断自己住在球面上还是平面上？下一章，我们走进微分几何：弯曲空间中的距离和方向。

第十七章 微分几何：弯曲空间中的距离和方向


17.1 地图上那条奇怪的弯路

打开任意一张世界地图，找到北京和旧金山。现在想象你是一名民航飞行员，要规划两地之间最省油的航线。直觉告诉你：拿一把直尺，在地图上把两个城市连起来，沿直线飞就是了。

可是真实的航班不这么飞。从北京起飞的航班会先向东北方向爬升，掠过我国东北和俄罗斯远东，擦过阿留申群岛附近，再折向东南降落在旧金山。在地图上看，这条路线明显是弯的——它向北鼓出一个大大的弧线。航空公司每年烧掉的航空燃油以万吨计，绝不可能无缘无故绕远路。

再来看一个更古老的例子。十五世纪的航海家早就发现：沿着同一条纬线一直向西航行，并不是去远方港口最省时间的路；聪明的船长会先向高纬度方向偏航，再转回来。船员们管这叫“大圆航行”。他们不知道为什么，只知道这样走更快。

于是问题摆在了我们面前：



球面上的一个三角形：三条边都是大圆弧

在弯曲的表面上，“直”是什么意思？“距离”该怎么量？“方向”又该怎么描述？这些问题听起来像是给飞行员和船长准备的，但它们背后是一门深刻的数学——微分几何。它研究弯曲空间中的长度、角度和形状，并且在二十世纪初成为爱因斯坦描述引力的语言。这一章，我们从一条绕弯的航线出发，一直走到弯曲的时空。

17.2 直觉失灵：摊不平的橘子皮

面对球面上的距离问题，第一个自然想法是：把球面摊平不就行了？摊成平面，用尺子量，多省事。

你可以在家做个实验。剥一个橘子，尽量保持橘皮完整，然后试着把橘皮平平地铺在桌面上，不许有裂缝也不许重叠。你会发现根本做不到：要么边缘裂开一道道口子，要么中间拱起来。现在对比另一件事：拿一张平整的纸，把它卷成一个圆筒，毫不费力；展开，纸又恢复原样，没有撕裂也没有褶皱。

这个厨房里的失败实验其实揭示了一条深刻的分界线：圆柱面和平面是“亲戚”，可以不拉伸地互相变形；球面和平面不是。任何把球面画到平面上的地图，都必然要付出扭曲的代价。

代价有多大？看看最常见的世界地图（墨卡托投影）：地图上格陵兰岛看起来和非洲差不多大，但实际上非洲的面积大约是格陵兰的十四倍。地图没有“画错”，它只是不可能同时保住所有的长度、角度和面积。有些地图保住角度就牺牲面积，有些保住面积就牺牲形状。数学家们证明了：一张既保距又保角又保面积的球面地图，根本不存在。

反例警报

“把球面摊平了再量，不就回到平面几何了吗？”——这是一个看似合理、实则走不通的方案。球面无法在不拉伸、不撕裂的情况下摊成平面，这意味着球面上的几何学不是平面几何的“化装舞会”，而是一门有自己规律的独立学问。同理，“沿纬线飞就是从北京到旧金山的最短路”也是错的：除了赤道，任何纬线圈都不是大圆，沿纬线走一定绕远。

第一次尝试失败了，但失败指了路：我们不能再想着“把曲面变成平面”，而要学会在曲面内部生活——像球面上的一只蚂蚁那样，不跳出来，只靠脚下的测量理解整个世界。

17.3 给曲面建立坐标：一本地图册就够了

蚂蚁不需要一张覆盖整个球面的完美地图。它需要的只是一本地图册：每一页只画球面上的一小片区域，这一小片可以近似当成平面；相邻的两页之间有一段重叠，重叠处的同一个地点在两页上有两套坐标，并且附有一份“换算规则”，告诉你怎么把一套坐标翻译成另一套。

这个想法非常重要，值得给它一个名字。

定义 17.1. 曲面上的一小块区域，如果能和平面上的一个圆盘一一对应、并且对应关系足够平滑，我们就给它配上平面坐标 (u, v) ，称为一张**坐标图**。若干张坐标图拼起来、彼此重叠处可以互相换算，覆盖整个曲面，合起来称为一册**坐标图册**。


你在家其实就有这样的东西。没有哪张世界地图能完美呈现整个地球，但一本分省地图册很好用：每页一个省，页边的重叠区域帮你翻页时接上。球面也是这样：一张坐标图覆盖不了全球（极点处总会出麻烦），但两三张图拼起来就够了。关键是，几何量——长度、角度、面积——必须在每张图里都能算，而且不同图算出来的结果在重叠处必须一致。只要满足这一点，蚂蚁就拥有了完整的几何学，它根本不需要知道“球面嵌在三维空间里”这回事。

这种“只在曲面内部看问题”的视角，叫作内蕴视角。与之相对的是站在外面看：三维空间里的球面当然是弯的，一眼就能看出来。数学史上的一个转折点，是数学家们意识到内蕴几何可以独立存在：曲面自己弯不弯、弯多少，不用到“外面”去也能测量出来。一位数学家把这方面的核心结果称为“绝妙定理”——内蕴曲率是曲面的固有属性，压扁、卷起这些不改变内蕴曲率的操作，骗不过生活在曲面上的测量者。

17.4 切平面与切向量：在曲面上站稳

蚂蚁要在球面上爬行，首先得回答一个问题：什么叫“方向”？

在平面上，方向就是箭头——向量。可球面上的箭头往哪儿指？如果箭头要画在球面上，它得弯曲地贴着球面，那就不是我们熟悉的向量了。解决办法是：在球面上的点 P 处，放一块无限薄的平板，让它刚好只在 P 点接触球面，其他地方都“悬空”。这块平板叫作球面在 P 点的**切平面**。



圆在 P 点的切线：曲面在 P 点的切平面的二维类比

定义 17.2. 曲面在点 P 的**切平面**，是在 P 点与曲面相切、并且包含曲面在该点所有方向的平面。切平面中以 P 为起点的向量，称为曲面在 P 点的**切向量**。

切向量解决了一个真实的麻烦：它让“在曲面上朝某个方向走一小步”有了精确含义。走的那一小步确实贴着曲面弯曲，但步子无穷小的时候，它和切平面上的直线段几乎没有差别——误差比步长本身缩小得更快。这正是“微分”两个字的分工：无穷小的局部，弯曲的表面和它的切平面是同一种东西。

你其实每天都活在这个近似里。地球半径约 6371 千米，你脚下的地面是球面的一部分；可是在方圆几十米的尺度上，大地和切平面的偏差只有毫米量级，盖房子、踢足球完全可以当它是平的。局部像平面，整体是弯的——请记住这句话，它后面还会以更重要的身份出现。

术语卡片：切平面

直观解释：把一块玻璃板轻轻贴在篮球表面的某一点上，玻璃板所在的平面就是切平面。换一点，玻璃板的朝向就变了。

正式定义：曲面在一点的切平面，是该点处所有光滑曲线的切线（方向）张成的平面。

一个例子：地球表面上，你所站的地面附近那一小块，就近似是你脚下那点的切平面；水平仪测的就是它。

17.5 曲率：弯了多少，用什么量

有了切平面，就可以量化“弯”了。想法很直接：曲线上的点离开切平面的速度越快，曲面在那里就越弯。

先看一维的类比。平面上半径为 r 的圆，它的弯曲程度处处相同，数学家定义它的曲率为 $1/r$ ：半径越小，圆弯得越急；半径趋于无穷大时，曲率趋于零，圆就退化成了直线——直线的曲率是零。

数值例子：半径 $r = 2$ 的圆，曲率是 $1/2$ ；半径 $r = 100$ 的圆，曲率只有 0.01 ，你在上面走一小段几乎感觉不出它在弯。

曲面上的情况复杂一点：在同一点，朝不同方向走，弯曲的程度可能不一样。球面上每个方向都一样弯，半径为 R 的球面，沿任何方向的截线都是半径 R 的大圆，各个方向的曲率都是 $1/R$ 。圆柱面就不同了：沿着圆环方向截，得到一个半径 R 的圆，曲率 $1/R$ ；沿着母线（竖直方向）截，得到一条直线，曲率是零。把两个极端方向的曲率乘起来，得到的量叫**高斯曲率**。于是：

$$\text{球面的高斯曲率} = \frac{1}{R} \cdot \frac{1}{R} = \frac{1}{R^2}, \quad \text{圆柱面的高斯曲率} = \frac{1}{R} \cdot 0 = 0.$$

这个结果初看违反直觉：圆柱面明明“看起来是弯的”，高斯曲率怎么是零？回想剥橘皮的实验就明白了：圆柱面可以由一张纸不拉伸地卷成，生活在圆柱面上的蚂蚁做的任何测量，和平面上的蚂蚁完全一样——它的内蕴几何就是平面几何。高斯曲率量的正是这种内蕴的弯，而不是从外面看起来的弯。反过来，球面的高斯曲率 $1/R^2$ 处处为正，这就是橘皮摊不平的定量证据。数值例子：地球半径约 6371 千米，地表的高斯曲率约为 $1/(6.371 \times 10^6)^2 \approx 2.5 \times 10^{-14}$ 每平方米——极其微小的正数，但不为零，日积月累就让你的世界地图永远画不完美。

还有第三种可能：马鞍面。在马鞍的中心点，沿前后方向曲面向下弯，沿左右方向向上弯，两个方向的弯曲“符号相反”，乘出来的高斯曲率是负的。负曲率的曲面摊到平面上会怎样？它既不像球面那样“料不够”（会裂），而是“料太多”——摊平后会起皱、重叠，像一片木耳。三种符号，三种命运：正曲率裂开，零曲率服帖，负曲率起皱。

17.6 球面三角形：内角和的反叛

初中几何的第一批定理里，有一条刻在我们脑子里：三角形内角和等于 180° 。现在我们要看着它在球面上失效，并且失效得很有规律。

先明确球面上“三角形”的定义。球面上扮演直线角色的是大圆——过球心的平面与球面的交线，比如赤道和所有的经线圈（纬线圈除了赤道都不是大圆，因为它们所在的平面不过球心）。

定义 17.3. 球面上取三个不在同一大圆上的点，用三段大圆弧把它们两两连接，围成的图形叫作**球面三角形**。它的三个内角，是顶点处两段大圆弧的切线之间的夹角。

立刻看一个极端又漂亮的例子。取北极点 A ，再取赤道上经度相差 90° 的两个点 B 、 C 。边 AB 、 AC 都是经线，边 BC 是赤道的一段。顶点 A 处，两条经线的夹角就是经度差 90° ；顶点 B 处，经线与赤道垂直，夹角 90° ；顶点 C 同理，也是 90° 。三个角都是直角，内角和是 270° ，比平面上整整多出 90° ！

这多出来的部分不是误差，而是面积。十九世纪初，一位数学家证明了球面几何里最优美的公式之一：

定理 17.4 (球面三角形的面积公式). 设球面半径为 R ，球面三角形的三个内角（用弧度制）为 A 、 B 、 C ，面积为 S ，则

$$S = R^2 (A + B + C - \pi).$$

特别地，球面三角形的内角和一定大于 π （即 180° ），且超出的量 $A + B + C - \pi$ 与面积成正比。

证明. 证明分三步, 每一步都可以在图上指出来。

第一步：二三角形的面积。两个大圆相交, 把球面分成四个”月牙”形的区域, 每个叫作二三角形。夹角为 A (弧度) 的二三角形, 占整个球面的比例是 $A/(2\pi)$ (把球面像切西瓜一样按经度均分成 2π 弧度, 它占其中 A 弧度)。全球面积为 $4\pi R^2$, 所以夹角 A 的二三角形面积为

$$4\pi R^2 \cdot \frac{A}{2\pi} = 2R^2 A.$$

检验: 当 $A = \pi$ 时二三角形恰好是半球, 公式给出 $2\pi R^2$, 与半球面积一致。

第二步：三对二三角形覆盖整个球面。设球面三角形 T 的三个内角为 A 、 B 、 C 。过 A 的两条边所在的大圆, 围出夹角 A 的一对对顶二三角形, 每个面积 $2R^2 A$; 同理得夹角 B 、 C 的各一对二三角形。这六个二三角形合起来覆盖整个球面, 但覆盖有重复: 三角形 T 本身被覆盖了 3 次, 球面另一侧与 T 对顶的全等三角形也被覆盖了 3 次, 其余每点恰好被覆盖 1 次。

第三步：列方程。六个二三角形面积之和, 等于全球面积加上多算的 4 份 T (T 多算了 2 份, 对顶三角形也多算了 2 份):

$$2(2R^2 A + 2R^2 B + 2R^2 C) = 4\pi R^2 + 4S.$$

两边除以 $4R^2$, 整理得

$$S = R^2(A + B + C - \pi).$$

证毕。 □

用前面的数值例子验证: 北极加赤道两点的三角形, $A = B = C = \pi/2$, 内角和为 $3\pi/2$, 公式给出 $S = R^2(3\pi/2 - \pi) = \pi R^2/2$ 。直接看: 这个三角形占全球八分之一 (两条相差 90° 的经线切出四分之一, 再取北半球的一半), 面积 $\frac{1}{8} \cdot 4\pi R^2 = \pi R^2/2$, 完全吻合。

推论 17.5. 球面上不存在内角和恰好等于 180° 的三角形; 内角和超出 180° 越多, 三角形越大。当三角形缩得很小时, 超出部分趋于零——小范围内, 球面几何近似回到平面几何。

这条推论把我们前面的话焊死了: 局部像平面, 整体是弯的。曲率正是通过”内角和背叛了多少”这种方式, 被曲面内部的居民测量出来。

连接线

回忆平面几何中”三角形内角和等于 180° ”的证明: 它依赖平行公设——过直线外一点恰有一条平行线。球面上任意两个大圆都相交, ”平行线”根本不存在, 平行公设失效, 内角和定理随之改写。这不是哪个定理的证明出了错, 而是几何的舞台换了。历史上, 正是对平行公设两千年的怀疑与争论, 最终把数学家们引向了弯曲空间的几何; 本章的球面几何, 就是那场内战留下的一份遗产。到了下一章, 你会看到另一个”习以为常的确定性”——一次测量的精确数字——同样会在随机性面前改写。

17.7 测地线：最直的，也是最短的

现在回到开篇的问题: 什么是在曲面上”直走”? 蚂蚁没有罗盘, 它对”直走”的理解是: 每一步都不向左拐也不向右拐, 头朝哪边就往哪边爬。这样的路线叫**测地线**。

术语卡片：测地线

直观解释：曲面上“不拐弯”的路线；在曲面上两点间拉紧一根橡皮筋，它静止时贴出的就是测地线。

正式描述：测地线是曲面上局部最短的曲线——它上面充分接近的任意两点之间，没有比它更短的曲面路线；等价地，它是沿曲面“直行”、左右加速度为零的曲线。

一个例子：球面上的测地线就是大圆；北京到旧金山的最短航线，是过两地和地心的大圆上较短的那段弧。

为什么“最直”和“最短”是同一件事？可以这样想：如果一条路线中间有弯，你在弯的地方抄近道切过去，路线就变短了；所以最短的路必然处处不弯。反过来，处处不弯的路，任何一小段都是最短。在平面上，测地线是直线；在球面上，测地线是大圆；在圆柱面上，把圆筒剪开摊平，测地线变成平面上的直线段，卷回去它可能是一条绕筒上升的螺旋线——螺旋也可以是“最直的路线”，这一点第一次听说时总让人愣一下。

来算一笔账，看看大圆航线省多少路。北京约为北纬 40° 、东经 116° ，纽约约为北纬 41° 、西经 74° ，两地几乎在同一纬度，经度相差约 170° 。如果“沿纬线直飞”（这正是平面地图上接近直线的走法），走的是北纬 40° 纬线圈，其半径是 $R \cos 40^\circ$ ，弧长为

$$\frac{170}{360} \times 2\pi R \cos 40^\circ \approx 0.472 \times 2\pi \times 6371 \times 0.766 \approx 14500 \text{ 千米}.$$

而实际的大圆航线长约 11000 千米，足足省下约三千五百千米——相当于多飞一个北京到乌鲁木齐的来回还有富余。地图上弯的那条弧，才是球面上真正的“直线”。

一分钟实验

找一个橙子或乒乓球、一支记号笔、一根软绳和一把量角器（没有量角器就估角度）。

第一步：用笔在“球”上点三个点，把软绳在两点间拉紧贴住球面，沿绳子画出三段“直线”——你画出的就是大圆弧，即测地线。

第二步：观察这个球面三角形的三个角，估计或量出每个角的度数并相加。把三角形画得越大，内角和超出 180° 越多；画得很小时，内角和接近 180° 。

第三步（对比实验）：把一张纸上画好的三角形卷成圆筒，再展开量角——内角和纹丝不动。想一想：为什么球面上的三角形“变了”，纸上的却“没变”？

17.8 流形：每一小块都是平面，整体可以千奇百怪

我们已经反复使用同一个句式：局部像平面，整体可能很不一样。数学家把这个句式本身变成了研究对象。

定义 17.6. 一个空间，如果它每一点周围的一小块区域都能和平面上的圆盘建立平滑的一一对应（可以画成一张坐标图），就称它为一个**二维流形**。把“平面”换成 n 维的平直空间，就得到 n 维流形。

术语卡片：流形

直观解释：流形就是”地图册能覆盖的空间”。身处其中任何一点，环顾四周你都以为自己站在平地上；只有环球旅行回来，才发现世界另有形状。

正式定义：每一点都有一个邻域与平直空间的开圆盘平滑等价，且图册中地图之间的换算足够光滑。

一个例子：球面是二维流形；甜甜圈表面（环面）也是；而两个平面交叉成的”十字”不是——交叉点的那一小块怎么也摊不成一个圆盘。

环面值得多说两句。甜甜圈表面有的地方像球面（外侧，正曲率），有的地方像马鞍（内侧，负曲率），整体却是一个闭合的、没有边界的流形。生活在环面上的蚂蚁画三角形，会发现有的三角形内角和大于 180° ，有的小于 180° ——曲率的符号随地点而变。更有意思的是，把长方形纸的两条对边分别粘合（先卷成筒，再把筒的两头接上），得到的也是一个环面，而这个”纸环面”在内蕴几何上居然是平的——上面居然存在内角和恰为 180° 的几何学。同一个拓扑形状，可以承载不同的几何；这区分”形状”与”几何”两层结构，正是现代几何学的起点。

曲面	三角形内角和	测地线的样子	能否不拉伸地摊平
平面	恰为 180°	直线	本来就是平的
球面	大于 180° ，越大超得越多	大圆弧	不能（会裂）
圆柱面	恰为 180°	展开后是直线（可为螺旋）	能
马鞍面	小于 180°	向外发散的曲线	不能（会皱）

流形这个概念为什么值得如此大费周章？因为我们自己就生活在一个”流形”里。抬头看宇宙：我们所能直接经验的，永远是身边一小块近似平直的空间；宇宙整体是闭合的还是开放的、是平的还是弯的，无法一眼看穿，只能靠内部的测量——三角形的内角和、平行光束的聚散、遥远星系的计数——一点点推断。蚂蚁研究球面的方法，正是天文学家研究宇宙的方法。

17.9 从局部几何到星空：一次科普性的远眺

1854 年，一位数学家在演讲中系统提出了”任意维数的弯曲空间”的数学：空间可以在每一点有自己的曲率，长度和角度由一张逐点变化的”度量表”决定，直线让位给测地线。这套工具在当时纯粹是智力游戏——没有人知道它能用来干什么。

六十一年后，1915 年，爱因斯坦发现这正是他需要的语言。广义相对论的核心图景可以这样科普地讲：我们以为的”引力”，其实是时空本身的弯曲；物质和能量的存在让时空弯曲，而弯曲时空中自由下落的物体，沿着时空的测地线运动——行星绕太阳转，并不是被一根无形的绳子拽着，而是在弯曲时空里”直走”。1919 年日全食期间，天文学家观测到遥远星光掠过太阳附近时的偏折，偏折量与理论预言吻合：光线走的是时空的测地线，而太阳让那片时空弯曲了。

必须诚实地标明边界：以上是一段科普类比。真实的广义相对论处理的是四维时空（三维空间加一维时间）的弯曲，其几何与时间的流逝交织在一起，由一组精确的方程描述，远不是”橡皮膜上放铁球”的图片所能概括。本章能给你的，是这幅图景的入口：弯曲的空间可以用内蕴的度量来研究，测地线取代了直线，曲率取代了引力——这三件事，你现在已经能在球面上亲手验证。

继续攀登

继续攀登的路标：高斯曲率与“绝妙定理”；协变导数与平行移动（向量沿曲线搬运时如何变化）；高斯-博内定理（曲面的总曲率与它的“洞数”挂钩，是几何与拓扑的桥）；黎曼几何与度量张量；再往前，是微分几何与广义相对论的正式课程。这些关键词，等你学了多元微积分和线性代数之后，都可以一一兑现。

数学工具箱

本章新添的工具：

- **坐标图与图册**：用一片片平面坐标覆盖曲面，重叠处负责换算——几何学研究曲面不必把它摊平。
- **切平面与切向量**：曲面在一点的所有方向构成切平面；无穷小尺度下，曲面与切平面无法区分。
- **高斯曲率**：两个极端方向曲率的乘积，刻画内蕴的弯曲；正者摊平会裂，零者服帖，负者起皱。
- **球面三角形面积公式** $S = R^2(A + B + C - \pi)$ ：内角和的“盈余”就是面积，小三角形近似平面。
- **测地线**：曲面上不拐弯的路，也就是局部最短的路；球面上是大圆。
- **流形**：局部处处像平直空间、整体形状自由的空间——我们自己的宇宙很可能就是一个。

思考题**观察题**

1. 在地球仪（或橙子）上找三个点：北极点，以及赤道上经度相差 120° 的两个点。连出球面三角形，观察它的三个角并相加。

提示：三个角彼此相等；先想顶点处经线之间、经线与赤道之间的夹角各是多少，再对照面积公式检验你的结果。

2. 找一只圆筒形的杯子，在侧面画一个三角形，再把纸面（或想象纸面）摊开。

提示：观察哪些量在卷与摊的过程中保持不变——长度、角度、内角和；想想这说明圆筒面的内蕴几何是什么。

证明题

1. 证明：球面上不存在“内角和等于 180° ”的退化情形之外的三角形。

提示：直接用面积公式 $S = R^2(A + B + C - \pi)$ ，注意面积 S 是正数。

2. 证明：球面上任意两个大圆必相交，而且恰好交于一对对径点（直径的两端）。

提示：大圆是“过球心的平面”与球面的交线；两个过球心的平面必交于一条过球心的直线。

挑战题

1. 在球面上，是否存在“三边两两全等、内角和却不同”的两个三角形？在平面上，边边边

相等保证全等；球面上还成立吗？

提示：用面积公式把内角和与面积挂钩，再想想球面上三角形的面积有没有上限。

2. 甜甜圈（环面）表面上，有的地方内角和大于 180° ，有的小于 180° 。但存在一种“完全平坦”的环面几何（由长方形粘合对边得到）。思考：平坦环面上，测地线有哪些不同的“绕法”？

提示：把环面还原成长方形，测地线在长方形里是直线；边的粘合意味着直线“走出一边就从对边回来”。

通往下一章的门

这一章里，我们学会了在弯曲的世界里测量距离和方向。可是请注意一个被我们悄悄略过的前提：测量是精确的。绳子拉紧贴住球面，量出的弧长就是弧长；量角器读出的角度，就是角度。

现实中的测量从不这么乖。测量一座山的高度，今天测是 8848.86 米，明天换一台仪器是 8848.83 米；导航卫星报出你的位置，每次都有几米的飘忽；就连光速这样的常数，测量值也在小数点后面微微抖动。面对一堆“都对、又都不完全一样”的数字，哪一个真相？还是说，“真相”这个词本身就需要重新定义？

从微分几何走向广义相对论，人类学会了描述弯曲但确定的空间；而下一章要面对的，是另一种更日常的弯曲——不确定性本身。让我们走进概率与统计的世界。

第十八章 概率与统计：不确定性也能被精确研究

18.1 一场生日聚会上的赌局

新学期开学，班里转来了几位新同学，全班一共三十个人。课间有人起哄玩一个游戏：每个人报出自己的生日（只看月和日，不看年份），看看有没有两个人同一天。班长小林信心十足地说：“一年有三百六十五天，咱们才三十个人，撞上的机会太小了。我敢打赌，肯定没有！”同桌小雨却笑了：“我反而敢打赌，很可能有。赌一瓶汽水，来不来？”

同学们纷纷开始报生日。报到第十个人的时候，教室里忽然爆出笑声：三月十四号出现了两次。再往后报，十一月二号也撞了车。小林目瞪口呆地掏出一瓶汽水的钱，嘴里嘀咕：“这纯粹是运气吧？”

这真的只是运气吗？三十个人里有两个人生日相同，到底是小概率的巧合，还是本该如此？凭直觉，几乎所有人都会站在小林一边。三百六十五对三十，差距悬殊。可是这一章要告诉你：在这类问题面前，人类的直觉几乎总是会输，而数学会赢。我们不仅能把“运气”算成一个精确的数，还能把这个数算给你看。

18.2 直觉给出的答案错得离谱

先别急着看答案，凭直觉猜一猜：一个三十人的班级里，至少有两人生日相同的概率大概是多少？百分之一？百分之十？多数人猜的数字都不到百分之二十。

现在来算一算。直接算“至少两人相同”很麻烦，因为可能是两个人撞、三个人撞、好几对分别撞……情况太杂。数学家遇到“至少”两个字，常用的招数是反过来算：先算“所有人的生日全都不同”的概率，再用 1 减去它。

假设一年有 365 天，每个人的生日等可能地落在任意一天（先不管闰年）。第一个人随便占一天；第二个人的生日要和他不同，有 $\frac{364}{365}$ 的机会；第三个人要和前两个人都不同，有 $\frac{363}{365}$ 的机会……依次类推，三十个人生日全不相同的概率是

$$\frac{365}{365} \times \frac{364}{365} \times \frac{363}{365} \times \cdots \times \frac{336}{365}.$$

这串乘积算出来大约等于 0.294。也就是说，“至少两人生日相同”的概率是

$$1 - 0.294 = 0.706,$$

超过百分之七十！二十三个人时这个概率就超过了一半，五十个人时高达百分之九十七左右。小林的赌局，从一开始就注定大概率要输。

为什么直觉错得这么厉害？因为我们下意识地只拿“三十”和“三百六十五”做比较，却忘了题目比较的不是人数和天数，而是“人对”和天数。三十个人里能配出多少对人呢？第一个人可以和另外二十九人配对，第二个人还可以和后面二十八人配……一共是

$$\frac{30 \times 29}{2} = 435$$

对。四百三十五对，每一对都有撞生日的可能，这就完全不是“三十对三百六十五”的观感了。直觉盯着单个的人，数学盯着人和人之间的关系——这就是它赢的原因。

这个现象太有名了，人们给它起了个名字：生日悖论。注意，它不是真正的逻辑矛盾，而是一条“结论与直觉严重冲突”的定理。数学里凡是叫“悖论”的东西，往往是在提醒我们：直觉需要升级了。

18.3 给“可能性”一个数

刚才的计算里，我们一直在说“概率”，可是概率到底是什么？这个问题曾经困扰了数学家几百年。

回到更简单的场面：掷一枚均匀的硬币，正面朝上的可能性是多少？你会脱口而出：二分之一。为什么？因为结果只有两种，对称，谁也没有理由更偏向谁。一枚均匀的骰子掷出六点呢？六种等可能的结果里占一种，所以是 $\frac{1}{6}$ 。这种想法叫“古典概型”：如果所有基本结果等可能，那么

$$\text{某事件的概率} = \frac{\text{该事件包含的结果数}}{\text{所有结果的总数}}.$$

生日问题的计算用的就是这个公式，只不过“结果数”多得要用乘法原理来数。

可是生活中大量的事情没法这样数。明天下雨的可能性是多少？某位球员罚点球命中的可能性是多少？这里既没有有限个等可能的结果，也不能把明天重复一遍。于是我们换一个思路：看频率。让同样的试验重复很多很多次，数一数目标事件出现了几回，用

$$\text{频率} = \frac{\text{出现的次数}}{\text{试验的总次数}}$$

去逼近它。掷硬币十次，可能正面出现七次，频率是 0.7；掷一千次，频率通常会落在 0.5 附近；掷十万次，几乎一定非常接近 0.5。经验告诉我们：随着试验次数增加，频率会稳定在某个数附近，这个稳定的数，就是我们想找的“概率”。

定义 18.1. 一个随机试验中，事件 A 的**概率**，记作 $P(A)$ ，是这样一个数：当试验在相同条件下独立地重复非常多次时， A 出现的频率会稳定在 $P(A)$ 附近。概率满足三条基本规则：对任何事件 A 有 $0 \leq P(A) \leq 1$ ；必然发生的事件概率为 1；两个不可能同时发生的事件 A 、 B ，满足 $P(A \text{ 或 } B) = P(A) + P(B)$ 。

术语卡片：频率与概率

直观解释：频率是“已经发生了多少回”，概率是“长远来看会稳定在哪儿”。正式定义：频率是实验中数出来的比值，随每次实验波动；概率是频率在试验次数趋于无穷时逼近的那个数。一个例子：掷均匀硬币一万次，正面出现 5031 次，频率是 0.5031，而概率是 0.5。

第三条规则有个常用推论： $P(A \text{ 不发生}) = 1 - P(A)$ 。生日问题里我们正是靠它“反着算”才绕开了繁琐的分类。别小看这一步，从“正面硬算”换成“算反面”，是概率论里最省力的思维方式之一。

还要强调“独立地重复”这几个字。每次掷硬币，硬币不记得上一次的结果。这句话听起来平平无奇，后面我们会看到，不理解它的人会在赌场里付出真金白银的代价。

18.4 已知一半信息之后

现在把问题拧得更紧一点。袋子里有 3 个红球、2 个白球，摸出第一个球不放回，再摸第二个。第二个球是红球的概率是多少？这取决于第一个球摸到了什么——信息变了，可能性就跟着变。这种“在某事已经发生的条件下”的概率，叫条件概率，记作 $P(A | B)$ ，读作“在 B 发生的条件下 A 的概率”。

定义 18.2. 设 $P(B) > 0$ ，定义

$$P(A | B) = \frac{P(A \text{ 且 } B)}{P(B)}.$$

为什么要这样定义？把试验重复 N 次 (N 很大)，其中 B 大约出现 $NP(B)$ 次；在这 $NP(B)$ 次里， A 也跟着发生的，大约就是“ A 且 B ”出现的次数 $NP(A \text{ 且 } B)$ 。所以在“ B 已经发生”的世界里， A 出现的频率是两者的比值——定义只是把这句大白话写成了符号。

如果 B 的发生丝毫不改变 A 的可能性，即 $P(A | B) = P(A)$ ，就称 A 与 B 相互独立。代入定义式，独立等价于

$$P(A \text{ 且 } B) = P(A)P(B).$$

先后掷两次硬币，第一次的结果不影响第二次，所以“第一次正面”和“第二次正面”独立，同出正面的概率是 $\frac{1}{2} \times \frac{1}{2} = \frac{1}{4}$ 。而摸球不放回的情形里，两次摸球并不独立。

条件概率最惊人的应用，是下面这个定理。

定理 18.3 (贝叶斯公式). 设事件 $B_1, B_2, \dots, B_n$ 把全部可能结果不重不漏地分成几类，且每个 $P(B_i) > 0$ 。则对任一事件 A ,

$$P(B_i | A) = \frac{P(A | B_i)P(B_i)}{P(A | B_1)P(B_1) + P(A | B_2)P(B_2) + \dots + P(A | B_n)P(B_n)}.$$

证明. 分两步。第一步，分母是什么？事件 A 发生时，必然是和某一个 B_j 一起发生的（因为 B_j 们覆盖了一切可能），而且这些“ A 且 B_j ”两两不能同时出现，于是

$$P(A) = P(A \text{ 且 } B_1) + P(A \text{ 且 } B_2) + \dots + P(A \text{ 且 } B_n).$$

再由条件概率的定义， $P(A \text{ 且 } B_j) = P(A | B_j)P(B_j)$ ，代进去就得到分母那一长串。第二步，看分子。同样由定义，

$$P(A \text{ 且 } B_i) = P(A | B_i)P(B_i) = P(B_i | A)P(A).$$

把最后一个等号两边除以 $P(A)$ ，再把 $P(A)$ 换成第一步展开的长串，公式成立。□


公式看着吓人，用一个真实味道的例子就立刻清楚了。假设某种疾病在人群中的患病率是 0.1%，即千分之一。有一种检测方法很灵敏：患者检测呈阳性的概率是 99%，健康人检测呈阴性的概率也是 99%（也就是说健康人有 1% 被误报为阳性）。现在某人检测呈阳性，他真的患病的概率是多少？

直觉会喊：“百分之九十九吧，检测这么准！”算一算。想象一座一百万人的城市：患者约 1000 人，其中约 990 人检测阳性；健康人约 999000 人，其中约 1%、也就是 9990 人被误报阳性。阳性报告一共约 $990 + 9990 = 10980$ 份，其中真患者只有 990 人。所以

$$P(\text{患病} | \text{阳性}) = \frac{990}{10980} \approx 0.09,$$

只有百分之九左右！用贝叶斯公式写就是

$$\frac{0.99 \times 0.001}{0.99 \times 0.001 + 0.01 \times 0.999} \approx 0.09.$$



这张图揭示了全部秘密：误报的比例虽小，但健康人的基数太大，假阳性的人数反而十倍于真患者。直觉只盯着“检测准确率 99%”，忘记了患病率这个“先验信息”。贝叶斯公式的全部精神就是一句话：**新证据要和旧背景一起算**。先验概率 $P(B_i)$ 是旧背景，检测结果 A 是新证据， $P(B_i | A)$ 是更新之后的判断。这也正是现代医学筛查、垃圾邮件过滤、搜索引擎拼写纠错背后的共同思想。

18.5 平均值能告诉我们什么

概率回答“会不会发生”，接下来的问题是“平均下来会怎样”。设一个抽奖箱里有 100 张券：90 张“谢谢参与”（奖金 0 元），9 张奖金 10 元，1 张奖金 100 元。抽一张，平均能拿到多少钱？

“平均”在这里的意思不是某一次的结果——单次你只能拿到 0、10 或 100 中的一个。它的意思是：如果你抽一万次（每次抽完放回），总奖金大约是多少，分摊到每次是多少。按概率算，一万次里大约有 9000 次 0 元、900 次 10 元、100 次 100 元，总奖金约 $9000 \times 0 + 900 \times 10 + 100 \times 100 = 19000$ 元，平均每次约 1.9 元。写成公式就是

$$E = 0 \times 0.9 + 10 \times 0.09 + 100 \times 0.01 = 1.9 \text{ (元)}.$$

定义 18.4. 设随机量 X 能取值 $x_1, x_2, \dots, x_n$ ，取每个值的概率分别是 $p_1, p_2, \dots, p_n$ ，则称

$$E(X) = x_1 p_1 + x_2 p_2 + \dots + x_n p_n$$

为 X 的**数学期望**（也叫均值）。

期望是“用概率加权的平均”。它有一个立刻能用的推论：如果每张券卖 3 元，而期望奖金只有 1.9 元，那么长期玩下去，玩家平均每局净亏 1.1 元。所有的彩票、赌场游戏都建立在同一笔账上——庄家的期望收益永远为正，玩家的永远为负。期望不能预言下一局的输赢，但它精确地预言了长期的结果。

只看平均值还不够。两个班的平均分都是 80 分，一个班人人都在 78 到 82 之间，另一个班一半是满分、一半不及格，这两个班完全不同。我们需要一个刻画“波动有多大”的数：先算每个取值离期望有多远，把距离平方（平方是为了不让正负抵消），再按概率加权平均，得到

$$\text{Var}(X) = (x_1 - E)^2 p_1 + (x_2 - E)^2 p_2 + \cdots + (x_n - E)^2 p_n,$$

这叫**方差**。方差大，说明结果散落得开，随机性强；方差小，说明结果总挤在期望附近。上面那个抽奖的方差很大（大多数人空手而归，少数人拿大奖），而掷骰子点数的方差就小得多。投资里所谓“高风险高收益”，翻译成数学语言就是：期望大，方差也大。

反例警报

“这个抽奖的期望是 1.9 元，所以我抽一张券，大概能拿到接近两块钱。”——错。单抽一张，你只可能拿到 0、10 或 100 元，永远拿不到 1.9 元。期望是关于“长期平均”的陈述，不是关于“下一次”的陈述。把期望当成对单次结果的预言，是最常见的误读之一。

18.6 掷得足够多，混乱就变成了秩序


到目前为止，我们一直在用“频率会稳定在概率附近”这句话。它到底是一条铁律，还是只是一种常见的经验？数学家把它变成了定理。

定理 18.5 (大数定律 (直观版))。把一个随机试验在相同条件下独立地重复 n 次，设每次结果的期望是 E 。那么当 n 越来越大时，这 n 次结果的算术平均值会以几乎必然的方式逼近 E ；试验次数越多，平均值偏离 E 超过任何给定小数的概率就越接近 0。

完整的证明需要更多工具，但它的思想可以摸得着：单次试验的上下波动，在取平均时会互相抵消——有人今天运气极好，就有人运气极差，拉平之后剩下的就是期望。大数定律是保险业的根基：没人知道某位客户明年会不会出车祸，但保险公司面对一百万客户时，总赔付几乎是一个确定的数，于是保费可以精确地定出来。赌场也一样：它不怕某个赌客今晚赢钱，它只怕没有足够多的赌客。大数定律站在它那边。

还有一个更惊人的事实。掷一枚骰子，点数的分布是“平”的：1 到 6 各六分之一，画出来是六根一样高的柱子，毫无钟形可言。可是改掷两枚骰子看点数之和，和为 7 有 6 种凑法，和为 2、12 各只有 1 种，分布中间高两头低。掷的骰子越多，和的分布就越接近一条光滑的、对称的钟形曲线。这不是骰子的特殊性质：

定理 18.6 (中心极限定理 (直观版))。大量相互独立的微小随机因素叠加在一起，不管每个因素本身服从什么分布，它们的和（或平均）的分布都会接近同一条钟形曲线——正态分布。因素越多，逼近得越好。



这就是为什么身高、测量误差、考试分数、零件尺寸……全都长成差不多形状的钟形：它们每一个都是无数小因素叠加的产物。中心极限定理被称为概率论的“王冠”，因为它解释了为什么混乱的源头各不相同，秩序的形状却惊人地统一。它的证明超出本书范围，难点在于要精确控制“越来越像”的速度，这需要第 12 章介绍的分析工具。

说完秩序，必须回头清算一个顽固的直觉错误。赌场轮盘连续开出了七次红色，围观的人纷纷押黑色：“都红这么多次了，该黑了！”错。轮盘没有记忆，下一次开出红与黑的概率和之前一模一样。这种想法叫**赌徒谬误**：把“长期会拉平”误当成“短期会补偿”。大数定律只说十万次之后红与黑的比例会接近，从不说接下来十次会往哪个方向“还债”。一九一三年，蒙特卡洛的一家赌场曾连续开出二十六次黑色，押红色“该回了”的赌客们输掉了成堆的法郎——他们每个人都是赌徒谬误的受害者。

反例警报

“抛硬币连出五次正面，下一次出反面的概率更大。”——错。各次抛掷相互独立，第六次出反面的概率仍然是 $\frac{1}{2}$ 。真正稀有的是“连续六次正面”这个序列，而不是序列里的某一步。混淆“整段历史”的概率和“下一步”的概率，是赌徒谬误的机关所在。

连接线


你在第 9 章学过的极限，在这里换了一副面孔出现：大数定律说的正是“平均值这个数列收敛到期望”，只不过收敛的方式要允许随机性。而中心极限定理里的钟形曲线，它的方程是 $y = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$ ，里面同时住着 π 和 e ——一个来自圆，一个来自增长与复利。圆、增长、随机性，看似毫不相干的三件事，在这一个公式里会师了。数学各分支之间的暗道，比你想象的多。

18.7 用乱撒的点子算出圆周率

前面所有例子都是“知道概率，预测频率”。现在反过来：利用频率，去算一个本来和随机毫不相干的确定常数。这个思路叫蒙特卡洛方法，名字来自那座以赌场闻名的城市——因为它的燃料就是随机数。

拿一张边长为 2 的正方形纸，在里面画一个半径为 1、与四边相切的圆。正方形面积是 4，圆面积是 π 。现在闭上眼睛，朝正方形里随机撒点——比如把一把芝麻抛上去，或者在方格纸上蒙眼戳笔尖。假设撒了 N 个点，其中 M 个落在圆内。只要每个点落在正方形里任何位置的机会均等，那么

$$\frac{M}{N} \approx \frac{\text{圆面积}}{\text{正方形面积}} = \frac{\pi}{4}, \quad \text{于是} \quad \pi \approx \frac{4M}{N}.$$



圆内点数与总点数之比 $\approx \pi/4$

这个办法粗得可爱：撒几百个点，可能得到 $\pi \approx 3.1$ ；撒几十万个点（当然得请计算机帮忙撒），就能逼近到小数点后两三位。它的精度随点数增长得很慢——误差大致和 $\sqrt{N}$ 成反比，想把精度提高十倍，点数得增加一百倍。所以估算 π 它不是最快的办法，它的真正威力在于另一类问题：计算形状极其古怪、根本写不出面积公式的区域的面积，或者高维空间里的体积。物理学里计算粒子穿过材料的轨迹、金融学里评估复杂产品的价格、计算机图形学里渲染光影，背后都是同一招：**用随机试验把算不出的量“摸”出来**。第 11 章的积分在这里以最意想不到的方式回来了——蒙特卡洛方法本质上就是“用掷骰子做积分”。

还有一个更古典的玩法，叫蒲丰投针。把许多根长度为 l 的针随机抛到画满平行线的纸上，线间距为 d （设 $l \leq d$ ）。数学家蒲丰在十八世纪证明：针与某条线相交的概率恰好是 $\frac{2l}{\pi d}$ 。也就是说，反复投针、统计相交的频率 f ，就能反推出

$$\pi \approx \frac{2l}{fd}.$$

一根针、一张纸、一个无聊的下午，就能让圆周率从随机噪声里浮出来。证明的思路要用到积分：针的位置和角度都是随机的，把所有可能的位置按“机会大小”加权累加起来，相交的条件就化成了一个可以积出来的区域。这个思路的细节属于“继续攀登”的部分。

一分钟实验

撒点估 π (家庭版)。在方格纸上画一个 10×10 的大正方形，以一角为圆心、边长为半径，用圆规画一个四分之一圆。然后合上眼，用铅笔尖朝纸上随机戳，每戳一次睁眼记录点落在四分之一圆内还是圆外（戳到纸外就重来）。戳 100 次，若圆内有 M 个点，就用 $\frac{4M}{100}$ 估计 π 。和同学把数据合并起来——把五个人的 500 个点合在一起算，比较合并前后的估计哪个更准。你能从中亲眼看到大数定律在工作：点越多，估计越稳。

数学工具箱

本章新添的工具：

- **反向计算**：求“至少发生一次”的概率，先算“一次都不发生”，再用 1 去减。
- **条件概率与贝叶斯公式**： $P(A|B) = \frac{P(A \text{ 且 } B)}{P(B)}$ ；新证据要和先验背景一起算。
- **独立性检验**： $P(A \text{ 且 } B) = P(A)P(B)$ 成立才叫独立，别凭感觉。
- **期望与方差**： $E(X)$ 管长期平均， $\text{Var}(X)$ 管波动大小。
- **大数定律**：次数够多，平均值就逼近期望——它保证长期，不承诺下一局。
- **蒙特卡洛方法**：用随机试验的频率逼近面积、常数和积分。

18.8 当统计开始骗人

学会了工具，更要学会识别陷阱。除了生日悖论和赌徒谬误，还有几个专门坑害“半懂不懂”的人的机关。

第一个叫幸存者偏差。二战时，统计学家研究返航轰炸机上的弹孔分布，机翼上弹孔最多。军官们主张加固机翼，而数学家建议加固的恰恰是弹孔最少的发动机部位——因为发动机中弹的飞机根本没飞回来，你看到的全是幸存者。只看得见回来的飞机，数据就先天地缺了一半。今天的“读书无用论”（举几个没上学的富翁当证据）、“成功学课程”（只采访活下来的公司），犯的是同一个错误。

第二个叫平均数幻觉。“某公司员工平均年薪五十万”——可能老板一个人年薪五千万，其他人都在五万上下。期望对极端值极其敏感，这时“中位数”（排最中间的那个数）才是更诚实的描述。下次看到任何“平均”，先问一句：这是哪种平均？被平均的又是谁？

第三个是把相关当因果。冰淇淋销量和溺水人数同步上升，难道是冰淇淋导致溺水？其实背后有个共同原因：夏天到了。两件事一起涨，可能是一个涨导致另一个涨，可能方向相反，也可能纯属第三者作祟甚至巧合。统计能发现关联，但确认因果需要对照实验或更深的机制分析。这是数据时代每个公民的必修课。

继续攀登

继续向前，这些关键词在等你：**正态分布**（钟形曲线的精确方程与“ 3σ 法则”）、**假设检验**（“这个差异是巧合还是真的有效”的定量裁判）、**大数定律的严格证明**（切比雪夫不等式是入场券）、**马尔可夫链**（“明天只取决于今天”的随机过程，网页排序的数学引擎）、**信息论**（用概率度量“惊讶程度”，单位是比特）。竞赛和高中课程里，还会遇到用递推求概率的漂亮问题，比如著名的“赌徒破产问题”。

思考题**观察题**

1. 找一副扑克牌，洗牌后一张张翻开，记录前两张牌同花色的情况，重复二十次，估计“前两张同花色”的频率。再算一算理论概率（提示：第一张任意，第二张与第一张同花色的概率只取决于还剩几张同花色的牌），与你的频率比较。

2. 收集家里一周的用电量数据（电表读数之差），算平均值，再想想：哪个因素会让某天的读数偏离平均最远？这算不算方差的来源？

证明题

1. 证明：若事件 A 与 B 相互独立，则“ A 不发生”与“ B 不发生”也相互独立。（提示：用 $P(A \text{ 不发生}) = 1 - P(A)$ 展开 $P(\text{都不发生}) = 1 - P(A) - P(B) + P(A)P(B)$ ，再做因式分解。）

2. 把生日问题换一种问法：要多少人才能保证“至少两人生日相同”的概率超过 99%？给出你的估算过程。（提示：不必精确求解，逐个试 40、50、60 人时的“全不同”概率，利用对数或分步乘积估计。）

挑战题

1. 蒙提霍尔问题：三扇门后有一辆汽车和两只山羊。你选定一扇门后，主持人（他知道答案）打开另外两扇中藏有山羊的一扇，然后问你要不要换门。换门赢得汽车的概率是多少？用条件概率或枚举给出论证，并解释为什么“还剩两扇门所以各二分之一”是错的。（提示：关键是主持人不是随机开门——他的动作携带了信息。）

2. 设计一个蒙特卡洛实验来估计 $\sqrt{2}$ 的近似值，只需用到撒点和面积比较。（提示： $\sqrt{2}$ 是某个简单几何图形的边长或对角线长；也可以考虑比较曲线 $y = x^2$ 附近的面积。）

通往下一章的门

这一章里，我们好几次在紧要关头说出同一句话：“撒几十万个点”“掷十万次”“重复非常多回”。数学给出了公式，可是谁来做这几十万次枯燥的重复？人手做不到，人脑会出错，而有一台机器天生就爱干这个：它每秒能掷几十亿次骰子，从不喊累，从不抱怨。

蒙特卡洛方法真正改变世界，正是在电子计算机诞生之后——第一台通用电子计算机投入使用时，数学家们最先让它算的，就是用随机数模拟中子在材料里的穿行。可是新的问题立刻来了：计算机产生的“随机数”其实是由确定公式算出来的，它还算真正的随机吗？哪些问题计算机眨眼就能模拟，哪些问题给它一万年也算不完？下一章，我们推开数学与计算机之间的那扇门。

第十九章 数学与计算机：算法能走多远

19.1 一千万次成功之后

先来做一个小游戏。随便写一个正整数，然后反复执行下面的规则：如果这个数是偶数，就把它除以 2；如果是奇数，就把它乘 3 再加 1。比如从 6 出发：

$$6 \rightarrow 3 \rightarrow 10 \rightarrow 5 \rightarrow 16 \rightarrow 8 \rightarrow 4 \rightarrow 2 \rightarrow 1.$$

到了 1 之后，1 会变成 4，4 变回 2，2 又变回 1，陷入 $4 \rightarrow 2 \rightarrow 1$ 的小圈子，我们就停在这里。

这个规则简单到不能再简单，可它提出的问题却难倒了全世界。数学家们猜想：无论从哪个正整数出发，经过有限步之后都会掉进 $4 \rightarrow 2 \rightarrow 1$ 的圈子。这就是著名的“ $3n+1$ 猜想”，也叫角谷猜想或冰雹猜想（因为数在降下来之前常常忽上忽下，像冰雹在云里翻滚）。

这个猜想至今没有被证明，也没有被推翻。但是人们做了一件很“笨”的事：让计算机去试。一台普通的笔记本电脑，一秒钟就能检查几百万个数；专业团队用上大型计算机，已经把从 1 到 2^{68} 左右——大约三亿亿——之间的所有整数都验证了一遍。每一个数最终都落进了 $4 \rightarrow 2 \rightarrow 1$ 的圈子。一个例外都没有。

三亿亿次成功，无一例外。现在问你一个问题：这个猜想算是被证明了吗？

直觉上，很多同学会说“肯定是对的呀，都试了这么多了”。也有人会犹豫：“万一在更大更大的地方藏着一个反例呢？”这一章，我们就从这个犹豫出发，去看看数学和计算机之间这段既亲密又微妙的关系：计算机到底能为数学做什么，又永远做不到什么。

19.2 验证了这么多，为什么还不算证明？

先别急着站队，我们来看几个历史故事，看看“试了很多次都对”这件事有多么靠不住。

19.2.1 一个骗了四十次的公式

考虑式子 $n^2 - n + 41$ 。把 $n = 1$ 代进去，得 41，是素数； $n = 2$ 得 43，素数； $n = 3$ 得 47，还是素数。你可以继续代： $n = 4, 5, 6, \dots$ 一路代下去，得到的 43, 47, 53, 61, 71, 83, 97, ... 竟然全都是素数！事实上，从 $n = 1$ 一直代到 $n = 40$ ，整整四十次，次次都是素数。

如果让计算机来验证，它会信心满满地报告：“连续四十次成功！”可是 $n = 41$ 的时候：

$$41^2 - 41 + 41 = 41^2 = 41 \times 41,$$

这显然不是素数。四十次成功之后紧跟着的就是失败。

19.2.2 藏在九亿后面的反例

如果说四十次太少，那九亿次够不够？数学家波利亚在 1919 年提出过一个关于素数分布的猜想（细节不重要，重要的是它是一个“看起来大概率正确”的命题）。人们逐个验证，发现它对九亿以内的所有数都成立。九亿个数啊，一个人一秒钟检查一个，要不吃不喝查上二十多年。

然而 1958 年有人证明，这个猜想是错的，最小的反例出现在 906 150 257 附近——九亿多一点的地方。换句话说，前九亿次验证全部“成功”，却丝毫没有触碰到真相的边缘。大自然把第一个例外藏在了一个靠蛮力极难够到的地方。

19.2.3 大人物的猜想也会翻船

大数学家欧拉在 1769 年提出过一个猜想，大意是：至少要有 n 个“ n 次方的数”加起来，才可能等于另一个数的 n 次方。这个猜想挺立了近两百年，很多人都相信它——毕竟欧拉看问题极少出错。

结果到了 1966 年，两位数学家借助计算机搜索，找到了一个干干净净的反例：

$$27^5 + 84^5 + 110^5 + 133^5 = 144^5.$$

按照欧拉的猜想，至少需要 5 个五次方才能凑出一个五次方，可这里只用了 4 个。近两百年的信任，被一行等式推翻。值得注意的是，是计算机帮助找到了这个反例——机器搜索了人工不可能搜索的庞大范围。计算机在这里扮演的角色不是“证明者”，而是“找茬高手”。

反例警报

反例警报：验证了 N 次，就宣布结论成立。

不管 N 是一百、一百万还是三亿亿，“前 N 个都对”只说明结论在**有限范围**内成立。数学猜想谈论的通常是**无穷多个**对象，而无穷是试不完的。有限次验证可以提供**证据**，让我们更有信心；可以帮我们**发现规律**；运气好的话还能**撞上反例**把猜想推翻——但它永远不能代替覆盖所有情况的证明。反过来说，推翻一个猜想只需要一个反例，而证明一个猜想需要对付无穷多种情况，这两件事的难度天生就不对称。

回到 $3n + 1$ 猜想：三亿亿次验证给了我们很强的信心，但波利亚猜想的故事提醒我们，第一个例外完全可能藏在一百亿亿亿之后。所以在它被真正证明（或者找到反例）之前，我们只能老老实实地叫它“**猜想**”，而不是定理。

19.3 算法：一台思想上的机器

刚才我们一直在说“让计算机去验证”。可是计算机到底在干什么？它既没有眼睛也没有直觉，它做的事本质上只有一件：**一步一步地执行预先写好的指令**。这样的指令序列有个名字——算法。

术语卡片：算法

直观解释：算法就是一份写得足够死的操作手册，死到让一个完全不懂数学、只会机械照办的人（或机器）也能一步步执行下去，并且在有限步之后给出结果。

正式定义：算法是一组有限的、明确的指令，对每类合法的输入，按指令执行有限步之后停止，并输出一个确定的答案。”有限步内停止”这一条很关键——永远转个不停的程序不配叫算法。

一个例子：求两个正整数的最大公约数，可以用两千年前的辗转相除法。比如求 1071 和 462 的最大公约数： $1071 = 2 \times 462 + 147$ ， $462 = 3 \times 147 + 21$ ， $147 = 7 \times 21 + 0$ ，余数为 0 时停下，答案是 21。每一步都有明确指令，有限步内必停，这就是教科书级别的算法。

为什么我们这么在意”算法”这个概念？因为它给”机械地计算”划了一条清晰的边界。一旦把”算法”定义清楚了，我们就可以问一些惊人的问题：

- 是不是**所有**数学问题都有算法能解决？
- 如果有，我们能不能造一台机器，把任何数学命题输进去，它就自动告诉我们”真”还是”假”？

第二个问题听起来简直是数学家的终极梦想——如果这种机器存在，证明定理就成了按按钮的体力活，数学家们可以集体退休了。二十世纪初，确实有不少数学家怀抱着这样的希望。

19.4 有些事，算法永远做不到

梦想在 1936 年被击碎了。英国数学家图灵在思考”计算”的本质时，提出了一个朴素的问题：**能不能造一个算法，判断任意给定的程序会不会停机？**

先解释一下什么叫”停机”。程序有两种命运：要么运行有限步后结束（停机），比如辗转相除法；要么陷入死循环，永远跑下去，比如一个写着”从 1 开始不断加 1，永不停止”的程序。一个程序会不会停机，取决于它的代码和输入。有些程序一眼就能看出会死循环，有些程序——比如”从某个大数开始不断执行 $3n + 1$ 规则”——会不会停，恰恰是没人知道的难题。

定义 19.1. 停机问题：是否存在一个算法 H ，给它任意程序 P 和任意输入 x ，它都能在有限时间内正确回答” P 作用在 x 上会不会停机”？

图灵的答案石破天惊：这样的算法**不存在**。不是”暂时没人找到”，而是逻辑上根本不可能存在，过去、现在、未来都不会有。这是本章的核心定理。

定理 19.2 (停机问题不可判定). 不存在一个能对任意程序和任意输入判定其是否停机的通用算法。

证明. 用反证法。假设这样的算法 H 存在。 H 接收一段程序文本和一份输入，总是能在有限步后回答”停”或”不停”，而且永远答对。

现在我们用 H 做零件，拼装一个怪程序 D 。 D 只吃一种东西：一段程序文本 Q 。 D 的工作流程是：

1. 先调用 H ，问它：”程序 Q 拿它自己的文本当输入时，会停机吗？”

2. 如果 H 回答“会停”， D 就故意进入死循环，永不停机；
3. 如果 H 回答“不会停”， D 就立刻停机。

简单说， D 的脾气是：**你说我停，我偏不停；你说我不停，我偏停**。构造 D 没有任何技术障碍——既然 H 是个现成的算法，把它包进 D 里只是写几行代码的事。

好戏来了：把 D 自己的文本喂给 D ，问： D 作用在 D 上，停不停机？

- 假如 $D(D)$ 停机。那 H 对“ D 作用在自己上会不会停”的回答必然是“会停”，可按照 D 的设计， H 答“会停”时 D 偏偏要进死循环—— $D(D)$ 不停机。矛盾。
- 假如 $D(D)$ 不停机。那 H 的回答必然是“不会停”，可按照 D 的设计， H 答“不会停”时 D 立刻停机—— $D(D)$ 停机。又矛盾。

两种情况都导致矛盾，问题只能出在最初的假设上：算法 H 根本不存在。 □

这个证明的巧妙之处在于“自己指自己”：让一个判断程序去判断一个专门跟它对着干的程序，于是自相矛盾。这和说谎者悖论（“这句话是假的”）、和前面章节里见过的对角线方法，在精神上是亲戚——**任何强大到能谈论自身的系统，都会被“自我指涉”咬到尾巴**。

停机问题不可判定，带来的震动远不止“程序员没法写出万能死循环检测器”这么简单。它意味着：**存在这样的数学问题，答案明明客观存在（程序要么停要么不停，没有第三种可能），却没有任何算法能系统地求出它**。这类问题被称为“不可计算的”或“不可判定的”。后来人们还证明，许多看上去纯粹的数学问题——比如“任给一个多项式方程组，判断它有没有整数解”（希尔伯特第十问题）——同样不可判定。

连接线

连接线：停机问题与哥德尔不完备定理。

在稍早的章节里我们见过哥德尔的不完备定理：任何足够强的数学公理系统里，都存在“真但无法在该系统内证明”的命题。停机问题和它是同一场大地震的两个震感。事实上，如果一个数学系统完备到能判定一切命题，我们马上就能用它造出停机判定算法——把“程序 P 会停机”这个命题交给系统去判就行了。既然停机问题不可判定，完备的系统就不可能存在。计算和证明，在深渊底部是连通的。

19.5 快与慢的鸿沟：计算复杂度

停机问题告诉我们：有些问题**原则上**就没有算法。接下来一个更实际的问题是：在那些有算法的问题里，是不是所有算法都一样好用？

答案显然是否定的。看两个算法：

顺序查找：在一摞 n 张打乱的书签里找夹着枫叶的那张，只能一张一张翻，最坏情况要翻 n 次。

二分查找：如果书签按页码排好了序，先看正中间那张，页码偏大就往左半摞找，偏小就往右半摞找，每翻一次就排除一半。 n 张书签最多翻 $\log_2 n$ 次——1000 张只要 10 次，一百万张也只要 20 次。

同样一个问题，算法不同，工作量天差地别。计算机科学干脆把问题本身按”最好的算法有多快”分类，这就是**计算复杂度**研究的事。其中最引人注目的一条鸿沟，横在两类问题之间：


- ”容易算”的问题（记作 P 类）：存在算法，所需步数大约是输入规模的**多项式**级别，比如 n 、 n^2 、 n^3 。排序、求最大公约数、找最短路径都在这一类。
- ”容易验”的问题（记作 NP 类）：答案可能很难**找**，但一旦有人把答案送到你面前，你能在多项式时间内**验证**它对不对。数独是典型：填满一个九宫格可能让你抓耳挠腮，但检查一份填好的答案合不合法，只需扫一遍每行每列每宫。

每个 P 类问题天然也是 NP 类（能算出来当然能验证）。反过来呢？**每个容易验证的问题，是不是其实也容易算？**这就是价值百万美元的”P 对 NP”问题，至今无人解决。大多数专家猜测 P 不等于 NP——也就是说，确实存在”验证容易、寻找难”的问题。

为什么多项式和别的增长差别这么大？看一张表就明白了。假设计算机每秒执行十亿步：

输入规模 n	n^2 步	2^n 步	2^n 步大约耗时
10	100	1024	一瞬间
20	400	约一百万	一瞬间
30	900	约十亿	约一秒
40	1600	约一万亿	约十八分钟
60	3600	约一百亿亿	约三十六年

多项式（比如 n^2 ）长得不算快，输入翻几倍，时间翻几十倍，咬咬牙总能算完。指数（比如 2^n ）却是头怪兽：输入每加 1，工作量直接翻倍。很多重要的问题——比如”给几十个城市排一条最短的巡回路线”——目前只找得到指数级别的算法。输入稍大一点，宇宙的年龄都不够用。注意这和停机问题不同：这些问题**有**算法，只是算法慢得没有实用价值。数学把它们和”原则上无解”的问题区分开来，一层一层地给”难”分级。



注. 上图只是示意草图：两条曲线都在加速，但虚线的指数增长很快就会把任何多项式甩得无影无踪——虽然在小 n 处它们看上去差别不大。这正是”渐近”（看长远趋势）思想的价值。

这条鸿沟不只是学术游戏。你每天上网购物、登录账号时用的密码，其安全性就建立在”验证容易、逆向难”之上：把两个大素数乘起来很容易，把一个几百位的大数拆回两个素数却难到所有超级计算机联手都算不动。如果有人证明了 P 等于 NP 并且构造出快速算法，整个现代密码体系的地基就会动摇。

19.6 计算机反过来帮助数学

前面我们强调了计算机的局限：不能靠蛮力验证代替证明，有些问题永远算不出来，有些问题算出来也等不起。但如果就此得出“计算机对数学没什么用”的结论，那就大错特错了。真实的图景有趣得多：计算机正在以至少三种方式深刻地改变数学本身。

19.6.1 海量计算，作为证明的一部分：四色定理

1852 年有人提出：给地图上色，要求相邻国家颜色不同，四种颜色够不够？这个“四色问题”折腾了数学家一百二十多年。1976 年，两位数学家宣布证明了它——但证明的方式前所未闻：他们把问题归结为一千多种基本情形，然后用计算机逐一检查了这一千多种情形全部成立。定理成立，但其中一千多步推理是机器干的，没有任何人能手算复查。

数学界炸开了锅：这算证明吗？没人能人工核对的证明，你敢信吗？争论持续了很多年。如今主流的观点是：只要程序本身被严格审查、计算逻辑清晰，机器完成的穷举可以算证明的一部分。后来这个证明被不断简化、重新验证。但四色定理永远改变了“证明”这个词的含义——**证明的可靠性，从“每个聪明人都能复查”变成了“逻辑链条的每一环都可被审查，哪怕其中一环只有机器干得动”。**

19.6.2 机器当校对员：形式化证明

另一条路更彻底：与其争论机器参与的证明算不算数，不如干脆把证明**整个**写成机器能检查的严格语言。这就是“形式化证明”。像 Lean、Coq 这样的“证明助手”软件，要求数学家把每一步推理写到毫无含糊的程度，然后由机器逐行检查逻辑是否严密。人负责出主意，机器负责挑毛病。

这项工作枯燥但回报惊人。最著名的战例是开普勒猜想：把同样大小的球堆进箱子，最密的堆法就是水果店那种堆法。这个命题直觉上“显然”，证明却难如登天。1998 年，数学家黑尔斯宣布证出，证明里有大量计算机计算；审稿人花了几年的工夫，最后只能表示“百分之九十九确信它是对的”——那剩下的百分之一，正是没人查得动的机器计算部分。黑尔斯干脆发起了一个工程，把整个证明用形式化语言重写，2014 年机器盖章确认：每一步逻辑无误。怀疑彻底消失。

继续攀登

继续攀登

想往高处看，可以留意这些关键词：**图灵机**（图灵为“算法”建立的数学模型，整个计算机科学的地基）；**P vs NP 问题**（克雷数学研究所七大千禧年难题之一，悬赏一百万美元）；**希尔伯特第十问题**（丢番图方程可解性的不可判定性）；**证明助手 Lean**（如今数学界正在用它把现代数学的整个大厦逐步“机器化”）；**SAT 求解器**（工业界验证芯片逻辑的超级穷举引擎）。

19.6.3 机器当望远镜：探索几何、数论与分析

计算机最浪漫的角色，是做数学家的“望远镜”和“显微镜”——帮人类**看见**原本看不见的数学世界，至于证明，仍然由人来完成。

在**几何**里，计算机把迭代过程画成图，炸出了一个全新的世界。曼德博集合——按规则 $z \mapsto z^2 + c$ 对复数反复迭代，把“永远不跑远”的点涂黑——画出来的图形边缘层层分形，放大任何一小段边

缘都会涌现出新的花纹，无穷无尽。在计算机出现之前，没有人知道如此简单的公式里藏着如此繁复的几何。今天”分形几何”已经用来描述海岸线、云和血管的形状。

在**数论**里，计算机是超级筛子。已知的最大素数是梅森素数，有两千多万位，由全球志愿者用闲置电脑联网搜寻（GIMPS 计划）找到。人们还用计算机验证哥德巴赫猜想（”每个大于 2 的偶数都是两个素数之和”）到极大的范围、统计素数分布的精细规律——这些海量数据常常为猜想提供灵感，有时也为推翻猜想提供弹药。

在**分析**里，数值实验时常先于理论发现规律。一个传奇的例子是 π 的 BBP 公式：人们用计算机做数值搜索，先发现了一个能从 π 的十六进制展开中直接”抠出”任意一位的公式，随后才补上严格证明。机器先”看”到规律，人再搞懂它为什么成立——探索的顺序被颠倒了，而这正是实验科学的经典流程。

数学工具箱

本章数学工具箱

- **有限验证 $\neq$ 证明**：验证再多有限情形也只提供证据；一个反例足以推翻猜想，一个证明必须覆盖无穷情形。
- **算法**：有限、明确、必然终止的指令序列。它是讨论”能不能机械求解”的精确语言。
- **停机问题**：存在**原则上**无法用算法判定的问题；自我指涉 + 反证法是识别这类障碍的利器。
- **计算复杂度**：在有算法的问题中再分快慢；多项式增长可控，指数增长是怪兽；P 对 NP 是最大的未解之谜之一。
- **人机分工**：机器做海量计算、严格校对、图像探索；人负责提出问题、发明概念、完成真正需要洞察的推理。

19.7 纸上机房：动手实验

一分钟实验

实验一：亲手跑一遍 $3n + 1$ 。

从 27 出发，在纸上一步一步执行规则：偶数除以 2，奇数乘 3 加 1。耐心算下去，数一数用了多少步才到达 1（答案在一百步上下，做好心理准备），并记录途中出现的最大值。你会发现 27 这个小个子居然能蹿到 9232 那么高再跌下来。再试试从 31 或 97 出发。体会一下：为什么计算机验证这个猜想并不轻松——路径忽高忽低，毫无规律，却至今每次都有惊无险地落地。

实验二：用一摞书感受二分查找。

把 16 本书在桌上按书脊的高矮（或页码）从左到右排好。请一位同学心里默想其中一本，你只许问“是这本吗，还是说目标在它的左边/右边”。先每次从中间那本问起，记录你最多几次就能锁定目标；再换从第一本开始挨个问，记录最坏情况要几次。16 本书，二分法最多 4 次，挨个问最坏 16 次。把书加到 32 本重做一次：二分法只多 1 次，挨个问却翻了一倍——这就是对数增长和线性增长的差别，亲手摸一遍就再也忘不掉。

实验三：给“撒谎的程序”画像。

不碰电脑，只在纸上推演：假设同桌宣称他写了一个万能程序 H ，能判断任何程序会不会死循环。模仿本章定理的证明，向同桌描述那个专门跟他对着干的程序 D ，让他亲口说出“ D 作用在 D 上到底停不停”。无论他怎么回答，你都指出其中的矛盾。这个纸笔游戏做完，你会对“反证法”和“自我指涉”产生真正的手感。

思考题

观察题

1. 用 $n^2 - n + 41$ 对 $n = 1, 2, \dots, 8$ 算出结果并检查是否都是素数，再直接计算 $n = 41$ 的情形。（提示： $n = 41$ 时前两项 $41^2 - 41$ 能提取出公因数 41，所以整个式子必有因数 41。）
2. 观察 $3n + 1$ 过程中：任何一个到达 1 的轨道，最后几个数必定是什么？（提示：想想什么样的数经过“除以 2”能变成 1，再往前倒推一步。）

证明题

3. 模仿停机问题的证明，说明不存在这样的算法 G ：给它任意程序 P ， G 总能正确判断“ P 运行时会不会在屏幕上打印出‘你好’两个字”。（提示：假设 G 存在，造一个怪程序：先问 G “我会打印你好吗”，听到“会”就偏不打印，听到“不会”就偏要打印，然后让它判断自己。）
4. 证明：如果书架上有 n 本按顺序排好的书，二分查找最多需要 $\lceil \log_2 n \rceil + 1$ 次以内就能找到任意一本。（提示：每翻一次，待查范围至少减半；想想范围从 n 缩到 1 需要减半多少次。）

挑战题

5. 有人宣布他证明了“ P 等于 NP ”，并且找到了在多项式时间内解决数独的算法。假设他是对的，列举三件我们日常生活中会因此天翻地覆的事，并说明理由。（提示：回忆本章讲的密码学；再想得更远一点——数学定理的“证明”本身，验证起来难不难？如果验证容易的事寻找也容易，“自动证明定理”意味着什么？）
6. $3n + 1$ 猜想至今没被证明。有人说：“既然停机问题不可判定，说不定 $3n + 1$ 猜想本质上

也是‘不可判定的’，所以才证不出来。”这个推理有哪些地方站得住，哪些地方是偷换概念？（提示：注意“不存在一个万能算法判定**所有**程序”和“某一个具体命题无法被证明”是两回事；但也确实有数学家构造出与停机问题本质等价的具体数论问题。）

通往下一章的门

这一章我们看到了一幅奇特的图景：计算机是人类造过的最强大的计算工具，它能在眨眼间验证三亿亿个数，能逐行检查人一辈子查不完的证明，能画出人脑无法想象的分形——可是它面前同样矗立着不可逾越的高墙：有些问题永远没有算法，有些问题算法慢到等不起，而“验证了一亿次”在数学上依然不等于“永远成立”。

机器的力量和机器的边界，其实都映照出数学自身的力量和边界。哥德尔说不完备性是任何足够强的公理系统逃不掉的宿命；图灵说不可判定性是什么计算装置绕不开的暗礁；而“P 对 NP”这样的谜题至今悬而未决，提醒我们今天引以为傲的大厦依然建在不少未探明的地基上。

那么，数学这座大厦的地基究竟是什么样子？极限、无穷、连续这些让初中数学开始“不踏实”的概念，是怎样被十九世纪的数学家们一寸一寸夯实的？那些深刻的定理——从微积分基本定理到伽罗瓦理论——又是怎样把看似毫不相干的数学分支缝合成一张统一地图的？下一章，我们将走到数学世界的边缘，回头看它的全貌：边界在哪里，地图又通向何方。

第二十章 数学的边界与统一地图

20.1 挂在校园里的一幅地图

想象你们学校要迎接校庆，总务处决定画一幅巨大的校园平面图，挂在操场边的墙上，连每一棵树、每一条长椅都要标出来。负责画图的美术老师精益求精，画完之后忽然冒出一个念头：这幅地图挂在墙上，本身也是校园的一部分。那么，一幅“完整”的校园地图，是不是应该把“墙上挂着一幅地图”这件事也画进去？

如果画进去，麻烦就来了：地图里那幅小地图也是校园的一部分，小地图里还得有一幅更小的地图，更小的里面还要有更更小的……一层套一层，永远画不完。美术老师被自己的完美主义逼进了死胡同。

这个听起来像脑筋急转弯的问题，其实戳中了二十世纪数学最深的一道伤口：当一个东西开始谈论它自己的时候，会发生什么？地图谈论校园，顺便谈论了地图自己；一句话可以谈论另一句话，也可以谈论它自己——“这句话是假的”，它到底是真还是假？一个集合可以装着别的东西，它能不能装它自己？

在这一章里，我们要沿着这条裂缝往下走，看看数学家们在一百多年前发现了什么：无穷原来不止一种；“什么都能装”的集合概念会爆炸；甚至连“数学能证明一切真理”这件事本身，也被证明是做不到的。然后我们会掉转方向，做一件同样重要的事：把这本书走过的所有路画在一张地图上，看看“数、形、变、结构、随机、证明”这六个镜头是怎样把同一个世界照出六种颜色的。这是全书的最后一章，所以它同时也是一张地图和一扇门。

20.2 无穷也分大小吗？

先从一个更朴素的问题开始：有没有“最大的”无穷？

凭直觉，大多数人会摇头：无穷就是无穷嘛，数不完的数，还能比大小？自然数 $1, 2, 3, \dots$ 数不完，偶数 $2, 4, 6, \dots$ 也数不完， 0 到 1 之间的小数还是数不完——它们不都是“无穷多个”吗？

这个直觉，正是我们要展示的第一次失败。在往下读之前，你可以先猜一猜：偶数的个数和自然数的个数，谁多？很多人脱口而出：偶数只有自然数的一半，当然是自然数多！这个答案听起来天经地义，但它是错的。错的根源在于，我们直接把“比有限集合大小”的经验搬到了无穷上。比较两堆糖果，我们可以数一数各有多少颗，再比数字；可是两边都数不完的时候，“个数”这个词本身就失去了意义。

要比较无穷，得先发明一种新的比较方式。

定义 20.1 (等势). 两个集合 A 和 B 称为等势的，如果能在它们的元素之间建立一个一一对应： A 中每个元素恰好配对 B 中一个元素， B 中每个元素也恰好被配对一次，谁也不落单，谁也不重

复。

一一对应是个古老得多的想法：原始人数羊群，不用会数数，每放出一只羊就在绳子上打一个结，羊和结一一对应，就知道羊有没有丢。这个定义绕开了“数完再说”的麻烦——它**不要求数完**。

自然数	偶数
1	2
2	4
3	6
4	8
$\vdots$	$\vdots$

看上图：每个自然数 n 配对偶数 $2n$ 。每个偶数都被配到，每个自然数都有伴，对应严丝合缝。所以按照等势的定义，偶数和自然数**一样多**——尽管偶数明明只是自然数的一部分！“部分可以等于整体”，这是无穷世界的第一条怪规则，伽利略就注意过这个怪事，但它困扰了数学家两百多年。真正把这件事彻底搞清楚的，是十九世纪末的数学家康托尔。他当时被同行猛烈攻击，有人说他的理论是“疾病”，但他坚持把“一一对应”作为衡量无穷的尺子。

用这把尺子，康托尔先量了一些熟悉的集合：整数（含负数和零）和自然数等势——把 $0, -1, 1, -2, 2, \dots$ 排成一队就行；更令人吃惊的是，**有理数也和自然数等势**。直觉上有理数密密麻麻布满数轴，随便一小段里就有无穷多个，怎么可能数得清？但可以把所有正分数按“分子加分母”的大小分组排队：先是和为 2 的 $\frac{1}{1}$ ，再是和为 3 的 $\frac{1}{2}, \frac{2}{1}$ ，再是和为 4 的 $\frac{1}{3}, \frac{2}{2}, \frac{3}{1}$ ……每个分数迟早都会排到，于是每个有理数都能领到一个号码牌。和自然数等势的集合，叫作**可数集**——意思是虽然数不完，但至少可以“排队领号”。

到此为止，无穷好像只有一种，只是爱捉迷藏。真正的惊雷在下面。

定理 20.2 (康托尔对角线定理). 实数集合与自然数集合不等势：实数**排不成**一队。换句话说，无穷至少有两种大小。

证明. 用反证法。假设有声称他把 0 到 1 之间的所有实数排成了一队：

第 1 个： 0.**3**1415 ...
 第 2 个： 0.2**7**182 ...
 第 3 个： 0.14**1**42 ...
 第 4 个： 0.577**2**1 ...
 $\vdots$

我们当场构造一个新的小数 r ：它的第 1 位小数取“第 1 个数第 1 位”之外的值，比如 3 改成 4；第 2 位取“第 2 个数第 2 位”之外的值，7 改成 8；第 3 位把对角线上的 1 改成 2；第 4 位把 2 改成 3……每一位都照着对角线改动一下。得到的 $r = 0.4823\dots$ 是 0 到 1 之间的一个实实在在的实数。

可是它在队伍里吗？它不是第 1 个，因为第 1 位不同；不是第 2 个，因为第 2 位不同；不是第 n 个，因为它和第 n 个数的第 n 位不同。它对每一个号码都“正好错一位”，所以**这份号称完整的名单漏掉了它**。任何排队方案都逃不过同样的构造——你给出任何队伍，我都能沿对角线造出一个漏网之鱼。所以假设不成立：实数排不成队，它比自然数“更多”。□

术语卡片：基数

直观解释：集合的“大小”，但不靠数数，而靠配对。两堆东西能一一对应，就说它们基数相等。

正式说法：自然数集合的基数记作 $\aleph_0$ （读作“阿列夫零”），实数集合的基数更大，称为连续统的基数。可以证明 $\aleph_0$ 是最小的无穷基数。

一个例子：偶数、整数、有理数的基数都是 $\aleph_0$ ；而实数、0 到 1 之间的小数、数轴上的点的基数都是连续统基数。

对角线法得到的 r 不是嘴上说说的“假设有个数”，而是可以动手算出来的。下面的实验让你亲自当一回“漏网之鱼制造者”。

一分钟实验

拿一张纸，写下五个介于 0 和 1 之间的小数，每个写出小数点后五位（可以随手乱写，也可以抄圆周率的片段），排成五行。然后把每个数的第 i 位（第 i 行的第 i 个数字）加 1（9 变回 0），把得到的五个数字拼成一个小数。检查：它和第 1 行第 1 位不同，和第 2 行第 2 位不同……它不在你的名单上。换一组五个数再玩一次。你刚刚亲手执行了康托尔的对角线论证——只不过康托尔把它用在了无穷长的名单上，而“每一位都对不上”的逻辑一模一样。

故事还没完。康托尔接着证明：对任何集合 A ，把它的所有子集装在一起构成的集合（幂集）一定比 A 本身“更大”。于是无穷没有最大，只有更大： $\aleph_0$ 之上是连续统，连续统之上还有更大的，一层一层没有尽头。至于“连续统是不是紧挨着 $\aleph_0$ 的下一个无穷”这个自然的问题（连续统假设），答案比问题本身还离奇——我们到本章后面再揭晓。

20.3 理发师与那本不能存在的目录

无穷分大小已经够震撼了，但更深的裂缝出在“集合”这个概念本身。

二十世纪初，数学家们踌躇满志，觉得集合可以成为全部数学的地基：数可以定义成集合，图形、函数、方程都可以归约为集合，只要地基打牢，数学大厦就万古长青。地基的核心假设听起来人畜无害：**随便说一个清楚的条件，满足条件的东西就组成一个集合**。比如“是偶数”定义了偶数集合，“是红色的”定义了红东西的集合。

1901 年，罗素给这个假设找了一个致命的条件：“**自己不是自己的元素**”。大多数集合满足它——所有苹果的集合不是一个苹果，所以它不含自己。罗素问：把所有满足这个条件的集合装在一起，组成集合 R ，也就是

$$R = \{x \mid x \notin x\},$$

那么 R 含不含它自己？如果 $R \in R$ ，那 R 满足条件“不含自己”，所以 $R \notin R$ ；如果 $R \notin R$ ，那 R 恰好符合 R 的入会条件，所以 $R \in R$ 。两头都矛盾——**这样一个集合连存在都不能存在**。

有个著名的通俗版：村里有个理发师，宣称“我给、且只给村里所有不给自己刮脸的人刮脸”。那么他给不给自己刮脸？给他自己刮，他就属于“给自己刮脸的人”，按规矩不该刮；不刮，他就属于“不给自己刮脸的人”，按规矩必须刮。理发师不存在——不是他手艺差，而是那句宣称自相矛盾。

反例警报

“任何能说清楚的条件，都能定义一个集合。”——这句话听起来无懈可击，但罗素悖论表明它会引爆整个体系。另一个同样诱人的错误说法是：“数学里的无穷都是一回事，既然都数不完，就没什么可研究的。”康托尔的对角线证明告诉你：无穷不但有区别，而且区别的层次本身都无穷无尽。直觉在无穷面前经常罢工，这就是必须发明严格定义的原因。

罗素悖论的后果是：数学家不能再用“什么都能装”的朴素集合概念，必须给集合的“出生”立规矩——哪些集合允许构造、用什么方式构造，逐条写清楚。这些规矩就叫**公理**。今天最常用的集合论公理系统（ZF 公理，加上选择公理则称 ZFC）大意是：承认空集存在；已有的集合可以两两合并、可以取幂集、可以从无穷集里按明确规则挑子集；等等。注意“按明确规则挑子集”这一条——它允许你说“在已知集合 A 里，把满足某条件的元素挑出来”，但**不允许**你凭空说“把所有满足某条件的东西都收集起来”。罗素那个 R 需要的正是后一种无法无天的收集，于是它被客气地拒之门外，悖论烟消云散。

术语卡片：公理

直观解释：一盘棋的规则。规则本身不问“为什么”，问的是“按规则玩下去会不会自相矛盾、能玩出什么花样”。

正式说法：公理是一个理论不加证明就接受的起点命题；定理是从公理出发、按推理规则一步步证出来的结论。

一个例子：“过直线外一点，有且只有一条直线与已知直线平行”是欧氏几何的公理；换掉这一条，就得到完全不同的几何——这正是我们在几何章节里看到的平行公设故事。

这件事改变了数学家看“公理”的眼光。古希腊人把公理当作不证自明的真理；二十世纪的数学家则把公理当作游戏规则：重要的不是它“真不真”，而是这套规则**自治**（推不出矛盾）并且**好用**（能推出丰富的定理）。欧几里得的几何、集合论、概率论，都是先立规则再推演的世界。

20.4 哥德尔：数学装不下全部的真

公理化之后，数学家们燃起一个宏伟的希望：既然数学可以写成一套公理加推理规则的形式系统，那能不能找到一套足够强的公理，使得——第一，它**自治**，永远推不出矛盾；第二，它**完备**，凡是关于自然数的真命题都能在其中被证明；第三，这种自治性还能用数学方法自己证明给自己看？这个被称为“希尔伯特纲领”的计划，想给数学发一张一劳永逸的安全证书。

1931 年，二十五岁的哥德尔证明了两条定理，把这个计划的核心部分证伪了。用极度通俗的话讲：

定理 20.3 (哥德尔不完备定理 (通俗版))。任何一套足够强（至少能表达自然数加减乘除）、自治、规则可以机械检查的公理系统里，都存在**真的但在这个系统里证不出来的命题**；而且，这个

系统无法证明自己不自相矛盾。

通俗版的粗糙处必须说清楚，这是本节反复强调的**适用边界**：哥德尔的定理是关于“形式系统”的严格数学命题，它的假设里藏着不少技术性条件（比如“规则可以机械检查”意味着公理清单是一台计算机可以逐条核对的）；它的结论**不是**“数学不可靠”，**不是**“什么都不可信”，更不是“反正证不出来就随便相信”。它说的是一个精确的事实：**证明的能力和真**这两件事，在任何足够强的固定规则系统内都不能完全重合——总有一些真话，需要站到系统之外、或加入新的公理，才看得见。

哥德尔的构造妙得让人起鸡皮疙瘩：他发明了一种编码（现在叫哥德尔数），把每个公式、每个证明都翻译成一个自然数，于是“命题 P 在本系统中可证”这句话本身变成了关于自然数的算术命题——系统可以谈论“自己内部能证明什么”。然后他仿照说谎者悖论，造出一个算术命题 G ，大意是：“ G 在本系统中不可证。”如果系统能证 G ，那就证出了假话，与自洽矛盾；所以（在系统自洽的前提下） G 确实证不出来——可这正是 G 所说的话，所以 G 是真的。真而不可证，就是这么造出来的。还记得本章开头那幅“地图里画地图”吗？数学最锋利的突破，恰恰来自把“自指”这头怪兽驯化成工具。

连接线

哥德尔编码的思想——把“符号串”变成“数”，让系统处理关于自身的话语——在五十年后以另一种形式改变了世界：计算机程序本质上也是数（源代码是一串符号），程序可以分析别的程序，甚至分析自己。图灵证明“不存在能判断任意程序是否会停机的通用程序”，用的正是对角线加自指的同一招。而连续统假设的结局同样来自这个家族：数学家们证明，它在 ZFC 公理系统里**既不能证明也不能推翻**——哥德尔说的“真而不可及”不是理论恐吓，具体的重要问题真的落进了这个盲区。你看，无穷、自指、可计算性，在本章开头看起来毫不相干的三件事，在最深处是同一张网的三个结。

这对我们意味着什么？一个诚实的回答是：数学不是一台盖棺论定的盖章机，它更像一片永远有新疆界的国土。每解决一个问题，地图边缘就露出新的空白。这不是数学的失败，恰恰是它永远活着的证明。

数学工具箱

本章收获的新工具：

- **一一对应**：不靠数数就能比较两个集合（哪怕是无穷集合）的大小。
- **对角线法**：沿“第 n 个对象的第 n 个特征”动手修改，造出名单之外的新对象——既能证“实数不可数”，也是自指论证的引擎。
- **公理化思维**：把理论看成“规则加推演”，关注自洽与丰富，而非“不证自明”。
- **元视角**：跳出一个系统看系统本身，很多“能不能”的问题（能不能证、能不能算、能不能画完）只有站高一层才看得清。

20.5 六个镜头：把全书装进一张地图

走了二十章，是时候回头画地图了。回看整本书，数学世界大致可以用六个镜头来观看，它们彼此交叠、互相照亮：

镜头	关心的问题	一个仍未解决的猜想
数	计数、度量、精确表示	黎曼猜想（素数分布的精细规律）
形	位置、形状、距离、对称	高维球堆积的最优方式（多数维度未解决）
变	变化率、累积、极限	纳维-斯托克斯方程解的光滑性
结构	关系、运算、模式本身	P 对 NP 问题（验证是否总比求解容易）
随机	不确定性中的规律	随机过程与混沌边界的诸多问题
证明	凭什么相信	机器证明能走多远（开放问题）

数，是我们出发的地方：从结绳记事到分数、负数、无理数、虚数，每一次“这也能算数？”的惊愕，都是数的疆域在扩张。本章又添了一笔：连无穷都要分门别类地编号。

形，从勾股定理走到对称、变换、非欧几何。形不只是画图，它是把“位置关系”变成可以计算的对象的本领。

变，是从“静态的量”到“变化的过程”的飞跃：速度、斜率、面积如何互相转化，导数与积分怎样互为逆运算——数学第一次在纸面上抓住了运动本身。

结构，是最抽象也最现代的眼光：加法、旋转、置换、矩阵，表面上风马牛不相及，底下却是同一种运算模式。群、图、向量空间，研究的都是“关系的关系”。

随机，承认世界有用不掉的偶然，然后问：偶然里藏着什么必然？大数定律、期望、统计推断，让我们在不确定中做确定的决策。

证明，是把前面五个镜头黏在一起的胶水，也是本书从头到尾的暗线：从“看起来对”到“为什么对”，从归纳猜想到演绎链条。本章把这条暗线推到了尽头——证明本身也可以成为研究对象，而且它有边界。

六个镜头不是六个孤岛。接下来这个问题，会让你看到它们怎样在同一片风景上相遇。


20.6 一道题，三种命运：最短路径

考虑一个老问题：一只蚂蚁要从正方体纸盒顶点 A 爬到对角顶点 B ，盒面展开前它只能沿着盒子的表面爬。最短的路有多长？

第一种解法（形的镜头）：展开。把正方体沿着棱剪开摊平，表面上的路变成平面上的线，而平面上两点之间线段最短。正方体边长为 1 时，把相邻的两个面摊成一个 2×1 的长方形， A 到 B 的直线距离是 $\sqrt{2^2 + 1^2} = \sqrt{5}$ 。妙处在于：曲面（盒面）上的难题，被一个变换翻译成了平面上的易事。几何的威力常常不在硬算，而在**换一个空间看**。

第二种解法（结构的镜头）：图与贪心。把问题改一改：城市地图上有若干路口和已知道路长度，求从家到学校的最短路线。把路口画成点、道路画成带数字的边，这就是一张**图**。有个漂亮的贪心策略：从家出发，维护一张“目前离家最近的已知距离”清单，每次把清单里最近的那个路口**锁定**——因为绕任何其他路口再到它都不可能更近——然后用它更新邻居们的距离。重复下去，学

校被锁定的那一刻，最短距离就确定了。这个算法（迪杰斯特拉算法）是导航软件的“心脏”之一。它用的不是几何直觉，而是对“距离结构”的一步步压榨。



网格上的最短路径：不止一条，但都一样长

第三种解法（变的镜头）：让大自然来算。把问题再改一改：光从空气射入水中会弯折，弯折的角度恰好使得**总耗时最短**——这就是费马最短时间原理。折射定律不需要知道“光在想什么”，只要写出时间关于路径的表达式，再问“什么时候微小的改动不再减少时间”，答案就自动浮现。这是微积分和变分法的世界：不是从有限条候选里挑最短，而是在**无穷多条可能的路径**里求最优。物理学里大量的定律（最小作用量原理）都是这个句式。

同一个“最短”，三种灵魂：几何靠变换化归，算法靠结构推进，分析靠在无穷候选中寻优。它们互相翻译、互相启发：导航算法里藏着离散化的几何，变分问题里藏着连续化的贪心。所谓“统一的数学地图”，不是把所有数学合并成一门课，而是发现**同一座山的每一条登顶路线都在山顶相遇**。素数分布也有同样的命运：它既是数的谜题（筛法、因数），又是形的谜题（把素数排成螺旋会出现诡异的对角线条纹），又是随机的谜题（素数在大尺度上像一场精心设计的抽奖），还是变的谜题（素数定理用对数函数精确描述了它的疏密变化）。一个深刻的问题，从来不会只属于一个镜头。

继续攀登

想继续攀登的话，这些关键词等着你去查：**集合论**（无穷的算术）、**数理逻辑**（证明的数学）、**停机问题**（计算的边界）、**图论**（最短路径与网络流）、**变分法**（无穷选择中的最优）、**黎曼猜想**（悬赏百万美元的素数之谜）。每一个都是一本书的入口。

思考题

观察题

1. 仿照正文中“偶数与自然数等势”的构造，给出一个奇数与整数（含负数）之间的一一对应。提示：先把整数按 $0, 1, -1, 2, -2, \dots$ 排队，再设法配给奇数队伍。
2. 在正方体最短路径问题里，把盒子摊平的方式不止一种。画出另一种展开图，算出对应路径的长度，和 $\sqrt{5}$ 比一比。提示：注意摊开后 A, B 落在哪两个格点上；有的摊法给出 $\sqrt{5}$ ，有的给出更长的数——最短者胜。

证明题

3. 证明：0 到 1 之间的实数和所有实数一样多。提示：找一个把有限区间“拉开”到整条数轴的一一对应，比如先想 $y = \tan x$ 的图象，再说明它为什么是一一对应的。

4. 用对角线法的思路说明：不存在“所有集合的集合”。提示：假设这样的集合 U 存在，那么 U 的所有子集组成的集合（幂集）应该“不大于” U ，但康托尔证明了幂集严格更大。

挑战题

5. 理发师悖论的官方解决方案是“这样的理发师不存在”。但有人抬杠：那修改一下规矩——“我给所有不给自己刮脸的人刮脸，我自己除外”——悖论是不是就消失了？这套新规矩还有别的毛病吗？提示：新规矩不再矛盾，但想想“不给自己刮脸”的人群里还差谁，理发师的胡子到底归谁管；再想想 ZF 公理里“从已知集合中挑子集”那条是怎样模仿这种修补的。

6. 哥德尔命题 G 说“我不可证”。有人提议：把 G 直接添加为新公理，系统不就变完备了吗？这个办法为什么不能一劳永逸？提示：新系统仍然足够强、仍然自治（如果原系统是的话），那么定理的条件对新系统依然成立……

通往下一章的门

这本书没有下一章了。但你的下一章，刚刚开始。

如果把这本书当成一张地图，那么地图边缘写着“此处有龙”的地方，才是你真正要去的方向。最后，给不同口味的旅行者各留一条路标：

如果你喜欢**竞赛**，那里有把中学数学榨出最后一滴汁水的训练：组合、数论、几何、不等式，教你在资源最少的时候用最巧的招。竞赛的本质不是快，而是深——同一道题想出三种解法的人，比刷完三百道题的人走得更远。

如果你喜欢**编程**，你手里已经握着本书最称手的实验室：用代码验证哥德巴赫猜想的一亿个例子，用模拟看大数定律显形，写一个走迷宫的程序亲手实现迪杰斯特拉算法。数学给你眼光，代码给你蛮力，两者相加几乎是作弊。

如果你喜欢**建模**，真实世界等你很久了：疫情曲线为什么那样拐弯，外卖骑手的路径怎样规划，一首歌为什么好听。建模是把一团乱麻的现实翻译成六个镜头之一的艺术，翻错了不怕，误差会教你翻对。

如果你打算走向**大学数学**，你会遇见这本书所有故事的“完整版”：微积分变成分析学，几何变成拓扑与流形，随机变成测度论，本章的公理、对角线、不完备性会变成一门叫数理逻辑的课。到那时你会发现，本书里的每一个“通俗说明”，背后都站着一座真正的证明。

如果你只是想**纯兴趣**地走下去——那恭喜你，你拥有的是最好的理由。数学史上许多伟大的进展，始于一句毫无用处的“如果……会怎样”。康托尔追问无穷的时候，没有人知道这会变成计算机科学的地基；研究素数的数学家们也没想到，他们的游戏有一天会守着全世界的银行密码。

那幅挂在校园里的地图，美术老师最后是怎么解决的？听说她在地图角落画了一幅很小很小的地图，小地图里又点了一个几乎看不见的点，然后停笔，在旁边写了一行字：“再往下，就请你走进校园里看了。”

数学也是这样。地图画得再细，也代替不了脚步。这团火，我们已经把它点着了——接下来的路，轮到你去照亮。

附录 A 读懂数学证明的入门语法

学一门语言，先要学会它的语法；读数学证明也一样。证明并不是一堆符号的杂技，而是一套“把话说清楚”的规则：什么叫一句话成立，什么叫一句话被推翻，什么样的理由才算数。本附录把全书反复使用的这套语法集中在一起，配上初中水平的例子。读正文时如果哪里卡住了，随时可以翻回来查。

A.1 命题：可以判断真假的话

数学只讨论一种特殊的句子：**命题**，也就是能够明确判断对或错的陈述。“三角形的内角和是 180° ”是命题（它是对的）；“所有的质数都是奇数”也是命题（它是错的，2 就是反例）。但“数学真有意思”不是命题，因为没法判定真假；“ $x > 3$ ”单独看也不是命题，因为 x 没确定时无法判断——这正是量词要解决的问题（见后文）。

很多命题有“如果……那么……”的形状。比如“如果一个整数能被 4 整除，那么它能被 2 整除”。“如果”后面的部分叫条件，“那么”后面的部分叫结论。把条件和结论对调，得到的新句子叫原命题的**逆命题**。上面那句话的逆命题是：“如果一个整数能被 2 整除，那么它能被 4 整除。”请注意：原命题是对的，逆命题却是错的（6 能被 2 整除，却不能被 4 整除）。

反例警报

“原命题成立，逆命题就成立”是最常见的误会之一。“对顶角相等”是对的，但它的逆命题“相等的角是对顶角”明显错误——两直线平行时的同位角相等，却根本不是对顶角。判断一句话对不对，和判断它的逆命题对不对，是两笔独立的账，必须分开算。

A.2 充分条件与必要条件：两顶不能混戴的帽子

当“如果 p ，那么 q ”成立时，我们说 p 是 q 的**充分条件**：有 p 就“足够”保证 q 。同时说 q 是 p 的**必要条件**：想要 p 成立， q 是“必须”跨过的门槛。

例 A.1. “四边形是矩形”能保证“它是平行四边形”，所以“是矩形”是“是平行四边形”的充分条件；反过来，“是平行四边形”只是“是矩形”的必要条件——矩形首先得是平行四边形，但光平行还不够，还必须有直角。

一个生活类比：有电是灯泡发光的必要条件（没电一定不亮），但不是充分条件（有电，灯丝断了也不亮）。充分不一定必要，必要不一定充分；两者都满足时，我们称 p 是 q 的**充要条件**，记作 $p \Leftrightarrow q$ ，这时两者“同生同灭”，比如“三角形是等边三角形”与“它的三个内角都是 60° ”。

A.3 量词：把“所有”和“存在”说清楚

命题里最常见的两个词是“所有”（任意，记作 $\forall$ ）和“存在”（至少有一个，记作 $\exists$ ）。它们的行为很不一样：

- “所有偶数都能被 2 整除”要对，必须**每一个**偶数都过关；
- “存在整数 x 使 $x^2 = 4$ ”要对，只要**找到**一个就行（ $x = 2$ 即可）；
- 推翻“所有”型命题，只需要一个反例；推翻“存在”型命题，却需要论证“一个都找不到”。

否定它们时规则也很干脆：“所有乌鸦都是黑的”的否定不是“所有乌鸦都不黑”，而是“存在一只乌鸦不是黑的”。全称的否定是特称，特称的否定是全称——这个交换律在反证法里天天要用。

A.4 反例：一个就足够

“反例”是满足条件却不满足结论的具体例子。它是数学里最便宜的武器：再漂亮的猜想，一个反例就能推翻。猜想“对所有整数 a, b ，若 $a^2 > b^2$ 则 $a > b$ ”，听上去挺像回事，但取 $a = -3$ ， $b = 1$ ： $a^2 = 9 > 1 = b^2$ ，可是 $-3 < 1$ 。一个反例，猜想作废。反过来，验证了一百万个例子也不能算证明——例子只能说明“还没被打倒”，不能保证“永远不会被打倒”。

A.5 数学归纳法：推倒一排多米诺骨牌

想证明一个关于所有正整数 n 的命题 $P(n)$ ，比如

$$1 + 3 + 5 + \cdots + (2n - 1) = n^2,$$

一个个验算永远验不完。数学归纳法的想法是：只需做两件事——（1）**起点**：验证 $P(1)$ 成立；（2）**传递**：证明只要 $P(k)$ 成立，就能推出 $P(k+1)$ 成立。这就像推倒一排多米诺骨牌：第一块倒了，且每块倒下都会碰倒下一块，那么整排必倒。

证明. (起点) $n = 1$ 时, 左边 $= 1$, 右边 $= 1^2 = 1$, 成立. (传递) 假设 $n = k$ 时 $1 + 3 + \cdots + (2k - 1) = k^2$ 成立, 则 $n = k + 1$ 时

$$1 + 3 + \cdots + (2k - 1) + (2k + 1) = k^2 + (2k + 1) = (k + 1)^2,$$

正好是要证的式子。由归纳法，等式对所有正整数 n 成立。□

注意两步缺一不可：只验证起点，可能半路断掉；只证明传递，可能整排根本没被推倒。

A.6 反证法：先假设敌人是对的

有些命题正面进攻很难，那就换个打法：**假设结论不成立，往下推理，直到撞上矛盾**。矛盾说明开头的假设错了，于是结论只能成立。经典例子是“质数有无穷多个”。

证明. 假设质数只有有限个, 把它们全部列出来: $p_1, p_2, \dots, p_n$ 。造一个数 $N = p_1 p_2 \cdots p_n + 1$ 。 N 除以任何一个 p_i 都余 1, 所以没有一个已知质数能整除 N 。但任何大于 1 的整数要么本身是质数, 要么能被某个质数整除, 于是必然存在一个不在清单上的质数——这与“清单已列出全部质数”矛盾。所以质数不可能只有有限个。 $\square$

早在两千多年前, 欧几里得的《几何原本》里就有这个论证。反证法的威力在于: 它允许你“借用”一个假命题当梯子, 用完再把它拆掉。

数学工具箱

本附录的证明语法速查:

- 命题: 能判真假的句子; 逆命题是条件与结论对调, 真假要独立判断。
- $p \Rightarrow q$: p 充分, q 必要; 两者互为充要时写 $p \Leftrightarrow q$ 。
- $\forall$ 的否定是 $\exists$ “不”, $\exists$ 的否定是 $\forall$ “不”。
- 推翻“所有”只需一个反例; 证明“所有”可以用归纳法 (起点加传递)。
- 正面难攻时用反证法: 假设结论不成立, 推出矛盾。

思考题

观察题

1. 写出命题“正方形的四条边都相等”的逆命题, 并判断它的真假。提示: 找一个四条边都相等但不是正方形的图形。

证明题

1. 用数学归纳法证明 $1 + 2 + 3 + \cdots + n = \frac{n(n+1)}{2}$ 。提示: 传递那一步只需在两边同时加上 $k+1$, 再通分整理。

挑战题

1. 用反证法证明: $\sqrt{2}$ 不能写成两个整数的比。提示: 假设 $\sqrt{2} = \frac{p}{q}$ 且分数已约到最简, 两边平方后考察 p 的奇偶性。

附录 B 初等数学工具箱

本附录是一份“出发前检查清单”。正文默认你大致见过下面这些工具，但不要求熟练；如果哪一节读起来陌生，在这里花十分钟补一补就够了。每项工具我们只回答三个问题：它是什么、它解决了什么麻烦、一个典型例子。这份清单大致按工具在正文中出场的频率排列，越靠前的越常用。读法建议是“用时再查”，不必预先通读——但每一项后面的例子值得动手验算一遍，验算通过的，才算真正装进了你的工具箱。

B.1 分数与比例：整体的一部分

分数 $\frac{a}{b}$ 表示把单位“1”平均分成 b 份，取其中 a 份。它解决的麻烦是：整数不够用了——三个人分两张饼，每人分到 $\frac{2}{3}$ 张，这个数用整数写不出来。分数运算的两条主规则是：加减先通分， $\frac{1}{2} + \frac{1}{3} = \frac{3}{6} + \frac{2}{6} = \frac{5}{6}$ ；乘除很直接， $\frac{2}{3} \times \frac{3}{5} = \frac{2}{5}$ ，除以一个分数等于乘以它的倒数。

比例是两个量的相对大小。地图上“1:50000”表示图上1厘米对应实地50000厘米，即500米：图上量得3.6厘米，实地就是 $3.6 \times 500 = 1800$ 米。百分比只是把分母固定成100的比例：打八折就是付原价的80%。正比例 $y = kx$ 意味着一个量翻倍另一个也翻倍；反比例 $y = \frac{k}{x}$ 意味着一个翻倍另一个减半——速度翻倍，行同样路程的时间就减半。

用百分比描述变化时，务必看清“以谁为整体”：价格先涨10%再降10%，并不会回到原价——涨的时候基数小，降的时候基数大，最后只剩原价的99%。生活中大量的“数字陷阱”都藏在这一步里。

B.2 方程：把未知数当已知数来用

方程的核心思想只有一句话：给未知数起个名字，然后把它当已知数一样运算。“某数的3倍加5等于20”，设某数为 x ，写成 $3x + 5 = 20$ 。解方程靠的是“天平原则”：等式两边同时加、减、乘、除以同一个数（除数不为0），等号仍然成立。于是 $3x = 15$ ， $x = 5$ 。

再看一个完整的解题流程：“父亲今年40岁，儿子12岁，几年后父亲年龄是儿子的2倍？”设 x 年后，列方程 $40 + x = 2(12 + x)$ ，展开得 $40 + x = 24 + 2x$ ，移项得 $x = 16$ 。回代检验：16年后父亲56岁、儿子28岁，恰好两倍。设未知数、列方程、解方程、回代检验，四步缺一不可，而最后一步最容易被偷懒跳过。


二元一次方程组是两个天平一起用。例如

$$\begin{cases} x + y = 10, \\ x - y = 4, \end{cases}$$

两式相加消去 y ： $2x = 14$ ， $x = 7$ ，代回得 $y = 3$ 。一元二次方程 $x^2 - 5x + 6 = 0$ 常常可以因式分解为 $(x-2)(x-3) = 0$ ，于是 $x = 2$ 或 $x = 3$ ；分解不开时还有求根公式 $x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$ 兜底。

B.3 坐标：给平面上的每个点一个地址

在平面直角坐标系里，每个点对应一对有序实数 (x, y) ：先向东（负则向西）走 x ，再向北（负则向南）走 y 。这把“图形”翻译成了“数”，从此几何问题可以用代数计算，代数式子也可以画成图来看。



两点 (x_1, y_1) 与 (x_2, y_2) 之间的距离公式 $\sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$ 其实就是勾股定理穿上坐标的外衣：横差和纵差是两条直角边。中点公式 $\left(\frac{x_1 + x_2}{2}, \frac{y_1 + y_2}{2}\right)$ 说的是“两个地址各取平均”：(1, 2) 与 (3, 6) 的中点是 (2, 4)。一次函数 $y = 2x + 1$ 的图像是一条直线，斜率 2 表示“ x 每增加 1， y 增加 2”。

B.4 三角形：平面几何的基本积木

三条边围成的三角形是多边形里最“倔强”的：三边长度定了，形状就定了（这就是为什么房梁和自行车架爱用三角形）。三条最常用的性质：

- 内角和：三个内角之和恒为 180° ；
- 勾股定理：直角三角形两直角边 a, b 与斜边 c 满足 $a^2 + b^2 = c^2$ ，例如 $3^2 + 4^2 = 5^2$ ；
- 三边关系：任意两边之和大于第三边，所以 2, 3, 6 围不成三角形 ($2 + 3 < 6$)。

三角形面积等于“底乘高的一半”，这条公式将来会在积分思想里以“切成细条再加起来”的面目重新出现。两个三角形“全等”指完全重合（判定如“边边边”），“相似”指形状相同、大小可以不同，对应边成比例。相似还有一条常用推论：对应边之比为 k 时，面积之比是 k^2 ——边长翻倍，面积变四倍，这就是为什么大份披萨往往比小份“划算得不成比例”。测量旗杆高度用的正是相似：同一时刻，旗杆高与影长之比等于你的身高与影长之比。

B.5 指数与对数：乘法的加速器与倒车挡

指数把“连乘”缩写： 2^{10} 表示十个 2 相乘，等于 1024。指数法则 $a^m \cdot a^n = a^{m+n}$ 说的是“连乘的个数相加”；特别地， $a^0 = 1$ （一个也不乘）， $a^{-1} = \frac{1}{a}$ （倒过来）。科学记数法是指数的日常应用：光速约 3×10^8 米每秒，一个氢原子的质量约 1.67×10^{-27} 千克——太大和太小的数，都靠指数才写得下。

对数是指数的“倒车挡”： $\log_a b$ 回答的问题是“ a 的几次方等于 b ”。因为 $2^{10} = 1024$ ，所以 $\log_2 1024 = 10$ 。它解决的麻烦是：乘法太多算不动。利用 $\log_a(xy) = \log_a x + \log_a y$ ，对数能把乘法变成加法——在没有计算器的年代，天文学家靠对数表把几个月的乘法压缩成几天的加法。

术语卡片：对数

直观解释：一个数“需要乘几次底数才能得到”。正式定义：若 $a^x = b$ ($a > 0$, $a \neq 1$, $b > 0$)，则 $x = \log_a b$ 。例子： $\log_{10} 1000 = 3$ ，因为 $10^3 = 1000$ 。

数学工具箱

六件随身工具：分数与比例（部分与相对大小）、方程（未知数当已知数用）、坐标（图形与数互译）、三角形（内角和、勾股定理、三边关系）、指数（连乘的缩写）、对数（指数的反问）。正文任何一处用到它们，都可以回到本附录对照。

思考题

观察题

- 一杯糖水含糖 10%，喝掉一半后再加满水，浓度变成多少？提示：跟踪“糖还剩多少”，而不是跟踪“水加了多少”。

证明题

- 证明：边长为 1 的正方形，对角线长为 $\sqrt{2}$ 。提示：对角线把正方形切成两个什么样的三角形？

挑战题

- 不解方程，判断 $x^2 + x + 1 = 0$ 有没有实数解。提示：考察求根公式里根号下的 $b^2 - 4ac$ 。

附录 C 符号表与词汇表

数学符号不是密码，而是缩写——每个符号背后都藏着一个“说来话长”的直观想法。本附录把全书出现的主要符号和术语按领域分类整理。表格里“直观解释”是你第一眼该想到的图景，“例子”是最小可用的验证。遇到不认识的符号，先查这里，再回到正文看它干活的样子。使用时有两类姿势：正文里遇到生词，按领域翻到对应小节查；想预习某一章，可以先把相关表格扫一遍，混个脸熟。表格不是背诵材料，而是地图——走得多了，路线自然就记住了。

C.1 数

数的世界是一层一层扩建的：为了做减法添了负数，为了做除法添了分数，为了写出“边长为 1 的正方形的对角线”添了无理数。下表的符号就是这些楼层的名牌。

符号/术语	读法	直观解释	例子
$\mathbb{N}$	自然数集	数数用的数：0 或 1 起一个数下去	$0, 1, 2, 3, \dots$
$\mathbb{Z}$	整数集	自然数加上它们的“欠账”（负数）	$-3, 0, 7$
$\mathbb{Q}$	有理数集	能写成两整数之比的数	$\frac{2}{3}, 0.25$
$\mathbb{R}$	实数集	数轴上所有的点，没有缺口	$\sqrt{2}, \pi$
$a \mid b$	a 整除 b	b 能被 a 正好分完，没有剩余	$3 \mid 12$ ，但 $3 \nmid 14$
$\gcd(a, b)$	最大公约数	能同时整除 a 和 b 的最大整数	$\gcd(12, 18) = 6$
$ x $	绝对值	数轴上 x 到原点的距离，不分方向	$ -5 = 5$
$\approx$	约等于	近似相等，误差在可接受范围内	$\pi \approx 3.14$

C.2 代数

代数的核心动作是“用字母代替数”，于是运算规则可以脱离具体数字单独研究。字母 x 不是“某个神秘的数”，而是一个占位符：它占着位置，让规律现身。

符号/术语	直观解释	例子
a^n	n 个 a 连乘, 乘法的缩写	$2^5 = 32$
$\sqrt{a}$	平方后等于 a 的那个非负数	$\sqrt{9} = 3$
$\log_a b$	“ a 的几次方等于 b ” 的答案	$\log_2 8 = 3$
$\sum$	求和号: 把一串数按规则全加起来	$\sum_{k=1}^4 k = 1 + 2 + 3 + 4 = 10$
$f(x)$	函数: 一台机器, 送进 x 吐出唯一结果	$f(x) = 2x$, 则 $f(3) = 6$
多项式	未知数只有加、减、乘的式子	$x^2 - 3x + 2$
因式分解	把多项式拆成几个式子的乘积	$x^2 - 1 = (x + 1)(x - 1)$

C.3 几何

几何符号大多脱胎于图形本身：看到 $\triangle$ 想到三角形，看到 $\perp$ 想到墙角。记符号时顺手在纸上画一下，比默背十遍更有效。

符号/术语	直观解释	例子
$\angle ABC$	顶点在 B 处张开的角度	$\angle ABC = 60^\circ$
$\triangle ABC$	以 A, B, C 为顶点的三角形	三角形内角和 180°
$\cong$	全等：能完全重合	边边边判全等
$\sim$	相似：形状相同, 大小可不同	放大照片与原照片相似
$\perp$	垂直：夹角恰好 90°	墙角的两边互相垂直
$\parallel$	平行：同一平面内永不相交	铁轨的两条钢轨
π	圆周与直径的比, 对所有圆都一样	周长 $= 2\pi r$

C.4 分析

分析（微积分的严格化）研究“无限逼近”，它的符号几乎都在回答同一个问题：离目标到底有多近？把“近”说精确的艰难过程，正是正文第 9 到 12 章的故事。

符号/术语	直观解释	例子
$\lim$	极限:无限逼近但不必到达的目标	$\frac{1}{n} \rightarrow 0$ (n 越大越接近 0)
∞	无穷大: 比任何数都大的“方向”, 不是数	1, 2, 3, ... 数下去没有尽头
ε	任意小的误差预算, 你挑多小都行	精确到 $\varepsilon = 0.001$
Δx	变化量: x 改动的一小步	从 3 到 3.1, $\Delta x = 0.1$
$f'(x)$	导数: 曲线在一点的瞬时坡度	位移的导数是速度
$\int$	积分: 把无穷多个小条加起来求总量	速度对时间积分得路程

C.5 概率

概率论给“不确定”立规矩: 可能性用 0 到 1 之间的数表示, 0 是不可能, 1 是必然。它的难点往往不在计算, 而在把现实问题翻译成正确的“事件”。

符号/术语	直观解释	例子
$P(A)$	事件 A 发生的可能性, 0 到 1 之间	掷硬币 $P(\text{正面}) = \frac{1}{2}$
$P(A B)$	已知 B 发生后, A 发生的概率	已知下雨, 带伞的概率
$E(X)$	期望: 长期平均下来每次得到多少	掷骰子的期望是 3.5
随机变量 方差	结果带随机性的“测量值” 数据围绕期望的波动大小	掷骰子得到的点数 成绩越稳定, 方差越小

C.6 离散数学

离散数学研究“一个一个分开”的对象: 整数、集合、图。它是计算机科学的母语——计算机里的东西没有“半个”, 全是离散的。附录 A 里的量词符号也收录在本节, 它们是全书写证明时最频繁打交道的几个记号。

符号/术语	直观解释	例子
$\in$	属于: 某个东西在这个集合里	$2 \in \{1, 2, 3\}$
$\forall$	任意: 每一个都要满足	所有偶数能被 2 整除
$\exists$	存在: 至少能找到	存在一个偶质数
$a \equiv b \pmod{m}$	同余: a 和 b 除以 m 余数相同	$17 \equiv 2 \pmod{5}$
$n!$	阶乘: n 个东西排成一列的排列法数	$3! = 6$
$\binom{n}{k}$	组合数: 从 n 个中无序挑 k 个的挑法数	$\binom{4}{2} = 6$
图 (graph)	一些点和点之间的连线组成的网络	城市为点、公路为边的交通图

一个读符号的通用建议: 遇到陌生符号, 先大声读出来, 再问自己三件事——它作用在什么对象上? 它回答什么问题? 它的“反操作”是什么? 比如 $\log$ 作用在正数上, 回答“几次方”, 反操作是指数。三件事答齐了, 符号就不再吓人。

连接线

符号是会“串门”的: $\sum$ 在代数里求有限和, 到了分析里变成无穷级数; $\in$ 在集合里登记成员, 到了概率里又用来写“事件包含某个结果”。读任何一章遇到符号发懵时, 先回本附录对号入座, 再看它在新语境里被赋予了什么新任务。

最后提醒: 一个符号的含义由它的定义决定, 而不是由它的长相决定。同一个字母在不同章节可能扮演不同角色—— x 在方程里是未知数, 在函数里是自变量, 在几何里可能是横坐标。每次见面先问一句“这次它是谁”, 是读数学书的基本功。

附录 D 数学实验与编程资源

数学家也有“实验室”，只是器材便宜得多：一支笔、一张纸、一个表格软件，或者一台能写几行代码的电脑。本附录介绍三类零门槛的实验工具，每类配一两个可以立刻上手的活动。先用一句话立规矩：**实验负责观察，证明负责下结论**——工具能帮你看得更多、猜得更准，但看得再多也不能替代证明。

D.1 电子表格：最被低估的数学仪器

不用装任何专门软件，电脑或手机里的表格程序就能做严肃探索。单元格里写公式，往下拖动，规律就自己浮出来。

活动一：复利的威力。第一列填年份 0 到 30，第二列第一年填本金 1000，下面每格写“上一格乘以 1.05”（年利率 5%）。拖到底你会发现：30 年后变成约 4322，是本金的 4 倍多；更妙的是，大约每 14 年翻一番。这就是指数增长，它解释了为什么“利滚利”听起来温和、时间一长却惊人。一个小技巧：把利率单独放在一个单元格里，让公式引用它——改一次利率，整条曲线跟着变。这个“把可变的量单独放出来”的习惯，就是数学里“参数”的思想。

活动二：用筛子捞质数。第一列填 1 到 200，第二列判断每个数是不是质数（试除它前面的质数即可）。数一数每一百里面有多少个质数：1 到 100 有 25 个，101 到 200 只剩 21 个。你会亲眼看到“质数越往后越稀疏”——这个观察指向数论里一个大定理的方向。

D.2 GeoGebra：会动的几何

GeoGebra 是免费的动态几何软件（网页版即可使用）。它最大的本事是“拖动”：图形画好之后，拽住一个顶点晃动，所有依赖它的量实时跟着变。

活动一：拖不垮的内角和。画任意三角形，让软件量出三个内角并显示它们的和。然后使劲拖动顶点，把三角形拉成胖的、扁的、尖的——和始终停在 180° 。这不是证明，但会让你真心觉得“这件事值得证明”。

活动二：亲手逼近 π 。画一个圆，再画出它的内接正多边形，把边数从 6 加到 12、24、48，观察多边形周长与直径之比一步步逼近 $3.14159\dots$ 。拖动边数滑块时特别留意：多边形与圆之间的“缝隙”越来越小，却永远不会真正消失——这正是“逼近”二字最诚实的图景。两千多年前数学家们“割圆”求 π 的思路，你在屏幕上几分钟就能重演。

一分钟实验

没有电脑也能实验。拿一根绳子围着一个圆形杯口绕一圈，再量出杯口的直径，用绳子对着直径比一比：圆周的绳子长度总是直径的 3 倍多一点。换瓶盖、换碗口、换盘子，倍数几乎不变——你刚刚“观察”到了 π 的存在。

D.3 Python：让计算机替你数一万次

Python 是一门语法接近英语的编程语言，网上有免费的在线运行环境，不用安装任何东西。对学数学来说，它的价值是“不知疲倦”：你想试一百万个例子，它不嫌烦。

活动一：验证猜想。写一个小循环，对 n 从 1 到 1000 检查“ $n^2 + n + 41$ 是不是质数”。你会发现前几十个居然全是质数——这个著名的“质数制造机”公式能连对 40 次。但程序继续跑下去， $n = 40$ 时结果是 41×41 ，轰然倒塌。做完这个实验，你会对“例子再多也不是证明”有肌肉记忆般的理解。

活动二：撒点估 π 。让程序在边长为 1 的正方形里随机撒十万个点，数有多少落在内切圆里（到圆心距离小于半径）。圆面积与正方形面积之比是 $\frac{\pi}{4}$ ，所以“圆内点数除以总点数再乘 4”就是 π 的估计值。点撒得越多，估计越稳——这是概率论“频率逼近概率”的直观演示。

活动三：逼近 $\sqrt{2}$ 。让程序从区间 $[1, 2]$ 开始，每次取中点，看中点的平方比 2 大还是小，据此把区间砍掉一半，把 $\sqrt{2}$ 留在剩下那一半里。重复 30 次，区间长度不到十亿分之一—— $\sqrt{2}$ 被夹在一个极小的缝隙里。这就是“二分法”，也是极限思想的算法版：目标永远抓不到手里，但可以关进任意小的笼子。

做计算实验的基本功只有两条：改参数，看变化。把活动一里的 1000 改成 100000，把公式换成 $n^2 - n + 41$ ，猜猜结果会怎样，再跑一遍验证——猜错往往比猜对更有收获。

反例警报

“电脑验证了一百万个例子，所以命题成立”——这句话永远是错的。上面那个质数公式连对 40 次，第 41 次就失败了；数学史上还有连对几亿次才出错的例子。程序只能排除假命题（找到反例）或增强信心，**确认**一个关于无穷多对象的命题，必须靠证明。实验是望远镜，不是判决书。

D.4 去哪里找这些工具

电子表格用任何常见办公软件都行；GeoGebra 搜索名字即可找到官网，网页直接打开；Python 可以搜“在线 Python 运行”找到免安装的网页环境。入门不需要看大部头教程：把本附录的活动照着做一遍，卡住时搜一句“电子表格怎么写公式”或“Python for 循环”，边做边学最快。遇到报错别慌，报错信息是计算机在告诉你它哪里没听懂，这本身就是最实用的逻辑训练。

继续攀登

继续深入的关键词：数值计算（让计算机解方程）、蒙特卡洛方法（用随机撒点算面积和概率）、计算机辅助证明（著名的四色定理证明就靠计算机核验了大量情形，数学家们为此争论了多年：这算不算证明？）。这些话题在大学的计算数学与科学计算课程里等着你。

思考题

观察题

1. 在活动一里把年利率改成 10%，本金翻一番大约需要几年？提示：不必精算，观察第二列大约每隔几格翻倍，再和 5% 时的 14 年比较。

证明题

1. 证明：活动三每次“砍半”之后， $\sqrt{2}$ 一定落在留下的那个小区间里。提示：看中点的平方与 2 谁大，分两种情况讨论即可。

挑战题

1. 设计一个实验，估计“往画满平行线的纸上随机扔一根针，针压到线的概率”（布丰投针问题）。提示：先想清楚针落地时哪些量是随机的——位置是一个，还有别的吗？

附录 E 分级阅读路线

这本书的二十章不必从第一页一路啃到最后一页。数学不是一条单行道，更像一张地铁图：有几条主干线，也有许多换乘站。本附录给你一条“默认路线”和四条“兴趣路线”，你可以按自己的节奏和口味选择，也随时可以下车换乘。

E.1 默认路线：四级台阶

如果你没有特别的偏好，按下面的四级台阶走最稳，每一级都为下一级铺好路。

第一级：第 1–4 章，打基础。从字母、方程和函数出发，把“用符号思考”这件事练熟。这四章是全书的公共语言，后面无论走哪条路线都绕不开，建议按顺序读完，遇到不懂的初等知识随手翻附录 B。

第二级：第 5–8 章，加深。多项式、变换、向量等内容把第一级的工具用得更深。读这一级时你会第一次体会到：同一个对象（比如一个多项式）可以有代数的、几何的好几张面孔，而“换一张面孔看问题”正是数学家最趁手的招式。

第三级：第 9–12 章，进入高等数学的语言。从变化走向无限：极限、导数、积分的直观图景在这里登场。这一级的关键词是“逼近”——允许自己暂时不习惯“无限”的严格说法，先抓住图像和数值例子；严格性会随后跟上，直觉掉队了才真的麻烦。

第四级：第 13 章起，按兴趣分流。从这里开始，章节之间不再是严格的先后关系：数论、拓扑、几何、概率、数学基础各自成线。读完第三级后，你完全可以“哪里好玩跳哪里”，下面的四条兴趣路线就是为此准备的。

E.2 四条兴趣路线

路线一：想解题——第 1–6、13、14 章。如果你喜欢“题目刚看时没头绪、解出来一身轻”的快感，这条路线通向数学里最古老的狩猎场：整数。前六章把代数工具磨快，第 13、14 章进入数论，那里的问题往往一句话就能听懂（比如关于质数的猜想），却可能难住数学家几百年。建议随身带草稿纸，例题务必亲手算一遍再往下看；解题能力的单位不是“页”，是“草稿纸的张数”。

路线二：喜欢图形和空间——第 3、4、6–12、16、17 章。如果你看到图比看到式子更亲切，这条路从坐标与变换出发，经过函数图像、变化率与曲线，最后抵达拓扑和微分几何——那里研究的是“橡皮膜上的几何”和“弯曲空间里的最短路径”。读这条线时多画图，哪怕画得很丑；几何直觉是画出来的，不是看出来的。

路线三：喜欢无限和变化——第 8–12、15、17 章。“无限”是数学里最迷人的悬崖：无限小是什么？无限个正数加起来怎么会有有限？这条路线从变化率出发，正面走近极限与无穷级数，再

延伸到与之相连的几何与分析话题。走这条线需要一点耐心：每一个关于“无限”的结论，都要追问一句“它是怎么被一步步逼近的”。

路线四：喜欢密码、计算和现实应用——第 2、5、7、13-15、18、19 章。如果你关心“数学到底有什么用”，这条线从方程与代数结构出发，经过数论（现代密码的地基——你手机里的加密支付就在用质数的性质），再到概率与现实建模。建议配合附录 D 的实验：这条线上的很多想法，用电子表格或几行程序立刻就能玩起来。

连接线

四条路线在第 13 章交汇不是巧合：数论用的工具最“初等”（整除、余数），却连着密码、几何甚至分析。数学各分支之间有许多这样的暗道，本书正文的“连接线”盒子会不断指出它们——发现自己从一条路线溜达到另一条路线上，是读这本书的正常状态，值得高兴，不必纠正。

E.3 三条阅读建议

第一，**卡住是正常的**。每章只给提示的思考题，卡住几天再回头，往往比当场看答案收获大；数学家们自己也经常在同一个问题上卡几年。第二，**不必一次读懂**。第一遍可以只追主线故事，把证明留到第二遍；知道“哪里难”本身就是进步。第三，**动手优先**。遇到“一分钟实验”就停下来做，五分钟的动手常常胜过半小时的瞪眼。

读正文时，另外四个附录是手边工具：附录 A 是证明的语法书，第一次读证明发懵时翻它；附录 B 是初等工具箱，分数、方程、坐标忘了就查；附录 C 是符号字典；附录 D 提供实验器材。它们和本附录一起，构成这本书的“后勤部”——前线在哪一章，后勤随叫随到。

继续攀登

读完本书想继续攀登的读者，可以按路线找下一座山：解题路线通向竞赛数学与初等数论教材；图形路线通向《什么是数学》和拓扑学普及读物；无限路线通向微积分与数学分析的入门课；应用路线通向密码学和概率论的科普与公开课。关键词在手，图书馆和网络上都是路。

思考题

观察题

1. 翻翻目录，挑出你最想读的三章，看看它们各属于哪条路线。提示：一章可以属于多条路线，交叉处往往最好玩。

证明题

1. 本附录没有定理要证，但你可以试着向同学论证：为什么第 1-4 章被安排在几乎所有路线之前？提示：翻开后面任意一章，数一数它用到了前几章的哪些工具。

挑战题

1. 为自己设计一条本附录没有的路线（比如“喜欢数学史和人物故事”），写出停靠章节和每一站值得停的理由。提示：先想终点想看什么风景，再倒推途中需要哪些准备。